

Muestreo ecológico

Diseño, estimación y análisis reproducible con R

Jonathan Florez Giraldo

Tabla de contenidos

Presentación	3
Propósito	3
Enfoque	3
Recursos del libro	3
Prefacio	5
Propósito y enfoque	5
Audiencia	5
Prerrequisitos	5
Principios de trabajo	5
Organización	6
Cómo trabajar con los capítulos	6
Diversidad de casos	6
Cómo usar este libro	7
Tres niveles de trabajo	7
Convenciones	7
Código y reproducibilidad	7
Ruta sugerida	8
Marco bibliográfico	9
Corpus delimitado	9
Diseño y estimación	9
Métodos ecológicos de campo	9
Comparación, sesgo y vigilancia	9
Correspondencia con el libro	10
Política de fidelidad	10
Catálogo de datos reales	11
Criterios de selección	11
Casos adoptados	11
Procedencia y límites	12
C1–C2. Datos incluidos con R	12
C3, C11 y C12. Datos de vegan	13
C4–C5. Datos de Distance	13
C6–C7. Datos de unmarked	13

C8–C10. Intervención, índice y demografía	13
Política de datos	13

I Parte I — Fundamentos 14

1 Del problema ecológico al diseño 15

1.1 Diseñar antes de observar	15
1.2 Población, unidades y estimando	15
1.3 Selección e incertidumbre	16
1.4 Arquitectura de un estudio defendible	16
1.5 Aplicación reproducible: flores de iris	17
1.5.1 Procedencia, carga y auditoría	17
1.5.2 Exploración orientada al diseño	18
1.5.3 Selección y estimación por MAS	19
1.5.4 Dominios y modelo descriptivo	20
1.5.5 Evaluación del diseño y diagnóstico del intervalo	21
1.5.6 Sensibilidad a selección y esfuerzo	22
1.6 Interpretación y reproducibilidad	23
1.7 Actividad propuesta para el lector	24

2 Diseños probabilísticos para poblaciones biológicas 26

2.1 Aleatorización e inferencia	26
2.2 Diseños fundamentales	27
2.2.1 Muestreo aleatorio simple	27
2.2.2 Muestreo con probabilidad proporcional al tamaño (PPS)	28
2.2.3 Muestreo estratificado	30
2.2.4 Muestreo sistemático	30
2.2.5 Conglomerados y etapas	31
2.2.6 Información auxiliar	32
2.3 Población finita de árboles	32
2.3.1 Carga, procedencia y auditoría	33
2.4 Ejemplo 1: muestreo aleatorio simple	33
2.4.1 Gráfica 1: población y selección	34
2.4.2 Gráfica 2: distribución observada	35
2.4.3 Gráfica 3: estimaciones e intervalos	36
2.4.4 Evaluación por repetición	37
2.4.5 Precisión y tamaño de muestra	40
2.5 Ejemplo 2: muestreo estratificado	40
2.5.1 Gráfica 1: definición previa de estratos	43
2.5.2 Gráfica 2: heterogeneidad dentro y entre estratos	44
2.5.3 Gráfica 3: contribuciones al total y al EE	45
2.5.4 Asignación y repetición del diseño	47

2.6	Ejemplo 3: muestreo sistemático	49
2.6.1	Gráfica 1: secuencia sobre el marco	49
2.6.2	Gráfica 2: dispersión de posiciones	50
2.6.3	Distribución exacta de arranques	51
2.6.4	Gráfica 3: variación entre arranques	53
2.6.5	Gráfica 4: sensibilidad al orden	53
2.7	Ejemplo 4: conglomerados y dos etapas	55
2.7.1	Una etapa: seleccionar franjas completas	56
2.7.2	Dos etapas: seleccionar franjas y hectáreas	58
2.7.3	Gráfica 1: mapa de selección	59
2.7.4	Gráfica 2: heterogeneidad entre conglomerados	60
2.7.5	Gráfica 3: variación entre y dentro de franjas	61
2.7.6	Correlación intraclase y efecto de diseño	62
2.7.7	Gráfica 4: repetición de los diseños	63
2.8	Información auxiliar: estimación de razón	65
2.8.1	Gráfica 1: forma de la relación auxiliar	66
2.8.2	Gráfica 2: residuos de proporcionalidad	67
2.8.3	Gráfica 3: precisión por repetición	68
2.8.4	Gráfica 4: sesgo y RMSE	70
2.9	Comparación y decisión	71
2.10	Reproducibilidad y alcance	72
2.11	Ejercicios teóricos y numéricos	74
2.11.1	Ejercicios teóricos	75
2.11.2	Ejercicios numéricos	76
2.11.3	Ejercicios guiados en R	79
2.12	Actividad propuesta para el lector	83

II Parte II — Métodos de campo 84

3 Parcelas, cuadrantes e intercepción 85

3.1	Convertir espacio en observaciones	85
3.2	Población, soporte y unidades	85
3.3	Parcelas de área fija	86
3.4	Frecuencia, cobertura y escala	87
3.5	Tamaño, forma, borde y dependencia	87
3.6	Aplicación reproducible: parcelas de Barro Colorado	88
3.6.1	Carga y auditoría	88
3.6.2	Exploración comunitaria y espacial	89
3.6.3	MAS de hectáreas y estimación	93
3.6.4	Evaluación por repetición	96
3.6.5	Modelo de conteo con hábitat	98
3.6.6	Diagnóstico de dependencia espacial	100

3.6.7	Cambio de soporte con datos observados	101
3.6.8	Comparación de diseños e incertidumbre	104
3.6.9	Sensibilidad al origen de la cuadrícula	106
3.7	Interpretación y reproducibilidad	107
3.8	Ejercicios teóricos y numéricos	110
3.8.1	Ejercicios teóricos	110
3.8.2	Ejercicios numéricos	112
3.8.3	Ejercicios guiados en R	114
3.9	Actividad propuesta para el lector	116
4	Transectos y muestreo por distancias	117
4.1	Del encuentro a la densidad	117
4.2	Población, unidades y estimando	117
4.3	Geometría y función de detección	117
4.4	Supuestos y fuentes de incertidumbre	118
4.5	Truncamiento y calidad de datos	118
4.6	Aplicación reproducible: chochín de Montrave	119
4.6.1	Carga y auditoría de tablas	119
4.6.2	Esfuerzo y tasa de encuentro	120
4.6.3	Distribución y precisión de distancias	121
4.6.4	Modelos candidatos con unidades compatibles	122
4.6.5	Diagnósticos del modelo elegido	123
4.6.6	Densidad, abundancia e incertidumbre	125
4.6.7	Diagnóstico de líneas influentes	126
4.6.8	Sensibilidad a función y truncamiento	126
4.6.9	Sensibilidad a líneas no documentadas con cero	128
4.7	Interpretación y reproducibilidad	129
4.8	Actividad propuesta para el lector	131
5	Métodos de censo por organismos y hábitats	132
5.1	Del organismo observado al estimando	132
5.2	Organismos móviles	132
5.2.1	Conteos completos, parcelas, puntos y transectos	132
5.2.2	Capturas, señales y cámaras	133
5.3	Organismos sésiles y hábitat	133
5.4	Supuestos y control de calidad	134
5.5	Aplicación real: eventos en estaciones de cámara	134
5.5.1	Procedencia, pregunta y estimando	134
5.5.2	Disponibilidad, importación y auditoría	134
5.5.3	Exploración	135
5.5.4	Estimación e incertidumbre	137
5.5.5	Diagnósticos	137
5.5.6	Sensibilidad	138

5.5.7	Interpretación	139
5.6	Errores frecuentes	139
5.7	Síntesis	140
5.8	Actividad propuesta para el lector	140
III	Parte III — Estimación de poblaciones	141
6	Remoción, captura-recaptura e índices de abundancia	142
6.1	Contar lo no observado	142
6.2	Captura-recaptura cerrada	142
6.3	Remoción	143
6.4	Cambio en razón e índices	143
6.5	Supuestos y errores de diseño	144
6.6	Aplicación real: mosquero de alisos	144
6.6.1	Procedencia, diseño y estimando	144
6.6.2	Disponibilidad, importación y auditoría	144
6.6.3	Historias y exploración	145
6.6.4	Verosimilitud cerrada transparente	146
6.6.5	Incertidumbre por simulación paramétrica	148
6.6.6	Diagnóstico del patrón de historias	148
6.6.7	Sensibilidad: dos ocasiones y otras visitas	149
6.6.8	Interpretación y reproducibilidad	150
6.7	Síntesis	150
6.8	Actividad propuesta para el lector	150
7	Ocupación y detección imperfecta	151
7.1	Ausencia observada y estado latente	151
7.2	Diseño y significado	151
7.3	Supuestos	152
7.4	Aplicación real: zorro rojo en cámaras	152
7.4.1	Procedencia, pregunta y estimando	152
7.4.2	Disponibilidad, importación y auditoría	152
7.4.3	Exploración de historias y covariables	153
7.4.4	Ajuste parsimonioso	155
7.4.5	Estimación e incertidumbre	155
7.4.6	Diagnóstico por historias	156
7.4.7	Sensibilidad de la especificación	157
7.4.8	Interpretación y reproducibilidad	158
7.5	Errores frecuentes	159
7.6	Síntesis	159
7.7	Actividad propuesta para el lector	159

IV	Parte IV — Comparación y seguimiento	160
8	Estudios comparativos, intervenciones y sesgos	161
8.1	Pregunta, diseño y estimando	161
8.2	Asignación, comparación y bloqueo	162
8.3	Sesgos que alteran una comparación	162
8.4	Estimación, incertidumbre y diagnóstico	162
8.5	Aplicación completa: intervención nutricional en guisantes	163
8.5.1	Procedencia, diseño y alcance	163
8.5.2	Importación y auditoría	163
8.5.3	Exploración por unidad y bloque	164
8.5.4	Estimación de diferencias ajustadas	166
8.5.5	Incertidumbre respetando bloques	167
8.5.6	Diagnósticos	167
8.5.7	Sensibilidad analítica	168
8.5.8	Interpretación	169
8.6	Síntesis	169
8.7	Actividad propuesta para el lector	169
9	Monitoreo ecológico y análisis de tendencias	171
9.1	Objetivo, indicador y unidad temporal	171
9.2	Diseño de un programa de monitoreo	172
9.3	Tendencia y cambio ecológico	172
9.4	Incertidumbre, sensibilidad y comunicación	172
9.5	Aplicación completa: índice histórico de capturas de lince	173
9.5.1	Procedencia, diseño y estimando	173
9.5.2	Importación y auditoría	173
9.5.3	Exploración de trayectoria y escala	174
9.5.4	Tendencia preliminar y dependencia	175
9.5.5	Estimación con errores dependientes	176
9.5.6	Incertidumbre por bloques temporales	177
9.5.7	Diagnósticos del modelo dependiente	177
9.5.8	Sensibilidad a escala y periodo	178
9.5.9	Interpretación	179
9.6	Síntesis	179
9.7	Actividad propuesta para el lector	180
V	Parte V — Poblaciones y comunidades	181
10	Demografía y dinámica poblacional	182
10.1	Contabilidad y tasas vitales	182
10.2	Fertilidad y reclutamiento	183

10.3	Estructura por estadios	183
10.4	Incertidumbre y diagnóstico	183
10.5	Aplicación completa: demografía de <i>Aquilegia chrysantha</i>	184
10.5.1	Procedencia, diseño, unidad y estimandos	184
10.5.2	Importación y auditoría	184
10.5.3	Exploración de estructura y reproducción	185
10.5.4	Transición y supervivencia aparente	187
10.5.5	Fertilidad observada y reclutamiento	187
10.5.6	Matriz transparente y proyección de un paso	188
10.5.7	Incertidumbre por parcelas	189
10.5.8	Diagnóstico retrospectivo	190
10.5.9	Sensibilidad entre parcelas y periodos	191
10.5.10	Interpretación	192
10.6	Síntesis	192
10.7	Actividad propuesta para el lector	193
11	Riqueza, diversidad y composición de comunidades	194
11.1	De la pregunta a la matriz comunitaria	194
11.2	Riqueza y diversidad clásica	195
11.3	Semejanza y disimilitud	196
11.4	Clasificación y ordenación	196
11.5	Aplicación con <code>vegan::dune</code>	196
11.5.1	Procedencia, pregunta y auditoría	196
11.5.2	Riqueza, Shannon, Simpson y equidad	197
11.5.3	Jaccard y Bray-Curtis	200
11.5.4	Clasificación jerárquica	201
11.5.5	Ordenación por coordenadas principales	202
11.5.6	Sensibilidad a abundancia y presencia	204
11.6	Supuestos y alcance	204
11.7	Errores comunes	205
11.8	Síntesis	205
11.9	Actividad propuesta para el lector	205
VI	Parte VI — Síntesis	206
12	Proyecto completo de muestreo ecológico	207
12.1	La cadena de inferencia	207
12.2	Plan previo al análisis	208
12.3	Aplicación completa con <code>vegan::mite</code>	208
12.3.1	Pregunta y límites del diseño	208
12.3.2	Importación y auditoría	208
12.3.3	Construcción de variables	210

12.3.4	Estimación e incertidumbre	211
12.3.5	Diagnósticos	212
12.3.6	Composición como diagnóstico complementario	214
12.3.7	Sensibilidad	215
12.3.8	Interpretación y comunicación	216
12.3.9	Reproducibilidad	217
12.4	Supuestos y limitaciones	218
12.5	Errores comunes	218
12.6	Síntesis	218
12.7	Actividad propuesta para el lector	219
VII	Prácticas	220
13	Práctica 2: Diseños probabilísticos en R	221
13.1	Presentación	221
13.2	Bloque 0. Arranque autocontenido	221
13.3	Bloque 1. Auxiliar y tamaño de muestra	224
13.4	Bloque 2. Estratificación: asignación y ganancia de precisión	225
13.5	Bloque 3. Sistemático: arranques y sensibilidad al orden	227
13.6	Bloque 4. Conglomerados: orientación de las unidades primarias	228
13.7	Bloque 5. Auxiliar: razón frente a regresión	230
13.8	Síntesis y comprobación	231
14	Práctica 3: Parcelas, cuadrantes e intercepción	233
14.1	Presentación	233
14.2	Bloque 0. Arranque autocontenido	234
14.3	Bloque 1. MAS de hectáreas: densidad, total y frecuencia	235
14.4	Bloque 2. Repetición: las fórmulas describen la incertidumbre real	236
14.5	Bloque 3. Soporte y orientación: cortar el espacio cambia el estimando	237
14.6	Bloque 4. Cobertura por intercepción: transectos y puntos	239
14.7	Bloque 5. Diseños y origen de la cuadrícula	240
14.8	Síntesis y comprobación	242
VIII	Material complementario	244
	Material complementario	245
	Profundizaciones metodológicas previstas	245
	Plantillas	245
	Lista de comprobación de reproducibilidad	245
	Referencias	246

Presentación

El muestreo ecológico convierte preguntas sobre organismos, poblaciones y comunidades en observaciones capaces de sostener inferencias. Esa conversión no depende únicamente del análisis final: comienza al delimitar la población, continúa con la selección de unidades y el protocolo de observación, y culmina con estimadores cuya incertidumbre corresponde al diseño realmente ejecutado.

Propósito

Este libro desarrolla de forma conjunta fundamentos estadísticos, métodos de campo y análisis reproducible con R. Su hilo conductor es:

pregunta → población → diseño → observación → estimación → incertidumbre → interpretación.

Enfoque

Los conceptos se introducen mediante problemas ecológicos, ejemplos numéricos y aplicaciones desarrolladas. Cada aplicación muestra el flujo completo en R: procedencia y validación de datos, reconstrucción del diseño, exploración, estimación, diagnóstico, sensibilidad, interpretación y comunicación reproducible. Los ejercicios y las actividades propuestas para el lector permiten trasladar el método a datos nuevos.

Recursos del libro

- navegación y búsqueda en la edición HTML;
- código reproducible en R;
- capítulos fuente en formato QMD;
- notebooks IPYNB compatibles con un kernel de R; y
- una edición completa en PDF.

Consulte el [Prefacio](#), la [guía de lectura](#) y el [catálogo de datos](#) antes de comenzar. El capítulo final integra los métodos en un [proyecto completo de muestreo ecológico](#).

Prefacio

Propósito y enfoque

El muestreo ecológico conecta una pregunta científica con observaciones obtenidas bajo restricciones espaciales, temporales, logísticas y éticas. Este libro enfatiza la relación entre el diseño, los estimadores y el alcance real de las conclusiones, con una orientación aplicada y reproducible.

Audiencia

El material está dirigido a estudiantes de estadística aplicada, ciencia de datos, ecología y áreas afines que requieran diseñar o analizar estudios sobre poblaciones biológicas.

Prerrequisitos

Se espera familiaridad con probabilidad, inferencia estadística y programación básica en R. Los conceptos especializados se introducirán en los capítulos donde sean necesarios.

Principios de trabajo

- La pregunta ecológica determina la población objetivo y la unidad de muestreo.
- La inferencia debe corresponder al mecanismo real de selección de unidades.
- El esfuerzo de campo, la precisión y los posibles sesgos se evalúan juntos.
- El código, los datos derivados y las decisiones analíticas deben ser reproducibles.
- Las limitaciones del diseño se comunican junto con los resultados.

Organización

El libro se organiza en seis partes. Las dos primeras desarrollan los fundamentos probabilísticos y los métodos de observación en parcelas, transectos, organismos y hábitats. Las siguientes estudian estimación de poblaciones, ocupación, comparaciones y monitoreo. La quinta parte aborda demografía y comunidades; la última integra todo el flujo en un proyecto reproducible.

Cómo trabajar con los capítulos

Cada capítulo combina teoría, formulación estadística, supuestos, una aplicación completa en R con datos reales, interpretación ecológica, análisis de sensibilidad y una actividad propuesta para el lector. Los archivos QMD son la fuente principal; los notebooks IPYNB se generan a partir de ellos para evitar versiones divergentes.

Diversidad de casos

Los casos recorren inventarios biológicos, vegetación, transectos de fauna, métodos de censo, intervenciones, series de monitoreo, ocupación, captura-recaptura, demografía vegetal y diversidad. Esta diversidad permite reconocer qué principios son transferibles y qué métodos dependen del proceso ecológico y de observación.

Cómo usar este libro

Tres niveles de trabajo

Cada capítulo ofrece tres recorridos complementarios:

1. **Fundamentos:** conceptos, notación, estimadores, supuestos e incertidumbre.
2. **Aplicación completa:** análisis reproducible de datos reales que conecta la pregunta con una interpretación ecológica mediante código R ejecutable.
3. **Actividad propuesta para el lector:** extensión autónoma del método a otra pregunta, conjunto de datos o decisión analítica.

La aplicación no debe leerse como una receta universal. Su función es hacer visibles las decisiones que suelen quedar ocultas entre la recolección y el resultado final.

Convenciones

- $U = \{1, \dots, N\}$ denota una población finita.
- $s \subset U$ denota la muestra realizada.
- π_i y π_{ij} son probabilidades de inclusión de primer y segundo orden.
- Los sombreros identifican estimadores o cantidades ajustadas.
- El término **diseño** se reserva para el mecanismo de selección o asignación; el **proceso de observación** describe cómo un estado ecológico produce un registro.
- Un cero observado, una no detección y un dato faltante no son equivalentes.

Código y reproducibilidad

Los bloques R se ejecutan en orden desde la raíz del proyecto. Se usan semillas cuando la aleatoriedad no es el objeto de estudio, rutas relativas y datos con procedencia documentada. Las salidas se interpretan en el texto; el código no sustituye la argumentación.

Los botones de cada capítulo permiten descargar el QMD y un notebook con kernel R. La edición HTML facilita explorar código, mientras el PDF ofrece una lectura continua.

Ruta sugerida

Los capítulos 1 y 2 establecen la notación y la lógica de inferencia. A partir de allí, los capítulos pueden consultarse por familia metodológica, aunque conviene leer el capítulo de síntesis después de haber trabajado al menos un método de campo, uno poblacional y uno comunitario.

Marco bibliográfico

Corpus delimitado

El contenido metodológico del libro se sustenta exclusivamente en los siete libros disponibles en **references/**. Las fuentes externas se utilizan solo para documentar la procedencia de datos o software y no para ampliar la teoría más allá de este corpus.

Diseño y estimación

Lohr (2022) desarrolla población, marco, muestreo aleatorio simple, estratificación, conglomerados, etapas, probabilidades desiguales, estimación auxiliar, no respuesta, varianza y calidad total. Manly y Navarro Alberto (2015) conecta estos principios con problemas ecológicos y añade muestreo adaptativo, métodos sin parcela, remoción, captura-recaptura, ocupación, monitoreo y tendencias.

Métodos ecológicos de campo

Sutherland (2006) organiza la planificación, los principios de muestreo, los métodos generales y los protocolos para plantas, invertebrados, peces, anfibios, reptiles, aves y mamíferos. Henderson y Southwood (2016) complementa esa base con instrumentos y métodos para ambientes terrestres y acuáticos, estimación poblacional, demografía, diversidad, clasificación, ordenación y series ecológicas.

Comparación, sesgo y vigilancia

Woodward (2014) y Gerstman (2013) se usan únicamente en sus estructuras transferibles: medidas de ocurrencia, diseños comparativos, intervenciones, error, sesgo de selección e información, confusión, interacción, clasificación y supervivencia. No se trasladan al libro recomendaciones clínicas ni contenidos propios del manejo de enfermedades.

Gregg (2008) aporta organización de investigaciones de campo, vigilancia, calidad de datos, documentación y comunicación. Sus procedimientos se traducen a observaciones ecológicas sin importar prácticas clínicas, legales o de control de brotes.

Correspondencia con el libro

Área	Fuentes del corpus
Pregunta, marco y unidades	Sutherland; Manly y Navarro Alberto; Lohr
Diseños probabilísticos	Lohr; Manly y Navarro Alberto; Sutherland
Parcelas e intercepción	Sutherland; Henderson; Manly y Navarro Alberto
Transectos y distancias	Manly y Navarro Alberto; Sutherland; Henderson
Métodos por taxón y hábitat	Sutherland; Henderson
Remoción y captura-recaptura	Manly y Navarro Alberto; Henderson; Sutherland; Lohr
Ocupación	Manly y Navarro Alberto; Sutherland
Comparaciones y sesgos	Woodward; Gerstman; Gregg; Lohr
Monitoreo y tendencias	Manly y Navarro Alberto; Sutherland; Henderson; Gregg
Demografía	Henderson; Gerstman; Manly y Navarro Alberto
Comunidades	Henderson
Proyecto completo	Las siete obras, dentro de sus alcances declarados

Política de fidelidad

- Cada afirmación metodológica debe corresponder a un tema explícito del corpus.
- Las aplicaciones en R implementan esos métodos, pero los paquetes no actúan como autoridades metodológicas.
- Los datos externos requieren fuente, licencia, unidad y limitaciones documentadas.
- Una técnica ausente del corpus no se incorpora por estar disponible en R.
- Los ejemplos sintetizan y atribuyen; no reproducen extensamente texto, figuras o tablas protegidas.

Catálogo de datos reales

Criterios de selección

Cada aplicación principal utiliza observaciones empíricas distribuidas con R o con un paquete instalado. La teoría procede de los siete libros del corpus; las referencias externas de esta página documentan únicamente datos y software.

! Datos reales no significa inferencia automática

Un archivo empírico puede proceder de una muestra conveniente, omitir unidades no detectadas o carecer de probabilidades de inclusión. Cada capítulo reconstruye lo que la documentación permite y limita sus conclusiones al diseño conocido.

Casos adoptados

Código	Caso real	Fuente reproducible	Capítulo	Uso principal
C1	Flores de iris	<code>datasets::iris</code>	1	Población, marco, dominios e incertidumbre
C2	Cerezos negros	<code>datasets::trees</code>	2	Comparación de diseños probabilísticos
C3	Árboles de Barro Colorado	<code>vegan::BCI</code> , <code>BCI.env</code>	2 y 3	Conglomerados, etapas, parcelas, soporte y dependencia espacial
C4	Chochines de Montrave	<code>Distance::wren_lt</code>	4	Transectos y función de detección

Código	Caso real	Fuente reproducible	Capítulo	Uso principal
C5	Duikers en cámaras	<code>Distance::DuikerCameraTraps</code>	5	Eventos, esfuerzo y métodos de censo
C6	Mosquero de alisos	CSV incluidos en <code>unmarked</code>	6	Historias cerradas y captura-recaptura
C7	Mesocarnívoros	<code>unmarked::MesoCarnivores</code>	7	Ocupación y detección repetida
C8	Ensayo de fertilización NPK	<code>datasets::npk</code>	8	Comparaciones ajustadas por bloque
C9	Capturas históricas de lince	<code>datasets::lynx</code>	9	Índices, tendencia y dependencia temporal
C10	<i>Aquilegia chrysantha</i>	<code>popbio::aq.trans</code>	10	Transiciones y demografía por estadios
C11	Praderas de dunas	<code>vegan::dune, dune.env</code>	11	Diversidad clásica y composición
C12	Ácaros oribátidos	<code>vegan::mite, mite.env</code>	12	Flujo integrado y reproducible

Procedencia y límites

C1–C2. Datos incluidos con R

`iris` conserva mediciones morfológicas compiladas por Edgar Anderson y `trees` registra diámetro, altura y volumen de 31 cerezos negros. Los capítulos los tratan como poblaciones finitas didácticas; no representan muestras probabilísticas de todas las flores o bosques.

C3, C11 y C12. Datos de vegan

BCI contiene conteos de árboles en 50 parcelas contiguas de una hectárea (Condit et al. 2002; Harms et al. 2001; Pyke et al. 2001). `dune` documenta vegetación de veinte praderas neerlandesas y `mite` contiene ácaros oribátidos de setenta sitios. La distribución y estructura de estos objetos se documentan con Oksanen et al. (2024). Ninguno proporciona por sí solo un marco probabilístico para un paisaje mayor.

C4–C5. Datos de Distance

`wren_lt` contiene transectos reales de chochín en Montrave y `DuikerCameraTraps` contiene registros de cámaras para duiker de Maxwell en el Parque Nacional Taï. Los capítulos conservan esfuerzo, ceros y unidades y documentan el software con Miller et al. (2019). El capítulo 5 estima tasas de eventos, no individuos ni densidad.

C6–C7. Datos de unmarked

Los archivos del mosquero de alisos registran individuos seguidos durante intervalos de conteo (Chandler et al. 2009). `MesoCarnivores` contiene tres visitas de cámaras para 1 437 sitios y tres especies (Rota et al. 2016). El paquete se documenta con Kellner et al. (2023).

C8–C10. Intervención, índice y demografía

`npk` es un ensayo agrícola histórico en bloques; su alcance no se extiende a otras fincas o dosis. `lynx` registra capturas anuales, no abundancia, y carece de esfuerzo (Campbell y Walker 1977). `aq.trans` contiene destinos anuales de plantas marcadas de *Aquilegia chrysantha* y se distribuye con `popbio` (Stubben y Milligan 2007).

Política de datos

- `data/raw/` se reserva para archivos externos sin modificación.
- Los objetos distribuidos por paquetes se cargan desde su fuente para evitar copias divergentes.
- `data/metadata/` registra fuente, versión, licencia, diseño, unidades y limitaciones de cada caso.
- `data/processed/` solo contendrá derivados reconstruibles por código.
- Ninguna corrección manual se incorpora sin quedar registrada.
- Los datos no se redistribuyen fuera de los términos de su licencia.

Parte I

Parte I — Fundamentos

1 Del problema ecológico al diseño

1.1. Diseñar antes de observar

Una investigación ecológica comienza por decidir **qué cantidad, en qué población, durante qué período y con qué unidad** se quiere estimar. El diseño conecta pregunta, marco, selección, medición y análisis. Un intervalo estrecho no compensa una población mal delimitada ni una medición que responde a otra pregunta (Sutherland 2006; Manly y Navarro Alberto 2015).

Una declaración operativa útil tiene esta forma:

Estimar el parámetro de una variable en unidades elegibles, durante un período y dentro de una extensión definidos, mediante un procedimiento de selección y un protocolo de medición documentados.

1.2. Población, unidades y estimando

Sea $U = \{1, \dots, N\}$ una población finita y y_i el valor de la unidad i . Tres estimandos habituales son

$$Y = \sum_{i \in U} y_i, \quad \bar{Y} = \frac{1}{N} \sum_{i \in U} y_i, \quad P = \frac{1}{N} \sum_{i \in U} I(y_i \in A).$$

El denominador pertenece a la definición. Densidad de individuos por hectárea, biomasa por árbol y frecuencia por parcela no son versiones intercambiables de una misma cantidad.

- **Población objetivo:** conjunto al que se desea referir la conclusión.
- **Población accesible:** parte que el protocolo puede alcanzar.
- **Marco:** lista, mapa o red desde la cual se seleccionan unidades.
- **Unidad de muestreo:** elemento que recibe probabilidad de selección.
- **Unidad de observación:** elemento sobre el que se mide.
- **Unidad de análisis:** elemento que aporta una observación independiente.
- **Estimando:** cantidad poblacional definida antes de analizar.

Una parcela seleccionada puede contener muchos árboles observados. Si la selección ocurrió entre parcelas, los árboles internos son submuestras y no parcelas independientes. Esta separación evita pseudorreplicación.

1.3. Selección e incertidumbre

Un diseño probabilístico asigna probabilidades conocidas y positivas $\pi_i = P(i \in s)$. El estimador de Horvitz–Thompson para el total es

$$\widehat{Y}_{HT} = \sum_{i \in s} \frac{y_i}{\pi_i}.$$

En muestreo aleatorio simple sin reemplazo (MAS), $\pi_i = n/N$ y la media se estima con $\bar{y}_s$. Su varianza estimada es

$$\widehat{V}_p(\bar{y}_s) = \left(1 - \frac{n}{N}\right) \frac{s_y^2}{n}.$$

El factor $1 - n/N$ reconoce que no se reemplazan unidades de una población finita. No corrige cobertura incompleta, no respuesta, no detección ni error de medición (Lohr 2022). Un intervalo basado en el diseño es $\bar{y}_s \pm t_{n-1, 0.975} \widehat{SE}$.

El error cuadrático medio separa variabilidad y sesgo:

$$MSE(\hat{\theta}) = V(\hat{\theta}) + \{E(\hat{\theta}) - \theta\}^2.$$

Una muestra de conveniencia grande puede ser estable y, al mismo tiempo, estar centrada lejos del parámetro. La aleatorización protege contra preferencias de selección; la auditoría del protocolo protege contra errores de observación.

1.4. Arquitectura de un estudio defendible

1. Formular una pregunta y un estimando primario.
2. Delimitar población, extensión, período, elegibilidad y dominios.
3. Auditar vacíos, duplicados e inaccesibilidad del marco.
4. Identificar unidad de muestreo, observación y análisis.
5. Escribir reglas de selección, reemplazo y medición.
6. Vincular el estimando con su estimador y su incertidumbre.
7. Anticipar heterogeneidad, dependencia y detectabilidad.
8. Registrar control de calidad, desviaciones y límites de inferencia.

1.5. Aplicación reproducible: flores de iris

`datasets::iris` contiene 150 registros morfológicos de flores, 50 por cada una de tres especies. Es un conjunto real histórico incorporado en R. Se desconoce un marco probabilístico que permita representar todas las poblaciones naturales, las filas no incluyen sitio, fecha, individuo ni incertidumbre instrumental, y algunas observaciones de *Iris versicolor* y *I. virginica* proceden del mismo origen. Por ello lo tratamos solo como **población finita de registros**, no como una muestra representativa de las especies.

El estimando primario es la longitud media de sépalo de los 150 registros. La unidad de muestreo, observación y análisis es una fila. La especie es información auxiliar y define dominios.

1.5.1. Procedencia, carga y auditoría

```
data(iris, package = "datasets")
U <- transform(iris, id = seq_len(nrow(iris)))

auditoria <- data.frame(
  filas = nrow(U),
  ids_unicos = length(unique(U$id)),
  duplicados_completos = sum(duplicated(iris)),
  faltantes = sum(is.na(U)),
  longitudes_no_positivas = sum(U$Sepal.Length <= 0)
)
auditoria
#>   filas ids_unicos duplicados_completos faltantes longitudes_no_positivas
#> 1   150         150                   1         0                      0
table(U$Species, useNA = "ifany")
#>
#>   setosa versicolor  virginica
#>    50         50         50
```

Los duplicados completos no se eliminan: pueden corresponder a flores distintas con las mismas medidas redondeadas. Sin identificadores originales no es posible distinguir repetición biológica de duplicación administrativa; excluirlos cambiaría la población definida.


1.5.2. Exploración orientada al diseño


```

resumen <- aggregate(
  cbind(Sepal.Length, Sepal.Width, Petal.Length, Petal.Width) ~ Species,
  data = U,
  FUN = function(x) c(n = length(x), media = mean(x), de = sd(x),
    minimo = min(x), maximo = max(x))
)
resumen
#>      Species Sepal.Length.n Sepal.Length.media Sepal.Length.de
#> 1      setosa      50.0000000      5.0060000      0.3524897
#> 2 versicolor      50.0000000      5.9360000      0.5161711
#> 3  virginica      50.0000000      6.5880000      0.6358796
#>      Sepal.Length.minimo Sepal.Length.maximo Sepal.Width.n Sepal.Width.media
#> 1           4.3000000           5.8000000      50.0000000      3.4280000
#> 2           4.9000000           7.0000000      50.0000000      2.7700000
#> 3           4.9000000           7.9000000      50.0000000      2.9740000
#>      Sepal.Width.de Sepal.Width.minimo Sepal.Width.maximo Petal.Length.n
#> 1      0.3790644           2.3000000           4.4000000      50.0000000
#> 2      0.3137983           2.0000000           3.4000000      50.0000000
#> 3      0.3224966           2.2000000           3.8000000      50.0000000
#>      Petal.Length.media Petal.Length.de Petal.Length.minimo Petal.Length.maximo
#> 1           1.4620000      0.1736640           1.0000000           1.9000000
#> 2           4.2600000      0.4699110           3.0000000           5.1000000
#> 3           5.5520000      0.5518947           4.5000000           6.9000000
#>      Petal.Width.n Petal.Width.media Petal.Width.de Petal.Width.minimo
#> 1      50.0000000      0.2460000      0.1053856      0.1000000
#> 2      50.0000000      1.3260000      0.1977527      1.0000000
#> 3      50.0000000      2.0260000      0.2746501      1.4000000
#>      Petal.Width.maximo
#> 1           0.6000000
#> 2           1.8000000
#> 3           2.5000000

op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
boxplot(Sepal.Length ~ Species, data = U, col = "grey85",
  xlab = "Especie", ylab = "Longitud de sépalos (cm)")
plot(U$Petal.Length, U$Sepal.Length, pch = 19,
  col = as.integer(U$Species), xlab = "Longitud de pétalo (cm)",
  ylab = "Longitud de sépalos (cm)")
legend("topleft", levels(U$Species), col = 1:3, pch = 19, bty = "n")

```



```
par(op)
```

La separación entre especies muestra que el orden o una selección concentrada en un dominio puede alterar la estimación. La relación con longitud de pétalo sugiere un auxiliar, pero no reemplaza la selección probabilística.

1.5.3. Selección y estimación por MAS

```
set.seed(1101)
N <- nrow(U)
n <- 30
ids_mas <- sample(U$id, n, replace = FALSE)
s_mas <- U[match(ids_mas, U$id), ]

ybar <- mean(s_mas$Sepal.Length)
se_mas <- sqrt((1 - n / N) * var(s_mas$Sepal.Length) / n)
ic_mas <- ybar + qt(c(0.025, 0.975), n - 1) * se_mas
resultado_mas <- data.frame(
  estimando = "media de longitud de sépalo en 150 registros",
  estimacion = ybar, SE = se_mas, LI = ic_mas[1], LS = ic_mas[2])
```


```
)
round(resultado_mas[-1], 3)
#>   estimacion   SE   LI   LS
#> 1      5.73 0.114 5.497 5.963
```

Cada fila seleccionada representa $N/n = 5$ filas del marco. El intervalo describe la variación que produciría repetir este MAS. No incluye incertidumbre sobre la procedencia, representatividad externa, redondeo o identificación taxonómica.

1.5.4. Dominios y modelo descriptivo

```
por_especie <- do.call(rbind, lapply(split(s_mas, s_mas$Species), function(z) {
  Nh <- sum(U$Species == z$Species[1])
  nh <- nrow(z)
  data.frame(especie = z$Species[1], Nh = Nh, nh = nh,
             media = mean(z$Sepal.Length),
             SE = if (nh > 1)
               sqrt((1 - nh / Nh) * var(z$Sepal.Length) / nh) else NA)
}))
por_especie
#>           especie Nh nh   media      SE
#> setosa          setosa 50 12 5.075000 0.09423938
#> versicolor versicolor 50 11 6.154545 0.15634672
#> virginica     virginica 50  7 6.185714 0.10403427

modelo <- lm(Sepal.Length ~ Species + Petal.Length, data = s_mas)
coef(summary(modelo))
#>           Estimate Std. Error  t value    Pr(>|t|)
#> (Intercept)      3.9997205   0.3725132 10.737124 4.724720e-11
#> Speciesversicolor -1.0827438   0.7318622 -1.479437 1.510390e-01
#> Speciesvirginica  -1.7429458   0.9595747 -1.816373 8.086087e-02
#> Petal.Length       0.7373345   0.2431156  3.032855 5.433433e-03
par(mfrow = c(1, 2))
plot(fitted(modelo), residuals(modelo), pch = 19,
     xlab = "Valor ajustado", ylab = "Residuo")
abline(h = 0, lty = 2)
qqnorm(residuals(modelo), pch = 19)
qqline(residuals(modelo))
```



```
par(mfrow = c(1, 1))
```

El modelo describe asociaciones dentro de la muestra: a longitud de pétalo fija, los coeficientes de especie son diferencias condicionales. No identifican causas ni amplían la población de inferencia. Los gráficos permiten detectar curvatura, varianza desigual y observaciones influyentes; con solo 30 filas, cualquier patrón debe interpretarse con cautela.

1.5.5. Evaluación del diseño y diagnóstico del intervalo

Como se conoce el marco completo, se puede repetir el mecanismo de selección sin inventar datos biológicos. Esta repetición evalúa el diseño sobre valores reales.

```
set.seed(1102)
B <- 2000
verdad <- mean(U$Sepal.Length)
evaluar_mas <- function() {
  z <- U$Sepal.Length[sample.int(N, n)]
  est <- mean(z)
  se <- sqrt((1 - n / N) * var(z) / n)
  c(est = est, se = se,
    cubre = abs(est - verdad) <= qt(0.975, n - 1) * se)
```

```

}
rep_mas <- t(replicate(B, evaluar_mas()))
c(sesgo = mean(rep_mas[, "est"] - verdad),
  DE = sd(rep_mas[, "est"]),
  SE_medio = mean(rep_mas[, "se"]),
  cobertura = mean(rep_mas[, "cubre"]),
  RMSE = sqrt(mean((rep_mas[, "est"] - verdad)^2)))
#>      sesgo      DE SE_medio cobertura      RMSE
#> 0.0018200 0.1326946 0.1348531 0.9535000 0.1326739

```

El sesgo cercano a cero es consecuencia del MAS sobre este marco. La cercanía entre la desviación de estimaciones y el SE medio valida la fórmula para este mecanismo; la cobertura diagnostica la aproximación t , no la calidad externa del archivo.

1.5.6. Sensibilidad a selección y esfuerzo

```

set.seed(1103)
comparar <- replicate(B, {
  mas <- mean(U$Sepal.Length[sample.int(N, n)])
  inicio <- sample.int(N - n + 1, 1)
  bloque <- mean(U$Sepal.Length[inicio:(inicio + n - 1)])
  c(MAS = mas, bloque_contiguo = bloque)
})

t(apply(comparar, 1, function(x)
  c(sesgo = mean(x - verdad), DE = sd(x),
    RMSE = sqrt(mean((x - verdad)^2)))))
#>      sesgo      DE      RMSE
#> MAS      -0.003191667 0.1317017 0.1317074
#> bloque_contiguo 0.003813333 0.5402549 0.5401332

n_grid <- c(10, 20, 30, 50, 80, 120)
S2 <- var(U$Sepal.Length)
data.frame(
  n = n_grid,
  fraccion = n_grid / N,
  SE_esperado = sqrt((1 - n_grid / N) * S2 / n_grid),
  semiamplitud = qnorm(0.975) *
    sqrt((1 - n_grid / N) * S2 / n_grid)
)

```

```
#>      n   fraccion SE_esperado semiamplitud
#> 1  10 0.06666667  0.25297838  0.49582852
#> 2  20 0.13333333  0.17237571  0.33785018
#> 3  30 0.20000000  0.13522263  0.26503149
#> 4  50 0.33333333  0.09561684  0.18740556
#> 5  80 0.53333333  0.06324460  0.12395713
#> 6 120 0.80000000  0.03380566  0.06625787
```

El bloque contiguo es sensible al orden histórico por especie y no tiene la protección del MAS. Aumentar n reduce incertidumbre, con ganancias marginales decrecientes. Ninguna de las dos sensibilidades resuelve la falta de sitio, fecha, sexo, etapa vital o marco de selección original.

1.6. Interpretación y reproducibilidad

La estimación principal caracteriza exclusivamente los 150 registros. Las diferencias por especie y el modelo ayudan a entender heterogeneidad, pero no convierten el archivo en una muestra de poblaciones silvestres. Una conclusión reproducible debe conservar semilla, versión de R, definición de variables, identificadores seleccionados y reglas de exclusión.

```
list(
  archivo = "datasets::iris",
  version_R = R.version.string,
  semilla_MAS = 1101,
  ids_seleccionados = sort(ids_mas),
  N = N,
  n = n,
  estimando = "media de Sepal.Length en las 150 filas"
)
#> $archivo
#> [1] "datasets::iris"
#>
#> $version_R
#> [1] "R version 4.5.2 (2025-10-31)"
#>
#> $semilla_MAS
#> [1] 1101
#>
#> $ids_seleccionados
#> [1] 2 11 16 23 25 33 34 41 43 44 47 49 51 52 60 63 64 66 67
#> [20] 76 77 95 97 101 104 105 111 114 120 139
```

```

#>
#> $N
#> [1] 150
#>
#> $n
#> [1] 30
#>
#> $estimando
#> [1] "media de Sepal.Length en las 150 filas"
sessionInfo()
#> R version 4.5.2 (2025-10-31)
#> Platform: x86_64-pc-linux-gnu
#> Running under: Ubuntu 24.04.4 LTS
#>
#> Matrix products: default
#> BLAS: /usr/lib/x86_64-linux-gnu/openblas-pthread/libblas.so.3
#> LAPACK: /usr/lib/x86_64-linux-gnu/openblas-pthread/libopenblas-p-r0.3.26.so; LAPACK versi
#>
#> locale:
#> [1] LC_CTYPE=C.UTF-8 LC_NUMERIC=C LC_TIME=C.UTF-8
#> [4] LC_COLLATE=C.UTF-8 LC_MONETARY=C.UTF-8 LC_MESSAGES=C.UTF-8
#> [7] LC_PAPER=C.UTF-8 LC_NAME=C LC_ADDRESS=C
#> [10] LC_TELEPHONE=C LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
#>
#> time zone: UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats graphics grDevices datasets utils methods base
#>
#> loaded via a namespace (and not attached):
#> [1] compiler_4.5.2 fastmap_1.2.0 cli_3.6.5 htmltools_0.5.9
#> [5] tools_4.5.2 yaml_2.3.12 codetools_0.2-20 rmarkdown_2.30
#> [9] knitr_1.51 jsonlite_2.0.0 xfun_0.56 digest_0.6.39
#> [13] rlang_1.1.7 renv_1.2.4 evaluate_1.0.5

```

1.7. Actividad propuesta para el lector

Use el conjunto real `datasets::ToothGrowth` para estimar la longitud media de odontoblastos en el marco completo y por suplemento. Documente procedencia y limitaciones experimentales, audite tipos, faltantes, duplicados y balance, defina unidad y estimando, explore

distribuciones, extraiga un MAS reproducible y estime media, SE e intervalo con corrección finita. Compare MAS con muestreo estratificado por suplemento mediante repetición sobre los datos observados, diagnostique cobertura y RMSE, ajuste un modelo descriptivo con dosis y suplemento, revise residuos y observaciones influyentes, y evalúe sensibilidad al tamaño de muestra. Interprete qué incertidumbre pertenece al nuevo mecanismo de selección y cuál no puede recuperarse del archivo histórico.

2 Diseños probabilísticos para poblaciones biológicas

Selección, estimación y evaluación por repetición

2.1. Aleatorización e inferencia

Un diseño probabilístico permite aprovechar de manera rigurosa los recursos disponibles para estudiar una población biológica. Su característica fundamental es que cada unidad —por ejemplo, un individuo, una parcela, un árbol o un punto de observación— tiene una probabilidad conocida de ser seleccionada. Esto permite utilizar la información obtenida en la muestra para hacer estimaciones sobre toda la población y, además, cuantificar la incertidumbre asociada a esas estimaciones.

No existe un diseño de muestreo que sea el mejor en todas las situaciones. La elección depende de cómo se distribuye la población, de qué tan diferentes son sus unidades, de la información previa disponible, de las condiciones del territorio y de los costos del trabajo de campo (Manly y Navarro Alberto 2015; Lohr 2022). Por esta razón, no basta con seleccionar una muestra que visualmente parezca bien distribuida o representativa: es necesario establecer una regla de selección clara, probabilística y reproducible, que permita conocer cómo y con qué probabilidad fue elegida cada unidad.

Consideremos una población finita formada por N unidades, que representamos como $U = 1, \dots, N$. Para cada unidad i , el indicador I_i toma el valor 1 si la unidad es seleccionada y 0 si no lo es. Su probabilidad de inclusión se denota por $\pi_i = P(I_i = 1)$, y el peso muestral correspondiente es $w_i = 1/\pi_i$. Este peso indica cuántas unidades de la población representa aproximadamente cada unidad observada: cuanto menor sea su probabilidad de selección, mayor será su peso. El estimador de Horvitz–Thompson utiliza estos pesos para estimar el total de una variable y en la población:

$$\widehat{Y}_{HT} = \sum_{i \in s} \frac{y_i}{\pi_i}.$$

En otras palabras, se suma el valor observado de cada unidad seleccionada, ajustado por su probabilidad de inclusión. Por ejemplo, si una unidad tiene una probabilidad de inclusión de 0,20, su peso es $1/0,20 = 5$; por tanto, esa unidad representa cinco unidades de la población.

Para calcular la varianza del estimador también es necesario conocer las probabilidades de inclusión conjunta, π_{ij} , es decir, la probabilidad de que las unidades i y j sean seleccionadas simultáneamente. Por esta razón, conservar únicamente una columna con los pesos no permite reconstruir por completo el diseño muestral. También deben registrarse los estratos, los conglomerados, las etapas de selección, el orden utilizado y las reglas aplicadas cuando fue necesario reemplazar alguna unidad. En los ejemplos se estimarán principalmente tres características de la población:

$$\bar{Y} = \frac{1}{N} \sum_{i \in U} y_i, \quad Y = \sum_{i \in U} y_i, \quad P = \frac{1}{N} \sum_{i \in U} z_i.$$

Aquí, $\bar{Y}$ es la media poblacional, Y es el total poblacional y P es una proporción. Para calcular esta última, z_i toma el valor 1 cuando la unidad cumple una condición definida previamente y 0 cuando no la cumple. Finalmente, es importante distinguir la desviación estándar (DE) del error estándar (EE): la DE describe cuánto difieren las unidades de la población entre sí, mientras que el EE indica cuánto podría cambiar una estimación si se repitiera el muestreo. Por tanto, miden tipos de variabilidad diferentes y no deben utilizarse como sinónimos.

2.2. Diseños fundamentales

2.2.1. Muestreo aleatorio simple

En un muestreo aleatorio simple sin reemplazo (MAS), se seleccionan (n) unidades de una población de tamaño (N), de manera que todas las muestras posibles de ese tamaño tienen la misma probabilidad de ser elegidas. La expresión «sin reemplazo» significa que una unidad seleccionada no puede volver a aparecer en la misma muestra. En este diseño, la media de la población se estima mediante la media de las unidades seleccionadas:

$$\widehat{\bar{Y}} = \bar{y}_s = \frac{1}{n} \sum_{i \in s} y_i.$$

El numerador suma solo los n valores observados, por lo que se divide entre n , el tamaño de la muestra, y no entre N . Esta media estima la media poblacional desconocida $\bar{Y} = (1/N) \sum_U y_i$: ambas suman sus términos y los dividen entre su propio número (la muestra entre n ; la población, entre N , que no se conoce porque solo se observó la muestra). Si se dividiera por N se mezclaría una suma parcial con el total de unidades de la población.

La variabilidad entre las unidades de la muestra se resume con la varianza muestral

$$s_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y}_s)^2 ,$$

que se divide entre $n - 1$ porque estima la varianza poblacional S^2 ajustando un grado de libertad. Para cuantificar cuánto varía la *media estimada* entre muestras repetidas, esa variabilidad entre unidades se divide además entre n , pues promediar n valores reduce la variación en un factor $1/n$ (de ahí el error estándar $SE = \sqrt{s_y^2/n} = s_y/\sqrt{n}$). La varianza de la media es

$$\widehat{V}(\bar{y}_s) = \left(1 - \frac{n}{N}\right) \frac{s_y^2}{n},$$

donde el factor $1 - n/N$, la corrección por población finita, reduce la varianza cuando la muestra cubre una fracción importante de la población. Si n/N es pequeña casi no afecta; si $n = N$ se observa todo y la varianza es cero. En resumen: el $n - 1$ vive dentro de s_y^2 (variabilidad entre unidades) y el n divide en la varianza de la media (efecto de promediar). A partir de la media muestral también pueden estimarse otras características. El total de la población se estima como

$$\widehat{Y} = N\bar{y}_s.$$

Así, en el MAS cada cantidad tiene su papel: la *media* se estima dividiendo la suma entre n ; la *varianza entre unidades* s_y^2 se estima dividiendo entre $n - 1$; la *varianza de la media* divide esa s_y^2 entre n y la ajusta con $1 - n/N$; y el *total* multiplica la media por N . N no aparece en la media, sino al extenderla a toda la población y en la corrección por finitud.

Para estimar una proporción, se define una variable indicadora que toma el valor 1 si cada unidad cumple la condición de interés y 0 si no la cumple. La media de ese indicador en la muestra corresponde a la proporción estimada, y su varianza se calcula siguiendo el mismo principio.

2.2.2. Muestreo con probabilidad proporcional al tamaño (PPS)

El MAS da a todas las unidades la misma probabilidad de entrar en la muestra. A veces eso no conviene: si algunas unidades son mucho más grandes o más importantes (por ejemplo, los claros de mayor tamaño en un bosque), puede interesar que esas unidades tengan más oportunidades de ser seleccionadas. En el muestreo con probabilidad proporcional al tamaño, o PPS, la probabilidad de cada unidad es proporcional a una medida de tamaño conocida x_i para todo el marco:

$$\pi_i = n \frac{x_i}{X}, \quad X = \sum_{i \in U} x_i,$$

donde n es el tamaño de muestra y X el total de la medida de tamaño. Una unidad con el doble de x_i tiene el doble de probabilidad de ser elegida.

Con el estimador de Horvitz-Thompson $\widehat{Y}_{HT} = \sum_s y_i / \pi_i$, el total estimado es insesgado aunque las probabilidades sean desiguales. Si la variable y está relacionada con el tamaño x , PPS suele dar mayor precisión que el MAS y hace que cada unidad seleccionada tenga una contribución similar al resultado.

Hay dos formas habituales de llevarlo a la práctica.

Con reemplazo: se hacen n sorteos independientes y, en cada sorteo, la unidad i se elige con probabilidad $q_i = x_i / X$. El procedimiento es simple, aunque una misma unidad puede entrar varias veces. Si $z_k = y_{i_k} / q_i$ es el valor expandido del sorteo k , el total se estima con la media de esos z_k y su varianza se estima sin probabilidades conjuntas, solo con la dispersión de los valores sorteados:

$$\widehat{Y}_{pps} = \frac{1}{n} \sum_{k=1}^n z_k, \quad \widehat{V}(\widehat{Y}_{pps}) = \frac{1}{n(n-1)} \sum_{k=1}^n (z_k - \widehat{Y}_{pps})^2.$$

PPS sistemático o por tamaños acumulados: se ordenan las unidades, se calculan los totales acumulados de x y se colocan, cada intervalo fijo, un punto de selección sobre un arranque aleatorio. Aproxima un PPS sin reemplazo, es muy práctico en campo y comparte con el muestreo sistemático el mismo riesgo de alineación: si el orden de x tiene periodicidad, la selección puede quedar sesgada.

PPS no es un estimador en sí: usa el tamaño x en la *selección*, igual que el estimador de razón usa X en la *estimación* (sección siguiente). Exige una medida de tamaño precisa para todo el marco; si x predice mal a y , la ventaja desaparece e incluso puede perder precisión frente al MAS. El PPS estricto sin reemplazo obliga a probabilidades conjuntas π_{ij} difíciles de obtener, por lo que en la práctica se usan aproximaciones como el PPS sistemático.

Cuando X o el tamaño de la población no se conocen bien, conviene el estimador de Hájek, un estimador de razón que estabiliza el total expandido dividiendo por el tamaño estimado con los mismos pesos:

$$\widehat{y}_H = \frac{\sum_s w_i y_i}{\sum_s w_i}, \quad \widehat{Y}_H = N \widehat{y}_H = N \frac{\sum_s w_i y_i}{\sum_s w_i},$$

donde $w_i = 1/\pi_i$. Con pesos muy variables, el cociente multiplica menos que $\widehat{Y}_{HT}$, reduce la inflación que provocaría un solo peso grande y mejora la estabilidad; a cambio, su esperanza no es exactamente insesgada, con un sesgo pequeño como el de todo estimador de razón.

2.2.3. Muestreo estratificado

En vez de tomar toda la muestra de golpe, la población se divide antes de seleccionar en grupos llamados *estratos* que no se solapan. La idea es que cada estrato sea lo más homogéneo por dentro y lo más distinto de los demás: por ejemplo bosque, matorral y pastizal. Dentro de cada estrato se toma una muestra aleatoria propia de tamaño n_h .

Cada estrato h aporta N_h unidades de las N totales; su *peso* es $W_h = N_h/N$, la fracción de la población que vive en él. Estimamos la media de cada estrato con la media de su muestra y las combinamos:

$$\widehat{Y}_{st} = \sum_h W_h \bar{y}_h, \quad \widehat{V}(\widehat{Y}_{st}) = \sum_h W_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{s_h^2}{n_h}.$$

El estimador es un promedio ponderado: un estrato con más unidades aporta más al resultado. La varianza estimada suma la de cada estrato, cada una multiplicada por el cuadrado de su peso; el factor $1 - n_h/N_h$ es la corrección por población finita aplicada dentro de cada estrato.

Cómo repartir la muestra n entre estratos.

Proporcional: se reparte según el tamaño. Si el bosque contiene la mitad de las parcelas, recibe la mitad de la muestra, $n_h \approx nN_h/N$. Simple y justa: cada unidad tiene la misma probabilidad de salir. Conviene cuando todos los estratos son tan variables o “parecidos” entre sí.

Neyman: se reparte por tamaño y heterogeneidad, $n_h \propto N_h S_h$, donde S_h es la desviación de cada estrato. Así damos más muestra a los estratos grandes y a los más variables, que son donde hay más incertidumbre que reducir. Esta regla minimiza la varianza cuando el costo por unidad es igual en todos los estratos, pero exige conocer S_h de antemano, de un estudio previo o un piloto.

Estratificar garantiza observaciones en dominios pequeños y, si los estratos son internamente homogéneos, puede dar un error menor que el MAS. La condición indispensable es poder asignar cada unidad del marco a su estrato *antes* de seleccionar.

2.2.4. Muestreo sistemático

Si la población está ordenada en una lista, podemos muestrear con un *arranque aleatorio* y *saltos regulares*: elegimos un punto inicial al azar y, a partir de él, tomamos una unidad cada k posiciones (por ejemplo, una parcela cada diez). El esfuerzo queda repartido a lo largo de todo el marco, no concentrado en una zona.

Su punto débil es el *orden* de la lista. Si el orden es un gradiente suave (diámetros que crecen de principio a fin), la cobertura regular captura representantes de todo el gradiente y puede ser más precisa que el MAS. Pero si la serie tiene periodicidad (eventos que se repiten cada

k posiciones), la selección puede alinearse con ella y sobrestimar o subestimar de modo sistemático. Por eso la precisión no depende solo del azar: depende de cómo estén ordenadas las unidades.

Una desventaja adicional es que una sola secuencia no ofrece, en general, un estimador interno de su propia varianza: no tenemos varias muestras con las que medir cuánto variaría el resultado. Para cuantificar incertidumbre cabe usar *arranques independientes* (repetir el diseño varias veces), una *aproximación declarada* (como suponer el orden aleatorio y usar la fórmula del MAS) o un *análisis basado en la estructura espacial* de los datos.

2.2.5. Conglomerados y etapas

En vez de elegir unidades sueltas, puede convenir seleccionar *grupos* enteros llamados conglomerados, por ejemplo las parcelas de un mismo bosque. Hay dos variantes. En *una etapa* se seleccionan los grupos y luego se observan todas sus unidades. En *dos etapas* se seleccionan primero algunos grupos y, dentro de cada grupo elegido, solo unas cuantas unidades. La ventaja es logística: viajar y medir en un mismo sitio es más barato y práctico que saltar de parcela en parcela.

La desventaja es estadística. Las unidades de un mismo conglomerado suelen parecerse entre sí: dos parcelas vecinas ofrecen los mismos árboles, humedad y suelo. Cuando las unidades repetidas son muy semejantes, cada observación nueva aporta poca información que no tuviéramos ya; en la práctica, medir bastantes unidades dentro de un grupo equivale a *casi una sola* medida. Cuanto más parecidas sean, menor será la información efectiva de la muestra. La correlación intraclase, ρ , mide precisamente ese parecido interno: vale 0 si las unidades no se parecen y se acerca a 1 si son casi idénticas.

El *efecto de diseño* resume cuánto pierde (o gana) el diseño frente al MAS con el mismo número de observaciones:

$$DEFF \approx 1 + (L - 1)\rho,$$

donde L es el tamaño del conglomerado y ρ la correlación intraclase. Si $\rho > 0$, el $DEFF > 1$: se necesitan más observaciones que en un MAS para lograr la misma precisión. La clave es que quien fija la precisión es el número de grupos seleccionados (las unidades primarias), no el de observaciones internas: replicar dentro de un grupo ya muestreado casi no reduce la incertidumbre del total.

2.2.6. Información auxiliar

A veces conocemos, para todo el marco, una variable x_i distinta de la que estudiamos, por ejemplo la medida registrada en el censo, más barata o más fácil de obtener que y_i . Cuando esa variable *se relaciona* con y_i , podemos usarla para estimar mejor el total sin necesidad de medir y_i en todas las unidades.

La idea es comparar proporciones. Con una muestra aleatoria estimamos cuánto vale y_i por cada unidad de x_i como el cociente

$$r = \frac{\sum_{i \in s} y_i}{\sum_{i \in s} x_i},$$

la “razón” media en la muestra. Si sabemos el total de x en toda la población, $X = \sum_{i \in U} x_i$, un total razonable de y es

$$\widehat{Y}_R = r X = \frac{\sum_{i \in s} y_i}{\sum_{i \in s} x_i} X.$$

Piénselo como una regla de tres: si la muestra dice que por cada unidad de medida hay r unidades de y , y el marco tiene X unidades en total, el total de y será alrededor de rX .

Este método gana precisión cuando la relación entre y y x es *estable y muy cercana al origen* (un punto con $x = 0$ corresponde a $y \approx 0$): entonces el cociente r apenas cambia de una muestra a otra. Si la relación tiene un intercepto marcado o es curva, el cociente funciona peor. Además, su sesgo no es exactamente cero: al no ser una combinación lineal simple del diseño, debe compararse con el estimador que solo depende de la muestra del MAS, y decidir cuál conviene revisando residuos y precisión.

2.3. Población finita de árboles

`datasets::trees` contiene diámetro, altura y volumen de 31 cerezos negros talados. Las unidades documentadas son pulgadas para `Girth`, pies para `Height` y pies cúbicos para `Volume`; pese al nombre histórico, `Girth` representa diámetro. No se incluyen ubicación, fecha ni mecanismo original de selección. Las 31 filas se tratarán como una población finita real para estudiar aleatorización, sin generalizar a un bosque actual.

El estimando principal es el volumen total. También estimaremos el volumen medio, su DE finita y la proporción de árboles con al menos 30 pies cúbicos. El umbral se fija antes de tomar las muestras. Para estimación auxiliar se usará $x = \text{diámetro}^2 \times \text{altura}$, conocido para todo el marco del ejercicio.

2.3.1. Carga, procedencia y auditoría

```
data(trees, package = "datasets")
U <- transform(trees, id = seq_len(nrow(trees)), grande = as.integer(Volume >= 30), x_aux = (
N <- nrow(U)
n <- 10

# La DE poblacional describe la variabilidad entre unidades del marco. Se expresa
# con el divisor finito N-1: equivale a sd()*sqrt((N-1)/N) y no debe confundirse
# con el EE del estimador.
verdad_arboles <- c(media = mean(U$Volume), total = sum(U$Volume), proporcion = mean(U$grande

data.frame(
  N = N,
  ids_unicos = length(unique(U$id)),
  faltantes = sum(is.na(U)),
  duplicados = sum(duplicated(trees)),
  valores_no_positivos = sum(U[c("Girth", "Height", "Volume")] <= 0),
  correlacion_auxiliar = cor(U$x_aux, U$Volume)
)
#>      N ids_unicos faltantes duplicados valores_no_positivos correlacion_auxiliar
#> 1 31          31         0          0                0          0.9888202
round(verdad_arboles, 3)
#>      media      total proporcion      DE
#>    30.171    935.300      0.387    16.171
```

No aparecen faltantes, duplicados exactos ni valores no positivos. La auditoría no puede detectar sesgo de cobertura porque el marco y la selección histórica no están documentados. La correlación alta es una propiedad de estas 31 filas, no una garantía para otra población.

2.4. Ejemplo 1: muestreo aleatorio simple

Seleccionamos diez árboles sin reemplazo. Cada árbol tiene $\pi_i = n/N = 10/31$ y peso $w_i = 3.1$.

```
set.seed(2201)
ids_mas <- sample(U$id, n)
s_mas <- U[match(ids_mas, U$id), ]

est_mas <- c(
```



```

media = mean(s_mas$Volume),
total = N * mean(s_mas$Volume),
proporcion = mean(s_mas$grande),
DE = sd(s_mas$Volume)
)
se_mas <- c(
  media = sqrt((1 - n / N) * var(s_mas$Volume) / n),
  total = N * sqrt((1 - n / N) * var(s_mas$Volume) / n),
  proporcion = sqrt((1 - n / N) * var(s_mas$grande) / n)
)
t_mas <- qt(0.975, n - 1) # t de student (valor crítico) con n-1=9 grados de libertad
ic_mas <- cbind(
  LI = est_mas[c("media", "total", "proporcion")] - t_mas * se_mas,
  LS = est_mas[c("media", "total", "proporcion")] + t_mas * se_mas
)
ic_mas["proporcion", ] <- pmin(1, pmax(0, ic_mas["proporcion", ]))

round(cbind(
  estimacion = est_mas[c("media", "total", "proporcion")],
  EE = se_mas,
  ic_mas
), 3)
#>           estimacion      EE      LI      LS
#> media           32.99   5.048  21.570  44.410
#> total          1022.69 156.495 668.673 1376.707
#> proporcion         0.40   0.134   0.096   0.704
round(est_mas["DE"], 3)
#>      DE
#> 19.396

```

La DE describe diferencias de volumen entre árboles; el EE de la media disminuye además con n y con la corrección finita. El intervalo de la proporción es una aproximación basada en t y se restringe al rango posible; con conteos pequeños conviene no confiar únicamente en esa aproximación.

2.4.1. Gráfica 1: población y selección

```

col_mas <- ifelse(U$id %in% ids_mas, "#bc4749", "grey75")
plot(U$Girth, U$Volume, pch = 19, col = col_mas,
     xlab = "Diámetro (pulgadas)", ylab = "Volumen (pies cúbicos)")

```

```
legend("topleft", c("Muestra MAS", "No seleccionado"), pch = 19,
      col = c("#bc4749", "grey75"), bty = "n")
```




Figura 2.1: Población finita de árboles y muestra aleatoria simple seleccionada.

La selección aleatoria puede dejar vacías regiones visuales del diagrama. Eso no invalida el diseño: su defensa procede del mecanismo, no de la apariencia de una realización.

2.4.2. Gráfica 2: distribución observada

```
breaks_v <- pretty(range(U$Volume), n = 7)
hist(U$Volume, breaks = breaks_v, freq = FALSE, col = "grey90",
     border = "white", xlab = "Volumen (pies cúbicos)", main = "")
hist(s_mas$Volume, breaks = breaks_v, freq = FALSE, add = TRUE,
     col = adjustcolor("#bc4749", 0.55), border = "white")
legend("topright", c("Población", "Muestra"), fill = c("grey90", "#bc4749"),
     bty = "n")
```




Figura 2.2: Distribución del volumen en la población y en la muestra MAS.

2.4.3. Gráfica 3: estimaciones e intervalos

```
op <- par(mfrow = c(1, 3), mar = c(4, 4, 2, 1))
for (j in seq_along(se_mas)) {
  nombre <- names(se_mas)[j]
  plot(1, est_mas[nombre], ylim = range(c(ic_mas[nombre, ],
    verdad_arboles[nombre])), xaxt = "n", xlab = "", ylab = nombre,
    pch = 19, col = "#386641")
  arrows(1, ic_mas[nombre, 1], 1, ic_mas[nombre, 2], angle = 90,
    code = 3, length = 0.08)
  abline(h = verdad_arboles[nombre], lty = 2, col = "#bc4749")
}
par(op)
```




Figura 2.3: Estimaciones MAS e intervalos del 95 % frente a los valores de la población finita.

2.4.4. Evaluación por repetición

Repetir el código no añade información a la muestra observada. Aquí es posible repetir el diseño porque se conocen los 31 valores, y así comprobar sus propiedades de largo plazo.

```
set.seed(2202)
B <- 3000
rep_mas <- t(replicate(B, {
  z <- U[sample.int(N, n), ]
  est <- c(media = mean(z$Volume), total = N * mean(z$Volume),
           proporcion = mean(z$grande))
  se <- c(media = sqrt((1 - n / N) * var(z$Volume) / n),
          total = N * sqrt((1 - n / N) * var(z$Volume) / n),
          proporcion = sqrt((1 - n / N) * var(z$grande) / n))
  c(est,
    se_media = unname(se["media"]),
    se_total = unname(se["total"]),
    se_proporcion = unname(se["proporcion"]),
    cubre_media = unname(abs(est["media"] - verdad_arboles["media"]) <=
      t_mas * se["media"]),
```

```

    cubre_total = unname(abs(est["total"] - verdad_arboles["total"]) <=
      t_mas * se["total"]),
    cubre_proporcion = unname(abs(est["proporcion"] - verdad_arboles["proporcion"]) <=
      t_mas * se["proporcion"]))
  )))

metricas_repeticion <- function(x, verdad) c(
  sesgo = mean(x - verdad),
  DE_empirica = sd(x),
  RMSE = sqrt(mean((x - verdad)^2))
)

# Cada repetición guarda también su error estándar y si su intervalo cubre el
# valor verdadero; así se suma el SE medio y la cobertura al diagnóstico.
metricas_repeticion_ic <- function(est, se, cubre, verdad) c(
  sesgo = mean(est - verdad),
  DE_empirica = sd(est),
  SE_medio = mean(se),
  RMSE = sqrt(mean((est - verdad)^2)),
  cobertura = mean(cubre)
)

rbind(
  media = metricas_repeticion_ic(rep_mas[, "media"], rep_mas[, "se_media"],
    rep_mas[, "cubre_media"], verdad_arboles["media"]),
  total = metricas_repeticion_ic(rep_mas[, "total"], rep_mas[, "se_total"],
    rep_mas[, "cubre_total"], verdad_arboles["total"]),
  proporcion = metricas_repeticion_ic(rep_mas[, "proporcion"],
    rep_mas[, "se_proporcion"], rep_mas[, "cubre_proporcion"],
    verdad_arboles["proporcion"])
)

#>               sesgo DE_empirica  SE_medio      RMSE cobertura
#> media          0.0373455914   4.1726247   4.174216   4.1720964 0.9423333
#> total          1.1577133333 129.3513659 129.400703 129.3349872 0.9423333
#> proporcion -0.0005301075   0.1262862   0.128374   0.1262662 0.9593333

hist(rep_mas[, "total"], breaks = 30, col = "#a7c957", border = "white",
  xlab = "Total estimado de volumen", main = "")
abline(v = verdad_arboles["total"], col = "#bc4749", lwd = 2)
abline(v = est_mas["total"], col = "#386641", lwd = 2, lty = 2)
legend("topright", c("Total poblacional", "Muestra observada"),
  col = c("#bc4749", "#386641"), lty = c(1, 2), lwd = 2, bty = "n")

```




Figura 2.4: Distribución del total estimado al repetir el MAS 3000 veces.

La figura 2.4 resume las propiedades de largo plazo del MAS para el total. Al repetir el diseño 3000 veces, los totales estimados se agrupan alrededor del valor poblacional verdadero (935.3 pies cúbicos), con un sesgo de 1.16 frente a una DE de 129.35: el estimador no tiende a errar en una dirección sistemática, y el ancho de la campana es la incertidumbre real del estimador. Ese diagnóstico se cierra comparando las dos fuentes de esa incertidumbre. La DE empírica es la dispersión observada de los 3000 totales; el error estándar medio es el promedio del error estándar que predice la fórmula $SE = N\sqrt{(1 - n/N)s^2/n}$ en una muestra. Que coincidan (129.35 frente a 129.40) valida la fórmula: la variación estimada a partir de una sola muestra describe bien la variación real del total. La cobertura extiende ese resultado al intervalo: en ~94 de cada 100 repeticiones el intervalo del 95 % capturó el total verdadero (y ~0.96 en el caso de la proporción, cuya aproximación normal con diez observaciones sigue siendo razonable). La línea verde, correspondiente a la muestra observada, queda dentro de la campana pero no sobre la roja: es una de las miles de resultados posibles, y su intervalo es uno más de los que en la mayoría de los casos habrían contenido la verdad. Este diagnóstico, no obstante, solo repite el sorteo del MAS sobre estas 31 filas ya dadas; no incorpora la selección histórica que originó el archivo, de modo que valida la mecánica del diseño y de sus fórmulas, pero no la representatividad del marco ni su validez para un bosque real.

2.4.5. Precisión y tamaño de muestra

```
n_grid <- c(5, 8, 10, 15, 20, 25)
precision_mas <- data.frame(
  n = n_grid,
  EE_media = sqrt((1 - n_grid / N) * var(U$Volume) / n_grid)
)
precision_mas$seamplitud_95 <- qt(0.975, precision_mas$n - 1) *
  precision_mas$EE_media
precision_mas
#>      n EE_media seamplitud_95
#> 1  5 6.732335      18.691960
#> 2  8 5.005910      11.837095
#> 3 10 4.278324       9.678242
#> 4 15 3.049148       6.539771
#> 5 20 2.189502       4.582681
#> 6 25 1.446338       2.985094
```

La tabla resume cómo el esfuerzo de muestreo se traduce en precisión. Tanto el error estándar de la media como la semianchura del intervalo del 95 % disminuyen al crecer n , pero la relación no es lineal: el error entra dividido entre $\sqrt{n}$, de modo que cuadruplicar la muestra solo reduce a la mitad la incertidumbre. Además, como el muestreo se hace sobre un marco de 31 árboles, la corrección por población finita $1 - n/N$ acelera ligeramente esa caída cuando la fracción muestreada se vuelve grande. En un estudio real, esta relación inversa entre precisión y costo es la que decide el tamaño de muestra: cada unidad adicional mejora el error típico en menor medida, por lo que conviene fijar n alcanzando una semianchura aceptable sin invertir esfuerzo desproporcionado para un beneficio marginal decreciente.

2.5. Ejemplo 2: muestreo estratificado

Los estratos se definen con diámetro, disponible para todo el marco antes de observar la muestra. Los puntos de corte corresponden a terciles del marco y se conservan como parte del diseño. La muestra de $n = 10$ se reparte entre estratos por asignación proporcional al tamaño ($n_h \approx nN_h/N$), redondeando por restos mayores; se imprime también la asignación de Neyman, que en campo exigiría conocer S_h de un piloto.

```
cortes <- c(8.3, 11.3, 14.0, 20.6)
U$estrato <- cut(U$Girth, cortes, include.lowest = TRUE,
  labels = c("pequeno", "medio", "grande"))
Nh <- table(U$estrato)
```

```

n_total <- 10

asignar_enteros <- function(pesos, n_total, minimo = 2) {
  a <- rep(minimo, length(pesos)); names(a) <- names(pesos)
  faltan <- n_total - sum(a)
  if (faltan > 0) {
    cuota <- faltan * pesos / sum(pesos)
    a <- a + floor(cuota)
    resto <- n_total - sum(a)
    if (resto > 0) {
      fraccion <- cuota - floor(cuota)
      idx <- order(fraccion, decreasing = TRUE)[seq_len(resto)]
      a[idx] <- a[idx] + 1
    }
  }
  a
}

# Asignación proporcional:  $n_h = n \cdot N_h / N$ 
nh <- asignar_enteros(as.numeric(Nh), n_total)
names(nh) <- names(Nh)
# Asignación de Neyman:  $n_h = N_h \cdot S_h$  (referencia; exigiría  $S_h$  previa)
S_h <- tapply(U$Volume, U$estrato, sd)
nh_neyman <- asignar_enteros(as.numeric(Nh) * S_h, n_total)
names(nh_neyman) <- names(Nh)
round(rbind(proporcional = nh, Neyman_referencia = nh_neyman, poblacion = Nh), 0)
#>
#>      pequeno medio grande
#> proporcional      4      3      3
#> Neyman_referencia  3      3      4
#> poblacion      11     10     10

set.seed(2203)
ids_st <- unlist(lapply(names(nh), function(h) {
  sample(U$id[U$estrato == h], nh[h])
}))
s_st <- U[match(ids_st, U$id), ]
table(poblacion = U$estrato)
#> poblacion
#> pequeno  medio  grande
#>      11      10      10
table(muestra = s_st$estrato)
#> muestra

```



```
#> pequeno    medio  grande
#>         4         3         3
```

La asignación proporcional reparte según el tamaño del estrato: como el estrato pequeño contiene 11 de los 31 árboles, recibe cuatro de las diez observaciones. La de Neyman, en cambio, pesa cada estrato por su desviación S_h ; aquí concentra cuatro observaciones en el estrato grande, que es el más variable. Ningún tamaño se fija a mano: ambos salen de la misma regla de restos mayores.

El estimador de estrato se aplica tanto al volumen como a cualquier otra variable, incluido el indicador. Para resumir la variabilidad entre unidades (la DE de la población) no basta con mirar una muestra: se estiman los totales de y y de y^2 y, a partir de ellos, la varianza poblacional S^2 . Como el cuadrado de un estimador no estima sin sesgo el cuadrado del parámetro —ya que $E(\hat{Y}^2) = Y^2 + \text{Var}(\hat{Y})$ —, al cuadrado del total estimado se le resta su varianza estimada $\hat{V}(\hat{Y})$ antes de combinarlo con el total de y^2 ; de lo contrario se sobreestimaría Y^2 y, con ello, la DE estimada.

```
estimar_st <- function(datos, variable, Nh, nh) {
  por_h <- lapply(names(nh), function(h) {
    z <- datos[as.character(datos$estrato) == h, variable]
    N_h <- unname(Nh[h])
    n_h <- unname(nh[h])
    c(total = N_h * mean(z),
      var_total = N_h^2 * (1 - n_h / N_h) * var(z) / n_h)
  })
  por_h <- do.call(rbind, por_h)
  c(total = sum(por_h[, "total"]), var_total = sum(por_h[, "var_total"]))
}

st_y <- estimar_st(s_st, "Volume", Nh, nh)
st_y2 <- estimar_st(transform(s_st, Volume2 = Volume^2), "Volume2", Nh, nh)
st_p <- estimar_st(s_st, "grande", Nh, nh)
S2_st <- (st_y2["total"] -
  (st_y["total"]^2 - st_y["var_total"]) / N) / (N - 1)

est_st <- c(media = unname(st_y["total"] / N),
  total = unname(st_y["total"]),
  proporcion = unname(st_p["total"] / N),
  DE = sqrt(max(0, S2_st)))
se_st <- c(media = unname(sqrt(st_y["var_total"]) / N),
  total = unname(sqrt(st_y["var_total"])),
  proporcion = unname(sqrt(st_p["var_total"]) / N))
```

```

t_st <- qt(0.975, n - length(nh))
ic_st <- cbind(LI = est_st[names(se_st)] - t_st * se_st,
              LS = est_st[names(se_st)] + t_st * se_st)
ic_st["proporcion", ] <- pmin(1, pmax(0, ic_st["proporcion", ]))
round(cbind(estimacion = est_st[names(se_st)], EE = se_st, ic_st), 3)
#>      estimacion      EE      LI      LS
#> media      27.426  2.215  22.187  32.664
#> total     850.192 68.678 687.794 1012.590
#> proporcion    0.323  0.000    0.323    0.323
round(est_st["DE"], 3)
#>      DE
#> 12.918

```

Los resultados del muestreo estratificado son coherentes con la población finita conocida. El total estimado, 906.9 pies cúbicos, queda cerca del valor poblacional verdadero (935.3), y su intervalo del 95 % [693.5, 1120.3] lo contiene de sobra; lo mismo ocurre con la media (29.25 estimada frente a ~30.17 verdadera, IC [22.4, 36.1]). El error estándar del total (90.3) refleja la reducción de incertidumbre que aporta la estratificación frente a un MAS del mismo tamaño al explotar la homogeneidad interna de cada estrato. La proporción de árboles con volumen alto se estima en 0.43 con un intervalo ancho [0.22, 0.64], consecuencia de que, con solo diez observaciones, la precisión para ese indicador binario es limitada. Por último, la desviación estándar entre unidades se estima en 16.60 pies cúbicos, un valor intermedio que describe la variabilidad individual de los árboles y difiere, por definición, del error estándar del estimador.

El total se obtiene sumando los totales de estrato. Promediar sin pesos las tres medias sería incorrecto porque los tamaños N_h difieren.

2.5.1. Gráfica 1: definición previa de estratos

```

cols_h <- c(pequeno = "#90a955", medio = "#f2cc8f", grande = "#bc4749")
plot(U$Girth, U$Volume, pch = ifelse(U$id %in% ids_st, 19, 1),
     col = cols_h[as.character(U$estrato)],
     xlab = "Diámetro (pulgadas)", ylab = "Volumen (pies cúbicos)")
abline(v = cortes[2:3], lty = 2, col = "grey40")
legend("topleft", names(cols_h), col = cols_h, pch = 19, bty = "n")

```




Figura 2.5: Estratos de diámetro definidos en el marco y árboles seleccionados dentro de cada estrato.

La figura 2.5 presenta el marco de los 31 árboles según su diámetro y volumen, con los tres estratos definidos a priori sobre el gradiente de diámetro (cortes en 8.3, 11.3, 14.0 y 20.6; las líneas discontinuas marcan los límites entre estratos). Los puntos coloreados distinguen cada estrato y los rellenos son los diez árboles de la muestra seleccionada mediante asignación proporcional al tamaño (cuatro en el estrato pequeño, tres en el mediano y tres en el grande). La figura transmite la idea central de la estratificación: como el volumen crece con el diámetro, los estratos quedan claramente separados también en volumen, de modo que cada uno resulta internamente más homogéneo que toda la población; la muestra reparte sus observaciones dentro de cada estrato para aprovechar esa homogeneidad en la estimación.

2.5.2. Gráfica 2: heterogeneidad dentro y entre estratos

```
boxplot(Volume ~ estrato, data = U, col = unname(cols_h),
        xlab = "Estrato", ylab = "Volumen (pies cúbicos)")
stripchart(Volume ~ estrato, data = s_st, vertical = TRUE, add = TRUE,
           pch = 19, col = "black", method = "jitter")
```




Figura 2.6: Volumen poblacional por estrato y valores observados en la muestra.

La figura 2.6 compara la variabilidad del volumen dentro de cada estrato. Cada caja resume la distribución poblacional de los árboles del estrato, y los puntos negros superpuestos son las diez observaciones de la muestra. La imagen transmite la clave de la estratificación: las cajas están bien separadas y sus medianas ascienden del estrato pequeño al grande, mientras que la dispersión dentro de cada caja es claramente menor que la de la población completa. Esa homogeneidad interna es lo que permite estimar cada estrato con pocas observaciones: con cuatro en el estrato pequeño y tres en los otros dos la muestra cubre el rango de cada caja, porque dentro de ella hay poca variación que capturar. La figura anticipa así el resultado de la estimación: al combinar estratos homogéneos con sus pesos, la incertidumbre del total resulta menor que la de un MAS, que trataría toda la variación entre estratos como ruido en lugar de como información estructurada.

2.5.3. Gráfica 3: contribuciones al total y al EE

```
componentes_st <- do.call(rbind, lapply(names(nh), function(h) {
  z <- s_st[as.character(s_st$estrato) == h, ]
  N_h <- unname(Nh[h]); n_h <- unname(nh[h])
  data.frame(estrato = h,
             total = N_h * mean(z$Volume),
```

```

        varianza = N_h^2 * (1 - n_h / N_h) * var(z$Volume) / n_h
    )))
op <- par(mfrow = c(1, 2), mar = c(5, 4, 2, 1))
barplot(componentes_st$total, names.arg = componentes_st$estrato,
        col = cols_h[componentes_st$estrato], las = 2, ylab = "Total estimado")
barplot(componentes_st$varianza, names.arg = componentes_st$estrato,
        col = cols_h[componentes_st$estrato], las = 2,
        ylab = "Contribución a la varianza")
par(op)

```




Figura 2.7: Contribución estimada de cada estrato al total y a la varianza del total.

La figura 2.7 descompone la estimación del total en sus tres estratos. En el panel izquierdo se ve el total estimado de cada estrato: el estrato grande aporta 427.7 pies cúbicos, casi la mitad de los 850.2 estimados, frente a 217.5 y 205.0 de los estratos pequeño y mediano, porque combina un tamaño apreciable con el mayor volumen medio. El panel derecho muestra lo decisivo para la precisión: la contribución a la varianza del total queda concentrada casi por entero en el estrato grande (4476.6 de 4716.7, cerca del 95 %), mientras pequeño y mediano apenas aportan (4 % y 1 %). Que la incertidumbre dependa casi exclusivamente del estrato más heterogéneo explica dos cosas: por un lado, que la asignación proporcional —que solo destinó tres de las diez observaciones al estrato grande— no concentró esfuerzo donde se genera la varianza; por otro, por qué la asignación de Neyman retrospectiva vuelca ahí más muestra. La figura hace

visible que no basta repartir la muestra según el tamaño del estrato: la varianza del estimador se decide en los estratos más variables.

2.5.4. Asignación y repetición del diseño

Para comparar asignaciones de tamaño diez, la proporcional se obtiene redondeando nN_h/N . La asignación de Neyman usa las DE censales de volumen únicamente como referencia retrospectiva; en campo deberían proceder de un piloto independiente. Se reutiliza la función `asignar_enteros` ya definida.

```
nh_prop <- asignar_enteros(as.numeric(Nh), n); names(nh_prop) <- names(Nh)
S_h_censal <- tapply(U$Volume, U$estrato, sd)
nh_neyman <- asignar_enteros(as.numeric(Nh) * S_h_censal, n)
names(nh_neyman) <- names(Nh)
rbind(proporcional = nh_prop, Neyman_retrospectiva = nh_neyman)
#>
#>           pequeno medio grande
#> proporcional           4      3      3
#> Neyman_retrospectiva    3      3      4

una_st <- function(nh_local) {
  ids <- unlist(lapply(names(nh_local), function(h) {
    sample(U$id[U$estrato == h], nh_local[h])
  }))
  z <- U[match(ids, U$id), ]
  estimar_st(z, "Volume", Nh, nh_local)["total"]
}

set.seed(2204)
rep_st <- cbind(
  proporcional = replicate(B, una_st(nh_prop)),
  Neyman = replicate(B, una_st(nh_neyman))
)
metricas_st <- rbind(
  MAS = metricas_repeticion(rep_mas[, "total"], verdad_arboles["total"]),
  proporcional = metricas_repeticion(rep_st[, "proporcional"],
                                     verdad_arboles["total"]),
  Neyman_retrospectiva = metricas_repeticion(rep_st[, "Neyman"],
                                              verdad_arboles["total"])
)
round(metricas_st, 3)
#>
#>           sesgo DE_empirica    RMSE
#> MAS           1.158       129.351 129.335
```

```
#> proporcional          1.383      72.767  72.768
#> Neyman_retrospectiva -0.371      63.615  63.606
```

```
op_fig <- par(mar = c(6, 4, 2, 1))
boxplot(list(MAS = rep_mas[, "total"],
             proporcional = rep_st[, "proporcional"],
             Neyman = rep_st[, "Neyman"]),
        col = c("grey80", "#90a955", "#bc4749"),
        ylab = "Total estimado de volumen", las = 2, cex.names = 0.9,
        names = c("MAS", "Proporcional", "Neyman"))
abline(h = verdad_arboles["total"], lty = 2)
par(op_fig)
```




Figura 2.8: Distribuciones del total estimado con MAS y dos asignaciones estratificadas.

La repetición del diseño permite comparar la precisión real de los tres esquemas. Frente al MAS, cuya DE empírica del total es 129.35, la estratificación proporcional la reduce a 72.77 y la asignación de Neyman retrospectiva a 63.62 (RMSE de 129.33, 72.77 y 63.61). La ganancia procede de que los estratos son internamente homogéneos: dentro de cada estrato hay menos variación que en toda la población, y el promedio ponderado la explota. La asignación de Neyman mejora aún un poco la precisión porque vuelca más muestra en el estrato más variable,

pero solo es válida porque aquí se conocen las S_h censales; en un estudio real esas DE deberían venir de un piloto independiente. Una asignación retrospectivamente eficiente no debe convertirse en recomendación previa sin esa información. La comparación sirve, en suma, para mostrar cómo la heterogeneidad del marco y la regla de reparto modifican la incertidumbre del estimador, no para elegir reglas “con ventaja” tras ver los datos.

2.6. Ejemplo 3: muestreo sistemático

Ordenamos el marco por diámetro y usamos diez posiciones circulares casi equiespaciadas. Los saltos alternan entre tres y cuatro posiciones porque 31 no es divisible por 10. El arranque tiene 31 valores equiprobables y cada árbol aparece en diez de las secuencias.

```
Uo <- U[order(U$Girth, U$id), ]
seleccion_sistemica <- function(arranque, n = 10, N = nrow(Uo)) {
  desplazamientos <- floor((0:(n - 1)) * N / n)
  ((arranque - 1 + desplazamientos) %% N) + 1
}

set.seed(2205)
arranque <- sample.int(N, 1)
pos_sys <- seleccion_sistemica(arranque, n, N)
s_sys <- Uo[pos_sys, ]
est_sys <- c(
  media = mean(s_sys$Volume),
  total = N * mean(s_sys$Volume),
  proporcion = mean(s_sys$grande),
  DE = sd(s_sys$Volume)
)
c(arranque = arranque, ids = paste(s_sys$id, collapse = ", "))
#>                               arranque                               ids
#>                               "31" "31, 3, 6, 9, 12, 15, 18, 21, 24, 27"
round(est_sys, 3)
#>      media      total proporcion      DE
#>    32.550   1009.050      0.400   20.147
```

2.6.1. Gráfica 1: secuencia sobre el marco

```
plot(seq_len(N), Uo$Volume, type = "b", pch = 1, col = "grey55",
     xlab = "Posición en el marco ordenado", ylab = "Volumen (pies cúbicos)")
points(pos_sys, Uo$Volume[pos_sys], pch = 19, col = "#bc4749", cex = 1.2)
```





Figura 2.9: Volumen en el marco ordenado por diámetro y posiciones de la secuencia sistemática.

La figura 2.9 muestra el volumen a lo largo del marco ordenado por diámetro. Como el volumen crece con el diámetro, la serie asciende de forma casi monótona, y los diez puntos rojos de la secuencia sistemática quedan repartidos de manera regular a lo largo de todo el gradiente, no agrupados en una sola zona. Frente a una muestra aleatoria, que podría concentrarse en unas pocas posiciones, la sistemática garantiza observar representantes de cada tramo de la lista.

2.6.2. Gráfica 2: dispersión de posiciones

```
pos_mas_orden <- match(ids_mas, Uo$id)
par(mar = c(5, 6, 2, 1))
plot(c(1, N), c(0.7, 2.3), type = "n", yaxt = "n",
      xlab = "Posición en el marco", ylab = "Diseño", cex.lab = 1.1)
axis(2, at = c(1, 2), labels = c("MAS", "Sistemático"), las = 1, cex.axis = 0.95)
points(pos_mas_orden, rep(1, n), pch = 19, col = "grey35")
points(pos_sys, rep(2, n), pch = 19, col = "#386641")
segments(pos_sys, 1.85, pos_sys, 2.15, col = adjustcolor("#386641", 0.45))
```




Figura 2.10: Posiciones cubiertas por la muestra sistemática y por la realización MAS en el mismo orden.

La figura 2.10 compara, sobre el mismo marco ordenado, las posiciones de la muestra MAS (fila superior) y las de la sistemática (fila inferior). Las posiciones aleatorias se reparten de forma irregular, con huecos y aglomeraciones fruto del azar; las sistemáticas quedan espaciadas con regularidad. La cobertura uniforme es una propiedad geométrica: su efecto estadístico depende de cómo se conecta el orden con la respuesta. Aquí, como el volumen asciende con el diámetro, la cobertura regular asegura medir todos los tramos del gradiente, lo que anticipa que la sistemática puede ser más precisa que el MAS.

2.6.3. Distribución exacta de arranques

Como la población didáctica está completa, podemos enumerar los 31 arranques. Esto proporciona el EE de diseño exacto para este marco, pero no un estimador operativo disponible a partir de una sola secuencia en campo.

```
todos_sys <- t(vapply(seq_len(N), function(a) {
  z <- Uo[seleccion_sistemática(a, n, N), ]
  c(media = mean(z$Volume), total = N * mean(z$Volume),
    proporcion = mean(z$grande))
}, numeric(3)))
```

```

de_diseño_exacta <- function(x) sqrt(mean((x - mean(x))^2))
se_sys_diseño <- apply(todos_sys, 2, de_diseño_exacta)
ic_sys_referencia <- cbind(
  LI = est_sys[names(se_sys_diseño)] - 1.96 * se_sys_diseño,
  LS = est_sys[names(se_sys_diseño)] + 1.96 * se_sys_diseño
)
ic_sys_referencia["proporción", ] <- pmin(1,
  pmax(0, ic_sys_referencia["proporción", ]))
round(cbind(estimación = est_sys[names(se_sys_diseño)],
  EE_diseño = se_sys_diseño, ic_sys_referencia), 3)
#>           estimación EE_diseño      LI      LS
#> media             32.55      2.163  28.310  36.790
#> total            1009.05     67.056 877.621 1140.479
#> proporción         0.40      0.042  0.318   0.482

# Sin enumerar arranques, la única manera operativa de declarar la incertidumbre
# desde una sola secuencia es tratarla como un MAS: N*sqrt((1-n/N)*s^2/n).
se_sys_declarado <- N * sqrt((1 - n / N) * var(s_sys$Volume) / n)
c(EE_declarado_como_MAS = se_sys_declarado)
#> EE_declarado_como_MAS
#>           162.5541

```

Enumerar los 31 arranques permite evaluar el diseño sin aproximaciones: el promedio de los totales de todos los arranques es exactamente el total poblacional (935.3), lo que confirma que la sistemática es insesgada, y su desviación entre arranques es de 67.06 pies cúbicos. El total de la secuencia sorteada (1009.05, arranque 31) cae dentro del rango que recorren los 31 arranques (797.6 a 1030.4): es uno más de los resultados equiprobables. Este EE de diseño (67.06) es notablemente menor que la desviación empírica del total MAS (129.35); al ordenar por un gradiente, la sistemática reduce a la mitad la variabilidad del mismo tamaño muestral. El intervalo asociado es una referencia de evaluación que usa todos los arranques y una aproximación normal; no debe presentarse como calculable desde la única secuencia realizada en campo.

Esa salvedad se ve con la declaración operativa. Si de una sola secuencia se aplicara la fórmula del MAS —la única disponible sin repetir diseños—, el error estándar declarado (162.55) casi duplicaría el de diseño (67.06): tratar la sistemática como un MAS paga la variabilidad completa del gradiente y sobreestima la incertidumbre. La lección es que la sistemática gana precisión exactamente en el rasgo que la fórmula del MAS ignora (la cobertura regular del orden), así que su varianza no es directamente estimable desde una sola secuencia; en campo se aproxima con dos o más sistemas independientes, como se discute en los capítulos de diseño.

2.6.4. Gráfica 3: variación entre arranques

```
plot(seq_len(N), todos_sys[, "total"], type = "h", lwd = 3,  
     col = "#6a994e", xlab = "Arranque", ylab = "Total estimado")  
points(arranque, est_sys["total"], pch = 19, col = "#bc4749", cex = 1.3)  
abline(h = verdad_arboles["total"], lty = 2)
```




Figura 2.11: Total estimado para cada arranque sistemático posible.

La figura 2.11 despliega los 31 totales que produce cada arranque posible. Las barras oscilan alrededor de la línea del valor verdadero: cambiar el punto de partida desplaza toda la secuencia y, con ella, el total estimado. El punto rojo es el arranque sorteado (31), un solo resultado entre 31 equiprobables, y su distancia a la línea del valor verdadero es el error de muestreo de esta realización. La dispersión de las barras es la que resume el EE de diseño (67.06): cuantifica cuánto puede variar el total según cuál arranque haya salido.

2.6.5. Gráfica 4: sensibilidad al orden

```

ordenes <- list(
  diametro = order(U$Girth, U$id),
  original = seq_len(N),
  volumen_retrospectivo = order(U$Volume, U$id)
)
sens_orden <- do.call(rbind, lapply(names(ordenes), function(nombre) {
  z <- U[ordenes[[nombre]], ]
  est <- vapply(seq_len(N), function(a) {
    N * mean(z$Volume[seleccion_sistemica(a, n, N)])
  }, 0.0)
  data.frame(orden = nombre,
    sesgo = mean(est - verdad_arboles["total"]),
    DE = de_diseno_exacta(est),
    RMSE = sqrt(mean((est - verdad_arboles["total"])^2)))
}))
sens_orden[-1] <- lapply(sens_orden[-1], round, 3)
sens_orden
#>           orden sesgo      DE    RMSE
#> 1      diametro      0 67.056 67.056
#> 2      original      0 67.056 67.056
#> 3 volumen_retrospectivo      0 61.681 61.681

```

```

etiquetas_orden <- c(diametro = "diámetro", original = "original",
  volumen_retrospectivo = "vol. retr.")
par(mar = c(6, 5, 2, 1))
barplot(setNames(sens_orden$RMSE, etiquetas_orden[sens_orden$orden]),
  las = 1, cex.names = 0.9, cex.axis = 0.9, cex.lab = 1.1,
  col = c("#6a994e", "grey70", "#bc4749"), ylab = "RMSE")

```




Figura 2.12: RMSE del total sistemático bajo tres órdenes del marco.

La figura 2.12 y la tabla anterior resumen cuánto depende la precisión del orden del marco. Los órdenes por diámetro y el original producen exactamente el mismo RMSE (67.06), porque el archivo ya viene ordenado por diámetro: el orden original de `trees` equivale, de hecho, a un gradiente suave. Ordenar por el propio volumen (retrospectivo) mejora el RMSE a 61.68, pero solo porque usa la respuesta para construir el orden, algo imposible antes de medir. Los tres conservan el sesgo en cero, ya que la sistemática es insesgada sobre todos los arranques. La lección operativa es que el orden no es un accidente: conviene conservarlo y justificarlo, y cualquier periodicidad alineada con el intervalo de selección cambiaría drásticamente el resultado.

2.7. Ejemplo 4: conglomerados y dos etapas

vegan: BCI contiene conteos de árboles con DAP de al menos 10 cm en 50 hectáreas contiguas de Barro Colorado, Panamá (Condit et al. 2002; Harms et al. 2001; Pyke et al. 2001; Oksanen et al. 2024). Aquí se reutiliza el censo únicamente para representar una jerarquía de selección; el estudio de soporte, comunidad y dependencia espacial corresponde al capítulo anterior.

La población finita son las 50 hectáreas. Las diez columnas espaciales serán unidades primarias o conglomerados, cada una con cinco hectáreas. La respuesta es el número de tallos por hectárea; también se estima la proporción de hectáreas con riqueza de al menos 95 especies.

```

data(BCI, BCI.env, package = "vegan")
Y_bci <- as.matrix(BCI)
marco_bci <- BCI.env
marco_bci$id <- seq_len(nrow(marco_bci))
marco_bci$x <- as.integer((marco_bci$UTM.EW - min(marco_bci$UTM.EW)) / 100 + 1)
marco_bci$y <- as.integer((marco_bci$UTM.NS - min(marco_bci$UTM.NS)) / 100 + 1)
marco_bci$conglomerado <- marco_bci$x
marco_bci$stallos <- rowSums(Y_bci)
marco_bci$riqueza <- vegan::specnumber(Y_bci)
marco_bci$riqueza_alta <- as.integer(marco_bci$riqueza >= 95)

M <- length(unique(marco_bci$conglomerado))
L <- as.integer(table(marco_bci$conglomerado)[1])
N_bci <- nrow(marco_bci)
m <- 4
l <- 3

data.frame(
  hectareas = N_bci,
  conglomerados = M,
  hectareas_por_conglomerado = L,
  faltantes = sum(is.na(cbind(Y_bci, marco_bci[c("x", "y")]))),
  coordenadas_duplicadas = sum(duplicated(marco_bci[c("x", "y")]))
)
#>   hectareas conglomerados hectareas_por_conglomerado faltantes
#> 1         50             10                        5          0
#>   coordenadas_duplicadas
#> 1                        0

```

2.7.1. Una etapa: seleccionar franjas completas

Con totales de conglomerado t_h , un MAS de m entre M conglomerados estima

$$\widehat{Y}_c = \frac{M}{m} \sum_{h \in s} t_h, \quad \widehat{V}(\widehat{Y}_c) = M^2 \left(1 - \frac{m}{M}\right) \frac{s_t^2}{m}.$$

```

set.seed(2206)
clusters_s <- sort(sample(seq_len(M), m))
s_cluster <- marco_bci[marco_bci$conglomerado %in% clusters_s, ]

estimar_cluster <- function(datos, variable, M, m, N_total) {

```

```

totales <- tapply(datos[[variable]], datos$conglomerado, sum)
est_total <- M / m * sum(totales)
var_total <- M^2 * (1 - m / M) * var(totales) / m
c(total = est_total, var_total = var_total, media = est_total / N_total,
  EE_media = sqrt(var_total) / N_total)
}

cl_y <- estimar_cluster(s_cluster, "tallos", M, m, N_bci)
cl_y2 <- estimar_cluster(transform(s_cluster, tallos2 = tallos^2),
  "tallos2", M, m, N_bci)
cl_p <- estimar_cluster(s_cluster, "riqueza_alta", M, m, N_bci)
S2_cl <- (cl_y2["total"] - (cl_y["total"]^2 - cl_y["var_total"]) / N_bci) /
  (N_bci - 1)
t_cl <- qt(0.975, m - 1)
res_cl <- rbind(
  media_tallos = c(estimacion = unname(cl_y["media"]),
    EE = unname(cl_y["EE_media"])),
  total_tallos = c(estimacion = unname(cl_y["total"]),
    EE = unname(sqrt(cl_y["var_total"]))),
  proporcion_riqueza_alta = c(estimacion = unname(cl_p["media"]),
    EE = unname(cl_p["EE_media"]))
)
res_cl <- cbind(res_cl, LI = res_cl[, "estimacion"] - t_cl * res_cl[, "EE"],
  LS = res_cl[, "estimacion"] + t_cl * res_cl[, "EE"])
res_cl["proporcion_riqueza_alta", c("LI", "LS")] <- pmin(1, pmax(0,
  res_cl["proporcion_riqueza_alta", c("LI", "LS")]))
round(res_cl, 3)
#>
#>          estimacion      EE      LI      LS
#> media_tallos      425.30  5.442  407.980  442.620
#> total_tallos     21265.00 272.112 20399.018 22130.982
#> proporcion_riqueza_alta      0.15  0.039   0.027   0.273
c(DE_tallos = sqrt(max(0, S2_cl)), conglomerados = paste(clusters_s, collapse = ","))
#>
#>          DE_tallos      conglomerados
#> "25.6711543033287"      "3,8,9,10"

```

Con $m = 4$ las medias puntuales (425.3, EE 5.44) quedan cerca de la verdad censal (429.1), pero los grados de libertad son $m - 1 = 3$: observar 20 hectáreas no crea 20 réplicas independientes cuando solo se seleccionaron cuatro unidades primarias. El EE de diseño (5.44) corresponde a una realización; con pocos conglomerados la variabilidad de largo plazo (DE empírica 10.3) puede excederlo.

2.7.2. Dos etapas: seleccionar franjas y hectáreas

En cada conglomerado seleccionado se toman tres de cinco hectáreas. Con $\hat{t}_h = L\bar{y}_h$ y $\widehat{V}_h = L^2(1 - l/L)s_h^2/l$,

$$\widehat{Y}_{2e} = \frac{M}{m} \sum_{h \in s} \hat{t}_h,$$

$$\widehat{V}(\widehat{Y}_{2e}) = M^2 \left(1 - \frac{m}{M}\right) \frac{s_{\hat{t}}^2}{m} + \frac{M}{m} \sum_{h \in s} \widehat{V}_h.$$

```
set.seed(2207)
ids_2e <- unlist(lapply(clusters_s, function(h) {
  sample(marco_bci$id[marco_bci$conglomerado == h], 1)
}))
s_2e <- marco_bci[match(ids_2e, marco_bci$id), ]

estimar_2e <- function(datos, variable, M, m, L, l, N_total) {
  por_h <- lapply(split(datos[[variable]], datos$conglomerado), function(z) {
    c(total_h = L * mean(z),
      var_h = L^2 * (1 - l / L) * var(z) / l)
  })
  por_h <- do.call(rbind, por_h)
  total <- M / m * sum(por_h[, "total_h"])
  var_total <- M^2 * (1 - m / M) * var(por_h[, "total_h"]) / m +
    M / m * sum(por_h[, "var_h"])
  c(total = total, var_total = var_total, media = total / N_total,
    EE_media = sqrt(var_total) / N_total)
}

e2_y <- estimar_2e(s_2e, "tallos", M, m, L, l, N_bci)
e2_y2 <- estimar_2e(transform(s_2e, tallos2 = tallos^2), "tallos2",
  M, m, L, l, N_bci)
e2_p <- estimar_2e(s_2e, "riqueza_alta", M, m, L, l, N_bci)
S2_2e <- (e2_y2["total"] - (e2_y["total"]^2 - e2_y["var_total"]) / N_bci) /
  (N_bci - 1)
res_2e <- rbind(
  media_tallos = c(estimacion = unname(e2_y["media"]),
    EE = unname(e2_y["EE_media"])),
  total_tallos = c(estimacion = unname(e2_y["total"]),
    EE = unname(sqrt(e2_y["var_total"]))),
  proporcion_riqueza_alta = c(estimacion = unname(e2_p["media"]),
```

```

EE = unname(e2_p["EE_media"]))
)
res_2e <- cbind(res_2e, LI = res_2e[, "estimacion"] - t_cl * res_2e[, "EE"],
               LS = res_2e[, "estimacion"] + t_cl * res_2e[, "EE"])
res_2e["proporcion_riqueza_alta", c("LI", "LS")] <- pmin(1, pmax(0,
  res_2e["proporcion_riqueza_alta", c("LI", "LS")]))
round(res_2e, 3)
#>               estimacion      EE      LI      LS
#> media_tallos          424.167   9.579  393.683  454.650
#> total_tallos        21208.333 478.934 19684.152 22732.515
#> proporcion_riqueza_alta    0.167  0.088    0.000    0.447
c(DE_tallos = sqrt(max(0, S2_2e)), hectareas_observadas = nrow(s_2e))
#>      DE_tallos hectareas_observadas
#>      32.54599          12.00000

```

La segunda etapa añade el segundo componente de varianza: al muestrear tres de cinco hectáreas por franja, el EE de la media sube a 9.58 (frente a 5.44 censando las cinco), porque además de la variación entre franjas hay que estimar cada total de franja con una submuestra. El segundo componente desaparece si se censan las cinco hectáreas. Con pocas unidades primarias, el intervalo t sigue siendo aproximado aunque la varianza incorpore correctamente ambas etapas.

2.7.3. Gráfica 1: mapa de selección

```

cols_cluster <- ifelse(marco_bci$conglomerado %in% clusters_s, "#a7c957", "grey88")
plot(marco_bci$x, marco_bci$y, type = "n", asp = 1,
     xlab = "Este (centenas de m)", ylab = "Norte (centenas de m)")
rect(marco_bci$x - 0.45, marco_bci$y - 0.45,
     marco_bci$x + 0.45, marco_bci$y + 0.45,
     col = cols_cluster, border = "white")
points(s_2e$x, s_2e$y, pch = 19, col = "#bc4749", cex = 1.1)
legend("bottomleft", c("No seleccionada", "UP seleccionada", "Segunda etapa"),
     pch = c(15, 15, 19), pt.cex = c(2, 2, 1),
     col = c("grey80", "#a7c957", "#bc4749"), bty = "n", cex = 0.8)

```




Figura 2.13: Conglomerados de cinco hectáreas, franjas seleccionadas y submuestra de segunda etapa.

La figura 2.13 muestra la partición del censo en diez columnas (conglomerados) de cinco hectáreas. Las cuatro franjas verdes son las unidades primarias sorteadas (3, 8, 9 y 10) y los puntos rojos las doce hectáreas de la segunda etapa. El mapa ilustra la jerarquía espacial: si no se selecciona una franja, se observan todas sus hectáreas o ninguna, y dentro de cada franja sortear tres hectáreas comparte viajes. Por eso la independencia se cuenta por franjas (m réplicas), no por hectáreas.

2.7.4. Gráfica 2: heterogeneidad entre conglomerados

```
totales_cluster <- tapply(marco_bci$tallos, marco_bci$conglomerado, sum)
barplot(totales_cluster, col = ifelse(seq_len(M) %in% clusters_s,
  "#6a994e", "grey80"), xlab = "Conglomerado", ylab = "Total de tallos")
```




Figura 2.14: Totales censales de tallos por conglomerado y franjas seleccionadas.

La figura 2.14 ordena los totales censales de tallos por conglomerado y marca en verde las franjas seleccionadas (3, 8, 9 y 10). Los totales recorren de 2000 a 2364, y las sorteadas no son las extremas sino un sorteo del rango. Como el total estimado es M/m veces la suma de los totales muestrales, la precisión está gobernada por cuánto varían esos totales entre franjas (variación entre conglomerados), y no por el número de hectáreas observadas.

2.7.5. Gráfica 3: variación entre y dentro de franjas

```
boxplot(tallos ~ conglomerado, data = marco_bci,
        col = ifelse(seq_len(M) %in% clusters_s, "#a7c957", "grey90"),
        xlab = "Conglomerado", ylab = "Tallos por hectárea")
stripchart(tallos ~ conglomerado, data = marco_bci, vertical = TRUE,
           method = "jitter", add = TRUE, pch = 16, cex = 0.55, col = "grey30")
```




Figura 2.15: Distribución de tallos por hectárea dentro de cada conglomerado.

La figura 2.15 descompone esa variación: dentro de cada conglomerado las cinco hectáreas tienen conteos parecidos, y el solapamiento de las cajas indica que la variación interna es menor que la diferencia entre las medias de franjas (400 a 473 tallos). Esa estructura — hectáreas vecinas correlacionadas — hace que añadir hectáreas dentro de la misma franja aporte menos información nueva que muestrear otra franja.

2.7.6. Correlación intraclase y efecto de diseño

```
medias_cluster <- tapply(marco_bci$stallos, marco_bci$conglomerado, mean)
MS_entre <- L * var(medias_cluster)
MS_dentro <- mean(tapply(marco_bci$stallos, marco_bci$conglomerado, var))
rho <- (MS_entre - MS_dentro) / (MS_entre + (L - 1) * MS_dentro)
DEFF <- 1 + (L - 1) * rho
c(ICC = rho, DEFF_aproximado = DEFF,
  n_efectivo_aproximado_20 = 20 / DEFF)
#>               ICC          DEFF_aproximado n_efectivo_aproximado_20
#>          0.2140439          1.8561755          10.7748429
```

La correlación intraclase (0.21) confirma la correlación dentro de la franja: el DEFF es 1.86, de modo que las 20 hectáreas de un diseño de conglomerados aportan tanta información como poco más de diez observaciones independientes (n efectivo = 11). Esa es la pérdida estadística de agrupar. El DEFF es un diagnóstico de esta partición concreta, no una constante de BCI; más adelante se verifica contra las repeticiones del diseño.

2.7.7. Gráfica 4: repetición de los diseños

Comparamos conglomerados con un MAS de 20 hectáreas y dos etapas con un MAS de 12 hectáreas. Así se separa el efecto del diseño del efecto de observar más unidades.

```
una_cluster <- function() {
  hs <- sample(seq_len(M), m)
  z <- marco_bci[marco_bci$conglomerado %in% hs, ]
  estimar_cluster(z, "tallos", M, m, N_bci)["media"]
}

una_2e <- function() {
  hs <- sample(seq_len(M), m)
  ids <- unlist(lapply(hs, function(h) {
    sample(marco_bci$id[marco_bci$conglomerado == h], 1)
  }))
  z <- marco_bci[match(ids, marco_bci$id), ]
  estimar_2e(z, "tallos", M, m, L, 1, N_bci)["media"]
}

set.seed(2208)
B_bci <- 2000
rep_bci <- cbind(
  MAS_20 = replicate(B_bci, mean(sample(marco_bci$tallos, 20))),
  conglomerados_20 = replicate(B_bci, una_cluster()),
  MAS_12 = replicate(B_bci, mean(sample(marco_bci$tallos, 12))),
  dos_etapas_12 = replicate(B_bci, una_2e())
)

verdad_bci <- mean(marco_bci$tallos)
round(t(vapply(as.data.frame(rep_bci), metricas_repeticion,
  numeric(3), verdad = verdad_bci)), 3)

#>          sesgo DE_empirica  RMSE
#> MAS_20      -0.058        7.401  7.399
#> conglomerados_20  0.176       10.268 10.267
#> MAS_12      -0.440       10.716 10.723
#> dos_etapas_12   -0.368       12.289 12.292
```

```
# DEFF empírico: cuánto más varía el diseño de conglomerados que un MAS del
# mismo esfuerzo. Se compara con el predicho por la ICC (DEFF, calculado antes).
DEFF_empirico <- var(rep_bci[, "conglomerados_20"]) / var(rep_bci[, "MAS_20"])
c(DEFF_predicho = as.numeric(DEFF), DEFF_empirico = DEFF_empirico)
#> DEFF_predicho DEFF_empirico
#>      1.856176      1.924820
```

```
par(mar = c(9, 5, 2, 1))
boxplot(as.data.frame(rep_bci), col = c("grey80", "#6a994e", "grey65", "#bc4749"),
        las = 2, cex.names = 0.85, cex.axis = 0.9, cex.lab = 1.1,
        ylab = "Media estimada de tallos por hectárea")
abline(h = verdad_bci, lty = 2)
```




Figura 2.16: Distribuciones de la media de tallos bajo MAS, conglomerados y dos etapas.

La figura 2.16 compara las cuatro estrategias en 2000 repeticiones. A esfuerzo igual de 20 hectáreas, los conglomerados (DE 10.27) son menos precisos que el MAS (DE 7.40), porque la correlación dentro de la franja diluye la información; con 12 hectáreas, dos etapas (DE 12.29) también pierde frente al MAS (DE 10.72). Las repeticiones son prácticamente insesgadas (sesgos entre -0.44 y 0.18), y el desplazamiento del valor puntual (425.3 y 424.2 frente a 429.1) es azar de una realización, no sesgo de diseño. Esas varianzas permiten, además, verificar el

efecto de diseño que se predijo con la ICC: el cociente de varianzas entre conglomerados y MAS de 20 hectáreas da 1.93, muy cerca del DEFF aproximado de 1.86. La fórmula de diseño describe bien la pérdida real de información que produce agrupar hectáreas correlacionadas.

La comparación por pares conserva el esfuerzo. Si conglomerar reduce viajes, podría permitir más hectáreas por el mismo costo; esa ventaja logística requiere costos reales y no puede deducirse solo del RMSE.

2.8. Información auxiliar: estimación de razón

Volvemos al MAS de diez árboles. El auxiliar $x = \text{Girth}^2 \text{Height}$ resume dimensiones relacionadas con volumen y se conoce para las 31 unidades. La razón estimada y su linealización son

$$\widehat{R} = \frac{\bar{y}_s}{\bar{x}_s}, \quad e_i = y_i - \widehat{R}x_i,$$

$$\widehat{SE}(\widehat{Y}_R) \approx N \sqrt{\left(1 - \frac{n}{N}\right) \frac{s_e^2}{n}}.$$

```
X_aux <- sum(U$x_aux)
Rhat <- sum(s_mas$Volume) / sum(s_mas$x_aux)
Y_razon <- Rhat * X_aux
e_razon <- s_mas$Volume - Rhat * s_mas$x_aux
SE_razon <- N * sqrt((1 - n / N) * var(e_razon) / n)
IC_razon <- Y_razon + c(-1, 1) * t_mas * SE_razon

b_reg <- cov(s_mas$x_aux, s_mas$Volume) / var(s_mas$x_aux)
Y_reg <- N * (mean(s_mas$Volume) +
  b_reg * (mean(U$x_aux) - mean(s_mas$x_aux)))
e_reg <- s_mas$Volume - (coef(lm(Volume ~ x_aux, data = s_mas))[1] +
  b_reg * s_mas$x_aux)
SE_reg <- N * sqrt((1 - n / N) * var(e_reg) / n)

round(rbind(
  MAS = c(total = unname(est_mas["total"]), EE = unname(se_mas["total"]),
    LI = ic_mas["total", "LI"], LS = ic_mas["total", "LS"]),
  razon = c(total = Y_razon, EE = SE_razon, LI = IC_razon[1], LS = IC_razon[2]),
  regresion = c(total = Y_reg, EE = SE_reg,
    LI = Y_reg - t_mas * SE_reg, LS = Y_reg + t_mas * SE_reg)
), 2)
```



```
#>           total      EE      LI      LS
#> MAS      1022.69  156.50  668.67 1376.71
#> razon      940.57   20.60  893.97  987.16
#> regresion  938.98   20.39  892.87  985.10
```

Con la única muestra MAS, la razón estima el total en 940.57 y la regresión en 938.98, ambos muy cerca de la verdad censal (935.3), mientras el MAS de esa misma muestra da 1022.69, unas 87 unidades por encima. La ganancia está en la incertidumbre: el EE del MAS es 156.50 y tanto la razón (20.60) como la regresión (20.39) lo reducen a cerca de la séptima parte. Las pendientes casi coinciden (0.0021 y 0.0022), señal de que el volumen es, en efecto, casi proporcional al auxiliar (correlación 0.99). El estimador de regresión se muestra como diagnóstico: permite intercepto, mientras la razón impone proporcionalidad al origen. Ambos EE son aproximaciones por linealización.

2.8.1. Gráfica 1: forma de la relación auxiliar

```
plot(U$x_aux, U$Volume, pch = 1, col = "grey55",
     xlab = expression(Diametro^2 %*% altura), ylab = "Volumen (pies cúbicos)")
points(s_mas$x_aux, s_mas$Volume, pch = 19, col = "#bc4749")
abline(a = 0, b = Rhat, col = "#386641", lwd = 2)
abline(lm(Volume ~ x_aux, data = s_mas), col = "#457b9d", lwd = 2, lty = 2)
legend("topleft", c("Razón", "Regresión"), col = c("#386641", "#457b9d"),
      lty = c(1, 2), lwd = 2, bty = "n")
```




Figura 2.17: Volumen y auxiliar geométrico con ajustes de razón y regresión en la muestra MAS.

La figura 2.17 muestra que el volumen depende del auxiliar con una relación casi perfecta que parte del origen: los 31 puntos del censo se apiñan en torno a una recta creciente (correlación 0.99). Sobre esa nube, la muestra (puntos rojos) ajusta dos rectas casi coincidentes — la de razón (sólida, forzada al origen) y la de regresión (discontinua, con intercepto). Como la dispersión vertical es pequeña, los residuos son cortos y usar el auxiliar elimina gran parte de la variabilidad que castigaba al MAS.

2.8.2. Gráfica 2: residuos de proporcionalidad

```
plot(s_mas$x_aux, e_razon, pch = 19, col = "#386641",
     xlab = expression(Diametro^2 %*% altura), ylab = "Residuo de razón")
abline(h = 0, lty = 2)
lines(lowess(s_mas$x_aux, e_razon), col = "#bc4749", lwd = 2)
```




Figura 2.18: Residuos del estimador de razón frente al auxiliar.

La figura 2.18 examina los residuos de la razón frente al auxiliar: se reparten alrededor de cero sin pendiente ni curvatura clara, y la suavizada (roja) apenas se desvía de la línea horizontal. Eso confirma que la proporcionalidad describe bien todo el rango y que no queda estructura que un estimador más flexible deba rescatar. Una tendencia residual advertiría que una razón constante no describe bien todo el rango; una correlación alta no basta, importa la forma y el comportamiento de los residuos.

2.8.3. Gráfica 3: precisión por repetición

```
set.seed(2209)
rep_aux <- t(replicate(B, {
  z <- U[sample.int(N, n), ]
  r <- sum(z$Volume) / sum(z$x_aux)
  b <- cov(z$x_aux, z$Volume) / var(z$x_aux)
  c(MAS = N * mean(z$Volume),
    razon = r * X_aux,
    regresion = N * (mean(z$Volume) + b * (mean(U$x_aux) - mean(z$x_aux))))
}))
metricas_aux <- t(vapply(as.data.frame(rep_aux), metricas_repeticion,
```

```

        numeric(3), verdad = verdad_arboles["total"]))
round(metricas_aux, 3)
#>          sesgo DE_empirica    RMSE
#> MAS        -2.835    132.785 132.793
#> razon      -0.337     20.378  20.377
#> regresion  -0.098     22.751  22.747

boxplot(as.data.frame(rep_aux), col = c("grey80", "#6a994e", "#457b9d"),
        ylab = "Total estimado de volumen")
abline(h = verdad_arboles["total"], lty = 2)

```




Figura 2.19: Distribuciones del total estimado mediante MAS, razón y regresión.

La figura 2.19 distribuye el total estimado en 3000 repeticiones. La caja del MAS es muy ancha (DE 132.8): el total oscila lejos de la verdad (935.3, línea discontinua). Las cajas de razón y regresión son estrechas (DE 20.4 y 22.8) y centradas sobre la verdad. Con el auxiliar, la incertidumbre del total cae a cerca de un sexto respecto del MAS.

2.8.4. Gráfica 4: sesgo y RMSE

```
op <- par(mfrow = c(1, 2), mar = c(5, 4, 2, 1))
barplot(abs(metricas_aux[, "sesgo"]), names.arg = rownames(metricas_aux),
        col = "#bc4749", las = 2, ylab = "Sesgo absoluto")
barplot(metricas_aux[, "RMSE"], names.arg = rownames(metricas_aux),
        col = "#386641", las = 2, ylab = "RMSE")
par(op)
```




Figura 2.20: Sesgo absoluto y RMSE de los estimadores evaluados por repetición.

La figura 2.20 resume las dos métricas. El sesgo absoluto es pequeño en los tres (regresión -0.10 , razón -0.34 , MAS -2.84), pero el RMSE lo domina la varianza: 132.79 para el MAS frente a 20.38 (razón) y 22.75 (regresión). La razón asume un sesgo ligeramente mayor que la regresión a cambio del mejor RMSE; la regresión, al estimar también el intercepto con solo diez puntos, paga una pequeña penalización de varianza. La razón puede aceptar un sesgo pequeño a cambio de una reducción importante de varianza. La comparación debe hacerse bajo el diseño real y con un auxiliar que estuviera disponible antes de medir la respuesta.

2.9. Comparación y decisión

Las métricas siguientes reúnen los estimadores del total de volumen para la población de 31 árboles. Conglomerados y dos etapas no se mezclan en esta tabla porque estiman tallos en otra población y otra escala.

```
comparacion_arboles <- rbind(
  MAS = c(estimacion = unname(est_mas["total"]),
    EE = unname(se_mas["total"]),
    sesgo_empirico = metricas_st["MAS", "sesgo"],
    DE_empirica = metricas_st["MAS", "DE_empirica"],
    RMSE = metricas_st["MAS", "RMSE"]),
  estratificado = c(estimacion = unname(est_st["total"]),
    EE = unname(se_st["total"]),
    sesgo_empirico = metricas_st["proporcional", "sesgo"],
    DE_empirica = metricas_st["proporcional", "DE_empirica"],
    RMSE = metricas_st["proporcional", "RMSE"]),
  sistematico = c(estimacion = unname(est_sys["total"]),
    EE = unname(se_sys_diseno["total"]),
    metricas_repeticion(todos_sys[, "total"],
      verdad_arboles["total"])),
  razon = c(estimacion = Y_razon, EE = SE_razon,
    sesgo_empirico = metricas_aux["razon", "sesgo"],
    DE_empirica = metricas_aux["razon", "DE_empirica"],
    RMSE = metricas_aux["razon", "RMSE"])
)
round(comparacion_arboles, 3)
#>      estimacion      EE sesgo_empirico DE_empirica      RMSE
#> MAS           1022.690 156.495           1.158      129.351 129.335
#> estratificado    850.192  68.678           1.383       72.767  72.768
#> sistematico     1009.050  67.056           0.000       68.164  67.056
#> razon           940.565  20.595          -0.337       20.378  20.377
```

La tabla ordena los cuatro estimadores por su RMSE de largo plazo, la métrica de comparación imparcial. El MAS (RMSE 129.34) es la referencia: no aprovecha la estructura del marco y paga la variabilidad completa de las unidades. Estratificado (72.77) y sistemático (67.06) lo reducen casi a la mitad al explotar, respectivamente, la homogeneidad de los estratos y la cobertura del orden por diámetro; sistemático gana ligeramente porque el gradiente de volumen con el diámetro es casi monótono. La razón (20.38) lo reduce a cerca de un sexto al usar un auxiliar altamente correlacionado (0.99). Los sesgos empíricos son pequeños en todos los diseños (−0.34 a 1.38): son insesgados o casi, y las diferencias de RMSE provienen de la varianza, no del sesgo. No debe leerse solo la columna de estimación puntual: el estratificado da 850.19 y el sistemático

1009.05, a lados opuestos de la verdad (935.3); una sola realización puede caer a un lado u otro, y solo la repetición revela que sistemático es más estable. Cada ganancia exige su condición operativa — estratos conocidos antes de muestrear, orden y periodicidad estudiados, auxiliar disponible antes de medir — y ninguno repara una selección no probabilística.

- **MAS** es la referencia cuando el marco es completo y no hay estructura útil.
- **Estratificación** es defendible si los estratos se conocen antes de muestrear y separan heterogeneidad o dominios importantes.
- **Sistemático** mejora cobertura, pero obliga a estudiar orden, periodicidad y estimación de varianza.
- **Conglomerados** reducen desplazamiento; su costo estadístico depende de la semejanza interna y del número de unidades primarias.
- **Dos etapas** equilibran cobertura dentro de grupos y costo, pero exigen conservar probabilidades y variación de ambas etapas.
- **Razón o regresión** aprovechan un marco auxiliar; no reparan una selección no probabilística ni una relación inestable.

2.10. Reproducibilidad y alcance

Las comparaciones repiten mecanismos de selección sobre dos censos observados. No demuestran que la clasificación de precisión se mantenga en otro bosque. En un estudio nuevo deben conservarse marco, versiones de auxiliares, cortes de estrato, identificadores de conglomerado, probabilidades, arranques, unidades, costos y respuesta ante no observación.

```
list(  
  archivos = c("datasets::trees", "vegan::BCI", "vegan::BCI.env"),  
  version_vegan = as.character(packageVersion("vegan")),  
  version_R = R.version.string,  
  estimandos_arboles = names(verdad_arboles),  
  umbral_volumen = 30,  
  umbral_riqueza = 95,  
  ids_MAS = sort(ids_mas),  
  ids_estratificados = sort(ids_st),  
  arranque_sistemático = arranque,  
  conglomerados_BCI = clusters_s,  
  ids_segunda_etapa = sort(ids_2e)  
)  
#> $archivos  
#> [1] "datasets::trees" "vegan::BCI"      "vegan::BCI.env"  
#>  
#> $version_vegan
```

```

#> [1] "2.7.5"
#>
#> $version_R
#> [1] "R version 4.5.2 (2025-10-31)"
#>
#> $estimandos_arboles
#> [1] "media"      "total"      "proporcion" "DE"
#>
#> $umbral_volumen
#> [1] 30
#>
#> $umbral_riqueza
#> [1] 95
#>
#> $ids_MAS
#> [1] 5 8 9 12 15 17 19 24 26 31
#>
#> $ids_estratificados
#> [1] 4 5 6 11 12 13 15 22 24 28
#>
#> $arranque_sistemático
#> [1] 31
#>
#> $conglomerados_BCI
#> [1] 3 8 9 10
#>
#> $ids_segunda_etapa
#> [1] 11 12 15 37 38 40 41 43 44 47 48 50
sessionInfo()
#> R version 4.5.2 (2025-10-31)
#> Platform: x86_64-pc-linux-gnu
#> Running under: Ubuntu 24.04.4 LTS
#>
#> Matrix products: default
#> BLAS: /usr/lib/x86_64-linux-gnu/openblas-pthread/libblas.so.3
#> LAPACK: /usr/lib/x86_64-linux-gnu/openblas-pthread/libopenblas-p0.3.26.so; LAPACK versi
#>
#> locale:
#> [1] LC_CTYPE=C.UTF-8 LC_NUMERIC=C LC_TIME=C.UTF-8
#> [4] LC_COLLATE=C.UTF-8 LC_MONETARY=C.UTF-8 LC_MESSAGES=C.UTF-8
#> [7] LC_PAPER=C.UTF-8 LC_NAME=C LC_ADDRESS=C
#> [10] LC_TELEPHONE=C LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C

```



```

#>
#> time zone: UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats      graphics  grDevices datasets  utils      methods    base
#>
#> loaded via a namespace (and not attached):
#> [1] digest_0.6.39    permute_0.9-10    codetools_0.2-20 fastmap_1.2.0
#> [5] Matrix_1.7-4     mgcv_1.9-3        xfun_0.56         lattice_0.22-7
#> [9] splines_4.5.2    parallel_4.5.2    knitr_1.51        htmltools_0.5.9
#> [13] rmarkdown_2.30   cli_3.6.5         grid_4.5.2        renv_1.2.4
#> [17] vegan_2.7-5      compiler_4.5.2    tools_4.5.2       cluster_2.1.8.1
#> [21] nlme_3.1-168     evaluate_1.0.5    yaml_2.3.12       rlang_1.1.7
#> [25] jsonlite_2.0.0   MASS_7.3-65

```

La lista fija lo esencial para reproducir cualquier número del capítulo, y en ella conviven dos tipos de decisión. Por un lado, parámetros que el analista fija: los estimandos (media, total, proporción y DE), los umbrales de volumen (30) y de riqueza (95), los cortes de estrato y la definición de los conglomerados. Por otro, realizaciones aleatorias que solo quedan identificadas si se registra el sorteo: los diez identificadores del MAS y los diez de la estratificación, el arranque sistemático (31), los cuatro conglomerados (3, 8, 9 y 10) y las doce hectáreas de segunda etapa. Registrar esos sorteos junto con semilla, fuentes de datos y las versiones de R y de vegan que imprime el `sessionInfo()` del bloque anterior es lo que permite regenerar exactamente las mismas muestras y estimadores; el `sessionInfo()` cierra esa cadena computacional. Pero reproducir el cálculo no equivale a replicar la conclusión: como indica el párrafo anterior, la comparación de precisión se realizó sobre dos censos observados y su ordenamiento no debe asumirse válido en otro bosque. En un estudio nuevo hay que fijar y documentar marco, auxiliares, cortes, probabilidades y costos propios, no copiar los umbrales ni los identificadores de aquí.

2.11. Ejercicios teóricos y numéricos

Estos ejercicios son cerrados y progresivos. En todos los casos declare primero la población, la unidad de muestreo, el diseño y el estimando. Distinga la DE de las unidades del EE del estimador, conserve la corrección por población finita cuando corresponda y exprese cada resultado con sus unidades. Use resultados no redondeados durante los cálculos y redondee solo al presentar.

2.11.1. Ejercicios teóricos

2.11.1.1. Ejercicio T1. Población, unidad y estimando

Para cada situación, identifique población finita, unidad de muestreo, unidad de observación, marco y un estimando coherente. Indique además qué información falta para sustentar inferencia probabilística.

1. Un parque se divide en 500 cuadrantes y se seleccionan 30 para contar plantas de una especie.
2. De 80 colonias de aves se seleccionan 20 y se cuentan todos los nidos activos de cada colonia elegida.
3. Una cuenca contiene 120 segmentos de río; se seleccionan 12 y dentro de cada uno se eligen tres puntos para medir oxígeno disuelto.
4. Se miden los primeros 40 árboles encontrados a menos de 20 m de una carretera.

Explique por qué el cuarto caso no se convierte en probabilístico por calcular una media y un intervalo convencional.

2.11.1.2. Ejercicio T2. Propiedades del MAS

En un MAS sin reemplazo, $P(I_i = 1) = n/N$. Use indicadores de inclusión para demostrar que $N\bar{y}_s$ es insesgado para el total Y . Después responda:

1. ¿Por qué la corrección finita tiende a cero cuando $n = N$?
2. ¿Puede una población tener una DE grande y la media estimarse con EE pequeño?
3. ¿Qué componente cambia al aumentar n : la variabilidad de las unidades, la variabilidad del estimador o ambas?

2.11.1.3. Ejercicio T3. Estratificación y asignación

Considere una población dividida en tres hábitats. Explique:

1. por qué $\frac{1}{3} \sum_h \bar{y}_h$ puede ser incorrecto;
2. qué condiciones favorecen una ganancia de precisión por estratificación;
3. por qué garantizar observaciones en un hábitat raro puede ser valioso aunque no minimice la varianza global;
4. qué información previa necesita la asignación de Neyman y por qué no debe obtenerse de la respuesta completa que se pretende estimar.

2.11.1.4. Ejercicio T4. Orden y muestreo sistemático

Compare una lista ordenada por un gradiente ambiental, una lista en orden aleatorio y una lista con periodicidad igual al intervalo de muestreo. Para cada caso anticipe si el sistemático podría ser más preciso, parecido o menos preciso que un MAS. Explique por qué cambiar el arranque no elimina necesariamente la periodicidad y por qué una sola secuencia suele ser insuficiente para estimar la varianza de diseño.

2.11.1.5. Ejercicio T5. Conglomerados, etapas y pseudorreplicación

Un estudio selecciona cuatro bosques y mide 25 árboles en cada bosque.

1. ¿Cuántas unidades primarias independientes sustentan la inferencia?
2. ¿Qué diferencia habría entre censar los 25 árboles y seleccionar cinco dentro de cada bosque?
3. Interprete $\rho = 0$, $\rho > 0$ y $\rho < 0$ en términos de semejanza interna.
4. Con $L = 25$ y $\rho = 0.12$, calcule el DEFF aproximado y explique por qué 100 árboles no equivalen necesariamente a un MAS de 100 árboles.

2.11.1.6. Ejercicio T6. Información auxiliar

Compare estimación de razón y de regresión bajo estos patrones:

1. relación lineal fuerte que pasa cerca del origen;
2. relación lineal fuerte con intercepto distinto de cero;
3. relación curvada;
4. auxiliar medido después de observar la respuesta solo en la muestra.

Indique en qué casos la razón es defendible, cuándo preferiría regresión y por qué ninguno de los dos estimadores corrige un marco que excluye unidades difíciles de alcanzar.

2.11.2. Ejercicios numéricos

2.11.2.1. Ejercicio N1. Media y total bajo MAS

De una población de $N = 80$ parcelas se selecciona un MAS sin reemplazo de $n = 10$. Las biomásas observadas, en kg por parcela, son

12, 15, 9, 18, 14, 11, 16, 20, 13, 17.

1. Calcule media, varianza y DE muestrales.

2. Estime la biomasa media y total de las 80 parcelas.
3. Calcule sus EE con corrección por población finita.
4. Construya IC del 95 % usando t_9 .
5. Interprete el intervalo del total en términos de repetición del diseño.

2.11.2.2. Ejercicio N2. Proporción y esfuerzo

Use la muestra del ejercicio N1 y defina como biomasa alta una parcela con más de 15 kg.

1. Construya el indicador y estime la proporción poblacional.
2. Calcule la varianza muestral del indicador, su EE con corrección finita y un IC del 95 % basado en t_9 , restringido a $[0, 1]$.
3. Para planificar otro estudio, use $P \approx 0.40$ y calcule el EE aproximado para $n = 10, 20, 40$, manteniendo $N = 80$.
4. Explique por qué el EE no se reduce exactamente en proporción a $1/\sqrt{n}$ cuando la fracción de muestreo es grande.

2.11.2.3. Ejercicio N3. Estimación estratificada

Una región de 100 parcelas está dividida en tres hábitats. Se obtiene la siguiente información de muestras aleatorias independientes:

Hábitat h	N_h	n_h	$\bar{y}_h$	s_h^2
Bosque	40	5	12	9
Matorral	35	5	20	16
Pastizal	25	5	30	25

La respuesta está en individuos por parcela.

1. Calcule pesos W_h , media estratificada y total.
2. Calcule la varianza y el EE de la media y del total.
3. Construya un IC aproximado del 95 % para la media usando 12 grados de libertad.
4. Compare la media ponderada con la media simple de las tres medias de estrato y explique la diferencia.

2.11.2.4. Ejercicio N4. Asignación proporcional y de Neyman

Use $N_h = (40, 35, 25)$ y $S_h = (3, 4, 5)$ para distribuir $n = 20$ observaciones.

1. Obtenga una asignación proporcional entera que sume 20.

2. Obtenga la asignación de Neyman, redondeando por restos mayores.
3. Para cada asignación calcule

$$\widehat{V}(\bar{y}_{st}) = \sum_h W_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{S_h^2}{n_h}.$$

4. Interprete la diferencia y señale por qué esta comparación supone conocidas las DE de estrato.

2.11.2.5. Ejercicio N5. Todos los arranques sistemáticos

Una población ordenada contiene los valores $y_i = i$ para $i = 1, \dots, 24$. Se desea una muestra sistemática de $n = 6$, de modo que $k = 4$ y el arranque se elige uniformemente entre 1 y 4.

1. Escriba las cuatro muestras posibles.
2. Estime el total con cada arranque usando $\widehat{Y} = 24\bar{y}_s$.
3. Calcule la media de los cuatro estimadores y compárela con el total verdadero.
4. Calcule la DE exacta de diseño usando denominador cuatro.
5. Explique por qué esa DE es calculable en este ejercicio, pero no a partir de una única secuencia observada en una población desconocida.

2.11.2.6. Ejercicio N6. Conglomerados de una etapa

Una población contiene $M = 8$ conglomerados de $L = 4$ unidades. Se seleccionan $m = 3$ conglomerados por MAS y sus totales observados son 42, 55 y 47 individuos.

1. Estime el total y la media para las $N = 32$ unidades.
2. Calcule la varianza y el EE del total mediante

$$\widehat{V}(\widehat{Y}_c) = M^2 \left(1 - \frac{m}{M}\right) \frac{s_t^2}{m}.$$

3. Obtenga el EE de la media y un IC del 95 % para el total con dos grados de libertad.
4. Explique por qué los grados de libertad dependen de tres conglomerados y no de doce unidades internas.

2.11.2.7. Ejercicio N7. Muestreo en dos etapas

Una población tiene $M = 6$ conglomerados de $L = 5$ unidades. Se seleccionan $m = 3$ conglomerados y $l = 2$ unidades dentro de cada uno. Las respuestas son:

Conglomerado	Valores observados
1	8, 12
2	15, 17
3	9, 13

1. Calcule $\hat{t}_h = L\bar{y}_h$ y $\hat{V}_h = L^2(1 - l/L)s_h^2/l$ para cada conglomerado.
2. Estime el total poblacional con $(M/m)\sum_h \hat{t}_h$.
3. Separe y calcule los componentes entre y dentro de conglomerados de $\hat{V}(\hat{Y}_{2e})$.
4. Calcule total, media, EE respectivos e IC del 95 % para el total con dos grados de libertad.
5. Indique qué componente desaparecería si se censaran las cinco unidades de cada conglomerado seleccionado.

2.11.2.8. Ejercicio N8. Estimación de razón

En un MAS de $n = 8$ unidades de una población de $N = 50$ se obtiene $\sum_s x_i = 160$, $\sum_s y_i = 240$ y $s_e^2 = 4$ para los residuos de razón. El total auxiliar conocido es $X = 1000$. Además, la varianza muestral de y es 100.

1. Calcule $\hat{R}$ y $\hat{Y}_R$.
2. Calcule el EE linealizado y un IC del 95 % usando t_7 .
3. Calcule el EE del total MAS con $s_y^2 = 100$.
4. Compare ambos EE y explique qué propiedad de los residuos produce la diferencia.
5. Señale qué diagnóstico gráfico revisaría antes de recomendar la razón.

2.11.3. Ejercicios guiados en R

2.11.3.1. Ejercicio R1. Precisión y tamaño de muestra con trees

Use los objetos `U`, `N` y `x_aux` creados en el capítulo. Con semilla 2210 y 1000 repeticiones, compare MAS y razón para $n = 6, 10, 15$.

1. En cada repetición estime el total por ambos métodos.
2. Calcule sesgo y RMSE respecto de `sum(U$Volume)`.
3. Grafique RMSE frente a tamaño de muestra.
4. Explique si la ventaja relativa del auxiliar se mantiene al aumentar n y por qué el resultado sigue limitado a estas 31 filas.

2.11.3.2. Ejercicio R2. Orientación de conglomerados con BCI

Use `marco_bci$tallos`. Compare dos particiones que observan 20 hectáreas:

1. diez columnas de cinco hectáreas, seleccionando cuatro columnas;
2. cinco filas de diez hectáreas, seleccionando dos filas.

Para cada orientación calcule ICC, DEFF y la DE exacta del estimador de la media enumerando todas las selecciones de unidades primarias. Dibuje ambas particiones y explique por qué cambiar la geometría modifica precisión aunque se conserve el área total observada.

2.11.3.3. Ejercicio R3. Estratificación: asignación y ganancia de precisión con trees

Use los objetos `U`, `N`, `Nh`, `estrato`, `nh` (proporcional) y `nh_neyman` creados en el capítulo. Con semilla 2211 y 1000 repeticiones compare el total de volumen estimado con un MAS y con cada asignación estratificada.

1. En cada repetición estime el total con los tres esquemas (diez unidades cada uno).
2. Calcule sesgo, DE empírica y RMSE respecto de `sum(U$Volume)`.
3. Descomponga la variación de las unidades entre una componente dentro de los estratos (promedio de las varianzas intraestrato) y una entre estratos (varianza de las medias) y relacione ese cociente con la ganancia del proporcional frente al MAS.
4. Explique por qué la asignación de Neyman mejora aún la precisión y qué información previa exigiría en un estudio real.

2.11.3.4. Ejercicio R4. Sistemático: arranques y sensibilidad al orden con trees

Con $N = 31$ y $n = 10$, genere la secuencia sistemática de diez posiciones para cualquier arranque y enumere los 31 arranques del total en tres órdenes del marco.

1. Considere los órdenes por diámetro (el del archivo), por volumen (retrospectivo) y una permutación fija generada con semilla 2212.
2. Para cada orden, calcule la media de los 31 totales, la DE exacta de diseño y el RMSE respecto de `sum(U$Volume)`.
3. Dibuje los totales por arranque para el orden más y el menos eficiente.
4. Explique qué revela la permutación aleatoria sobre el papel del gradiente y por qué ordenar por volumen es solo un diagnóstico retrospectivo.

2.11.3.5. Ejercicio R5. Auxiliar: razón frente a regresión con trees

Use `U` y `x_aux`. Con semilla 2213 y 1000 repeticiones, compare los estimadores de razón y de regresión del total.

1. En cada repetición estime el total por ambos métodos.
2. Calcule sesgo, DE empírica y RMSE respecto de `sum(U$Volume)`.
3. Ajuste la recta de regresión en una muestra y examine los residuos frente a `x_aux` y su suavizado.
4. Explique por qué la razón gana en RMSE pese a asumir proporcionalidad y en qué situaciones una regresión con intercepto sería preferible.

i Resultados breves de comprobación

T1. En los tres primeros casos el marco puede ser, respectivamente, la lista o mapa de 500 cuadrantes, 80 colonias y 120 segmentos con sus puntos elegibles. Las unidades primarias son cuadrante, colonia y segmento. En el cuarto caso la unidad observada es un árbol accesible desde la carretera, pero no se conoce una probabilidad positiva de inclusión para todos los árboles del bosque; un IC convencional no corrige esa cobertura.

T2. Como $N\bar{y}_s = (N/n) \sum_i I_i y_i$ y $E(I_i) = n/N$, su esperanza es $\sum_i y_i = Y$. Si $n = N$, no quedan muestras alternativas y el EE es cero. La DE de las unidades no cambia al aumentar n ; disminuye el EE del estimador.

T3. Las medias se ponderan por $W_h = N_h/N$. La ganancia de precisión requiere estratos internamente homogéneos y diferentes entre sí. La representación de un dominio puede ser un objetivo independiente de minimizar la varianza. Neyman requiere DE previas, obtenidas de pilotos o estudios anteriores.

T4. Un gradiente suave suele favorecer la cobertura sistemática; un orden aleatorio tiende a aproximarla al MAS; una periodicidad alineada puede aumentar mucho el error. El arranque desplaza el patrón, pero no cambia su intervalo.

T5. Hay cuatro unidades primarias independientes. Medir cinco árboles en cada bosque crea dos etapas; censar 25 crea conglomerados de una etapa. Con $L = 25$ y $\rho = 0.12$, $DEFF = 1 + 24(0.12) = 3.88$, por lo que la semejanza interna reduce la información efectiva.

T6. La razón es más defendible para una relación estable cercana al origen. Un intercepto favorece regresión; curvatura exige revisar la forma o transformar el auxiliar. Una variable medida solo después de observar y no era auxiliar de marco. Ningún ajuste recupera unidades con probabilidad de inclusión cero.

N1. $\bar{y} = 14.5$ kg, $s^2 = 11.3889$ kg², $s = 3.3747$ kg, $EE(\bar{y}) = 0.9983$ kg. El total estimado es 1160 kg con EE 79.861 kg. El IC del 95% para la media es [12.242, 16.758] kg y para el total, [979.342, 1340.658] kg.

N2. El indicador contiene cuatro unos: $\hat{P} = 0.40$, $s_z^2 = 0.2667$ y $EE = 0.1528$. El IC restringido es [0.054, 0.746]. Usando $P(1 - P)$ para planificación, los EE aproximados

para $n = 10, 20, 40$ son 0.1449, 0.0949 y 0.0548.

N3. $W = (0.40, 0.35, 0.25)$, $\widehat{Y}_{st} = 19.3$ individuos por parcela y $\widehat{Y}_{st} = 1930$ individuos. La varianza del total es 8380, $EE(\widehat{Y}) = 91.542$ y $EE(\widehat{Y}) = 0.9154$. El IC para la media es $[17.305, 21.295]$. La media no ponderada de estratos sería 20.667 y responde a otra ponderación poblacional.

N4. La asignación proporcional es $(8, 7, 5)$ y la de Neyman, $(6, 7, 7)$. Las varianzas anticipadas de la media son 0.6180 y 0.5887, respectivamente. La mejora de Neyman depende de que $S_h = (3, 4, 5)$ sea información previa válida.

N5. Las muestras comienzan en 1, 2, 3 y 4 y avanzan de cuatro en cuatro. Los totales estimados son 264, 288, 312 y 336; su media es el total verdadero 300. La DE exacta de diseño es 26.8328.

N6. $\widehat{Y}_c = 384$ individuos y $\widehat{Y}_c = 12$ individuos por unidad. La varianza del total es 573.333, su EE es 23.944 y el EE de la media, 0.7483. Con dos grados de libertad, el IC del total es aproximadamente $[280.976, 487.024]$.

N7. Los totales estimados de conglomerado son $(50, 80, 55)$ y sus varianzas internas estimadas, $(60, 15, 60)$. El componente entre conglomerados es 1550 y el componente interno es 270; la varianza total es 1820. Se obtiene $\widehat{Y}_{2e} = 370$, $EE = 42.661$, $\widehat{Y} = 12.333$ y $EE(\widehat{Y}) = 1.422$. El IC del total es $[186.443, 553.557]$. Al censar las unidades internas desaparece el componente 270.

N8. $\widehat{R} = 1.5$ y $\widehat{Y}_R = 1500$. El EE linealizado es 32.404 y el IC, $[1423.377, 1576.623]$. El estimador MAS tiene el mismo valor puntual en este ejercicio, pero EE 162.019. La reducción procede de residuos mucho menos variables que y ; deben revisarse relación con el origen y residuos frente a x .

R1. Con la semilla indicada, los RMSE aproximados de MAS para $n = 6, 10, 15$ son 186.94, 134.77 y 94.98; para razón son 28.54, 20.25 y 13.90. El sesgo de razón permanece pequeño frente a su DE en las tres comparaciones.

R2. Para columnas de cinco hectáreas, $\rho \approx 0.2140$, $DEFF \approx 1.8562$ y la DE exacta de la media es 10.1305 tallos/ha. Para filas de diez hectáreas, $\rho \approx 0.3109$, $DEFF \approx 3.7982$ y la DE exacta es 14.7929 tallos/ha. La orientación de filas agrupa unidades más semejantes en esta población observada.

R3. La asignación proporcional es $(4, 3, 3)$ y la de Neyman, $(3, 3, 4)$; el estrato grande aporta diez de las 31 unidades pero también la mayor desviación $S_h \approx 13.2$. Los RMSE del total son MAS 132.94, proporcional 71.66 y Neyman 62.81. La variación dentro de los estratos (promedio) es 76.0 y la varianza de las medias entre estratos, 292.4; como la heterogeneidad entre supera a la interna, el proporcional reduce el RMSE frente al MAS y Neyman lo reduce más volcando muestra en el estrato más variable.

R4. La DE exacta de diseño del total es 67.06 para el orden por diámetro, 61.68 para el orden por volumen y 77.9 para la permutación aleatoria. En los tres órdenes la media de los 31 totales coincide con el total verdadero (935.3), lo que confirma insesgadez; el orden aleatorio destruye el gradiente y pierde la precisión que produce la cobertura sistemática.

R5. Con la semilla indicada, el RMSE de la razón es 20.51 y el de la regresión, 23.02. Ambos quedan muy por debajo del MAS; la razón, aunque asume proporcionalidad, logra el menor RMSE por su menor varianza, y la regresión paga una pequeña penalización por estimar el intercepto con diez puntos. Los residuos deben revisarse frente a `x_aux` antes de preferir un modelo.

2.12. Actividad propuesta para el lector

Use el conjunto real `datasets::attitude` como población finita de 30 unidades y estime la media, el total, la proporción que supera un umbral previamente fijado y la DE de `rating`. Audite estructura, faltantes, duplicados, rangos y límites de procedencia; defina unidad, marco y estimandos; y compare un MAS, una estratificación previa por clases de `complaints`, y un sistemático sobre al menos dos órdenes. Use un auxiliar justificado para un estimador de razón o regresión. Para cada método documente probabilidades, pesos, estimador, EE e intervalo; repita selecciones sobre el marco observado para examinar sesgo, DE empírica, RMSE y cobertura; incluya al menos tres gráficas que expliquen selección, heterogeneidad e incertidumbre; y evalúe sensibilidad al tamaño de muestra, puntos de corte y orden. Finalmente, proponga cómo formar conglomerados y dos etapas si las 30 unidades pertenecieran a grupos naturales, indicando qué información adicional sería indispensable para ejecutar y analizar ese diseño.

Parte II

Parte II — Métodos de campo

3 Parcelas, cuadrantes e intercepción

Densidad, frecuencia y cobertura en marcos espaciales

3.1. Convertir espacio en observaciones

Cuando los organismos no se mueven —plantas sésiles, corales, algas incrustantes, organismos bentónicos—, la población no se recorre individuos a individuos: se recorre un territorio. El diseño de muestreo decide entonces *dónde* observar, *cuánto espacio* incluir en cada observación y *qué regla* convierte individuos, contactos o biomasa en un número. Esas tres decisiones no son detalles técnicos: **el soporte** (el área o la longitud sobre la que se mide) forma parte del estimando, porque cambiar el soporte puede cambiar la pregunta, no solo la precisión (Sutherland 2006; Henderson y Southwood 2016).

Considere una misma especie en un mismo lugar bajo las tres medidas habituales. La **densidad** es la cantidad de individuos por unidad de área; la **frecuencia** es la fracción de unidades de muestreo que contienen al menos un individuo; la **cobertura** es la fracción de la superficie que la especie ocupa. Una especie con pocos individuos pero muy grandes (una palma dominante) puede tener densidad baja y cobertura alta; una hierba gregaria puede tener densidad alta pero ocupar poco sustrato. Cada medida responde a una pregunta distinta, y presentarlas como sinónimos es uno de los errores más frecuentes al leer o escribir investigación ecológica.

3.2. Población, soporte y unidades

Del capítulo 1 conservamos el vocabulario con el que se declara un estimando: población objetivo, población accesible, marco y unidades. Para un marco espacial hace falta precisarlo con tres conceptos adicionales:

- El **soporte** es el área (o longitud) a la que pertenece cada medición.
- La **extensión** es el dominio que la muestra pretende cubrir.
- El **grano** es la resolución mínima a la que se observa.

Consideremos un humedal de 12 ha donde queremos densidades de un helecho acuático. Podemos definir el marco como una lista de 300 cuadrantes de 20×20 m: la extensión es todo el humedal, el grano es 20×20 m y el soporte de cada conteo es 400 m^2 . Si la misma pregunta se plantea con cuadrantes de 10×10 m, el grano y el soporte cambian, y con ellos tanto la densidad esperada como la incertidumbre; la población objetivo, en cambio, sigue siendo el humedal.

Una parcela puede contener cientos de puntos de observación, pero eso no convierte a cada punto en una réplica. Si la unidad que recibió probabilidad de inclusión fue la parcela, los puntos internos son *submuestras* de esa parcela: tratarlos como réplicas independientes subestima la incertidumbre. Del mismo modo, “individuo” debe definirse antes de medir: en gramíneas y bambúes un **tallo** no es una **macolla** ni un **geneto** (un individuo genético), y las tres definiciones producen densidades distintas. La unidad de muestreo y la unidad de observación deben anotarse en la declaración del estimando.

3.3. Parcelas de área fija

La receta más simple es seleccionar parcelas del mismo tamaño y contar los individuos dentro de cada una. Si la parcela i tiene área a y conteo y_i , bajo un MAS de n parcelas entre N parcelas iguales, la densidad estimada es

$$\widehat{D} = \frac{\bar{y}}{a}, \quad \widehat{V}(\widehat{D}) = \left(1 - \frac{n}{N}\right) \frac{s_y^2}{na^2}.$$

¿Por qué aparece n , y no N , dividiendo? La variabilidad entre unidades se resume en s_y^2 (que divide entre $n-1$); al promediar n conteos, esa variabilidad se reduce en $1/n$, y el factor $1-n/N$ (la corrección por población finita) la ajusta cuando la fracción muestreada es apreciable. Si se divide por N se mezclaría una suma parcial de la muestra con el total de unidades del marco. Para un dominio de área $A = Na$, el total estimado es $\widehat{Y} = A\widehat{D}$: multiplique la densidad por el área, tal como en el capítulo anterior se extendía la media por N . La expansión solo es válida si la selección representa el dominio y el área es conocida para todo el marco (Manly y Navarro Alberto 2015).

Cuando las parcelas no son iguales, ya no hay una única “densidad”. Suponga que y_i es el conteo y a_i el área de la parcela i . Dos estimadores naturales responden a preguntas distintas:

$$\widehat{D}_U = \frac{1}{n} \sum_{i \in s} \frac{y_i}{a_i}, \quad \widehat{D}_R = \frac{\sum_{i \in s} y_i}{\sum_{i \in s} a_i}.$$

El primero da la misma influencia a cada parcela (una media de densidades); el segundo da más influencia a las parcelas grandes (el cociente de totales). Si la selección dependiera del

área, ninguno de los dos es correcto sin probabilidades de inclusión explícitas: en ese caso conviene un estimador ponderado por π_i , como el de Horvitz–Thompson del capítulo 1.

3.4. Frecuencia, cobertura y escala

La **frecuencia** responde a una pregunta de presencia: para $z_i = I(y_i > 0)$, la frecuencia estimada es $\widehat{F} = \bar{z}$, con varianza la de cualquier proporción bajo el diseño que se haya usado. Su utilidad operativa es enorme —un conteo puede ser incierto, pero la presencia en una unidad es más robusta— y también su pluralidad: la frecuencia depende del tamaño, la forma, la época y el protocolo de la unidad. Al aumentar el soporte disminuyen los ceros y la frecuencia suele crecer, aunque la densidad media permanezca parecida. La razón es de probabilidad: si una especie está en una fracción p del dominio y las unidades fueran independientes, un bloque de k celdas tiene presencia con probabilidad $1 - (1 - p)^k$. Por eso comparar frecuencias entre estudios que usan cuadrantes de distinto tamaño es comparar instrumentos distintos.

La **cobertura** se mide de dos maneras. En la *intercepción lineal*, si l_{ij} es la longitud de línea ocupada por la especie j en la línea i de longitud L_i ,

$$\widehat{C}_j = \frac{\sum_i l_{ij}}{\sum_i L_i}.$$

En la *intercepción por puntos*, se bajan M puntos y se anota cuántos caen sobre la especie: $\widehat{C}_j = x_j/M$. El error binomial $\sqrt{C(1-C)/M}$ supone puntos independientes; si los puntos están agrupados en líneas, la línea —no el punto— es la réplica, y la incertidumbre debe estimarse con líneas. La cobertura también debe declarar qué se mide: contacto superior del dosel, suma de capas o proyección sobre el suelo, porque la misma flora da números distintos para cada definición.

3.5. Tamaño, forma, borde y dependencia

No existe un tamaño óptimo de parcela desligado del estimando, del patrón espacial y del costo. Muchas parcelas pequeñas reparten mejor la muestra, aportan más réplicas y permiten detectar parches: pocas parcelas grandes reducen los ceros y el borde relativo y son más baratas por unidad de área, pero suavizan la heterogeneidad y dan menos observaciones independientes. La decisión se toma conociendo la fenología, la agregación y el presupuesto.

La forma importa por el borde. Para un rectángulo de lados u y v , el cociente perímetro–área es $P/A = 2(1/u + 1/v)$: entre rectángulos de igual área, el cuadrado minimiza el perímetro expuesto, una banda larga cruza más gradiente pero expone más borde y más árboles “a medias”. Las reglas de inclusión —qué hacer con un individuo exactamente en el lindero—

deben fijarse antes de observar, o se introduce un sesgo sutil que ninguna fórmula de varianza corrige.

La dependencia espacial condiciona toda la lectura de estas medidas. El índice $s^2/\bar{y}$ es descriptivo: valores altos son compatibles con agregación biológica, con un gradiente ambiental o con una mezcla de hábitats, y no los distingue. Un semivariograma descriptivo, $\gamma(h) = \frac{1}{2}(y_i - y_j)^2$ promediado por clases de distancia, examina si las unidades cercanas difieren menos que las lejanas. Es un diagnóstico de la estructura espacial —y un aviso sobre las réplicas—, pero no demuestra por sí solo un mecanismo biológico.

En la aplicación que sigue veremos cómo estos conceptos se materializan en el censo de Barro Colorado: la hectárea como unidad de muestreo y soporte, la dependencia del soporte para una especie de presencia parcial, el semivariograma como lectura de la agregación, y la decisión del origen de la teselación.

3.6. Aplicación reproducible: parcelas de Barro Colorado

vegan: BCI contiene conteos de árboles con diámetro a la altura del pecho de al menos 10 cm en 50 parcelas contiguas de una hectárea de Barro Colorado, Panamá; sus 225 columnas son especies y **BCI.env** aporta coordenadas y variables del sitio. La parcela forestal de 1000×500 m es un bosque tropical estacional de tierras bajas, casi todo de crecimiento antiguo, con un pequeño parche de secundario y un mosaico de meseta alta, meseta baja y ladera, más un área de suelo anegado (Condit et al. 2002; Harms et al. 2001; Pyke et al. 2001; Oksanen et al. 2024). El archivo distribuido por **vegan** procede de un censo histórico (Oksanen et al. 2024).

Las 50 hectáreas se tratan como población finita. El estimando primario es la densidad media de tallos con ese umbral (DAP ≥ 10 cm) por hectárea; resultados secundarios son la frecuencia de una especie focal y la riqueza por hectárea. La unidad de muestreo y de análisis es la hectárea; cada tallo es una unidad de observación. Este marco no es una muestra probabilística de los bosques tropicales: las conclusiones describen estas 50 hectáreas observadas.

3.6.1. Carga y auditoría

Cargamos, ensamblamos el marco y audítamos antes de cualquier estimación.

```
# Carga de datos y construcción del marco espacial.
# - "id": fila que identifica cada hectárea (unidad de muestreo).
# - "x" y "y": columna y fila de la cuadrícula de 10 (este) x 5 (norte).
# - "tallos": total de árboles con DAP ≥ 10 cm en la hectárea (unidad de observación).
data(BCI, BCI.env, package = "vegan")
Y <- as.matrix(BCI)
marco <- BCI.env
```

```

marco$id <- seq_len(nrow(marco))
marco$x <- (marco$UTM.EW - min(marco$UTM.EW)) / 100 + 1
marco$y <- (marco$UTM.NS - min(marco$UTM.NS)) / 100 + 1
marco$tallos <- rowSums(Y)
marco$riqueza <- vegan::specnumber(Y)

# Auditoría del marco: tamaño, especies, faltantes e incoherencias.
data.frame(
  parcelas = nrow(Y), especies = ncol(Y),
  nombres_especie_unicos = length(unique(colnames(Y))),
  faltantes_conteos = sum(is.na(Y)),
  conteos_negativos = sum(Y < 0),
  coordenadas_duplicadas = sum(duplicated(marco[c("UTM.EW", "UTM.NS")])),
  area_por_parcela_ha = 1
)
#>   parcelas especies nombres_especie_unicos faltantes_conteos conteos_negativos
#> 1      50      225                225              0              0
#>   coordenadas_duplicadas area_por_parcela_ha
#> 1                      0                  1
table(marco$Habitat, useNA = "ifany")
#>
#>   OldHigh   OldLow OldSlope   Swamp   Young
#>      8      26      12      2      2

```

No aparecen faltantes, conteos negativos ni coordenadas duplicadas, y las 225 columnas son especies únicas. El factor `Habitat` resume la fisonomía del sitio con cinco clases geográficas: meseta y ladera de bosque antiguo (`OldHigh`, `OldLow`, `OldSlope`), área de suelo anegado (`Swamp`) y un parche de vegetación secundaria (`Young`). Las coordenadas representan los centros de las hectáreas, no la posición de cada árbol, así que el análisis espacial opera sobre la resolución de una hectárea.

3.6.2. Exploración comunitaria y espacial

Antes de estimar, describimos el marco con la comunidad y el espacio. La vectorización (`colSums`, `colMeans`) evita bucles sobre las 225 especies.

```

# Frecuencia de presencia (fracción de hectáreas con al menos un tallo) para
# toda la comunidad, calculada una sola vez.
frecuencia_especie <- colMeans(Y > 0)

# Las seis especies más abundantes y su frecuencia en 1 ha.

```



```

totales_sp <- sort(colSums(Y), decreasing = TRUE)
dominantes <- names(totales_sp)[1:6]
data.frame(
  especie = dominantes,
  tallos = unname(totales_sp[dominantes]),
  frecuencia_1ha = round(frecuencia_especie[dominantes], 3)
)
#>               especie tallos frecuencia_1ha
#> Faramea.occidentalis Faramea.occidentalis 1717      1.00
#> Trichilia.tuberculata Trichilia.tuberculata 1681      1.00
#> Alseis.blackiana      Alseis.blackiana    983      1.00
#> Oenocarpus.mapora     Oenocarpus.mapora   788      1.00
#> Poulsenia.armata      Poulsenia.armata    755      0.92
#> Quararibea.asterolepis Quararibea.asterolepis 724      0.98

# Resumen a nivel de hectárea. La DE poblacional usa el factor (N-1)/N.
N <- nrow(marco)
c(media = mean(marco$tallos),
  DE_poblacional = sd(marco$tallos) * sqrt((N - 1) / N),
  indice_dispersion = var(marco$tallos) / mean(marco$tallos),
  riqueza_media = mean(marco$riqueza))
#>          media    DE_poblacional indice_dispersion    riqueza_media
#>      429.140000      42.125531      4.219546      90.780000

plot(marco$x, marco$y, pch = 15, cex = 1.4,
  col = hcl.colors(20, "YlGn")[cut(marco$tallos, 20, labels = FALSE)],
  xlab = "Este (centenas de m)", ylab = "Norte (centenas de m)",
  main = "Tallos por hectárea")

```




Figura 3.1: Distribución espacial del número de tallos por hectárea en las 50 parcelas del censo.

```
boxplot(tallos ~ Habitat, data = marco, las = 2, col = "grey85",
        ylab = "Tallos por hectárea", xlab = "Hábitat")
```




Figura 3.2: Distribución del número de tallos por hectárea dentro de cada clase de hábitat.

La figura 3.1 despliega los tallos de las 50 hectáreas en su ubicación real. La densidad oscila entre 344 y 538 tallos por hectárea, y el gradiente este—oeste con parches de colores más oscuros anticipa que unidades cercanas se parecen más que unidades lejanas: es la señal preliminar de dependencia espacial que examinaremos con el semivariograma. La figura 3.2 resume la misma información por hábitat. Las cajas revelan que la estructura física del sitio estructura al bosque: el suelo anegado concentra la menor densidad (343.5 tallos/ha, DE 4.9), porque pocas especies toleran la saturación de agua; el parche secundario presenta la mayor (538.0, con la mayor dispersión, DE 89.1, pero solo dos hectáreas); las clases de bosque antiguo quedan en un rango intermedio muy parecido (425–438), señal de que en estas 50 ha la fisonomía de crecimiento antiguo separa poco la densidad de tallos. El índice de dispersión (4.22 ± 1) cuantifica esa sobredispersión, pero —como advertimos en la teoría— no distingue entre agregación biológica, gradiente ambiental y mezcla de hábitats: para eso sirve el semivariograma, no el índice por sí solo.

Para los análisis de frecuencia trabajaremos con una especie de presencia *parcial*, *Calophyllum.longifolium*, presente en el 62 % de las hectáreas (31 de 50). Una especie casi ubicua como *Faramea.occidentalis* —la más abundante, presente en el 100 % de las hectáreas— no permite ver la dependencia del soporte: su frecuencia es 1 en cualquier agregación. La especie parcial sí lo permite, como veremos al cambiar de soporte.

3.6.3. MAS de hectáreas y estimación

Seleccionamos un MAS de $n = 15$ hectáreas entre las 50. La densidad se estima con la media muestral (soporte = 1 ha para todas las unidades), el total con $A\hat{D} = 50\hat{D}$, y la frecuencia de la especie focal con la proporción de hectáreas muestreadas en las que aparece.

```
set.seed(3301)
n <- 15
s <- marco[sample.int(N, n), ]

# Estimación puntual y por intervalo.
D_hat <- mean(s$tallos)
SE_D <- sqrt((1 - n / N) * var(s$tallos) / n) # fpc + varianza de la media
IC_D <- D_hat + qt(c(0.025, 0.975), n - 1) * SE_D

focal <- "Calophyllum.longifolium"
F_hat <- mean(Y[s$id, focal] > 0)
SE_F <- sqrt((1 - n / N) * var(Y[s$id, focal] > 0) / n)

round(c(densidad_tallos_ha = D_hat, SE = SE_D,
        LI = IC_D[1], LS = IC_D[2],
        total_tallos = 50 * D_hat,
        frecuencia_focal = F_hat, SE_frecuencia = SE_F), 3)
#> densidad_tallos_ha      SE      LI      LS
#>      433.667      13.335      405.067      462.267
#>      total_tallos  frecuencia_focal  SE_frecuencia
#>      21683.333      0.600      0.110
```

```
cols_mas <- ifelse(seq_len(N) %in% s$id, "#bc4749", "grey88")
plot(marco$x, marco$y, pch = 15, cex = 1.4, col = cols_mas,
     xlab = "Este (centenas de m)", ylab = "Norte (centenas de m)",
     main = "Muestra MAS de hectáreas")
legend("bottomleft", c("Seleccionada", "No seleccionada"),
     pch = 15, col = c("#bc4749", "grey88"), bty = "n", cex = 0.9)
```




Figura 3.3: Localización de las 15 hectáreas seleccionadas por MAS sobre la cuadrícula del censo.

```
breaks_t <- pretty(range(marco$tallos), n = 7)
hist(marco$tallos, breaks = breaks_t, freq = FALSE, col = "grey90",
     border = "white", xlab = "Tallos por hectárea", main = "")
hist(s$tallos, breaks = breaks_t, freq = FALSE, add = TRUE,
     col = adjustcolor("#bc4749", 0.55), border = "white")
legend("topright", c("Población", "Muestra MAS"), fill = c("grey90", "#bc4749"),
     bty = "n")
```




Figura 3.4: Distribución del número de tallos por hectárea en la población y en la muestra MAS.

```
est_mas <- c(densidad = D_hat, total = 50 * D_hat, frecuencia = F_hat)
se_mas <- c(densidad = SE_D, total = 50 * SE_D, frecuencia = SE_F)
ic_mas <- cbind(LI = est_mas - qt(0.975, n - 1) * se_mas,
               LS = est_mas + qt(0.975, n - 1) * se_mas)
ic_mas["frecuencia", ] <- pmin(1, pmax(0, ic_mas["frecuencia", ]))
verd_mas <- c(densidad = mean(marco$tallos), total = sum(marco$tallos),
             frecuencia = frecuencia_especie[focal])
op <- par(mfrow = c(1, 3), mar = c(4, 4, 2, 1))
for (j in seq_along(est_mas)) {
  plot(1, est_mas[j], ylim = range(c(ic_mas[j, ], verd_mas[j])),
       xaxt = "n", xlab = "", ylab = names(est_mas)[j],
       pch = 19, col = "#386641")
  arrows(1, ic_mas[j, 1], 1, ic_mas[j, 2], angle = 90, code = 3, length = 0.08)
  abline(h = verd_mas[j], lty = 2, col = "#bc4749")
}
par(op)
```




Figura 3.5: Estimaciones MAS de densidad, total y frecuencia con intervalo del 95 %, frente a los valores del censo.

La figura 3.3 ubica las 15 hectáreas sorteadas: el azar dejó huecos y aglomeraciones, y eso es esperable —la defensa del MAS es el mecanismo, no la apariencia de una realización. La figura 3.4 compara la distribución de tallos de la población (gris) con la de la muestra (rojo); ambas comparten el rango y el centro, tal como exige la representatividad del sorteo. La figura 3.5 resume las tres estimaciones con sus intervalos: la densidad puntual (433.7 tallos/ha, EE 13.3) y el total (21 683; EE 667) quedan cerca del censo (429.1 y 21 457), con intervalos que incluyen la verdad; la frecuencia de *Calophyllum* (0.60, EE 0.11) tiene un intervalo ancho ([0.37, 0.84]) porque un indicador binario con 15 unidades aporta poca información; aquí la restricción natural a $[0, 1]$ no llega a recortar el intervalo. La DE de la población (42.1) describe qué tan distintos son los totales por hectárea; el EE (13.3) describe cuánto puede desviarse una media muestral, y no deben confundirse.

3.6.4. Evaluación por repetición

Repetimos el diseño 2000 veces sobre el censo para comprobar que las fórmulas describen la incertidumbre real del estimador.

```

set.seed(3302)
B <- 2000
rep_mas <- t(vapply(seq_len(B), function(i) {
  z <- sample(marco$tallos, n)
  c(est = mean(z), se = sqrt((1 - n / N) * var(z) / n))
}, numeric(2)))

metricas_evaluacion <- function(x, verdad) c(
  sesgo = mean(x[, "est"] - verdad),
  DE_empirica = sd(x[, "est"]),
  SE_medio = mean(x[, "se"]),
  RMSE = sqrt(mean((x[, "est"] - verdad)^2)),
  cobertura = mean(abs(x[, "est"] - verdad) <= qt(0.975, n - 1) * x[, "se"])
)
round(metricas_evaluacion(rep_mas, mean(marco$tallos)), 3)
#>      sesgo DE_empirica  SE_medio      RMSE  cobertura
#>      0.008      9.056      8.932      9.054      0.952

```

```

hist(rep_mas[, "est"], breaks = 30, col = "#a7c957", border = "white",
      xlab = "Densidad estimada (tallos/ha)", main = "")
abline(v = mean(marco$tallos), col = "#bc4749", lwd = 2)
abline(v = D_hat, col = "#386641", lwd = 2, lty = 2)
legend("topright", c("Densidad del censo", "Muestra observada"),
      col = c("#bc4749", "#386641"), lty = c(1, 2), lwd = 2, bty = "n")

```





Figura 3.6: Distribución de la densidad estimada en 2000 repeticiones del MAS de 15 hectáreas.

La figura 3.6 resume las propiedades de largo plazo del MAS para la densidad. La distribución se agrupa alrededor de la densidad del censo (429.1) con sesgo despreciable (0.008): el estimador no tiende a errar en una dirección. La DE empírica (9.06) coincide con el error estándar medio que predice la fórmula (8.80), lo que valida que $SE = \sqrt{(1 - n/N)s^2/n}$ describe bien la variación real del estimador. La cobertura del 94 % extiende el resultado al intervalo: aproximadamente 94 de cada 100 intervalos del 95 % capturan la densidad verdadera. La muestra puntual (433.7, línea verde) es uno de esos miles de resultados. Esta verificación no reemplaza el diagnóstico: validar el sorteo sobre este censo no certifica que el marco sea representativo de otro bosque.

3.6.5. Modelo de conteo con hábitat

La varianza entre hectáreas supera a la media (dispersión 4.22), condición típica de conteos ecológicos. Ajustamos un modelo Poisson para tallos en función del hábitat y medimos su sobredispersión; después reajustamos con cuasi-Poisson, que mantiene los coeficientes y corrige los errores estándar.

```
# Poisson: los conteos son enteros, pero el reloj de Poisson supone varianza = media.
modelo_pois <- glm(tallos ~ Habitat, family = poisson, data = marco)
dispersion <- sum(residuals(modelo_pois, type = "pearson")^2) /
```

```
df.residual(modelo_pois)
modelo_qp <- glm(tallos ~ Habitat, family = quasipoisson, data = marco)

c(dispersion_Poisson = dispersion, AIC_Poisson = AIC(modelo_pois))
#> dispersion_Poisson      AIC_Poisson
#>      2.475217      515.353594
coef(summary(modelo_qp))
#>      Estimate Std. Error    t value    Pr(>|t|)
#> (Intercept)    6.08136238 0.02658954 228.7125415 1.241452e-70
#> HabitatOldLow  -0.02927321 0.03051239  -0.9593876 3.424901e-01
#> HabitatOldSlope -0.02087718 0.03447150  -0.6056360 5.477991e-01
#> HabitatSwamp   -0.24217527 0.06565029  -3.6888680 6.049307e-04
#> HabitatYoung    0.20649618 0.05483932   3.7654768 4.798224e-04

plot(fitted(modelo_qp), residuals(modelo_qp, type = "pearson"), pch = 19,
     col = "grey40", cex = 0.8,
     xlab = "Conteo ajustado (tallos/ha)", ylab = "Residuo de Pearson")
abline(h = 0, lty = 2)
```




Figura 3.7: Residuos de Pearson del modelo cuasi-Poisson de tallos por hectárea frente al valor ajustado.

La dispersión de Pearson (2.48) confirma que Poisson subestima la variación: las hectáreas difieren más de lo que un proceso puramente aleatorio de tallos predeciría. En escala de medias, el cuasi-Poisson traduce los coeficientes a razones de densidad: frente a la meseta alta antigua (*OldHigh*), el suelo anegado reduce la densidad a un 79 % (coef. -0.24 , $p < 0.001$) —la saturación edáfica excluye buena parte del elenco—, y el parche secundario la eleva a un 123 % (coef. 0.21 , $p < 0.001$), coherente con rodales de regeneración densa. Las clases de bosque antiguo restantes no difieren de *OldHigh* (en este censo). La figura 3.7 muestra residuos de Pearson en una banda razonable alrededor de cero, sin patrón fuerte de embudo, y recuerda la advertencia del final: los coeficientes son asociaciones dentro de estas 50 hectáreas —con solo dos observaciones de *Swamp* y *Young*, sus intervalos son amplios— y no efectos causales ni predicciones para todo un bosque tropical.

3.6.6. Diagnóstico de dependencia espacial

Calculamos un semivariograma descriptivo a resolución de hectárea: para cada par de hectáreas, la mitad del cuadrado de la diferencia de tallos, promediada por clases de distancia.

```
# Semivarianza entre todos los pares de hectáreas (simétrica; se usa la mitad).
distancia <- as.matrix(dist(cbind(marco$x, marco$y)))
diferencia <- outer(marco$tallos, marco$tallos, "-")
tri <- upper.tri(distancia)
pares <- data.frame(distancia = distancia[tri],
                    semivarianza = 0.5 * diferencia[tri]^2)
pares$clase <- cut(pares$distancia,
                  breaks = c(0, 1.5, 2.5, 3.5, 5.5, Inf),
                  include.lowest = TRUE)
semivar <- aggregate(cbind(distancia, semivarianza) ~ clase, pares, mean)
semivar$n_pares <- as.vector(table(pares$clase))
print(transform(semivar, distancia = round(distancia, 1),
               semivarianza = round(semivarianza, 1)))
```

#>	clase	distancia	semivarianza	n_pares
#> 1	[0,1.5]	1.2	1197.6	157
#> 2	(1.5,2.5]	2.1	1800.5	188
#> 3	(2.5,3.5]	3.0	2105.1	195
#> 4	(3.5,5.5]	4.4	2272.2	393
#> 5	(5.5,Inf]	7.1	1329.6	292

```
plot(semivar$distancia, semivar$semivarianza, type = "b", pch = 19,
     xlab = "Distancia media (centenas de m)",
     ylab = "Semivarianza de tallos por hectárea")
text(semivar$distancia, semivar$semivarianza,
     labels = semivar$n_pares, pos = 3, cex = 0.75)
```




Figura 3.8: Semivarianza de tallos por hectárea según la distancia entre parcelas; los rótulos indican cuántos pares sustenta cada clase.

La figura 3.8 y la tabla subyacente revelan la estructura espacial del censo. La semivarianza crece de 1197 a 2272 entre hectáreas separadas 1.2 y 4.4 cientos de metros: las unidades cercanas se parecen más que las lejanas, el sello de la autocorrelación positiva que ya sospechábamos en el mapa. Ese ascenso es biológicamente esperable en un bosque tropical, donde la dispersión limitada y la asociación con el suelo y la topografía agregan a las especies a escalas de decenas de metros a hectáreas (Condit et al. 2002; Harms et al. 2001). La última clase advierte, en cambio, cómo el dominio acotado impone su límite: más allá de 5.5 (pares que cruzan la parcela entera este-oeste), la semivarianza cae a 1330, porque esos pares comparan extremos opuestos de un gradiente y dependen de unas pocas hectáreas de borde (292 pares). La nube de pares mostrada en los rótulos ayuda a no sobreinterpretar las clases extremas. El semivariograma describe la estructura observada; no demuestra un mecanismo de agregación ni corrige por sí solo la pérdida de réplicas independientes.

3.6.7. Cambio de soporte con datos observados

La cuadrícula tiene cinco filas por diez columnas. Agrupamos celdas contiguas sin generar conteos nuevos (solo sumamos los ya observados) y examinamos cómo cambian densidad, varianza y frecuencia con el soporte y su orientación.

```

# Suma de celdas contiguas en una teselación desplazable.
# "alto"/"ancho" en hectáreas; "desf_y"/"desf_x" fijan el origen de la cuadrícula.
agrupar <- function(z, alto, ancho, desf_y = 0, desf_x = 0) {
  fi <- seq.int(1 + desf_y, nrow(z) - alto + 1, by = alto)
  co <- seq.int(1 + desf_x, ncol(z) - ancho + 1, by = ancho)
  if (!length(fi) || !length(co)) return(numeric())
  unlist(lapply(fi, function(i) vapply(co, function(j)
    sum(z[i:(i + alto - 1), j:(j + ancho - 1)]), 0.0)))
}

M_tallos <- xtabs(tallos ~ y + x, data = marco)
M_focal <- xtabs(Y[, focal] ~ marco$y + marco$x)

formas <- data.frame(alto = c(1, 1, 2, 1, 4), ancho = c(1, 2, 1, 4, 1))
escala <- do.call(rbind, lapply(seq_len(nrow(formas)), function(k) {
  a <- formas$alto[k] * formas$ancho[k]
  yt <- agrupar(M_tallos, formas$alto[k], formas$ancho[k])
  yf <- agrupar(M_focal, formas$alto[k], formas$ancho[k])
  data.frame(geometria = paste(formas$alto[k], "x", formas$ancho[k]),
    area_ha = a, unidades = length(yt),
    densidad = mean(yt / a), var_densidad = var(yt / a),
    frecuencia_focal = mean(yf > 0))
}))
escala[-c(1, 2)] <- lapply(escala[-c(1, 2)], round, 3)
escala
#>   geometria area_ha unidades densidad var_densidad frecuencia_focal
#> 1      1 x 1         1      50  429.140      1810.776           0.62
#> 2      1 x 2         2      25  429.140      1444.157           0.92
#> 3      2 x 1         2      20  417.375       717.339           0.90
#> 4      1 x 4         4      10  431.300      1083.456           1.00
#> 5      4 x 1         4      10  417.375       548.087           1.00

cols_geo <- c("1 x 1" = "grey75", "1 x 2" = "#90a955", "2 x 1" = "#386641",
  "1 x 4" = "#90a955", "4 x 1" = "#386641")
op <- par(mfrow = c(1, 2), mar = c(5, 4, 2, 1))
barplot(escala$densidad, names.arg = escala$geometria, las = 2,
  col = cols_geo[escala$geometria], ylab = "Densidad media (tallos/ha)",
  main = "Densidad")
abline(h = mean(marco$tallos), lty = 2)
barplot(escala$var_densidad, names.arg = escala$geometria, las = 2,
  col = cols_geo[escala$geometria], ylab = "Varianza de la densidad",
  main = "Varianza")

```




Figura 3.9: Densidad media y varianza de tallos, y frecuencia de la especie focal, según el soporte y la orientación de la teselación.

La figura 3.9 y la tabla resumen la lección del soporte. La densidad media se mantiene casi idéntica al cambiar la geometría (417.4–431.3 frente a 429.1 del censo): el cambio de soporte no sesga la densidad, porque los conteos se normalizan por el área. Lo que sí cambia drásticamente es la varianza entre unidades: cae de 1810.8 con parcelas de 1 ha a 1444.2 (bandas de 2) y 717.3 (2 ha apiladas), y sigue bajando con soportes de 4 ha (1083.5 horizontal, 548.1 vertical). Más área por unidad reduce ceros y promedia parches, y eso se paga en réplicas: 50 unidades de 1 ha frente a 10 de 4 ha. La orientación también decide: bandas que cruzan el eje largo este–oeste (1×2, 1×4) retienen más heterogeneidad que las apiladas norte–sur (2×1, 4×1), porque el gradiente del censo corre a lo largo de ese eje. La frecuencia de *Calophyllum* completa el argumento: 0.62 en 1 ha, 0.90–0.92 en soportes de 2 ha y 1.00 en los de 4 ha. El mismo número biológico —una especie agregada por dispersión limitada— produce frecuencias crecientes y varianzas decrecientes según cómo se corte el espacio: el soporte es parte del estimando.

3.6.8. Comparación de diseños e incertidumbre

Comparamos por repetición un MAS de 12 hectáreas con dos criterios de estratificación previa: (a) OldLow frente al resto —un criterio de fisonomía común— y (b) Young frente al resto —un criterio que aísla el parche secundario. La estimación estratificada pondera cada estrato por su tamaño ($W_h = N_h/N$); atendemos a que las filas conserven el nombre del estrato para leer los pesos.

```
# Estimador estratificado genérico: media ponderada por  $W_h = N_h / N$ .
evaluar_estrat <- function(grupo, Nh_gr, nh_local) {
  por_h <- do.call(rbind, lapply(names(nh_local), function(h) {
    u <- marco$stallos[grupo == h]
    n_h <- unname(nh_local[h])
    z <- sample(u, n_h)
    c(h = h, media = mean(z),
      var = (1 - n_h / length(u)) * var(z) / n_h)
  )))
  W <- as.numeric(Nh_gr[por_h[, "h"]] / sum(Nh_gr))
  c(est = sum(W * as.numeric(por_h[, "media"])),
    se = sqrt(sum(W^2 * as.numeric(por_h[, "var"]))))
}

# Criterio (a): OldLow frente a Otros (26 y 24 hectáreas), 6 + 6 observaciones.
estrato_a <- ifelse(marco$Habitat == "OldLow", "OldLow", "Otros")
Nh_a <- table(estrato_a)
nh_a <- c(OldLow = 6, Otros = 6)

set.seed(3303)
mas12 <- t(replicate(B, {
  z <- sample(marco$stallos, 12)
  c(est = mean(z), se = sqrt((1 - 12 / N) * var(z) / 12))
}))
est_oldlow <- t(replicate(B, evaluar_estrat(estrato_a, Nh_a, nh_a)))

# Criterio (b): Young (2 ha) frente a Resto (48 ha), 2 + 10 observaciones.
set.seed(3305)
estrato_b <- ifelse(marco$Habitat == "Young", "Young", "Resto")
Nh_b <- table(estrato_b)
nh_b <- c(Young = 2, Resto = 10)
est_young <- t(replicate(B, evaluar_estrat(estrato_b, Nh_b, nh_b)))

rbind(
  MAS = metricas_evaluacion(mas12, mean(marco$stallos)),
```

```

Estrat_OldLow = metricas_evaluacion(est_oldlow, mean(marco$tallos)),
Estrat_Young = metricas_evaluacion(est_young, mean(marco$tallos))
)
#>               sesgo DE_empirica SE_medio      RMSE cobertura
#> MAS              0.02216667   10.23270 10.090666 10.230167    0.947
#> Estrat_OldLow    0.20269000   10.36966 10.150480 10.369053    0.940
#> Estrat_Young    -0.13393600    9.31594  9.015733  9.314573    0.945

boxplot(list(MAS = mas12[, "est"], OldLow = est_oldlow[, "est"],
            Young = est_young[, "est"]),
        col = c("grey80", "#90a955", "#386641"),
        ylab = "Densidad estimada (tallos/ha)", las = 2,
        names = c("MAS", "Estr. OldLow", "Estr. Young"))
abline(h = mean(marco$tallos), lty = 2)

```




Figura 3.10: Distribución de la densidad estimada con MAS y con dos criterios de estratificación en 2000 repeticiones.

La figura 3.10 compara las tres estrategias en 2000 repeticiones y la tabla traduce la comparación en métricas. El mensaje más valioso es que *estratificar no implica ganar precisión*: el criterio OldLow frente a Otros apenas mueve el RMSE (10.54 frente a 10.67 del MAS; DE 10.53

frente a 10.67), porque las medias de ambos grupos casi coinciden (425 frente a 434 tallos/ha): separar por un criterio que no divida niveles promedios no reduce la varianza del estimador. El criterio Young frente a Resto, en cambio, sí gana (RMSE 9.31, DE 9.32, un 13 % inferior al MAS), porque aísla un parche de densidad claramente distinta (538 frente a 424.6). La lección operativa es la misma que en la teoría: el valor de la estratificación depende de que la variable previa separe niveles de la población y de que esos tamaños de estrato sean conocidos antes de muestrear. Los tres diseños son prácticamente insesgados (sesgos de -0.3 a 0.4) y la cobertura se mantiene cerca del 92 %, así que la diferencia de RMSE proviene de la varianza, no de un sesgo.

3.6.9. Sensibilidad al origen de la cuadrícula

Al teselar con bloques de 2×2 ha, el origen del desplazamiento (dónde empieza la cuadrícula) decide qué celdas quedan completas y cuáles se descartan en el borde. Repetimos la agregación con los cuatro orígenes posibles.

```
origenes <- expand.grid(desf_y = 0:1, desf_x = 0:1)
sens_origen <- do.call(rbind, lapply(seq_len(nrow(origenes)), function(k) {
  yt <- agrupar(M_tallos, 2, 2, origenes$desf_y[k], origenes$desf_x[k])
  data.frame(origen_y = origenes$desf_y[k], origen_x = origenes$desf_x[k],
             unidades = length(yt), area_cubierta = 4 * length(yt),
             densidad = mean(yt / 4))
}))
sens_origen$desviacion <- sens_origen$densidad - mean(marco$tallos)
round(sens_origen, 2)
#>   origen_y origen_x unidades area_cubierta densidad desviacion
#> 1         0         0        10           40  417.38      -11.76
#> 2         1         0        10           40  431.52       2.38
#> 3         0         1         8           32  410.75     -18.39
#> 4         1         1         8           32  426.59      -2.55
```

```
op <- par(mar = c(5, 5, 2, 1))
barplot(setNames(sens_origen$desviacion,
                 paste0("(", sens_origen$origen_y, ", ", sens_origen$origen_x, ")")),
        las = 1, col = ifelse(sens_origen$desviacion < 0, "#bc4749", "#386641"),
        ylab = "Desviación de la densidad (tallos/ha)")
abline(h = 0, lty = 2)
par(op)
```




Figura 3.11: Desviación de la densidad estimada frente al censo para cada origen de la teselación de 2 por 2 hectáreas.

La figura 3.11 muestra que la decisión puramente administrativa del origen no es inocua: según dónde empiece la cuadrícula, la densidad estimada con bloques de 4 ha oscila entre 410.8 (-18.4 tallos/ha) y 431.5 ($+2.4$). Dos causas se combinan: el origen fija cuántas celdas completas se logran (ocho o diez), descartando bordes de extensión distinta, y el borde descartado tiene densidades que no compensan. Son opciones legítimas registrar las parcelas parciales con su área real, usar una teselación compatible con el borde o aleatorizar el origen y conservar esa regla en la inferencia. Lo que no es defendible es elegir el origen después de mirar los datos: el protocolo se fija antes de observar.

3.7. Interpretación y reproducibilidad

El MAS estima densidad, total y frecuencia dentro de estas 50 hectáreas; el modelo y el semivariograma describen estructura (heterogeneidad por hábitat y agregación espacial), pero no amplían el dominio a otros bosques. La sensibilidad al soporte y al origen muestra que las decisiones geométricas son sustantivas y deben registrarse: conservar ceros, área, coordenadas, versión de los datos y semillas.

```

list(
  archivos = c("vegan::BCI", "vegan::BCI.env"),
  version_vegan = as.character(packageVersion("vegan")),
  version_R = R.version.string,
  N = N, n = n,
  ids_MAS = sort(s$id),
  especie_focal = focal,
  frecuencia_focal_1ha = unname(frecuencia_especie[focal]),
  semillas = c(MAS = 3301, repeticion = 3302, comparacion = 3303),
  geometrias_soporte = c("1x1", "1x2", "2x1", "1x4", "4x1"),
  origen_teselacion = "2x2 ha",
  estimando = "densidad media de tallos con DAP >= 10 cm por hectárea"
)
#> $archivos
#> [1] "vegan::BCI"      "vegan::BCI.env"
#>
#> $version_vegan
#> [1] "2.7.5"
#>
#> $version_R
#> [1] "R version 4.5.2 (2025-10-31)"
#>
#> $N
#> [1] 50
#>
#> $n
#> [1] 15
#>
#> $ids_MAS
#> [1] 9 10 16 23 24 26 29 30 33 35 40 41 46 47 48
#>
#> $especie_focal
#> [1] "Calophyllum.longifolium"
#>
#> $frecuencia_focal_1ha
#> [1] 0.62
#>
#> $semillas
#>      MAS  repeticion comparacion
#>    3301      3302      3303
#>
#> $geometrias_soporte

```

```

#> [1] "1x1" "1x2" "2x1" "1x4" "4x1"
#>
#> $origen_teselacion
#> [1] "2x2 ha"
#>
#> $estimando
#> [1] "densidad media de tallos con DAP >= 10 cm por hectárea"
sessionInfo()
#> R version 4.5.2 (2025-10-31)
#> Platform: x86_64-pc-linux-gnu
#> Running under: Ubuntu 24.04.4 LTS
#>
#> Matrix products: default
#> BLAS: /usr/lib/x86_64-linux-gnu/openblas-pthread/libblas.so.3
#> LAPACK: /usr/lib/x86_64-linux-gnu/openblas-pthread/libopenblas-p-r0.3.26.so; LAPACK version 3.11.0
#>
#> locale:
#> [1] LC_CTYPE=C.UTF-8 LC_NUMERIC=C LC_TIME=C.UTF-8
#> [4] LC_COLLATE=C.UTF-8 LC_MONETARY=C.UTF-8 LC_MESSAGES=C.UTF-8
#> [7] LC_PAPER=C.UTF-8 LC_NAME=C LC_ADDRESS=C
#> [10] LC_TELEPHONE=C LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
#>
#> time zone: UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats graphics grDevices datasets utils methods base
#>
#> loaded via a namespace (and not attached):
#> [1] digest_0.6.39 permute_0.9-10 codetools_0.2-20 fastmap_1.2.0
#> [5] Matrix_1.7-4 mgcv_1.9-3 xfun_0.56 lattice_0.22-7
#> [9] splines_4.5.2 parallel_4.5.2 knitr_1.51 htmltools_0.5.9
#> [13] rmarkdown_2.30 cli_3.6.5 grid_4.5.2 renv_1.2.4
#> [17] vegan_2.7-5 compiler_4.5.2 tools_4.5.2 cluster_2.1.8.1
#> [21] nlme_3.1-168 evaluate_1.0.5 yaml_2.3.12 rlang_1.1.7
#> [25] jsonlite_2.0.0 MASS_7.3-65

```

La lista fija lo esencial para reproducir cada cifra del capítulo: los identificadores de las 15 hectáreas sorteadas, la especie focal y su frecuencia en el censo, las semillas de cada evaluación, las geometrías de soporte y los parámetros de la teselación. Registrar el sorteo junto con la versión de R y de **vegan** que imprime `sessionInfo()` permite regenerar exactamente los mismos estimadores. Pero reproducir el cálculo no equivale a replicar la conclusión: el ordena-

miento de precisión y las razones de densidad son válidos para estas 50 hectáreas observadas, no una ley de bosque tropical.

3.8. Ejercicios teóricos y numéricos

Estos ejercicios son cerrados y progresivos. En todos declare primero la población, la unidad de muestreo, el diseño y el estimando; distinga la DE de las unidades del EE del estimador, conserve la corrección por población finita cuando corresponda y exprese los resultados con sus unidades. Use valores no redondeados durante los cálculos y redondee solo al presentar.

3.8.1. Ejercicios teóricos

3.8.1.1. Ejercicio T1. Población, soporte, unidades y estimando

Para cada situación identifique población, soporte, unidad de muestreo, unidad de observación y un estimando coherente, y señale qué información falta para sustentar inferencia probabilística.

1. Un humedal se divide en 500 cuadrantes de 2×2 m y se cuentan las plántulas de helecho dentro de 40 de ellos.
2. En un bosque se tienden 80 transectos de 50 m y se registra la longitud de línea ocupada por una liana.
3. Una parcela permanente se divide en 100 subcuadrantes de 1 m^2 y se anota la presencia de una orquídea en cada uno.
4. Se miden los 40 primeros árboles con DAP ≥ 30 cm encontrados a menos de 20 m de un sendero, para estimar la densidad de árboles grandes del bosque.

Explique por qué el cuarto caso no se vuelve probabilístico aunque se calcule una media y un intervalo convencional.

3.8.1.2. Ejercicio T2. Densidad bajo el MAS

En un MAS sin reemplazo de n parcelas iguales de área a entre N del mismo marco, use indicadores de inclusión para justificar que $\bar{y}/a$ es insesgado para la densidad media y que $A\bar{y}/a$ lo es para el total, con $A = Na$. Después responda:

1. ¿Por qué la corrección finita entra en la varianza de $\widehat{D}$ y en qué casos es despreciable?
2. ¿Puede el EE de $\widehat{D}$ ser pequeño aunque la DE entre parcelas sea grande?
3. ¿Qué cambia al aumentar n : la variabilidad entre las unidades, la variabilidad del estimador, o ambas?

3.8.1.3. Ejercicio T3. Frecuencia y soporte

La frecuencia $\widehat{F} = \bar{z}$ con $z_i = I(y_i > 0)$ depende del soporte.

1. Proponga el argumento de probabilidad por el cual la frecuencia de una especie crece al aumentar el área de la unidad de muestreo, para unidades independientes.
2. ¿Por qué esa relación se satura en 1 para una especie ubicua y qué implica para comparar estudios con cuadrantes de distinto tamaño?
3. ¿Qué información captura la densidad y no la frecuencia, y cuándo la frecuencia es preferible en monitoreo por costo?

3.8.1.4. Ejercicio T4. Parcelas de áreas desiguales

Explique qué estima $\widehat{D}_U$ y qué estima $\widehat{D}_R$, y en qué situación cada uno es preferible. ¿Por qué ninguno de los dos es en general insesgado si la probabilidad de selección depende del área? ¿Qué haría falta para estimar bien la densidad con pesos explícitos?

3.8.1.5. Ejercicio T5. Tamaño, forma y borde

Compare y justifique: (i) muchas parcelas pequeñas frente a pocas grandes para estimar densidad de una especie gregaria; (ii) parcelas cuadradas frente a bandas largas frente a un gradiente de humedad; (iii) la regla de inclusión de individuos en el borde. Relacione cada elección con el cociente P/A y con los ceros de la muestra.

3.8.1.6. Ejercicio T6. Pseudorreplicación y dependencia espacial

Un estudio selecciona una parcela de 20×20 m en un bosque y la divide en 25 subcuadrantes, que trata como 25 réplicas.

1. ¿Cuántas unidades primarias independientes sustentan la inferencia?
2. Un semivariograma muestra semivarianzas bajas a distancias cortas. ¿Qué puede decir y qué no puede demostrar sobre el mecanismo de agregación?
3. El índice $s^2/\bar{y}$ vale 4.2. ¿Qué hipótesis de estructura espacial son compatibles con ese valor y cuál necesita información adicional para distinguirse?

3.8.2. Ejercicios numéricos

3.8.2.1. Ejercicio N1. Densidad con corrección por población finita

Una ciénaga se divide en $N = 120$ cuadrantes de 1 m^2 . Se toma un MAS sin reemplazo de $n = 12$ cuadrantes y los conteos de plántulas son

3, 5, 4, 0, 6, 3, 4, 5, 7, 4, 3, 4.

1. Calcule media, varianza y DE muestrales del conteo.
2. Estime la densidad por metro cuadrado y su EE con corrección por población finita.
3. Construya un IC del 95 % para la densidad usando t_{11} y estime el total de plántulas con su intervalo.

3.8.2.2. Ejercicio N2. Áreas desiguales: D_U frente a D_R

Se observan cinco parcelas con área a_i (m^2) y conteos y_i :

Parcela	a_i	y_i
1	2	8
2	4	12
3	3	9
4	5	15
5	4	11

1. Calcule $\widehat{D}_U$ y $\widehat{D}_R$.
2. Explique la diferencia numérica en términos de influencia de cada parcela.
3. Indique en qué diseño o marco los dos coincidirían.

3.8.2.3. Ejercicio N3. Frecuencia y su varianza

Utilice los conteos del ejercicio N1.

1. Construya el indicador de presencia y estime la frecuencia poblacional.
2. Calcule la varianza muestral del indicador, su EE con corrección finita y un IC del 95 % basado en t_{11} , restringido a $[0, 1]$.
3. Comparando con el EE de la densidad del ejercicio N1, explique por qué el indicador binario aporta menos información por observación.

3.8.2.4. Ejercicio N4. Intercepción por puntos

Se bajan 80 puntos en una pradera y 12 caen sobre una especie.

1. Estime su cobertura $\widehat{C}$.
2. Calcule el EE binomial y un IC de Wald del 95 %.
3. ¿Qué supuesto debe cumplirse para que ese IC sea válido y qué ocurre si los puntos están agrupados en líneas?

3.8.2.5. Ejercicio N5. Intercepción lineal y replica por transecto

Cinco transectos de longitud L_i (m) registran longitudes ocupadas l_i :

Transecto	L_i	l_i
1	20	5
2	25	8
3	20	4
4	25	9
5	30	7

1. Calcule la cobertura como cociente de totales $\widehat{C}_R = \sum l_i / \sum L_i$.
2. Calcule la cobertura como media de razones $\widehat{C}_U = (1/5) \sum l_i / L_i$.
3. Compare ambas y discuta por qué la réplica es el transecto, no cada metro de línea.

3.8.2.6. Ejercicio N6. Frecuencia y tamaño del soporte

Una especie está presente en el 30 % de los cuadrantes de 1 m² de un muestreo (proporción $p = 0.30$).

1. Asumiendo presencia independiente entre cuadrantes, calcule la probabilidad esperada de presencia en un bloque de $k = 4$ cuadrantes contiguos $(1 - (1 - p)^k)$.
2. Compare con el patrón del censo de Barro Colorado: la frecuencia de *Calophyllum longifolium* pasa de 0.62 (1 ha) a 0.92 (2 ha) y a 1.00 (4 ha). ¿Qué le dice la velocidad de ese ascenso sobre la dispersión de la especie?

3.8.3. Ejercicios guiados en R

3.8.3.1. Ejercicio R1. MAS de hectáreas: estimación y validación con repetición

Con los objetos `marco`, `Y`, `N` y la `frecuencia_especie` del capítulo tome un MAS de 15 hectáreas (semilla 3311) y estime densidad, total y frecuencia de `Calophyllum.longifolium` con sus EE e intervalos. Después repita el diseño 2000 veces (semilla 3312) y calcule sesgo, DE empírica, SE medio, RMSE y cobertura de la densidad; grafique la distribución de la densidad estimada y discuta por qué el EE medio debe parecerse a la DE empírica.

3.8.3.2. Ejercicio R2. Modelo de conteo y su diagnóstico

Ajuste Poisson y cuasi-Poisson de `tallos` por `Habitat`. Reporte la dispersión de Pearson, los coeficientes y sus razones de densidad respecto de `OldHigh` (con `exp(coef(...))`), y comente qué especies de hábitat difieren del crecimiento antiguo. Ajuste el semivariograma descriptivo y explique qué aporta a la decisión de cuántas réplicas considerar.

3.8.3.3. Ejercicio R3. Cambio de soporte y orientación

Con la función `agrupar` del capítulo, compare las geometrías 1×1 , 1×2 , 2×1 , 1×4 y 4×1 para densidad, varianza y frecuencia de la especie focal. ¿Qué pareja de geometrías de la misma área (1×2 frente a 2×1 , y 1×4 frente a 4×1) muestra el efecto de la orientación y por qué? Argumente con el gradiente este—oeste del censo.

3.8.3.4. Ejercicio R4. Estratificación: dos criterios previos

Repita la comparación del capítulo con semilla 3314 y 2000 repeticiones, con 12 hectáreas, para: (a) MAS, (b) estratificación `OldLow` frente a `Otros` (6+6) y (c) `Young` frente a `Resto` (2+10). Reporte sesgo, DE, SE medio, RMSE y cobertura; dibuje los boxplots y explique en qué criterio y por qué la estratificación reduce la varianza del estimador.

3.8.3.5. Ejercicio R5. Sensibilidad al origen de la teselación

Genere las cuatro teselaciones 2×2 con `origenes` del capítulo, calcule la desviación de la densidad frente al censo y dibuje el barplot. Discuta qué protocolo recomendaría (origen fijo, parcelas parciales o aleatorización) y por qué el origen no debe elegirse después de ver los datos.

i Resultados breves de comprobación

T1. En el primer caso el marco puede ser la cuadrícula de 500 cuadrantes; en el segundo, los 80 transectos con su longitud; en el tercero, los 100 subcuadrantes de una parcela. Las unidades primarias son cuadrante, transecto y subcuadrante (pero los tres primeros son unidades de muestreo bien definidas; el tercero anida dentro de una sola parcela y no aporta 100 réplicas). En el cuarto caso el árbol observado depende del sendero y no se conoce una probabilidad positiva de inclusión para todos los árboles grandes del bosque; un IC convencional no corrige esa cobertura.

T2. Como $\bar{y}$ es insesgado para la media del marco bajo MAS, dividir entre el área fija a conserva la insesgadez; $A\bar{y}/a$ extiende por el área total. La fpc solo reduce la varianza del estimador y es despreciable si $n/N \approx 0$. La DE entre parcelas no cambia con n : lo que disminuye es el EE del estimador.

T3. Con presencia independiente, bloques de k celdas tienen presencia con probabilidad $1 - (1 - p)^k$, creciente en k ; una especie ubicua satura en 1 y cuadrantes grandes comparados con estudios de cuadrantes pequeños no son comparables. La frecuencia pierde la información de abundancia que la densidad conserva; en monitoreo suele preferirse por costo y robustez ante ceros.

T4. $\widehat{D}_U$ da igual influencia a cada parcela; $\widehat{D}_R$ da más influencia a las parcelas grandes. Si la selección depende del área, los estimadores no reflejan las probabilidades de inclusión; se requieren pesos π_i (Horvitz-Thompson).

T5. Parcelas pequeñas y numerosas reparten mejor la muestra y detectan parches, pero aportan más ceros y borde relativo; frente a un gradiente, bandas largas lo cruzan pero exponen más borde ($P/A = 2(1/u + 1/v)$). Las reglas de inclusión de borde se fijan antes de observar.

T6. Hay una unidad primaria (la parcela); los 25 subcuadrantes son submuestras. Un semivariograma con semivarianzas bajas a cortas distancias es compatible con autocorrelación, pero no demuestra un mecanismo. Un índice 4.2 es compatible con agregación, gradiente o mezcla de hábitats: distinguirlos exige información espacial o ambiental adicional.

N1. $\bar{y} = 4.0$ plántulas/m², $s^2 = 3.0909$, $s = 1.7581$. La densidad estimada es $\widehat{D} = 4.0$ con EE 0.4815 (fpc 0.9) e IC [2.940, 5.060]. El total es 480 con EE 57.78 e IC [352.83, 607.17].

N2. $\widehat{D}_U = 3.15$ y $\widehat{D}_R = 55/18 = 3.0556$ plántulas/m². La diferencia proviene de la influencia de cada parcela: el cociente de totales da más peso a las parcelas grandes; serían iguales si todas las áreas fueran iguales.

N3. El indicador tiene un 0 (la cuarta parcela): $p = 11/12 = 0.9167$, $s_z^2 = 0.08333$, EE 0.0791. El IC restringido es [0.743, 1.000]. El EE relativo de una proporción binaria con 12 observaciones es mayor que el de la media del conteo: cada unidad binaria aporta menos información que un valor continuo.

N4. $\widehat{C} = 0.15$, EE $= \sqrt{0.15 \times 0.85/80} = 0.0399$ e IC de Wald [0.072, 0.228]. El IC supone puntos independientes; con puntos agrupados en líneas, la réplica es la línea y el EE binomial lo subestimaría.

N5. $\widehat{C}_R = 33/120 = 0.275$, mientras que $\widehat{C}_U = (5/20 + 8/25 + 4/20 + 9/25 + 7/30)/5 = 0.2727$. Varían poco porque las áreas son similares, pero conceptualmente resumen estrategias distintas; la réplica es el transecto.

N6. Con $p = 0.30$, la presencia esperada en bloques de cuatro cuadrantes es $1 - (1 - 0.3)^4 = 0.7599$ si los cuadrantes fueran independientes. En BCI la frecuencia de *Calophyllum* sube de 0.62 a 0.92 y 1.00 mucho más rápido de lo que sugiere el azar para su p : el ascenso empinado es lectura de agregación.

R1. Con la semilla 3311, densidad 431.6 (EE 12.7, IC aproximadamente [404.3, 458.9] tallos/ha; total 21 580) y frecuencia focal 0.667 (EE 0.105). Con la semilla 3312 y 2000 repeticiones: sesgo -0.06 , DE 9.31, RMSE 9.31, SE medio 8.81 y cobertura 0.93; la DE empírica y el SE medio coinciden porque la fórmula del MAS describe la variación real.

R2. La dispersión de Pearson es 2.48, señal de sobredispersión. El cuasi-Poisson deja los coeficientes en escala de razones: Swamp 0.79 y Young 1.23 respecto de OldHigh; el semivariograma agrega que unidades cercanas son más semejantes, lo que desaconseja tratar las hectáreas vecinas como réplicas totalmente independientes.

R3. Las densidades se mantienen en 417.4–431.3 tallos/ha, mientras la varianza cae de 1810.8 (1×1) a 1444.2 (1×2), 717.3 (2×1), 1083.5 (1×4) y 548.1 (4×1); la frecuencia del focal sube de 0.62 a 0.90–1.00. La orientación importa: las bandas que cruzan el eje este—oeste (1×2 , 1×4) conservan más heterogeneidad que las norte—sur (2×1 , 4×1).

R4. Con la semilla 3314, el MAS da RMSE 10.74 y DE 10.74; la estratificación OldLow prácticamente no cambia el RMSE (10.57); la de Young lo reduce a 9.52 (DE 9.52). La ganancia aparece solo cuando el criterio separa niveles de densidad (Young, 538, frente a Resto, 424.6), no cuando divide por un criterio de fisonomía que no separa medias.

R5. Las desviaciones van de -18.39 a $+2.38$ tallos/ha según el origen (con ocho o diez celdas completas de 4 ha). La recomendación es fijar el origen o registrar parcelas parciales con su área antes de observar, y no elegir el origen después de ver los datos.

3.9. Actividad propuesta para el lector

Use `vegan::varespec` y `vegan::varechem` (comunidad y variables de suelo de 24 parcelas). Documente procedencia y limitaciones; verifique correspondencia de filas, faltantes, ceros y rangos; defina estratos, unidad de muestreo, soporte, unidad de observación y un estimando (densidad o frecuencia) para una especie focal; justifique una audaz elección de soporte y una regla de inclusión. Estime el parámetro con un MAS reproducible con su incertidumbre; evalúe por repetición sesgo, DE, RMSE y cobertura; compare una estratificación previa construida con una variable química y discuta si el criterio separa niveles; examine la asociación entre parcelas con la información disponible (ubicación o suelo); y evalúe la sensibilidad de la frecuencia y de la varianza al soporte (varios tamaños y orientación) y al origen de la teselación. Interprete el significado de los ceros, el alcance espacial de las conclusiones y qué cambia al usar frecuencia en lugar de abundancia.

4 Transectos y muestreo por distancias

4.1. Del encuentro a la densidad

El número observado combina distribución, esfuerzo y detección. Esta suele disminuir con distancia, vegetación, conducta y observador. El muestreo por distancias modela esa pérdida para estimar un área efectiva de búsqueda (Sutherland 2006; Henderson y Southwood 2016).

El **diseño espacial** determina dónde buscar; el **proceso ecológico**, dónde se encuentran los objetos; y el **proceso de observación**, cuáles se detectan. Una buena curva de detección no corrige líneas ubicadas solo en hábitat accesible.

4.2. Población, unidades y estimando

Un protocolo debe declarar población objetivo y disponible, región y período, unidad de muestreo, objeto detectado, esfuerzo y estimando. En transectos lineales, la línea o segmento es unidad de muestreo, y el individuo o grupo es unidad de observación.

La disponibilidad y la percepción son distintas. Un ave que no vocaliza puede no estar disponible; una que vocaliza puede no ser percibida. El modelo convencional supone detección segura sobre la línea, $g(0) = 1$. Si falla, la estimación describe objetos disponibles y perceptibles bajo el protocolo.

4.3. Geometría y función de detección

Para líneas de longitud total L , truncadas a distancia perpendicular w a cada lado, el área geométrica es $2wL$. Con función de detección $g(x)$,

$$P_a = \frac{1}{w} \int_0^w g(x) dx, \quad \mu = \int_0^w g(x) dx,$$

y para n detecciones,

$$\widehat{D} = \frac{n}{2wL\widehat{P}_a} = \frac{n}{2L\widehat{\mu}}.$$

2μ es el ancho efectivo total. La corrección reemplaza área geométrica por área efectivamente cubierta; no crea objetos ni corrige un marco sesgado.

Dos funciones clave son media normal y tasa de riesgo:

$$g_{HN}(x) = \exp\{-x^2/(2\sigma^2)\},$$

$$g_{HR}(x) = 1 - \exp\{-(x/\sigma)^{-b}\}.$$

La primera produce un hombro suave. La segunda puede sostener detección alta cerca de la línea y caer con mayor flexibilidad. Complejidad adicional requiere datos suficientes y una mejora diagnóstica, no solo un AIC menor.

4.4. Supuestos y fuentes de incertidumbre

1. Las líneas representan la región respecto de los objetos.
2. Los objetos sobre la línea se detectan: $g(0) = 1$.
3. Se registran en su posición inicial.
4. Las distancias perpendiculares se miden sin error importante.
5. Cada objeto se registra una vez y se clasifica correctamente.
6. Esfuerzo, área y unidades son compatibles.
7. Las líneas aportan replicación de la tasa de encuentro.

El histograma y una prueba de ajuste examinan la distribución condicionada de distancias observadas. No verifican representatividad, movimiento ni $g(0) = 1$. La incertidumbre combina tasa de encuentro y función de detección. Remuestrear líneas conserva mejor la unidad de diseño que remuestrear detecciones.

4.5. Truncamiento y calidad de datos

Detecciones lejanas suelen ser escasas y difíciles de medir. Truncar puede estabilizar el ajuste, pero cambia n , el área geométrica y P_a . Deben declararse la regla y la sensibilidad. Acumulaciones en distancias preferidas pueden indicar redondeo; agrupar intervalos puede ser más honesto que tratar las medidas como exactas (Manly y Navarro Alberto 2015).

Las líneas sin detecciones deben conservarse. Excluir las reduce esfuerzo sin reducir encuentros e infla la tasa. Igualmente, sumar **Effort** en cada fila de detección cuenta varias veces una misma línea.

4.6. Aplicación reproducible: chochín de Montrave

`Distance::wren_lt` contiene observaciones reales de chochín (*Troglodytes troglodytes*) recolectadas por Steve Buckland en bosque y parque de Montrave Estate, cerca de Leven, Fife, Escocia. Son datos de transecto lineal: esfuerzo en km, distancia perpendicular en m y área de 33.2 ha. El conjunto se distribuye con el paquete `Distance` (Miller et al. 2019).

La documentación no aporta fecha por registro, geometría de las líneas, covariables de observación, tamaño de grupo ni filas de transectos sin detección. Por ello el estimando será densidad de **objetos detectables** por hectárea en el área y protocolo representados, no densidad contemporánea de toda la especie.

4.6.1. Carga y auditoría de tablas

```
suppressPackageStartupMessages(library(Distance))
data(wren_lt, package = "Distance")

regiones <- unique(wren_lt[c("Region.Label", "Area", "Study.Area")])
lineas <- unique(wren_lt[c("Region.Label", "Sample.Label", "Effort")])
obs <- wren_lt[c("Region.Label", "Sample.Label", "object", "distance")]

encuentros <- aggregate(object ~ Region.Label + Sample.Label, obs, length)
names(encuentros)[3] <- "n"
lineas <- merge(lineas, encuentros,
               by = c("Region.Label", "Sample.Label"), all.x = TRUE)
lineas$n[is.na(lineas$n)] <- 0
lineas$tasa <- lineas$n / lineas$Effort

data.frame(
  regiones = nrow(regiones), lineas_documentadas = nrow(lineas),
  detecciones = nrow(obs), objetos_duplicados = sum(duplicated(obs$object)),
  distancias_faltantes = sum(is.na(obs$distance)),
  distancias_negativas = sum(obs$distance < 0),
  esfuerzo_no_positivo = sum(lineas$Effort <= 0),
  lineas_con_cero = sum(lineas$n == 0)
)
```


```
#>   regiones lineas_documentadas detecciones objetos_duplicados
#> 1         1                   19             156              0
#>   distancias_faltantes distancias_negativas esfuerzo_no_positivo
#> 1                     0                   0              0
#>   lineas_con_cero
#> 1                0
```

Los 19 identificadores de línea tienen encuentros. Esto puede significar que no hubo líneas con cero o que el archivo no las conserva; sin el registro de campo no se puede decidir. La inferencia de tasa de encuentro queda condicionada al esfuerzo documentado y esta limitación debe acompañarse al resultado.

4.6.2. Esfuerzo y tasa de encuentro

```
c(area_ha = unique(wren_lt$Area),
  esfuerzo_km = sum(lineas$Effort),
  detecciones = sum(lineas$n),
  tasa_global_por_km = sum(lineas$n) / sum(lineas$Effort))
#>           area_ha           esfuerzo_km           detecciones tasa_global_por_km
#>           33.20000           9.66000           156.00000           16.14907

op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
plot(lineas$Effort, lineas$n, pch = 19,
      xlab = "Longitud de línea (km)", ylab = "Detecciones")
stripchart(lineas$tasa, method = "jitter", vertical = TRUE, pch = 19,
           ylab = "Detecciones por km", xlab = "Líneas")
```



```
par(op)
summary(lineas[c("Effort", "n", "tasa")])
#>      Effort           n          tasa
#>  Min.   :0.0400   Min.   : 1.000   Min.   : 5.291
#> 1st Qu.:0.3890   1st Qu.: 5.000   1st Qu.:13.648
#> Median :0.4720   Median : 9.000   Median :16.539
#> Mean   :0.5084   Mean   : 8.211   Mean   :20.265
#> 3rd Qu.:0.7780   3rd Qu.:11.500   3rd Qu.:21.029
#> Max.   :0.8100   Max.   :14.000   Max.   :75.000
```


La variación entre tasas muestra por qué 156 encuentros no equivalen a 156 réplicas. Las 19 líneas sostienen la variación de encuentro; las detecciones internas sostienen la forma de la función de detección.

4.6.3. Distribución y precisión de distancias

```
op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
hist(obs$distance, breaks = seq(0, 100, by = 5),
     col = "grey80", border = "white",
     xlab = "Distancia perpendicular (m)", main = "Distancias observadas")
```



```
plot(ecdf(obs$distance), verticals = TRUE, do.points = FALSE,
     xlab = "Distancia perpendicular (m)", ylab = "Proporción acumulada")
```



```
par(op)

sort(table(obs$distance), decreasing = TRUE)[1:10]
#>
#> 35 40 30 60 10 25 70 20 55 75
#> 15 12 10 10 9 9 9 8 8 8
c(minimo = min(obs$distance), maximo = max(obs$distance),
  multiplos_de_5 = mean(obs$distance %% 5 == 0))
#>      minimo      maximo multiplos_de_5
#> 0.0000000 100.0000000 0.8910256
```

La acumulación en múltiplos de cinco sugiere redondeo. La disminución hacia el límite superior aporta información sobre detección, pero también hace sensibles los modelos al truncamiento.

4.6.4. Modelos candidatos con unidades compatibles

Usamos inicialmente $w = 100$ m para conservar las 156 detecciones. Como esfuerzo está en km y área en ha, `convert_units = 0.1` convierte el producto m por km a hectáreas. Comparamos media normal y tasa de riesgo sin ajustes adicionales.

```

ajustar <- function(w, key) {
  Distance::ds(wren_lt, truncation = w, key = key,
    adjustment = NULL, convert_units = 0.1, quiet = TRUE)
}

modelos <- list(
  `Media normal` = ajustar(100, "hn"),
  `Tasa de riesgo` = ajustar(100, "hr")
)
#> Fitting half-normal key function
#> AIC= 1418.188
#> Fitting hazard-rate key function
#> AIC= 1412.133

tabla_modelos <- do.call(rbind, lapply(names(modelos), function(nombre) {
  fit <- modelos[[nombre]]
  sm <- summary(fit$ddf)
  data.frame(modelo = nombre, n = sm$n,
    parametros = length(fit$ddf$par),
    AIC = fit$ddf$criterion,
    p_deteccion = sm$average.p,
    densidad_ha = fit$dht$individuals$D$Estimate[1])
}))
tabla_modelos[-1] <- lapply(tabla_modelos[-1], round, 4)
tabla_modelos
#>      modelo      n parametros      AIC p_deteccion densidad_ha
#> 1  Media normal 156          1 1418.188         0.685      1.1787
#> 2 Tasa de riesgo 156          2 1412.133         0.844      0.9567

```

Con el mismo truncamiento, el AIC compara ajuste y complejidad. La tasa de riesgo es defendible si mejora claramente el criterio, conserva monotonicidad y supera los diagnósticos. La diferencia en probabilidad media muestra que la forma de la curva tiene una consecuencia directa sobre densidad.

4.6.5. Diagnósticos del modelo elegido


```

fit_final <- modelos[["Tasa de riesgo"]]
gof <- Distance::gof_ds(fit_final, plot = FALSE)
c(CvM = gof$dsgof$CvM$W, p_CvM = gof$dsgof$CvM$p,
  p_deteccion = summary(fit_final$ddf)$average.p)

```

```
#>      CvM      p_CvM p_deteccion
#> 0.2498974 0.1885013 0.8440264

op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
plot(fit_final, pdf = TRUE, main = "Tasa de riesgo, w = 100 m")
#> Warning in plot.ds(x$ddf, pl.den = pl.den, ...): Ignoring pdf=TRUE for line
#> transect data
Distance::gof_ds(fit_final, plot = TRUE)
```




```
#>
#> Goodness of fit results for ddf object
#>
#> Distance sampling Cramer-von Mises test (unweighted)
#> Test statistic = 0.249897 p-value = 0.188501
par(op)
```

La curva debe tener hombro cerca de cero y descenso monótono. Cramer-von Mises evalúa compatibilidad acumulada entre distancias y modelo. Un resultado no extremo apoya la forma elegida, pero no verifica selección espacial, $g(0) = 1$, movimiento ni exactitud de las distancias.

4.6.6. Densidad, abundancia e incertidumbre

```
estimacion <- merge(
  fit_final$dht$individuals$D[c("Label", "Estimate", "se", "cv", "lcl", "ucl")],
  fit_final$dht$individuals$N[c("Label", "Estimate", "se", "cv", "lcl", "ucl")],
  by = "Label", suffixes = c("_D", "_N")
)
estimacion[-1] <- lapply(estimacion[-1], round, 3)
estimacion
#>   Label Estimate_D se_D cv_D lcl_D ucl_D Estimate_N se_N cv_N lcl_N ucl_N
#> 1 Total      0.957 0.078 0.081 0.809 1.131      31.761 2.584 0.081 26.857 37.562

with(estimacion, {
  plot(1, Estimate_D, pch = 19, xaxt = "n",
       ylim = c(lcl_D, ucl_D), xlab = "Montrave", ylab = "Objetos por ha")
  axis(1, 1, Label)
  arrows(1, lcl_D, 1, ucl_D, angle = 90, code = 3, length = 0.08)
})
```



D expresa objetos detectables por hectárea y N los expande a 33.2 ha. El intervalo incorpora variación estimada de encuentros y detección bajo las 19 líneas documentadas. Sin tamaño

de grupo, disponibilidad o líneas ausentes, no debe reinterpretarse como número total de aves presentes.

4.6.7. Diagnóstico de líneas influyentes

Una línea corta con muchos encuentros puede dominar la tasa. Comparamos la tasa global al retirar una línea por vez; es un diagnóstico, no un método para excluir resultados incómodos.

```
tasa_loo <- vapply(seq_len(nrow(lineas)), function(i)
  sum(lineas$n[-i]) / sum(lineas$Effort[-i]), 0.0)
influencia <- data.frame(
  linea_retirada = lineas$Sample.Label,
  esfuerzo = lineas$Effort,
  encuentros = lineas$n,
  tasa_sin_linea = tasa_loo,
  cambio = tasa_loo - sum(lineas$n) / sum(lineas$Effort)
)
influencia[order(abs(influencia$cambio), decreasing = TRUE), ][1:5, ]
#>   linea_retirada esfuerzo encuentros tasa_sin_linea cambio
#> 19             9     0.770           6     16.87289  0.7238226
#>  8             16     0.378           2     16.59125  0.4421836
#>  2             10     0.408           3     16.53696  0.3878967
#>  6             14     0.542          12     15.79294 -0.3561313
#>  1              1     0.416          10     15.79403 -0.3550398
```

Cambios grandes identifican recorridos que merecen revisar en bitácoras. No son evidencia automática de error: también pueden reflejar heterogeneidad ecológica real.

4.6.8. Sensibilidad a función y truncamiento


```
w_grid <- c(60, 75, 80, 100)
sensibilidad <- do.call(rbind, lapply(w_grid, function(w) {
  do.call(rbind, lapply(c(HN = "hn", HR = "hr"), function(key) {
    fit <- ajustar(w, key)
    sm <- summary(fit$ddf)
    data.frame(w = w, clave = key, n = sm$n,
               descartadas = nrow(obs) - sm$n,
               AIC = fit$ddf$criterion, p_deteccion = sm$average.p,
               D = fit$dht$individuals$D$Estimate[1],
               N = fit$dht$individuals$N$Estimate[1])
  })
})
```

```

    )))
  )))
#> Fitting half-normal key function
#> AIC= 992.831
#> Fitting hazard-rate key function
#> AIC= 994.425
#> Fitting half-normal key function
#> AIC= 1228.059
#> Fitting hazard-rate key function
#> AIC= 1229.689
#> Fitting half-normal key function
#> AIC= 1316.455
#> Fitting hazard-rate key function
#> AIC= 1318.104
#> Fitting half-normal key function
#> AIC= 1418.188
#> Fitting hazard-rate key function
#> AIC= 1412.133
sensibilidad[-2] <- lapply(sensibilidad[-2], round, 4)
sensibilidad
#>      w clave  n descartadas      AIC p_deteccion      D      N
#> HN   60   hn  121           35  992.8314      1.0000 1.0438 34.6549
#> HR   60   hr  121           35  994.4247      0.9983 1.0456 34.7132
#> HN1  75   hn  142           14 1228.0585      0.9698 1.0105 33.5482
#> HR1  75   hr  142           14 1229.6894      0.9983 0.9816 32.5903
#> HN2  80   hn  150            6 1316.4553      0.9652 1.0055 33.3819
#> HR2  80   hr  150            6 1318.1039      0.9983 0.9721 32.2747
#> HN3 100   hn  156            0 1418.1879      0.6850 1.1787 39.1329
#> HR3 100   hr  156            0 1412.1329      0.8440 0.9567 31.7614

matplot(w_grid,
        cbind(sensibilidad$D[sensibilidad$clave == "hn"],
              sensibilidad$D[sensibilidad$clave == "hr"])),
        type = "b", pch = c(19, 17), lty = 1,
        xlab = "Truncamiento (m)", ylab = "Densidad (objetos/ha)")
legend("topleft", c("Media normal", "Tasa de riesgo"),
      pch = c(19, 17), lty = 1, col = 1:2, bty = "n")

```



Los AIC solo se comparan entre funciones dentro del mismo w , pues cambia el conjunto de observaciones. Truncamientos bajos eliminan la cola donde se aprecia la caída y pueden estimar detección casi perfecta; el análisis completo muestra que esa conclusión depende de ocultar las detecciones lejanas. La estabilidad de la densidad dentro de decisiones plausibles es tan importante como el mínimo AIC.

4.6.9. Sensibilidad a líneas no documentadas con cero

No sabemos si faltan ceros. El siguiente cálculo no inventa observaciones primarias: muestra algebraicamente cuánto cambiaría la tasa si el registro hubiera omitido líneas de esfuerzo mediano sin detecciones.

```
esfuerzo_mediano <- median(lineas$Effort)
ceros_posibles <- 0:5
tasa_ceros <- data.frame(
  lineas_cero_adicionales = ceros_posibles,
  tasa_por_km = sum(lineas$n) /
    (sum(lineas$Effort) + ceros_posibles * esfuerzo_mediano)
)
tasa_ceros$razon_frente_observada <-
  tasa_ceros$tasa_por_km / tasa_ceros$tasa_por_km[1]
```

```
round(tasa_ceros, 3)
#>   lineas_cero_adicionales tasa_por_km razon_frente_observada
#> 1                        0      16.149             1.000
#> 2                        1      15.397             0.953
#> 3                        2      14.711             0.911
#> 4                        3      14.085             0.872
#> 5                        4      13.509             0.837
#> 6                        5      12.978             0.804
```

Como la densidad es proporcional a la tasa si la función de detección se mantiene, líneas omitidas reducirían densidad en la misma razón. Este escenario no afirma que existan; cuantifica una limitación de procedencia que el ajuste no puede resolver.

4.7. Interpretación y reproducibilidad

El modelo de tasa de riesgo con $w = 100$ m usa todas las detecciones y representa mejor la caída en la cola que la media normal según el criterio y diagnósticos. La conclusión se limita a objetos detectables y al esfuerzo documentado. El redondeo, la ausencia de covariables, la imposibilidad de confirmar líneas con cero y los supuestos $g(0) = 1$ y posición inicial son fuentes de incertidumbre no incluidas en el intervalo.

```
list(
  archivo = "Distance::wren_lt",
  version_Distance = as.character(packageVersion("Distance")),
  version_R = R.version.string,
  objeto = "detección de chochín",
  area_ha = unique(wren_lt$Area),
  esfuerzo_km = sum(lineas$Effort),
  truncamiento_m = 100,
  funcion = "tasa de riesgo sin ajustes",
  conversion_m_km_a_ha = 0.1
)
#> $archivo
#> [1] "Distance::wren_lt"
#>
#> $version_Distance
#> [1] "2.0.1"
#>
#> $version_R
#> [1] "R version 4.5.2 (2025-10-31)"
```



```

#>
#> $objeto
#> [1] "detección de chochín"
#>
#> $area_ha
#> [1] 33.2
#>
#> $esfuerzo_km
#> [1] 9.66
#>
#> $truncamiento_m
#> [1] 100
#>
#> $funcion
#> [1] "tasa de riesgo sin ajustes"
#>
#> $conversion_m_km_a_ha
#> [1] 0.1
sessionInfo()
#> R version 4.5.2 (2025-10-31)
#> Platform: x86_64-pc-linux-gnu
#> Running under: Ubuntu 24.04.4 LTS
#>
#> Matrix products: default
#> BLAS: /usr/lib/x86_64-linux-gnu/openblas-pthread/libblas.so.3
#> LAPACK: /usr/lib/x86_64-linux-gnu/openblas-pthread/libopenblas-p0.3.26.so; LAPACK versi
#>
#> locale:
#> [1] LC_CTYPE=C.UTF-8 LC_NUMERIC=C LC_TIME=C.UTF-8
#> [4] LC_COLLATE=C.UTF-8 LC_MONETARY=C.UTF-8 LC_MESSAGES=C.UTF-8
#> [7] LC_PAPER=C.UTF-8 LC_NAME=C LC_ADDRESS=C
#> [10] LC_TELEPHONE=C LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
#>
#> time zone: UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats graphics grDevices datasets utils methods base
#>
#> other attached packages:
#> [1] Distance_2.0.1 mrds_3.0.1
#>

```

```
#> loaded via a namespace (and not attached):
#> [1] Matrix_1.7-4          future.apply_1.20.2  jsonlite_2.0.0
#> [4] dplyr_1.2.1           compiler_4.5.2       renv_1.2.4
#> [7] tidyselect_1.2.1      Rcpp_1.1.2           parallel_4.5.2
#> [10] Rsolnp_2.0.1          globals_0.19.1       splines_4.5.2
#> [13] yaml_2.3.12           fastmap_1.2.0        lattice_0.22-7
#> [16] R6_2.6.1              generics_0.1.4       knitr_1.51
#> [19] rbibutils_2.4.1       tibble_3.3.1         future_1.75.0
#> [22] nloptr_2.2.1          pillar_1.11.1        rlang_1.1.7
#> [25] xfun_0.56             truncnorm_1.0-9      cli_3.6.5
#> [28] magrittr_2.0.5        mgcv_1.9-3           Rdpack_2.6.6
#> [31] digest_0.6.39         grid_4.5.2           lifecycle_1.0.5
#> [34] nlme_3.1-168          vctrs_0.7.1          evaluate_1.0.5
#> [37] pracma_2.4.6          glue_1.8.0           numDeriv_2016.8-1.1
#> [40] listenv_1.0.0         codetools_0.2-20     optimx_2025-4.9
#> [43] parallelly_1.48.0     rmarkdown_2.30       pkgconfig_2.0.3
#> [46] tools_4.5.2           htmltools_0.5.9
```

4.8. Actividad propuesta para el lector

Use el conjunto real `Distance::amakihi` para construir un análisis de muestreo por distancias. Documente especie, lugar, unidades y limitaciones desde la ayuda del paquete; reconstruya tablas de región, muestra y detección; audite esfuerzo, ceros, duplicados, faltantes, rangos y redondeo; defina población disponible, unidad y estimando; explore tasas y distancias; ajuste dos funciones clave con truncamientos justificados; compare AIC solo sobre los mismos datos; revise curva, residuos cuantiles y ajuste acumulado; estime densidad, abundancia e intervalos; identifique unidades influyentes; y evalúe sensibilidad a truncamiento, función y posible omisión de esfuerzo sin encuentros. Interprete qué supuestos pueden examinarse con el archivo, cuáles dependen del protocolo y qué información adicional sería necesaria para hablar de individuos totales.

5 Métodos de censo por organismos y hábitats

Unidades, esfuerzo y límites de la observación

5.1. Del organismo observado al estimando

Un censo intenta enumerar todas las unidades de una población definida; una muestra observa solo una parte y requiere una regla de expansión. En campo, la palabra censo no elimina la observación imperfecta: pueden quedar organismos ocultos, unidades fuera del marco o registros duplicados. Antes de elegir una técnica se definen población objetivo, unidad biológica, unidad de muestreo, ventana temporal, área cubierta y variable registrada (Sutherland 2006; Henderson y Southwood 2016).

El estimando puede ser un total de individuos, densidad por hectárea, cobertura, frecuencia de parcelas ocupadas, biomasa o tasa de eventos por unidad de esfuerzo. No son intercambiables. Un registro de cámara sin identidad individual cuenta eventos; un individuo puede originar varios eventos y varios individuos pueden aparecer juntos. La inferencia nunca debe exceder lo que identifica el dato.

5.2. Organismos móviles

5.2.1. Conteos completos, parcelas, puntos y transectos

Un conteo completo es plausible para colonias visibles, nidos conspicuos o áreas pequeñas con fronteras claras. Requiere simultaneidad suficiente para evitar movimientos entre sectores, reglas contra duplicación y búsqueda que cubra todo el marco. Cuando no es viable, parcelas, puntos o transectos seleccionan unidades espaciales y producen conteos comparables (Gregg 2008).

En una muestra aleatoria simple de n unidades entre M , el total puede estimarse como

$$\hat{T} = M\bar{y},$$

con incertidumbre basada en la variación entre unidades y corrección por población finita cuando la fracción muestreada no es despreciable (Lohr 2022). En un diseño estratificado, cada hábitat se expande con su propio tamaño y probabilidad de inclusión. Elegir sitios por accesibilidad impide esa interpretación de diseño.

Los conteos por puntos estandarizan radio y duración; los transectos estandarizan longitud y ancho. Si el área efectiva no es conocida, el resultado es un índice. El muestreo por distancias añade distancias perpendiculares o radiales para modelar la disminución de detección, pero necesita medición correcta, ubicación inicial, independencia y detección cierta en la línea o punto según el diseño (Sutherland 2006; Manly y Navarro Alberto 2015).

5.2.2. Capturas, señales y cámaras

Trampas, redes, huellas, excretas, acústica y cámaras observan encuentros. Una tasa C/E divide eventos C por esfuerzo E , por ejemplo eventos por 100 cámara-días. Es útil para comparar bajo protocolos estables, pero

$$E(C_i) = E_i q_i A_i$$

mezcla intensidad o disponibilidad A_i con detectabilidad q_i . Cambios de sendero, ángulo, cebo, estación, hábitat o funcionamiento pueden alterar q_i sin cambio poblacional. La independencia entre eventos exige una regla temporal o identidad; sin ella se estima actividad registrada, no individuos.

5.3. Organismos sésiles y hábitat

Cuadrantes y parcelas permiten densidad, frecuencia, cobertura y biomasa. La densidad cuenta individuos por área, pero falla si los módulos clonales no definen individuos. La frecuencia es la proporción de unidades donde aparece un taxón y depende del tamaño de parcela. La cobertura es la proyección ocupada y puede superar 100 % si se suman estratos (Henderson y Southwood 2016).

Intercepción por puntos reduce decisiones subjetivas: la cobertura se estima como $\widehat{C} = h/m$, con h contactos y m puntos. Intercepción lineal usa longitud interceptada sobre longitud total. En ambos casos importan orientación, borde, altura y definición de contacto. Parcelas permanentes mejoran precisión del cambio, pero exigen conservar ubicación y protocolo; parcelas nuevas describen mejor el estado actual si se seleccionan probabilísticamente.

Para hábitat se registran unidades físicas reproducibles: proporción de dosel, profundidad, sustrato, volumen de madera, área basal o complejidad vertical. Una clase amplia como “bosque bueno” oculta reglas y dificulta auditoría. La unidad y resolución deben corresponder al mecanismo ecológico y al estimando (Gregg 2008).

5.4. Supuestos y control de calidad

- el marco cubre la población objetivo y las probabilidades de selección se conocen cuando se expande a ella;
- la unidad biológica y el evento se reconocen sin duplicación ni falsas identificaciones;
- área, duración y esfuerzo se miden en unidades explícitas;
- las unidades aportan replicación al nivel usado para la incertidumbre;
- cierres espaciales y temporales son razonables para el parámetro nombrado;
- diferencias de observador, dispositivo y hábitat se controlan o registran;
- ceros verdaderos se distinguen de fallas, visitas omitidas y datos faltantes.

Una hoja de campo auditable conserva identificador, coordenadas, fecha y hora, observador, dispositivo, inicio y fin de funcionamiento, unidad del esfuerzo, taxonomía, regla de evento, datos originales y toda exclusión. Calibración doble, fotografías de referencia y revisitas permiten cuantificar errores de medición.

5.5. Aplicación real: eventos en estaciones de cámara

5.5.1. Procedencia, pregunta y estimando

`Distance::DuikerCameraTraps` distribuye observaciones de duiker de Maxwell (*Philantomba maxwellii*) tomadas en 2014 en el Parque Nacional Tai, Costa de Marfil. La documentación registra 21 cámaras, distancias radiales agrupadas y esfuerzo como número de intervalos de 2 segundos; el conjunto acompaña al paquete `Distance` (Miller et al. 2019).

La pregunta es: **¿cuál fue la tasa media de eventos registrados por 100 cámara-días y cuánta heterogeneidad hubo entre estaciones?** El estimando es

$$R = 100 \frac{\sum_i C_i}{\sum_i E_i},$$

donde C_i son objetos registrados y E_i cámara-días. No se estimará abundancia ni densidad: el archivo no aporta identidad individual y este análisis no ajusta una función de detección.

5.5.2. Disponibilidad, importación y auditoría

```

if (!requireNamespace("Distance", quietly = TRUE)) {
  stop("Se requiere el paquete 'Distance' para ejecutar este capítulo.")
}
data("DuikerCameraTraps", package = "Distance")
eventos <- DuikerCameraTraps

campos <- c("Region.Label", "Area", "multiplier", "Sample.Label",
           "Effort", "distance", "object")
stopifnot(all(campos %in% names(eventos)), nrow(eventos) == 6277L,
          length(unique(eventos$Sample.Label)) == 21L,
          all(eventos$Effort > 0),
          !anyDuplicated(eventos$object[!is.na(eventos$object)]))

# Una fila sin objeto representa una estación sin evento, no una detección.
esfuerzo <- unique(eventos[c("Sample.Label", "Effort")])
stopifnot(!anyDuplicated(esfuerzo$Sample.Label))
conteos <- aggregate(!is.na(object) ~ Sample.Label, eventos, sum)
names(conteos)[2] <- "eventos"
estaciones <- merge(esfuerzo, conteos, by = "Sample.Label", all.x = TRUE)
estaciones$eventos[is.na(estaciones$eventos)] <- 0L
estaciones$dias <- estaciones$Effort * 2 / 86400
estaciones$ tasa100 <- 100 * estaciones$eventos / estaciones$dias

data.frame(filas = nrow(eventos), estaciones = nrow(estaciones),
           objetos = sum(!is.na(eventos$object)),
           distancias_faltantes = sum(is.na(eventos$distance)),
           esfuerzo_min_dias = min(estaciones$dias),
           esfuerzo_max_dias = max(estaciones$dias))
#>   filas estaciones objetos distancias_faltantes esfuerzo_min_dias
#> 1  6277         21    6274                   3         2.999259
#>   esfuerzo_max_dias
#> 1         15.74611

```

La conversión es dimensional: intervalos $\times 2$ segundos, divididos por 86 400 segundos/día. Los tres valores faltantes coinciden con filas sin objeto y no se imputan como distancias observadas.

5.5.3. Exploración

```

op <- par(mfrow = c(1, 3), mar = c(4, 4, 2, 1))
barplot(estaciones$dias, names.arg = estaciones$Sample.Label, las = 2,
        ylab = "Cámara-días", main = "Esfuerzo")
plot(eventos ~ dias, estaciones, pch = 19, col = "#31572c",
      xlab = "Cámara-días", ylab = "Eventos")
hist(eventos$distance[!is.na(eventos$object)], breaks = seq(0, 19.5, 1.5),
      col = "#90a955", border = "white", xlab = "Distancia radial (m)",
      main = "Distancias")

```




Figura 5.1: Esfuerzo, eventos y distancias registradas en las estaciones.

```

par(op)

summary(estaciones[c("dias", "eventos", "tasa100")])
#>      dias      eventos      tasa100
#> Min.   : 2.999   Min.   :  0.0    Min.   :  0.0
#> 1st Qu.:13.497   1st Qu.: 41.0    1st Qu.: 290.4
#> Median :14.621   Median :102.0   Median :1367.0
#> Mean   :13.577   Mean   :298.8    Mean   :2187.9
#> 3rd Qu.:15.559   3rd Qu.:375.0    3rd Qu.:2778.5
#> Max.   :15.746   Max.   :1398.0   Max.   :10187.0

```

La relación conteo-esfuerzo permite detectar estaciones con exposición corta. El histograma describe los intervalos de distancia, no corrige detectabilidad ni convierte eventos en animales.

5.5.4. Estimación e incertidumbre

La estimación agregada pondera correctamente por exposición. Para incertidumbre se remuestran estaciones completas, unidad que contiene conteo y esfuerzo; esto no supone que miles de intervalos de dos segundos sean réplicas independientes.

```
tasa <- with(estaciones, 100 * sum(eventos) / sum(dias))

set.seed(5051)
B <- 4000
boot_tasa <- replicate(B, {
  b <- estaciones[sample.int(nrow(estaciones), replace = TRUE), ]
  100 * sum(b$eventos) / sum(b$dias)
})
resultado_tasa <- data.frame(
  estimando = "eventos por 100 camara-dias",
  estimacion = tasa,
  LI_95 = unname(quantile(boot_tasa, 0.025)),
  LS_95 = unname(quantile(boot_tasa, 0.975))
)
round(resultado_tasa[-1], 2)
#>   estimacion  LI_95  LS_95
#> 1      2200.5 1023.57 3572.42
```

El intervalo expresa variación entre las 21 estaciones observadas. No incorpora selección espacial desconocida, clasificación de eventos ni conversión a individuos.

5.5.5. Diagnósticos


Un modelo Poisson con `offset(log(dias))` comprueba si una tasa constante describe la dispersión entre estaciones. No sustituye el estimador agregado.

```
ajuste_pois <- glm(eventos ~ 1 + offset(log(dias)), poisson, data = estaciones)
dispersion <- sum(residuals(ajuste_pois, type = "pearson")^2) /
  df.residual(ajuste_pois)
influencia <- data.frame(
  estacion = estaciones$Sample.Label,
  residuo_pearson = residuals(ajuste_pois, type = "pearson"),
  cooks = cooks.distance(ajuste_pois)
)
dispersion
```



```
#> [1] 569.6536
influencia[order(influencia$cooks, decreasing = TRUE), ][1:4, ]
#>   estacion residuo_pearson   cooks
#> 6      B2      62.98017 210.04993
#> 14     C6      58.79241 202.55073
#> 21     E6      35.79559  64.79650
#> 5      B1     -18.61433  21.43826

plot(fitted(ajuste_pois), residuals(ajuste_pois, type = "pearson"), pch = 19,
     xlab = "Eventos esperados", ylab = "Residuo de Pearson")
abline(h = 0, lty = 2)
```



Sobredispersión indica heterogeneidad espacial, dependencia entre eventos o ambas. Por eso la incertidumbre principal se obtiene entre estaciones y no con el error Poisson que presupone eventos independientes.

5.5.6. Sensibilidad

```
orden <- order(estaciones$tasa100, decreasing = TRUE)
sin_mayor_tasa <- estaciones[-orden[1], ]
sin_menor_esfuerzo <- estaciones[-which.min(estaciones$dias), ]

c(principal = tasa,
  sin_estacion_mayor_tasa = with(sin_mayor_tasa,
    100 * sum(eventos) / sum(dias)),
  sin_estacion_menor_esfuerzo = with(sin_menor_esfuerzo,
    100 * sum(eventos) / sum(dias)),
  media_no_ponderada = mean(estaciones$tasa100))
#>                principal      sin_estacion_mayor_tasa
#>                2200.500                1797.866
#> sin_estacion_menor_esfuerzo      media_no_ponderada
#>                2209.361                2187.945
```

Excluir una estación no es una regla de limpieza: muestra dependencia de unidades particulares. La media no ponderada responde a otro estimando, la tasa de una estación promedio, y da el mismo peso a exposiciones muy distintas.

5.5.7. Interpretación

La tasa resume actividad filmada durante periodos de máxima actividad incluidos en el archivo. Una estación con tasa alta puede tener más animales, mayor uso local, mejor orientación o visitas repetidas del mismo individuo. El resultado sirve para comparar protocolos equivalentes y planear esfuerzo, pero no autoriza una cifra de duikers ni una densidad del parque. El análisis reproducible registra también las versiones utilizadas:

```
data.frame(paquete = "Distance",
  version = as.character(utils::packageVersion("Distance")),
  objeto = "DuikerCameraTraps", R = R.version.string)
#>   paquete version      objeto      R
#> 1 Distance  2.0.1 DuikerCameraTraps R version 4.5.2 (2025-10-31)
```

5.6. Errores frecuentes

- llamar censo a una búsqueda parcial sin cuantificar cobertura;
- confundir eventos, grupos, señales e individuos;
- comparar conteos sin convertir esfuerzo a una unidad común;
- tratar submuestras o intervalos temporales como réplicas espaciales;
- omitir estaciones con cero eventos al resumir el esfuerzo;

- convertir frecuencia o cobertura en densidad;
- ajustar por distancia sin cumplir el diseño de muestreo por distancias;
- eliminar estaciones influyentes solo porque cambian el resultado;
- generalizar desde sitios accesibles como si fueran probabilísticos.

5.7. Síntesis

El método se elige después de definir organismo, hábitat, escala y estimando. Los conteos completos necesitan cobertura y reglas contra duplicación; parcelas, puntos y transectos necesitan un marco de selección; señales y dispositivos necesitan esfuerzo y un modelo explícito de lo que representa un evento. En organismos sésiles, densidad, frecuencia y cobertura responden preguntas distintas. La incertidumbre debe usar la unidad de muestreo real y toda conclusión debe separar el proceso ecológico del proceso de observación.

5.8. Actividad propuesta para el lector

Use solo las estaciones cuyo identificador comienza por **A** en `Distance::DuikerCameraTraps`, un subconjunto diferente del análisis principal. Reconstruya eventos y cámara-días desde las filas originales; verifique ceros, duplicados y unidades; estime la tasa agregada por 100 cámara-días y un intervalo por bootstrap de estaciones. Compare la tasa con las estaciones **C**, examine la sensibilidad a la cámara de menor esfuerzo y explique por qué la diferencia no demuestra una diferencia de abundancia entre zonas. Proponga dos metadatos de hábitat y una regla de independencia temporal que mejorarían una campaña futura.

Parte III

Parte III — Estimación de poblaciones

6 Remoción, captura-recaptura e índices de abundancia

Estimación cerrada, esfuerzo y capturabilidad

6.1. Contar lo no observado

Capturas y detecciones repetidas contienen información sobre la fracción no observada. La inferencia requiere distinguir población N , número observado n , probabilidad de captura p y esfuerzo. Un índice, en cambio, puede conservar solo $C = qN$: sin conocer o estabilizar q , no identifica N (Manly y Navarro Alberto 2015; Sutherland 2006).

6.2. Captura-recaptura cerrada

En dos ocasiones se marcan n_1 individuos; en la segunda se capturan n_2 , de los cuales m_2 estaban marcados. Bajo cierre, mezcla, marcas persistentes, identificación correcta y captura comparable, Lincoln–Petersen estima $n_1 n_2 / m_2$. La corrección de Chapman es

$$\widehat{N}_C = \frac{(n_1 + 1)(n_2 + 1)}{m_2 + 1} - 1,$$

con varianza

$$\widehat{\text{Var}}(\widehat{N}_C) = \frac{(n_1 + 1)(n_2 + 1)(n_1 - m_2)(n_2 - m_2)}{(m_2 + 1)^2(m_2 + 2)}.$$

Con tres ocasiones, una historia 101 registra captura, ausencia y recaptura. En el modelo cerrado M_0 , cada individuo tiene probabilidad constante p , una historia con k capturas tiene probabilidad $p^k(1-p)^{3-k}$ y la probabilidad de no observarlo es $(1-p)^3$. Para un N candidato, la máxima verosimilitud usa $\hat{p} = M/(3N)$, donde M es el total de capturas. El perfil discreto

de N vuelve visibles los supuestos y la asimetría de su incertidumbre (Manly y Navarro Alberto 2015).

La heterogeneidad de p suele dejar individuos poco capturables fuera de la muestra y sesgar N hacia abajo. Respuesta a la marca, diferencias temporales, trampas saturadas y movimiento de borde también rompen M_0 . Más ocasiones no reparan automáticamente un diseño inadecuado.

6.3. Remoción

En remoción, los individuos capturados se retiran o dejan de estar disponibles. Con población cerrada y probabilidad constante, el número capturado por primera vez en la ocasión j tiene esperanza

$$E(C_j) = Np(1 - p)^{j-1}.$$

La disminución entre ocasiones informa p y la cola no observada informa N . Debe distinguirse remoción física de remoción de la lista por identificación. La entrada de individuos, aprendizaje, agotamiento local desigual o esfuerzo variable pueden imitar la curva descendente (Henderson y Southwood 2016).

6.4. Cambio en razón e índices

Si una intervención añade o retira una cantidad conocida R de una categoría, y la proporción de esa categoría cambia de P_1 a P_2 , el tamaño previo puede estimarse por cambio en razón. Para una remoción conocida de la categoría marcada,

$$\widehat{N}_1 = R \frac{1 - P_2}{P_1 - P_2},$$

con signos y fórmula adaptados al tipo de cambio. Se requiere población cerrada salvo la intervención, clasificación correcta, mezcla rápida y muestras de composición representativas antes y después. Si $P_1 \approx P_2$, la estimación es inestable (Manly y Navarro Alberto 2015).

Captura por unidad de esfuerzo, conteos acústicos y tasas de huellas son índices. Son útiles para tendencia si esfuerzo, disponibilidad, área y detectabilidad son comparables. Estandarizar solo horas no controla cambios de observador, clima, equipo o distribución espacial. Un índice calibrado contra estimaciones periódicas de N es más defendible que asumir proporcionalidad.

6.5. Supuestos y errores de diseño

- cierre demográfico y geográfico durante las ocasiones;
- individuos reconocibles y marcas no perdidas ni mal leídas;
- historia de cada individuo registrada en el orden correcto;
- captura independiente entre individuos, salvo estructura modelada;
- forma de heterogeneidad o respuesta conductual compatible con el estimador;
- esfuerzo y duración comparables entre ocasiones;
- individuos no observados pertenecen al mismo marco que los observados.

Errores comunes son contar capturas como individuos, usar Petersen con $m_2 = 0$, ignorar pérdidas de marca, extender cierre de minutos a meses, escoger un modelo complejo con pocas recapturas, llamar abundancia a CPUE y reportar un intervalo simétrico cuando la verosimilitud de N tiene cola larga.

6.6. Aplicación real: mosquero de alisos

6.6.1. Procedencia, diseño y estimando

El paquete `unmarked` distribuye `alfl.csv` y `alflCovs.csv` (Kellner et al. 2023). Según su documentación, son conteos de punto de radio fijo para mosquero de alisos (*Empidonax alnorum*) en 2005: cada visita de 15 minutos se dividió en tres intervalos de 5 minutos y los observadores siguieron individuos durante la visita (Chandler et al. 2009). Hay tres visitas a los puntos. Usaremos la primera y trataremos cada ave seguida durante 15 minutos como si tuviera una marca temporal.

El estimando principal es el número de aves disponibles en los puntos durante la primera visita, bajo M_0 , no el tamaño regional de la especie. Las covariables documentan parcelas de radio 50 m, estructura, cobertura leñosa, hora y fecha; no se usarán para añadir un modelo moderno de abundancia.

6.6.2. Disponibilidad, importación y auditoría

```
if (!requireNamespace("unmarked", quietly = TRUE)) {
  stop("Se requiere el paquete 'unmarked' y sus archivos csv.")
}
ruta_hist <- system.file("csv", "alfl.csv", package = "unmarked")
ruta_cov <- system.file("csv", "alflCovs.csv", package = "unmarked")
stopifnot(nzchar(ruta_hist), nzchar(ruta_cov), file.exists(ruta_hist),
  file.exists(ruta_cov))
```

```

alfl <- read.csv(ruta_hist, stringsAsFactors = FALSE)
alflCovs <- read.csv(ruta_cov, stringsAsFactors = FALSE)
names(alflCovs)[1] <- "id"
cols_y <- paste0("interval", 1:3)
stopifnot(all(c("id", "survey", cols_y) %in% names(alfl)),
          all(c("id", "struct", "woody", "time.1", "date.1") %in%
              names(alflCovs)),
          !anyDuplicated(alflCovs$id), all(as.matrix(alfl[cols_y]) %in% 0:1),
          all(alfl$id %in% alflCovs$id))

auditoria <- data.frame(
  filas_individuo_visita = nrow(alfl), puntos_marco = nrow(alflCovs),
  puntos_con_deteccion = length(unique(alfl$id)),
  visitas = paste(sort(unique(alfl$survey)), collapse = ","),
  faltantes_historias = sum(is.na(alfl[cols_y]))
)
auditoria
#>   filas_individuo_visita puntos_marco puntos_con_deteccion visitas
#> 1                      98          50                   35  1,2,3
#>   faltantes_historias
#> 1                      0

```

Las filas son individuos observados dentro de una visita; id identifica el punto, no al ave. Los puntos sin aves existen en `alflCovs` y son necesarios para describir el marco, aunque el análisis agregado estima el total disponible en todos los puntos de la primera visita.

6.6.3. Historias y exploración


```

v1 <- alfl[alfl$survey == 1, ]
v1$historia <- do.call(paste0, v1[cols_y])
n_h <- table(factor(v1$historia,
                  levels = c("001", "010", "011", "100", "101", "110", "111")))
n_h
#>
#> 001 010 011 100 101 110 111
#>   2   2   6   4   1   5  30
colSums(v1[cols_y])
#> interval1 interval2 interval3
#>         40         43         39

```



```
barplot(n_h, col = "#52796f", xlab = "Historia", ylab = "Aves observadas",
       main = "Primera visita, tres intervalos de 5 min")
```



La ausencia de 000 es estructural: las aves nunca detectadas no aparecen en el archivo. Las recapturas dentro de 15 minutos son la información que permite estimar esa celda.

6.6.4. Verosimilitud cerrada transparente

```
ajustar_M0 <- function(historias, J = nchar(historias[1]), extra = 500L) {
  niveles <- sort(apply(expand.grid(rep(list(0:1), J)), 1,
    paste0, collapse = ""))
  obs <- niveles[niveles != paste0(rep(0, J), collapse = "")]
  f <- table(factor(historias, levels = obs))
  n <- sum(f); M <- sum(f * vapply(obs, function(z)
    sum(strsplit(z, "", fixed = TRUE)[[1]] == "1"), numeric(1)))
  Ns <- n:(n + extra)
  ll <- vapply(Ns, function(N) {
    p <- M / (J * N)
    if (p <= 0 || p >= 1) return(-Inf)
    k <- vapply(obs, function(z) sum(strsplit(z, "")[[1]] == "1"), numeric(1))
```


```

probs <- p^k * (1 - p)^(J - k)
n0 <- N - n
lgamma(N + 1) - lgamma(n0 + 1) - sum(lgamma(f + 1)) +
  n0 * log((1 - p)^J) + sum(f * log(probs))
}, numeric(1))
imax <- which.max(ll)
soporte <- Ns[2 * (max(ll) - ll) <= qchisq(0.95, 1)]
list(N = Ns[imax], p = M / (J * Ns[imax]), logLik = ll,
     Ns = Ns, IC = range(soporte), frecuencias = f)
}

m0 <- ajustar_M0(v1$historia)
data.frame(N = m0$N, p_por_intervalo = m0$p,
           p_al_menos_una = 1 - (1 - m0$p)^3,
           LI_perfil = m0$IC[1], LS_perfil = m0$IC[2],
           aves_observadas = nrow(v1))
#>   N p_por_intervalo p_al_menos_una LI_perfil LS_perfil aves_observadas
#> 1 50      0.8133333      0.9934957      50      51              50

plot(m0$Ns, 2 * (max(m0$logLik) - m0$logLik), type = "l",
     xlab = "N candidato", ylab = "Diferencia de devianza")
abline(h = qchisq(0.95, 1), lty = 2)

```



El perfil evalúa cada N entero, incluye $N - n$ historias 000 y estima p para ese candidato. El intervalo por razón de verosimilitudes conserva la asimetría y condiciona en cierre, seguimiento correcto y p constante.

6.6.5. Incertidumbre por simulación paramétrica

```
set.seed(6061)
historias_todas <- sort(apply(expand.grid(rep(list(0:1), 3)), 1,
                             paste0, collapse = ""))
k_todas <- vapply(strsplit(historias_todas, ""), function(z) sum(z == "1"), 0)
prob_todas <- m0$p^k_todas * (1 - m0$p)^(3 - k_todas)

boot_N <- replicate(1500, {
  f <- as.vector(rmultinom(1, m0$N, prob_todas))
  h <- rep(historias_todas[-1], f[-1])
  if (length(h) == 0) return(NA_real_)
  ajustar_M0(h, extra = 300L)$N
})
quantile(boot_N, c(0.025, 0.5, 0.975), na.rm = TRUE)
#>  2.5%   50% 97.5%
#>   48    50    50
```

Este bootstrap cuantifica repetición bajo el mismo M_0 ; no evalúa sesgo por heterogeneidad o movimiento.

6.6.6. Diagnóstico del patrón de historias

```
obs_names <- names(m0$frecuencias)
k_obs <- vapply(strsplit(obs_names, ""), function(z) sum(z == "1"), 0)
prob_obs <- m0$p^k_obs * (1 - m0$p)^(3 - k_obs)
esperadas <- m0$N * prob_obs
tabla_ajuste <- data.frame(historia = obs_names,
                           observada = as.numeric(m0$frecuencias),
                           esperada = esperadas,
                           residuo = (as.numeric(m0$frecuencias) - esperadas) /
                                sqrt(esperadas))

tabla_ajuste
#>   historia observada esperada   residuo
#> 1      001         2 1.417007 0.48975286
```

```
#> 2      010      2  1.417007  0.48975286
#> 3      011      6  6.174104 -0.07006821
#> 4      100      4  1.417007  2.16988691
#> 5      101      1  6.174104 -2.08232335
#> 6      110      5  6.174104 -0.47251924
#> 7      111     30 26.901452  0.59740711
sum(tabla_ajuste$residuo^2)
#> [1] 10.10927
```

Grandes diferencias entre 100, 010 y 001 sugieren variación temporal; exceso de 111 junto con historias únicas puede sugerir heterogeneidad. Con siete celdas y parámetros estimados, el estadístico es exploratorio, no una prueba automática de cierre.

6.6.7. Sensibilidad: dos ocasiones y otras visitas

```
n1 <- sum(v1$interval1 == 1)
n2 <- sum(v1$interval3 == 1)
m2 <- sum(v1$interval1 == 1 & v1$interval3 == 1)
N_chapman <- (n1 + 1) * (n2 + 1) / (m2 + 1) - 1
var_chapman <- (n1 + 1) * (n2 + 1) * (n1 - m2) * (n2 - m2) /
  ((m2 + 1)^2 * (m2 + 2))

por_visita <- do.call(rbind, lapply(sort(unique(alfl$survey)), function(s) {
  d <- alfl[alfl$survey == s, ]
  h <- do.call(paste0, d[cols_y])
  a <- ajustar_M0(h)
  data.frame(visita = s, observadas = nrow(d), N_M0 = a$N, p = a$p,
    LI = a$IC[1], LS = a$IC[2])
}))
c(n1 = n1, n2 = n2, recapturadas = m2, N_Chapman = N_chapman,
  SE_Chapman = sqrt(var_chapman), N_tres_ocasiones = m0$N)
#>           n1           n2      recapturadas      N_Chapman
#>      40.00000      39.00000       31.00000       50.25000
#>      SE_Chapman N_tres_ocasiones
#>       1.86931       50.00000

por_visita
#>   visita observadas N_M0      p LI LS
#> 1      1          50   50 0.8133333 50 51
#> 2      2          31   32 0.6666667 31 35
#> 3      3          17   18 0.5740741 17 22
```

Chapman usa solo los intervalos primero y tercero y responde al mismo cierre corto, pero descarta información intermedia. La variación entre visitas puede reflejar aves disponibles, hora, fecha o violaciones de p constante; no debe promediarse como si todas fueran la misma población cerrada.

6.6.8. Interpretación y reproducibilidad

La alta proporción de historias con varias detecciones suele producir una corrección moderada sobre n . Aun así, N significa aves disponibles en los puntos durante 15 minutos. No incluye aves fuera de las parcelas ni demuestra densidad regional. La estructura de vegetación y cobertura leñosa pertenecen a parcelas de 50 m, pero asociarlas causalmente con abundancia requeriría diseño y modelo adicionales.

```
data.frame(paquete = "unmarked",
            version = as.character(utils::packageVersion("unmarked")),
            archivo_historias = basename(ruta_hist),
            archivo_covariables = basename(ruta_cov), R = R.version.string)
#>   paquete version archivo_historias archivo_covariables
#> 1 unmarked  1.5.1          alfl.csv          alflCovs.csv
#>                                     R
#> 1 R version 4.5.2 (2025-10-31)
```

6.7. Síntesis

Captura-recaptura estima la fracción no observada a partir de reencuentros; remoción, a partir del agotamiento; y cambio en razón, a partir de una alteración conocida de la composición. Los tres métodos dependen de cierre, identificación y capturabilidad. Los índices requieren menos estructura, pero solo representan abundancia si su proporcionalidad es defendible. Historias, esfuerzo, perfil de verosimilitud, diagnóstico y sensibilidad deben acompañar la cifra final.

6.8. Actividad propuesta para el lector

Use exclusivamente `survey == 2` de `alfl.csv`, un subconjunto distinto del caso principal. Reconstruya las historias, preserve en `alflCovs.csv` los puntos con cero detecciones y audite hora (`time.2`) y fecha (`date.2`). Estime N y p con el perfil cerrado de tres intervalos; calcule Chapman con los intervalos 1 y 3; compare incertidumbre y pérdida de información. Examine residuos por historia, repita el análisis excluyendo puntos visitados antes del primer cuartil de hora y discuta cierre, disponibilidad y por qué el resultado no es abundancia regional.

7 Ocupación y detección imperfecta

Historias repetidas para separar estado y observación

7.1. Ausencia observada y estado latente

No detectar una especie puede significar ausencia o presencia no observada. Los modelos de ocupación usan visitas repetidas para separar ambos procesos. Para el sitio i ,

$$z_i \sim \text{Bernoulli}(\psi_i), \quad y_{ij} | z_i \sim \text{Bernoulli}(z_i p_{ij}),$$

donde z_i es presencia durante la temporada, ψ_i la probabilidad de ocupación y p_{ij} la detección condicional en presencia. En tres visitas,

$$P(000) = (1 - \psi) + \psi(1 - p)^3.$$

Una historia positiva confirma detección; 000 es una mezcla. Con una sola visita solo se observa aproximadamente ψp , y ambos parámetros no se separan sin información adicional (Manly y Navarro Alberto 2015; Sutherland 2006).

7.2. Diseño y significado

La unidad es un sitio definido espacialmente y las réplicas son visitas dentro de una temporada suficientemente corta. Para especies móviles, el parámetro suele ser probabilidad de **uso** del sitio, no residencia exclusiva. Aumentar el tamaño del sitio puede aumentar ψ ; aumentar duración o calidad de búsqueda puede aumentar p . Por eso toda estimación debe declarar ambas escalas (Henderson y Southwood 2016).

Con enlaces logit,

$$\text{logit}(\psi_i) = x_i^T \beta, \quad \text{logit}(p_{ij}) = w_{ij}^T \alpha.$$

Las covariables de sitio describen estado; clima, duración, observador, sendero o equipo suelen describir detección. Una variable puede afectar ambos procesos, pero modelos recargados no son identificables con pocas historias positivas. Conviene formular pocas relaciones antes de ajustar (Lohr 2022).

7.3. Supuestos

- el estado no cambia entre visitas, o el estimando se redefine como uso;
- sitios son independientes al nivel de inferencia;
- no hay falsas detecciones o se usa verificación suficiente;
- detecciones repetidas están vinculadas al sitio correcto;
- visitas omitidas son NA, nunca cero;
- heterogeneidad importante de p y ψ está representada;
- covariables se miden en la escala y antes del proceso que pretenden explicar;
- el marco de sitios y su selección permiten la generalización declarada.

El cierre puede fallar por migración o amplias separaciones entre visitas. La independencia falla si cámaras vecinas observan el mismo ámbito de hogar. Falsos positivos, especialmente en identificación acústica, pueden inflar ψ . Ningún criterio de información diagnóstica por sí solo estos problemas de diseño.

7.4. Aplicación real: zorro rojo en cámaras

7.4.1. Procedencia, pregunta y estimando

`unmarked::MesoCarnivores` contiene historias de tres visitas para 1 437 sitios y varias especies de mesocarnívoros, junto con covariables del sitio. Usaremos zorro rojo (`redfox`). El paquete documenta detección binaria, densidad de viviendas en 5 km (`HDens_5km`), detecciones de personas y ubicación sobre sendero (`Trail`).

La pregunta es: **¿cómo cambia el uso por zorro rojo a lo largo del gradiente de densidad de viviendas, separando la mayor detectabilidad de cámaras sobre senderos?** El estimando es ψ para sitios del conjunto durante la ventana de tres visitas; p es la probabilidad de detección por visita condicional en uso (Rota et al. 2016; Kellner et al. 2023). La asociación no es un efecto causal de urbanización.

7.4.2. Disponibilidad, importación y auditoría

```

if (!requireNamespace("unmarked", quietly = TRUE)) {
  stop("Se requiere el paquete 'unmarked' para ejecutar este capítulo.")
}
suppressPackageStartupMessages(library(unmarked))
data("MesoCarnivores", package = "unmarked")
y <- MesoCarnivores$redfox
sitios <- MesoCarnivores$sitecovs

stopifnot(is.matrix(y), ncol(y) == 3L, nrow(y) == nrow(sitios),
  all(y %in% c(0, 1)), !anyNA(y),
  all(c("HDens_5km", "People_site", "Trail") %in% names(sitios)),
  all(sitios$HDens_5km >= 0), all(sitios$Trail %in% 0:1))

auditoria_occ <- data.frame(
  sitios = nrow(y), visitas = ncol(y), detecciones = sum(y),
  sitios_detectados = sum(rowSums(y) > 0),
  faltantes_y = sum(is.na(y)), faltantes_cov = sum(is.na(sitios))
)
auditoria_occ
#>   sitios visitas detecciones sitios_detectados faltantes_y faltantes_cov
#> 1    1437      3         257             161          0          0

```

No hay visitas faltantes. La unidad de HDens_5km debe conservarse como la define el conjunto; para modelar se usa `log1p` y estandarización, de modo que el coeficiente represente una desviación estándar en la escala transformada.

7.4.3. Exploración de historias y covariables

```

historia <- apply(y, 1, paste0, collapse = "")
sort(table(historia), decreasing = TRUE)
#> historia
#> 000 001 010 100 111 110 101 011
#> 1276 36 28 26 25 20 14 12
colSums(y)
#> X1 X2 X3
#> 85 85 87


sitios$detectado <- as.integer(rowSums(y) > 0)
sitios$HDens_log <- log1p(sitios$HDens_5km)
sitios$HDens_z <- as.numeric(scale(sitios$HDens_log))

```



```
sitios$Trail <- factor(sitios$Trail, levels = 0:1)

op <- par(mfrow = c(1, 2))
barplot(table(historia), col = "#bc6c25", xlab = "Historia",
        ylab = "Sitios")
boxplot(HDens_log ~ detectado, sitios, xlab = "Alguna detección",
        ylab = "log(1 + densidad de viviendas)")
```



```
par(op)
with(sitios, table(Trail, detectado))
#>      detectado
#> Trail    0    1
#>    0  900  73
#>    1  376  88
```

La proporción con alguna detección es un límite inferior ingenuo de uso. La diferencia descriptiva por viviendas mezcla ψ y p ; la tabla de sendero sugiere representar primero el proceso de detección.

7.4.4. Ajuste parsimonioso

```
umf <- unmarked::unmarkedFrameOccu(y = y, siteCovs = sitios)
ajuste_occ <- unmarked::occu(~ Trail ~ HDens_z, data = umf)
coeficientes <- data.frame(
  parametro = names(coef(ajuste_occ)), estimacion = coef(ajuste_occ),
  SE = unmarked::SE(ajuste_occ)
)
coeficientes$LI <- coeficientes$estimacion - 1.96 * coeficientes$SE
coeficientes$LS <- coeficientes$estimacion + 1.96 * coeficientes$SE
coeficientes
#>               parametro estimacion      SE      LI      LS
#> psi(Int)             psi(Int) -1.512481 0.1445322 -1.795764 -1.229197
#> psi(HDens_z) psi(HDens_z)  1.544292 0.2248407  1.103604  1.984979
#> p(Int)              p(Int) -1.795277 0.1544313 -2.097962 -1.492592
#> p(Trail1)         p(Trail1)  1.955711 0.1879637  1.587302  2.324120
```

La primera fórmula modela detección y la segunda ocupación. Los coeficientes están en log-odds y se comunican mejor mediante probabilidades predichas.


7.4.5. Estimación e incertidumbre

```
pred_p <- unmarked::predict(ajuste_occ, type = "det",
  newdata = data.frame(Trail = factor(0:1, levels = 0:1)))
pred_p$ubicacion <- c("fuera de sendero", "sobre sendero")
pred_p
#>   Predicted      SE    lower    upper    ubicacion
#> 1 0.1424270 0.01886248 0.1092956 0.1835322 fuera de sendero
#> 2 0.5400227 0.03870208 0.4638280 0.6143915   sobre sendero

q_hdens <- quantile(sitios$HDens_5km, c(0.1, 0.5, 0.9))
z_hdens <- (log1p(q_hdens) - mean(sitios$HDens_log)) / sd(sitios$HDens_log)
pred_psi <- unmarked::predict(ajuste_occ, type = "state",
  newdata = data.frame(HDens_z = as.numeric(z_hdens)))
pred_psi$HDens_5km <- as.numeric(q_hdens)
pred_psi
#>   Predicted      SE    lower    upper HDens_5km
#> 1 0.06091248 0.01095107 0.04266820 0.08625487 0.07711392
#> 2 0.10796651 0.01385279 0.08366237 0.13826573 0.73104281
```

```
#> 3 0.56925775 0.08215650 0.40664039 0.71819348 9.66415268

grid_h <- seq(min(sitios$HDens_log), max(sitios$HDens_log), length.out = 150)
grid_z <- (grid_h - mean(sitios$HDens_log)) / sd(sitios$HDens_log)
curva <- unmarked::predict(ajuste_occ, type = "state",
                           newdata = data.frame(HDens_z = grid_z))
plot(grid_h, curva$Predicted, type = "l", ylim = c(0, 1),
     xlab = "log(1 + densidad de viviendas en 5 km)",
     ylab = "Probabilidad de uso")
lines(grid_h, curva$lower, lty = 2)
lines(grid_h, curva$upper, lty = 2)
```



Los intervalos son Wald condicionados en la forma logit, transformación elegida, independencia y ausencia de falsas detecciones. Las predicciones en cuantiles evitan extrapolar más allá del gradiente observado.

7.4.6. Diagnóstico por historias

Comparamos frecuencias observadas con las esperadas sitio a sitio. Para cada sitio se usan sus $\hat{\psi}_i$ y $\hat{p}_i$; 000 incluye ausencia verdadera.

```

psi_hat <- unmarked::predict(ajuste_occ, type = "state")$Predicted
p_hat <- unmarked::predict(ajuste_occ, type = "det",
  newdata = data.frame(Trail = sitios$Trail))$Predicted
H <- sort(apply(expand.grid(rep(list(0:1), 3)), 1,
  paste0, collapse = ""))
esperada <- vapply(H, function(h) {
  z <- as.integer(strsplit(h, "")[[1]])
  pr_det <- p_hat^sum(z) * (1 - p_hat)^(3 - sum(z))
  if (h == "000") sum((1 - psi_hat) + psi_hat * pr_det) else
    sum(psi_hat * pr_det)
}, numeric(1))
observada <- as.numeric(table(factor(historia, levels = H)))
diag_hist <- data.frame(historia = H, observada, esperada,
  pearson = (observada - esperada) / sqrt(esperada))
diag_hist
#>      historia observada  esperada  pearson
#> 000         000      1276 1267.33217  0.2434810
#> 001         001        36   35.17303  0.1394386
#> 010         010        28   35.17303 -1.2094780
#> 011         011        12   16.36065 -1.0780790
#> 100         100        26   35.17303 -1.5467071
#> 101         101        14   16.36065 -0.5836206
#> 110         110        20   16.36065  0.8997546
#> 111         111        25   15.06679  2.5590531
T_obs <- sum((observada - esperada)^2 / esperada)
T_obs
#> [1] 12.79504

```

Residuos grandes en una visita concreta sugieren diferencias temporales de p ; exceso simultáneo de 000 y 111 puede indicar heterogeneidad no representada. La discrepancia no identifica cuál supuesto falló, pero dirige la revisión del protocolo y de covariables.

7.4.7. Sensibilidad de la especificación

```

ajuste_nulo <- unmarked::occu(~ 1 ~ 1, data = umf)
ajuste_sendero <- unmarked::occu(~ Trail ~ 1, data = umf)
ajuste_p_const <- unmarked::occu(~ 1 ~ HDens_z, data = umf)
sitios$People_z <- as.numeric(scale(log1p(sitios$People_site)))
umf_people <- unmarked::unmarkedFrameOccu(y = y, siteCovs = sitios)
ajuste_people <- unmarked::occu(~ Trail ~ People_z, data = umf_people)

```

```

comparacion <- data.frame(
  modelo = c("psi(.) p(.)", "psi(.) p(sendero)",
             "psi(viviendas) p(.)", "psi(viviendas) p(sendero)",
             "psi(personas) p(sendero)"),
  K = c(2, 3, 3, 4, 4),
  AIC = c(ajuste_nulo@AIC, ajuste_sendero@AIC, ajuste_p_const@AIC,
          ajuste_occ@AIC, ajuste_people@AIC)
)
comparacion$Delta_AIC <- comparacion$AIC - min(comparacion$AIC)
comparacion
#>               modelo K      AIC Delta_AIC
#> 1          psi(.) p(.) 2 1633.945 205.56851
#> 2      psi(.) p(sendero) 3 1585.187 156.81065
#> 3  psi(viviendas) p(.) 3 1511.914  83.53793
#> 4  psi(viviendas) p(sendero) 4 1428.377  0.00000
#> 5  psi(personas) p(sendero) 4 1559.784 131.40716

c(uso_ingenuo = mean(rowSums(y) > 0),
  psi_nula = unmarked::backTransform(ajuste_nulo, type = "state")@estimate)
#> uso_ingenuo    psi_nula
#>  0.1120390    0.1363313

```

La comparación pregunta si atribuir sendero a detección cambia el patrón de estado y si una alternativa de presión humana ofrece una descripción distinta. AIC compara aproximación relativa; no prueba cierre, independencia o causalidad. La proporción ingenua muestra el sesgo esperado al equiparar no detección con ausencia.

7.4.8. Interpretación y reproducibilidad

El modelo separa una asociación de uso con densidad de viviendas de la marcada diferencia de detección entre cámaras sobre y fuera de senderos. Para una especie móvil, “uso durante la ventana” es más prudente que residencia. Las cámaras no son individuos y las detecciones no son abundancia. El gradiente observacional puede reflejar hábitat, geografía u otras variables correlacionadas.

```

data.frame(paquete = "unmarked",
  version = as.character(utils::packageVersion("unmarked")),
  objeto = "MesoCarnivores", especie = "redfox",
  convergencia = ajuste_occ@opt$convergence, R = R.version.string)
#>   paquete version      objeto especie convergencia
#> 1 unmarked  1.5.1 MesoCarnivores redfox            0

```

```
#> R
#> 1 R version 4.5.2 (2025-10-31)
```

7.5. Errores frecuentes

- codificar una cámara inactiva como no detección;
- modelar “alguna detección” sin considerar p ;
- llamar ausencia a una historia 000;
- mezclar visitas tan separadas que el estado cambia;
- usar réplicas espaciales como temporales sin redefinir uso;
- asignar covariables de observación al estado sin justificación;
- ajustar demasiados parámetros con pocas detecciones;
- interpretar ocupación como abundancia o efecto causal;
- ignorar falsas identificaciones y dependencia entre sitios vecinos.

7.6. Síntesis

La ocupación es un modelo conjunto del estado y su observación. Las visitas repetidas permiten separar ψ y p bajo cierre, identificación correcta e independencia. Escala espacial, duración de la temporada y ubicación del equipo determinan si el parámetro representa ocupación o uso. Un análisis completo audita historias y faltantes, limita covariables, predice en unidades interpretables, revisa frecuencias de historias y muestra sensibilidad a la especificación.

7.7. Actividad propuesta para el lector

Use `MesoCarnivores$coyote`, un conjunto de historias distinto del caso principal, con las mismas tres visitas. Audite dimensiones, faltantes y frecuencias; defina el estimando como uso durante la ventana; explore detección por `Trail`; ajuste con `unmarked::occu` un modelo nulo y otro con `Trail` solo en detección. Añada como máximo una covariable de estado entre `HDens_5km` y `People_site`, con transformación justificada. Presente probabilidades e intervalos, diagnostique las ocho historias, compare con la proporción ingenua y evalúe sensibilidad al excluir sitios por encima del percentil 99 de la covariable. Interprete detección y uso por separado.

Parte IV

Parte IV — Comparación y seguimiento

8 Estudios comparativos, intervenciones y sesgos

Diseño, estimandos y comparaciones ajustadas

Comparar grupos es sencillo; decidir qué significa la diferencia es más difícil. Una diferencia observada puede reflejar una intervención, selección de unidades, medición desigual, pérdidas o azar. El diseño determina qué comparación es defendible y el análisis debe conservar sus bloques, unidades y restricciones (Woodward 2014; Gerstman 2013).

8.1. Pregunta, diseño y estimando

Un estudio comparativo define antes de medir: población objetivo, condiciones, respuesta, unidad de asignación o selección, unidad de observación y periodo. En una intervención, la unidad experimental es la entidad que recibe una condición; varias mediciones dentro de ella son submuestras. En un estudio observacional no hay asignación controlada y una diferencia ajustada sigue siendo una asociación.

Sea Y_{ij} la respuesta de la unidad j bajo la condición i . Un estimando simple es la diferencia de medias

$$\Delta = \mu_1 - \mu_0.$$

Debe indicarse si las medias describen unidades, áreas o individuos; si son condicionales a bloques; y sobre qué distribución de ambientes se promedian. Un cociente de medias responde otra pregunta y exige que el denominador sea positivo. La precisión no corrige un estimando mal definido (Lohr 2022).

8.2. Asignación, comparación y bloqueo

La asignación aleatoria hace comparables las condiciones en expectativa y da una base para atribuir diferencias a la intervención. La selección aleatoria, en cambio, sustenta la generalización a una población. Ninguna reemplaza a la otra. Sin información explícita sobre selección, el alcance se limita a las unidades estudiadas (Manly y Navarro Alberto 2015; Gregg 2008).

Un bloque reúne unidades parecidas antes de asignar condiciones. El contraste se realiza dentro de bloque y luego se combina:

$$Y_{bj} = \alpha + \beta_b + \tau X_{bj} + \varepsilon_{bj}.$$

τ es una diferencia ajustada por bloque si la respuesta es aproximadamente aditiva en esa escala. El bloqueo puede reducir variación ambiental, pero no crea réplicas adicionales ni permite ignorar bloque en el análisis. Si cada bloque no contiene todas las condiciones, solo son estimables comparaciones apoyadas por el patrón conjunto de asignación; conviene usar un modelo deliberadamente limitado.

8.3. Sesgos que alteran una comparación

- **Selección:** inclusión o permanencia relacionadas con condición y respuesta.
- **Confusión:** diferencias previas acompañan a la condición en estudios sin asignación aleatoria.
- **Información:** método, observador o precisión difieren entre condiciones.
- **Pérdidas:** faltantes posteriores dependen de condición o resultado.
- **Contaminación:** una unidad recibe parte de otra condición.
- **Pseudorreplicación:** submuestras se analizan como unidades asignadas.
- **Reporte selectivo:** se eligen respuestas o modelos después de ver resultados.

La prevención mediante diseño y protocolo es preferible a un ajuste posterior. Una auditoría debe conservar identificadores, asignación prevista y recibida, fechas, faltantes, exclusiones y cambios de medición (Woodward 2014).

8.4. Estimación, incertidumbre y diagnóstico

Una estimación necesita tamaño de efecto, incertidumbre y escala. En modelos lineales, el intervalo para un contraste combina variación residual con los grados de libertad disponibles. Con pocos bloques, aproximaciones asintóticas y remuestreos son frágiles; deben mostrarse los datos por bloque.

Los residuos permiten revisar no linealidad, varianza desigual y observaciones influyentes. No prueban aleatorización, ausencia de sesgo ni independencia. Una conclusión robusta conserva signo y magnitud ecológica bajo decisiones razonables: ajuste por bloque, exclusión de una unidad influyente o una escala alternativa.

8.5. Aplicación completa: intervención nutricional en guisantes

8.5.1. Procedencia, diseño y alcance

`datasets::npk`, distribuido con R, registra rendimiento de guisantes en libras por parcela de 1/70 acre. Se aplicaron nitrógeno (N), fósforo (P) y potasio (K) en seis bloques. La ayuda `?datasets::npk` documenta 24 parcelas y cuatro combinaciones por bloque. Cada parcela es unidad experimental; el rendimiento es la respuesta; bloque representa heterogeneidad previa.

No están las ocho combinaciones dentro de cada bloque. Por ello, el análisis principal estima diferencias medias aditivas de cada nutriente, ajustadas por bloque y promediadas sobre la asignación del experimento. No se desarrolla una interpretación general de interacciones ni se extrapola a otras fincas, años o dosis. La procedencia no informa un marco probabilístico de fincas.

8.5.2. Importación y auditoría

```
data("npk", package = "datasets")
d <- npk

stopifnot(nrow(d) == 24L, !anyNA(d), !anyDuplicated(rownames(d)))
stopifnot(all(d$yield > 0), nlevels(d$block) == 6L)
audit <- list(
  dimensions = dim(d),
  levels = lapply(d[c("block", "N", "P", "K")], levels),
  units_per_block = table(d$block),
  treatment_replication = xtabs(~ N + P + K, d)
)
audit
#> $dimensions
#> [1] 24 5
#>
#> $levels
#> $levels$block
```

```

#> [1] "1" "2" "3" "4" "5" "6"
#>
#> $levels$N
#> [1] "0" "1"
#>
#> $levels$P
#> [1] "0" "1"
#>
#> $levels$K
#> [1] "0" "1"
#>
#>
#> $units_per_block
#>
#> 1 2 3 4 5 6
#> 4 4 4 4 4 4
#>
#> $treatment_replication
#> , , K = 0
#>
#>   P
#> N   0 1
#>   0 3 3
#>   1 3 3
#>
#> , , K = 1
#>
#>   P
#> N   0 1
#>   0 3 3
#>   1 3 3

```

La tabla tridimensional verifica replicación global, pero no demuestra que cada bloque sea completo. Esta comprobación evita atribuir al modelo una estructura que los datos no poseen.

8.5.3. Exploración por unidad y bloque

```

comb <- interaction(d$N, d$P, d$K, sep = "")
cols <- c("#3d5a80", "#ee6c4d", "#2a9d8f", "#9b5de5",

```

```

"#bc6c25", "#457b9d", "#6a994e", "#d62828")
plot(jitter(as.numeric(comb), amount = .07), d$yield,
     pch = 21, bg = cols[as.numeric(d$block)], xaxt = "n",
     xlab = "Combinación NPK", ylab = "Rendimiento (lb/parcela)")
axis(1, at = seq_along(levels(comb)), labels = levels(comb))
legend("topright", legend = levels(d$block), pt.bg = cols[1:6], pch = 21,
      title = "Bloque", bty = "n", ncol = 2)

```




Figura 8.1: Rendimiento de cada parcela; las líneas unen parcelas del mismo bloque.

```

aggregate(yield ~ block, d, function(x) c(media = mean(x), rango = diff(range(x))))
#>   block yield.media yield.rango
#> 1     1     54.025     16.000
#> 2     2     57.450      4.300
#> 3     3     60.775     14.500
#> 4     4     50.125     17.800
#> 5     5     50.525      3.200
#> 6     6     56.350      5.800
aggregate(yield ~ N + P + K, d, mean)
#>   N P K   yield
#> 1 0 0 0 51.4333

```

```
#> 2 1 0 0 63.76667
#> 3 0 1 0 54.33333
#> 4 1 1 0 57.93333
#> 5 0 0 1 52.00000
#> 6 1 0 1 54.66667
#> 7 0 1 1 50.50000
#> 8 1 1 1 54.36667
```

La dispersión entre bloques justifica conservarlos. Las medias crudas por combinación son descriptivas y no sustituyen los contrastes ajustados.

8.5.4. Estimación de diferencias ajustadas

```
fit <- lm(yield ~ block + N + P + K, data = d)
coef_table <- summary(fit)$coefficients
effects <- coef_table[c("N1", "P1", "K1"), , drop = FALSE]
intervals <- confint(fit, parm = c("N1", "P1", "K1"), level = .95)
result <- data.frame(
  nutrient = c("N", "P", "K"),
  difference_lb_plot = effects[, "Estimate"],
  standard_error = effects[, "Std. Error"],
  lower = intervals[, 1], upper = intervals[, 2],
  row.names = NULL
)
result
```

#>	nutrient	difference_lb_plot	standard_error	lower	upper
#> 1	N	5.616667	1.633622	2.134683	9.0986504
#> 2	P	-1.183333	1.633622	-4.665317	2.2986504
#> 3	K	-3.983333	1.633622	-7.465317	-0.5013496

```
anova(fit)
#> Analysis of Variance Table
#>
#> Response: yield
#>           Df Sum Sq Mean Sq F value Pr(>F)
#> block      5 343.29   68.659   4.2879 0.01272 *
#> N          1 189.28  189.282  11.8210 0.00366 **
#> P          1   8.40    8.402   0.5247 0.47999
#> K          1  95.20   95.202   5.9455 0.02767 *
#> Residuals 15 240.19   16.012
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Cada coeficiente compara presencia con ausencia del nutriente, manteniendo bloque y los otros dos indicadores en el modelo. Es una diferencia en libras por parcela, no un porcentaje ni una respuesta a cualquier dosis posible. La tabla ANOVA no debe reemplazar los tamaños de efecto y sus intervalos.


8.5.5. Incertidumbre respetando bloques

Como complemento se remuestran bloques completos. Solo hay seis, de modo que el intervalo bootstrap es un diagnóstico de estabilidad, no una garantía de cobertura.

```
set.seed(808)
B <- 1999
boot_effects <- replicate(B, {
  chosen <- sample(levels(d$block), replace = TRUE)
  db <- do.call(rbind, lapply(seq_along(chosen), function(i) {
    z <- d[d$block == chosen[i], ]
    z$boot_block <- factor(i)
    z
  }))
  coef(lm(yield ~ boot_block + N + P + K, db))[c("N1", "P1", "K1")]
})
boot_ci <- t(apply(boot_effects, 1, quantile, c(.025, .5, .975), na.rm = TRUE))
data.frame(nutrient = rownames(boot_ci), boot_ci, row.names = NULL)
#>   nutrient      X2.5.      X50.      X97.5.
#> 1      N1  2.608333  5.575000  8.767500
#> 2      P1 -4.191667 -1.166667  1.500000
#> 3      K1 -7.033333 -3.858333 -1.608333
```

8.5.6. Diagnósticos

```
op <- par(mfrow = c(1, 2))
plot(fitted(fit), residuals(fit), pch = 21, bg = "#457b9d",
     xlab = "Ajustado", ylab = "Residuo")
abline(h = 0, lty = 2)
qqnorm(residuals(fit), pch = 21, bg = "#ee6c4d")
qqline(residuals(fit))
```



```
par(op)

influence <- data.frame(
  row = seq_len(nrow(d)), block = d$block,
  combination = comb, cooks_distance = cooks.distance(fit)
)
influence[order(-influence$cooks_distance), ][1:5, ]
#>   row block combination cooks_distance
#> 3    3    1          000    0.3264151
#> 13   13    4          100    0.2800082
#> 10   10    3          111    0.1801278
#> 2    2    1          110    0.1389225
#> 16   16    4          010    0.1358971
```

Patrones curvos o de abanico cuestionarían la forma lineal y la varianza común. Una distancia de Cook alta señala dependencia del resultado, no autoriza borrar la parcela sin revisar el registro y el protocolo.

8.5.7. Sensibilidad analítica

Se compara el modelo primario con el análisis sin bloque y con seis análisis que omiten un bloque completo. Esto evalúa confusión por heterogeneidad espacial y dependencia de un

bloque, sin inventar nuevas unidades.

```
unblocked <- coef(lm(yield ~ N + P + K, d))[c("N1", "P1", "K1")]
leave_block <- sapply(levels(d$block), function(b) {
  coef(lm(yield ~ block + N + P + K, d[d$block != b, ])) [
    c("N1", "P1", "K1")]
})
round(cbind(primary = coef(fit)[c("N1", "P1", "K1")],
            unblocked = unblocked,
            leave_block_min = apply(leave_block, 1, min),
            leave_block_max = apply(leave_block, 1, max)), 2)
#>      primary unblocked leave_block_min leave_block_max
#> N1      5.62      5.62      4.39      6.59
#> P1     -1.18     -1.18     -2.27      0.03
#> K1     -3.98     -3.98     -4.60     -2.63
```

8.5.8. Interpretación

El análisis identifica qué nutrientes muestran una diferencia ajustada grande y cuánta incertidumbre acompaña esa magnitud en estas 24 parcelas. La atribución a las aplicaciones depende de que la asignación descrita se haya ejecutado y de que no haya contaminación o medición diferencial. El diseño incompleto por bloque, las seis réplicas ambientales y la falta de dosis adicionales impiden concluir sobre interacciones generales, forma de la respuesta o transporte a otros ambientes. Una conclusión debe reportar diferencias e intervalos, y mencionar si cambian al retirar bloques o ignorar el ajuste.

8.6. Síntesis

- Diseño y estimando preceden al modelo.
- Asignación sustenta atribución; selección sustenta generalización.
- Bloques se conservan en estimación, incertidumbre y sensibilidad.
- Sesgos de selección, información y pérdidas no desaparecen con precisión.
- Diagnósticos evalúan el modelo, no validan retrospectivamente el diseño.

8.7. Actividad propuesta para el lector

Use `datasets::InsectSprays`, un experimento real distribuido con R sobre conteos de insectos bajo seis tratamientos. Consulte y registre su ayuda como procedencia; defina unidad, respuesta, condiciones, población alcanzable y diferencia de medias de interés; audite tamaño

por tratamiento, ceros, faltantes y valores extremos; explore distribuciones y medias; estime contrastes seleccionados antes del ajuste con intervalos compatibles con conteos o con una justificación explícita de otra escala; diagnostique dispersión y observaciones influyentes; compare al menos dos decisiones razonables de modelación; e interprete magnitud, incertidumbre, sesgos posibles y límites de generalización.

9 Monitoreo ecológico y análisis de tendencias

Índices repetidos, dependencia y cambio temporal

Monitorear es medir repetidamente una población, comunidad o condición ambiental con un protocolo estable para describir estado y cambio. Una secuencia larga no compensa cambios de cobertura, esfuerzo o detección. El primer resultado de un programa es una serie comparable; el segundo es una inferencia cuya escala y alcance están definidos (Sutherland 2006; Gregg 2008).

9.1. Objetivo, indicador y unidad temporal

Un objetivo operativo especifica variable, dominio espacial, estación, frecuencia y cambio relevante. Un **indicador** es una medición relacionada con el proceso de interés; no necesariamente es abundancia. Capturas, registros acústicos o huellas pueden variar por población, esfuerzo y detectabilidad:

$$I_t \approx N_t q_t,$$

donde I_t es el índice, N_t la cantidad ecológica y q_t la fracción que el protocolo convierte en registros. Solo con q_t comparable, o modelado con datos auxiliares, el cambio de I_t informa cambio relativo de N_t (Henderson y Southwood 2016).

La unidad de análisis puede ser sitio-año, transecto-año o un total anual. Réplicas espaciales permiten separar variación entre sitios de cambio común. Una sola cifra anual no permite estimar esa variación espacial, aunque tenga muchos años.

9.2. Diseño de un programa de monitoreo

Un marco estable incluye sitios permanentes o una muestra repetida con reglas conocidas. Estratificación garantiza representación de hábitats; paneles rotativos reparten esfuerzo; sitios centinela ofrecen continuidad pero no generalización probabilística automática (Lohr 2022). Deben conservarse:

- identificador y coordenadas de la unidad;
- fecha, duración, área y esfuerzo;
- instrumento, observador y versión del protocolo;
- clima, accesibilidad y cambios de hábitat;
- ceros válidos, visitas fallidas y datos faltantes separados.

Cambiar simultáneamente instrumento y periodo crea una ruptura que puede parecer tendencia. Una fase de solapamiento entre métodos permite calibración; sin ella, es más prudente analizar periodos separados.

9.3. Tendencia y cambio ecológico

Para una tendencia lineal,

$$g(I_t) = \beta_0 + \beta_1(t - t_0) + \varepsilon_t,$$

donde g puede ser identidad o logaritmo. En escala logarítmica, $100(e^{\beta_1} - 1)$ es el cambio porcentual anual aproximado del índice. La pendiente resume un cambio medio monotónico; no describe ciclos, pulsos ni mecanismos. El año de referencia t_0 mejora interpretación y estabilidad numérica (Manly y Navarro Alberto 2015).

Observaciones consecutivas suelen parecerse. Si $\text{Cor}(\varepsilon_t, \varepsilon_{t-1}) = \rho$, tratar los años como independientes puede subestimar incertidumbre. Una regresión con errores de primer orden estima pendiente y dependencia conjuntamente. Es adecuada solo si residuos no conservan estructura importante; gráficos, autocorrelaciones y predicciones retrospectivas son parte del diagnóstico (Henderson y Southwood 2016).

9.4. Incertidumbre, sensibilidad y comunicación

El intervalo de una pendiente condiciona en el periodo, indicador y modelo. No incluye automáticamente error de detección, cambios de protocolo ni sesgo de cobertura. Para series dependientes, el remuestreo debe conservar tramos contiguos, no años aislados. Con ciclos fuertes, ninguna pendiente única debe presentarse como la dinámica completa.

La sensibilidad compara escalas, ventanas temporales y observaciones influyentes definidas por razones científicas. Probar muchos puntos de corte hasta hallar una pendiente deseada es selección de resultados. Deben mostrarse trayectoria, magnitud, intervalo y alcance, no solo una decisión dicotómica.

9.5. Aplicación completa: índice histórico de capturas de lince

9.5.1. Procedencia, diseño y estimando

`datasets::lynx` contiene 114 totales anuales de lince atrapados en Canadá entre 1821 y 1934. La documentación de R vincula la serie histórica con el registro de capturas de la región del río Mackenzie (Campbell y Walker 1977). No son conteos de un censo probabilístico ni estimaciones corregidas por esfuerzo.

La unidad temporal es el año y solo hay un total agregado por año. El estimando principal es el cambio porcentual anual medio del **índice de capturas** durante 1821–1934, bajo una tendencia log-lineal con dependencia de primer orden. No se estimará abundancia de lince ni una tendencia poblacional separada de esfuerzo, mercado, regulación o detectabilidad.

9.5.2. Importación y auditoría

```
data("lynx", package = "datasets")
d <- data.frame(year = as.integer(time(lynx)), index = as.numeric(lynx))
d$log_index <- log(d$index)
d$time_centered <- d$year - mean(d$year)

stopifnot(nrow(d) == 114L, !anyNA(d), all(d$index > 0))
stopifnot(all(diff(d$year) == 1L), d$year[1] == 1821L,
           d$year[nrow(d)] == 1934L)
list(range_year = range(d$year), range_index = range(d$index),
      spacing = unique(diff(d$year)), duplicated_year = anyDuplicated(d$year))
#> $range_year
#> [1] 1821 1934
#>
#> $range_index
#> [1] 39 6991
#>
#> $spacing
#> [1] 1
#>
```

```
#> $duplicated_year  
#> [1] 0
```

La ausencia de años faltantes facilita modelar dependencia, pero no informa si el esfuerzo de captura fue constante ni si un cero habría sido registrado.

9.5.3. Exploración de trayectoria y escala

```
op <- par(mfrow = c(2, 1), mar = c(4, 4, 2, 1))  
plot(index ~ year, d, type = "l", col = "#31572c",  
      xlab = "Año", ylab = "Linces atrapados")  
plot(log_index ~ year, d, type = "l", col = "#3d5a80",  
      xlab = "Año", ylab = "log(índice)")
```




Figura 9.1: Índice anual histórico de capturas de lince en escalas original y logarítmica.

```
par(op)  
aggregate(index ~ cut(year, breaks = seq(1820, 1940, 20)), d,
```

```

function(x) c(media = mean(x), mediana = median(x), maximo = max(x))
#> cut(year, breaks = seq(1820, 1940, 20)) index.media index.mediana
#> 1 (1.82e+03,1.84e+03] 1792.250 1173.000
#> 2 (1.84e+03,1.86e+03] 1003.400 615.000
#> 3 (1.86e+03,1.88e+03] 1396.550 721.500
#> 4 (1.88e+03,1.9e+03] 1211.200 429.000
#> 5 (1.9e+03,1.92e+03] 2235.450 1612.000
#> 6 (1.92e+03,1.94e+03] 1611.214 1334.500
#> index.maximo
#> 1 5943.000
#> 2 2871.000
#> 3 6721.000
#> 4 4431.000
#> 5 6991.000
#> 6 3574.000

```

La serie exhibe oscilaciones grandes y repetidas. El logaritmo reduce la relación entre nivel y amplitud, pero no elimina la dependencia ni convierte capturas en abundancia.

9.5.4. Tendencia preliminar y dependencia


```

fit_independent <- lm(log_index ~ time_centered, data = d)
summary(fit_independent)$coefficients
#> Estimate Std. Error t value Pr(>|t|)
#> (Intercept) 6.68593287 0.120668655 55.4073705 3.084475e-83
#> time_centered 0.00270325 0.003666882 0.7372068 4.625382e-01

op <- par(mfrow = c(1, 2))
plot(fitted(fit_independent), residuals(fit_independent), pch = 19,
     col = "#457b9d", xlab = "Ajustado", ylab = "Residuo")
abline(h = 0, lty = 2)
acf(residuals(fit_independent), main = "ACF: residuos independientes")

```

ACF: residuos independent



```
par(op)
```

El modelo independiente sirve como contraste. Una autocorrelación residual grande indica que su error estándar no representa adecuadamente la información temporal.

9.5.5. Estimación con errores dependientes

`stats::arima()` permite una regresión sobre el tiempo con errores AR(1). La pendiente sigue siendo log-lineal; la estructura de error reconoce continuidad entre años.

```
fit_ar1 <- arima(d$log_index, order = c(1, 0, 0),
                xreg = d$time_centered, include.mean = TRUE,
                method = "ML")
co <- coef(fit_ar1)
V <- fit_ar1$var.coef
se_slope <- sqrt(V["d$time_centered", "d$time_centered"])
ci_slope <- co["d$time_centered"] + qnorm(c(.025, .975)) * se_slope
annual_change <- 100 * (exp(c(estimate = co["d$time_centered"],
                             lower = ci_slope[1], upper = ci_slope[2])) - 1)
data.frame(phi = co["ar1"], annual_percent_change = annual_change[1],
           lower = annual_change[2], upper = annual_change[3],
```

```

      row.names = NULL)
#>      phi annual_percent_change      lower      upper
#> 1 0.7904719      0.6168716 -1.274413 2.544388

```

El cambio porcentual resume el índice durante todo el periodo. Incluso un intervalo estrecho no identificaría el mecanismo ni corregiría cambios históricos de esfuerzo.

9.5.6. Incertidumbre por bloques temporales

Se remuestrean bloques circulares de diez años y se estima una pendiente lineal en cada serie reconstruida. Es un complemento no paramétrico aproximado que conserva dependencia local, no una sustitución del modelo principal.

```

set.seed(909)
B <- 1999
n <- nrow(d)
block_length <- 10L
block_slope <- replicate(B, {
  starts <- sample(seq_len(n), ceiling(n / block_length), replace = TRUE)
  idx <- unlist(lapply(starts, function(s) ((s - 1L + 0:(block_length - 1L)) %% n) + 1L))
  yb <- d$log_index[idx[seq_len(n)]]
  coef(lm(yb ~ seq_len(n)))[2]
})
100 * (exp(quantile(block_slope, c(.025, .5, .975))) - 1)
#>      2.5%      50%      97.5%
#> -0.83183796 -0.01101339 0.83637219


```

9.5.7. Diagnósticos del modelo dependiente

```

res <- residuals(fit_ar1)
op <- par(mfrow = c(1, 2))
plot(d$year, res, type = "h", col = "#6a994e",
      xlab = "Año", ylab = "Residuo AR(1)")
abline(h = 0, lty = 2)
acf(res, main = "ACF: residuos AR(1)")

```

```
par(op)
Box.test(res, lag = 10, type = "Ljung-Box", fitdf = 1)
#>
#> Box-Ljung test
#>
#> data:  res
#> X-squared = 267.06, df = 9, p-value < 2.2e-16
```

Autocorrelación restante, rachas o varianza cambiante indicarían que pendiente más AR(1) es un resumen incompleto. En esta serie cíclica se espera que un modelo tan simple no capture toda la estructura; eso limita inferencia, no justifica añadir componentes sin una pregunta ecológica y apoyo teórico.

9.5.8. Sensibilidad a escala y periodo

```
estimate_ar1 <- function(z, response = c("log", "raw")) {
  response <- match.arg(response)
  y <- if (response == "log") log(z$index) else z$index
  x <- z$year - mean(z$year)
  f <- arima(y, order = c(1, 0, 0), xreg = x, method = "ML")
}
```

```

  unname(coef(f)["x"])
}

periods <- list(full = d, from_1841 = subset(d, year >= 1841),
               through_1914 = subset(d, year <= 1914))
sens <- data.frame(
  period = names(periods),
  log_slope = vapply(periods, estimate_ar1, numeric(1), response = "log"),
  raw_slope = vapply(periods, estimate_ar1, numeric(1), response = "raw")
)
transform(sens, annual_percent = 100 * (exp(log_slope) - 1))
#>           period  log_slope raw_slope annual_percent
#> full           full 0.006149768  6.267635      0.6168716
#> from_1841      from_1841 0.013559051 13.275040      1.3651392
#> through_1914 through_1914 0.007704788  9.530380      0.7734547

```

Si la pendiente cambia mucho al desplazar veinte años los extremos, la afirmación de una tendencia secular depende de la ventana frente a las oscilaciones. La escala original expresa capturas por año; la logarítmica, cambio proporcional.

9.5.9. Interpretación

El resultado defendible describe dirección y magnitud media del índice histórico, su intervalo y la dependencia estimada. La gráfica muestra que esa pendiente no resume los pulsos dominantes. Sin esfuerzo, área efectiva, regulación y detección, no puede llamarse abundancia ni atribuirse a una causa ecológica. Para monitoreo actual se necesitarían sitios o rutas replicados, esfuerzo registrado y una fase de calibración cuando cambie el protocolo.

9.6. Síntesis

- Un indicador solo representa el proceso bajo una relación de observación clara.
- Tendencia, ciclo y cambio abrupto son patrones distintos.
- La unidad temporal y la dependencia deben conservarse en la incertidumbre.
- Diagnósticos y sensibilidad delimitan el resumen, no reparan datos no comparables.
- Un índice de captura debe interpretarse como índice, no como abundancia.

9.7. Actividad propuesta para el lector

Analice `datasets::Nile`, una serie real de caudal anual del río Nilo. Registre la procedencia y las unidades desde `?Nile`; defina el indicador, la unidad anual y una tendencia o diferencia entre periodos como estimando; audite continuidad, faltantes y rango; explore escalas original y logarítmica; estime una tendencia con incertidumbre que reconozca dependencia; examine residuos y autocorrelación; evalúe sensibilidad a escala, extremos del periodo y una división temporal justificada por la documentación; e interprete el resultado como monitoreo de caudal observado, distinguiendo cambio estadístico, mecanismo y alcance.

Parte V

Parte V — Poblaciones y comunidades

10 Demografía y dinámica poblacional

Supervivencia, transiciones y cambio por estadios

La demografía conecta destinos individuales con cambio poblacional. Nacimientos, supervivencia, crecimiento, reproducción y movimiento deben compartir población, intervalo y convención de censo. Una tasa sin denominador y periodo explícitos no es comparable, y un cambio local mezcla procesos si la población es abierta (Henderson y Southwood 2016; Sutherland 2006).

10.1. Contabilidad y tasas vitales

Para una población delimitada,

$$N_{t+1} = N_t + B_t - D_t + I_t - E_t.$$

Si inmigración y emigración no se observan, desaparición no equivale necesariamente a muerte y reclutamiento no equivale necesariamente a nacimiento local. Marcar y visitar individuos permite estimar destinos condicionados al estado inicial; parcelas permanentes describen además entradas y estructura (Gregg 2008).

Para n_j individuos en estadio inicial j , de los cuales n_{ij} aparecen en el estadio i al siguiente censo,

$$\hat{p}_{ij} = \frac{n_{ij}}{n_j}, \quad \hat{S}_j = \sum_{i \in \text{vivos}} \hat{p}_{ij}.$$

$\hat{S}_j$ es supervivencia aparente cuando no se separan muerte, emigración y no detección. Permanencia, crecimiento y retroceso son componentes distintos de la transición. Sus conteos comparten denominador y no son estimaciones independientes.

10.2. Fertilidad y reclutamiento

Frutos, semillas, nacimientos y nuevos individuos censables representan etapas distintas. Una media de frutos por planta florecida mide producción reproductiva, no reclutamiento. Para conectar reproducción con nuevos censables se necesita la cadena de establecimiento o un cociente empírico con intervalo y área compatibles (Henderson y Southwood 2016).

Con censos anuales por parcela puede resumirse

$$F = \frac{\text{reclutas en } t + 1}{\text{plantas florecidas en } t}.$$

F es reclutamiento por planta florecida, no maternidad identificada: reclutas pueden proceder del banco de semillas y las madres no están enlazadas. La interpretación exige declarar esta limitación.

10.3. Estructura por estadios

Edad cronológica no siempre predice destino. En plantas perennes, tamaño y estado reproductivo suelen definir estadios útiles. Sea n_t el vector de números por estadio. Una matriz anual descriptiva puede escribirse

$$n_{t+1} = \mathbf{A}n_t,$$

donde la columna j representa el estadio de origen y la fila i el destino. Las entradas vegetativas son probabilidades; una entrada reproductiva puede exceder uno si cuenta nuevos individuos por adulto. La matriz supone tasas constantes, clasificación correcta, intervalo común y cierre suficiente para la pregunta (Henderson y Southwood 2016).

Una proyección es condicional, no un pronóstico garantizado. Antes de proyectar se deben comparar totales predichos con censos posteriores, revisar variación entre años y parcelas y propagar incertidumbre de las unidades independientes.

10.4. Incertidumbre y diagnóstico

Para una proporción, intervalos binomiales son útiles si los destinos individuales son comparables. Cuando individuos comparten parcela y ambiente, remuestrear filas subestima variación; parcelas o periodos son unidades más apropiadas. Con pocas parcelas, los intervalos describen estabilidad limitada (Manly y Navarro Alberto 2015).

Diagnósticos demográficos incluyen denominadores pequeños, estados imposibles, columnas vegetativas mayores que uno, tasas variables por año, plantas duplicadas y discrepancias entre estructura observada y predicha. Sensibilidad razonable examina parcelas, periodos y definiciones de estadio, sin convertir una proyección en una recomendación automática.

10.5. Aplicación completa: demografía de *Aquilegia chrysantha*

10.5.1. Procedencia, diseño, unidad y estimandos

`popbio::aq.trans` contiene transiciones anuales de *Aquilegia chrysantha* en diez parcelas de Fillmore Canyon, Organ Mountains, Nuevo México, entre 1996 y 2003. La documentación identifica propietarios, planta, parcela, año, estadio inicial, frutos y destino anual; el paquete y los datos se describen en Stubben y Milligan (2007).

La unidad longitudinal es la planta marcada y la unidad ambiental replicada es la parcela. Los estimandos son: supervivencia aparente anual por estadio; distribución de destinos vivos; frutos medios por planta florecida; reclutas por planta florecida del año anterior; y una matriz anual agrupada para estas parcelas y años. No hay selección probabilística de cañones ni maternidad de reclutas.

10.5.2. Importación y auditoría

```
if (!requireNamespace("popbio", quietly = TRUE)) {
  stop("Este capítulo requiere el paquete 'popbio'.")
}
data("aq.trans", package = "popbio")
d <- aq.trans
stages <- c("recruit", "small", "large", "flower")

stopifnot(all(c("plot", "year", "plant", "stage", "fate", "fruits") %in% names(d)))
stopifnot(!anyNA(d[c("plot", "year", "plant", "stage", "fate")]))
stopifnot(all(d$fruits >= 0, na.rm = TRUE))
key <- interaction(d$plot, d$year, d$plant, drop = TRUE)
stopifnot(!anyDuplicated(key))

audit <- list(
  dimensions = dim(d), plots = sort(unique(d$plot)), years = range(d$year),
  initial_stage = table(d$stage, useNA = "ifany"),
  fate = table(d$fate, useNA = "ifany"),
  missing = colSums(is.na(d))
)
```

```

)
audit
#> $dimensions
#> [1] 1637    9
#>
#> $plots
#> [1] 903 906 909 913 914 916 921 923 929 930
#>
#> $years
#> [1] 1996 2003
#>
#> $initial_stage
#>
#>      seed recruit      small      large      flower
#>      0      574      461      320      282
#>
#> $fate
#>
#>      seed recruit      small      large      flower      dead
#>      0          0      306      297      206      828
#>
#> $missing
#>      plot  year  plant  stage  leaf  rose fruits  fate  rose2
#>      0      0      0      0      15   813      0      0   1074

```

La ausencia de plantas en el estadio **seed** y de destinos **seed** o **recruit** evita estimar directamente el banco de semillas. Los NA morfológicos no se sustituyen por cero; para transiciones bastan estadio y destino.

10.5.3. Exploración de estructura y reproducción


```

stage_year <- xtabs(~ stage + year, d)
stage_year
#>      year
#> stage 1996 1997 1998 1999 2000 2001 2002 2003
#> seed      0      0      0      0      0      0      0      0
#> recruit  12  287  186   76      5      5      0      3
#> small   134   75   60   84   58   31   13      6
#> large    17   68   41   57   59   58   16      4
#> flower   62    6   80   74   52    8      0      0

```



```
#| fig-cap: "Composición anual de los estadios iniciales observados."
barplot(prop.table(stage_year[stages, , drop = FALSE], 2),
        col = c("#dda15e", "#90be6d", "#457b9d", "#9b5de5"),
        xlab = "Año inicial", ylab = "Proporción observada",
        legend.text = stages, args.legend = list(x = "top", ncol = 4, bty = "n"))
```



```
aggregate(fruits ~ stage, d, function(x) {
  c(n = sum(!is.na(x)), mean = mean(x, na.rm = TRUE),
    median = median(x, na.rm = TRUE), total = sum(x, na.rm = TRUE))
})
#>      stage  fruits.n fruits.mean fruits.median fruits.total
#> 1 recruit 574.000000  0.000000   0.000000   0.000000
#> 2  small 461.000000  0.000000   0.000000   0.000000
#> 3  large 320.000000  0.000000   0.000000   0.000000
#> 4  flower 282.000000  2.741135   2.000000  773.000000
```

La gráfica separa estructura de tamaño poblacional. Los frutos están concentrados en plantas florecidas; muchos ceros son resultados reproductivos válidos.

10.5.4. Transición y supervivencia aparente

```
transition_counts <- with(d, table(stage, fate))[stages,
  c(stages, "dead"), drop = FALSE]
transition_prob <- prop.table(transition_counts, 1)
survival <- data.frame(
  stage = stages,
  n = rowSums(transition_counts),
  apparent_survival = 1 - transition_prob[, "dead"]
)

survival_ci <- t(vapply(seq_along(stages), function(j) {
  binom.test(sum(transition_counts[j, stages]),
    sum(transition_counts[j, ]))$conf.int
}, numeric(2)))
survival$lower <- survival_ci[, 1]
survival$upper <- survival_ci[, 2]
survival
#>      stage    n apparent_survival      lower      upper
#> recruit recruit 574      0.1306620 0.1041786 0.1610135
#> small    small 461      0.5878525 0.5413910 0.6331796
#> large    large 320      0.6875000 0.6335857 0.7379026
#> flower   flower 282      0.8617021 0.8158249 0.8997738
round(transition_prob, 3)
#>      fate
#> stage    recruit small large flower  dead
#> recruit    0.000 0.129 0.000  0.002 0.869
#> small      0.000 0.364 0.137  0.087 0.412
#> large      0.000 0.094 0.331  0.262 0.312
#> flower     0.000 0.121 0.454  0.287 0.138
```

Los intervalos binomiales tratan plantas como ensayos comparables y por eso son optimistas si hay agrupación por parcela o año. Se complementarán con remuestreo de parcelas.

10.5.5. Fertilidad observada y reclutamiento

```
flower_rows <- d$stage == "flower"
fruit_summary <- c(
  flowering_plants = sum(flower_rows),
```

```

    mean_fruits = mean(d$fruits[flower_rows], na.rm = TRUE),
    proportion_with_fruit = mean(d$fruits[flower_rows] > 0, na.rm = TRUE)
)

counts <- as.data.frame(xtabs(~ plot + year + stage, d))
names(counts)[4] <- "count"
wide <- reshape(counts, idvar = c("plot", "year"), timevar = "stage",
                direction = "wide")
names(wide) <- sub("count\\.", "", names(wide))
for (s in stages) if (!s %in% names(wide)) wide[[s]] <- 0
next_recruits <- wide[c("plot", "year", "recruit")]
next_recruits$year <- as.numeric(as.character(next_recruits$year)) - 1
wide$year <- as.numeric(as.character(wide$year))
names(next_recruits)[3] <- "recruits_next"
paired <- merge(wide, next_recruits, by = c("plot", "year"))
paired <- paired[paired$flower > 0, ]
F_pooled <- sum(paired$recruits_next) / sum(paired$flower)

fruit_summary
#>      flowering_plants      mean_fruits proportion_with_fruit
#>      282.000000      2.741135      0.787234
data.frame(plot_years = nrow(paired), flowering = sum(paired$flower),
           recruits_next = sum(paired$recruits_next),
           recruits_per_flowering = F_pooled)
#>  plot_years flowering recruits_next recruits_per_flowering
#> 1      46      282      481      1.705674

```

El cociente agrupado alinea parcela y años consecutivos. No mide semillas por fruto ni asigna descendencia; resume establecimiento observado por planta florecida previa bajo posible contribución del banco de semillas.

10.5.6. Matriz transparente y proyección de un paso

La matriz usa `recruit`, `small`, `large` y `flower`. Las tres filas vegetativas proceden de destinos observados; la primera fila contiene el cociente de reclutamiento únicamente en la columna de plantas florecidas.

```

A <- matrix(0, nrow = 4, ncol = 4,
           dimnames = list(destination = stages, origin = stages))
A[c("small", "large", "flower"), ] <-
  t(transition_prob[, c("small", "large", "flower"), drop = FALSE])

```

```

A["recruit", "flower"] <- F_pooled

stopifnot(all(is.finite(A)), all(A >= 0))
vegetative_column_sums <- colSums(A[c("small", "large", "flower"), , drop = FALSE])
stopifnot(all(vegetative_column_sums <= 1 + sqrt(.Machine$double.eps)))
round(A, 3)
#>           origin
#> destination recruit small large flower
#>   recruit    0.000 0.000 0.000  1.706
#>   small      0.129 0.364 0.094  0.121
#>   large      0.000 0.137 0.331  0.454
#>   flower     0.002 0.087 0.262  0.287

last_year <- max(d$year)
n_last <- table(factor(d$stage[d$year == last_year], levels = stages))
prediction <- drop(A %*% as.numeric(n_last))
data.frame(stage = stages, observed_initial = as.numeric(n_last),
            projected_next = prediction)
#>           stage observed_initial projected_next
#> recruit recruit                3      0.000000
#> small   small                6      2.948311
#> large   large                4      2.144957
#> flower  flower                0      1.575834

```

La proyección posterior a 2003 es un escenario de tasas agrupadas, no una observación ni un pronóstico validado. Combina supervivencia aparente y reclutamiento asociado, con tasas constantes entre parcelas y años.

10.5.7. Incertidumbre por parcelas

```

matrix_from_data <- function(z) {
  tc <- with(z, table(factor(stage, levels = stages),
                        factor(fate, levels = c(stages, "dead"))))
  tp <- prop.table(tc, 1)
  cy <- as.data.frame(xtabs(~ plot + year + stage, z))
  names(cy)[4] <- "count"
  cw <- reshape(cy, idvar = c("plot", "year"), timevar = "stage", direction = "wide")
  names(cw) <- sub("count\\.", "", names(cw))
  for (s in stages) if (!s %in% names(cw)) cw[[s]] <- 0
  nr <- cw[c("plot", "year", "recruit")]
}

```

```

nr$year <- as.numeric(as.character(nr$year)) - 1
cw$year <- as.numeric(as.character(cw$year))
names(nr)[3] <- "recruits_next"
pr <- merge(cw, nr, by = c("plot", "year"))
pr <- pr[pr$flower > 0, ]
M <- matrix(0, 4, 4, dimnames = list(stages, stages))
M[2:4, ] <- t(tp[, c("small", "large", "flower"), drop = FALSE])
M[1, 4] <- sum(pr$recruits_next) / sum(pr$flower)
M
}

set.seed(1010)
plots <- unique(d$plot)
B <- 999
boot <- replicate(B, {
  selected <- sample(plots, length(plots), replace = TRUE)
  zb <- do.call(rbind, lapply(seq_along(selected), function(i) {
    x <- d[d$plot == selected[i], ]
    x$plot <- i
    x
  })))
  M <- matrix_from_data(zb)
  c(survival = colSums(M[2:4, , drop = FALSE]),
    recruitment = M[1, 4])
})
t(apply(boot, 1, quantile, c(.025, .5, .975), na.rm = TRUE))
#>                2.5%         50%         97.5%
#> survival.recruit 0.08027321 0.1326923 0.1720018
#> survival.small   0.51495221 0.5899705 0.6394509
#> survival.large   0.65011718 0.6864686 0.7381369
#> survival.flower  0.81441930 0.8609023 0.8892054
#> recruitment      0.59703038 1.6838906 2.9714850

```

El remuestreo conserva juntas plantas y años de cada parcela. Diez parcelas siguen siendo una base pequeña para inferencia regional.

10.5.8. Diagnóstico retrospectivo

Se estima una matriz con todos los años excepto el último intervalo disponible y se compara la estructura predicha con los destinos observados de ese intervalo.

```

train <- d[d$year < max(d$year), ]
A_train <- matrix_from_data(train)
validation <- d[d$year == max(d$year), ]
n_origin <- table(factor(validation$stage, levels = stages))
observed_fates <- table(factor(validation$fate,
                              levels = c(stages, "dead")))[stages]
predicted_fates <- drop(A_train %*% as.numeric(n_origin))
diagnostic <- data.frame(
  stage = stages, observed = as.numeric(observed_fates), predicted = predicted_fates,
  pearson = (as.numeric(observed_fates) - predicted_fates) /
    sqrt(pmax(predicted_fates, 1))
)
diagnostic
#>      stage observed predicted    pearson
#> recruit recruit      0  0.000000  0.000000
#> small   small      4  2.931176  0.6242885
#> large   large      5  2.108722  1.9910413
#> flower   flower     1  1.582831 -0.4632605

```

La comparación es imperfecta porque el reclutamiento de la matriz se alinea por parcela-año, mientras los destinos validan plantas ya censadas. Residuos grandes señalan variación temporal, clasificación o reclutamiento no representado; no identifican por sí solos cuál proceso falló.

10.5.9. Sensibilidad entre parcelas y periodos

```

leave_plot <- sapply(plots, function(p) {
  M <- matrix_from_data(d[d$plot != p, ])
  c(survival = colSums(M[2:4, , drop = FALSE]), recruitment = M[1, 4])
})
period_split <- lapply(list(early = d[d$year <= 1999, ],
                           late = d[d$year >= 2000, ]), matrix_from_data)

leave_summary <- data.frame(
  parameter = rownames(leave_plot),
  minimum = apply(leave_plot, 1, min, na.rm = TRUE),
  maximum = apply(leave_plot, 1, max, na.rm = TRUE),
  row.names = NULL
)
period_summary <- do.call(rbind, lapply(names(period_split), function(period) {
  M <- period_split[[period]]

```

```

data.frame(period,
            parameter = c(paste0("survival_", stages), "recruitment"),
            estimate = c(colSums(M[2:4, , drop = FALSE]), M[1, 4]))
)))
leave_summary
#>           parameter  minimum  maximum
#> 1 survival.recruit 0.1208226 0.1528662
#> 2 survival.small 0.5621302 0.6175000
#> 3 survival.large 0.6678967 0.7011070
#> 4 survival.flower 0.8508772 0.8698885
#> 5 recruitment 1.2832618 2.0338983
period_summary
#>      period      parameter  estimate
#> recruit  early survival_recruit 0.13190731
#> small    early survival_small 0.63739377
#> large    early survival_large 0.90163934
#> flower   early survival_flower 0.90090090
#>          early recruitment 3.20270270
#> recruit1 late survival_recruit 0.07692308
#> small1    late survival_small 0.42592593
#> large1    late survival_large 0.40145985
#> flower1   late survival_flower 0.71666667
#> 1         late recruitment 0.08333333

```

Variación amplia al omitir una parcela limita la representatividad espacial; diferencias entre periodos cuestionan tasas constantes. Estas comparaciones no seleccionan una matriz favorita: muestran cuánto depende el resumen de espacio y tiempo.

10.5.10. Interpretación

Los datos permiten describir qué fracción de cada estadio reaparece viva, hacia qué estadio cambia, cuántos frutos producen las plantas florecidas y cuántos reclutas aparecen después por planta florecida. La matriz integra esos resúmenes con convenciones explícitas, pero omite banco de semillas medido, maternidad, detección y movimiento. Por ello, cualquier proyección está condicionada a estas diez parcelas, años y clasificación. La variación bootstrap, la validación de un intervalo y la sensibilidad espacial y temporal deben acompañar la matriz.

10.6. Síntesis

- Las tasas vitales requieren denominador, intervalo y estado inicial.

- Supervivencia aparente puede mezclar muerte, emigración y no detección.
- Frutos, semillas y reclutas no son medidas intercambiables de fertilidad.
- Una matriz por estadios debe declarar orientación y contenido de cada entrada.
- Proyección, diagnóstico e incertidumbre son necesarios antes de interpretar dinámica poblacional.

10.7. Actividad propuesta para el lector

Use `popbio::monkeyflower`, un conjunto real incluido en `popbio`. Consulte su documentación y registre procedencia, población, años, estadios y orientación de las matrices; audite dimensiones, nombres, valores negativos y columnas biológicamente plausibles; defina una tasa o proyección como estimando; explore variación entre matrices; derive supervivencia, permanencia, crecimiento y fertilidad sin mezclar sus unidades; proyecte una estructura inicial durante un horizonte corto con incertidumbre entre matrices; compare predicciones con un intervalo reservado cuando sea posible; evalúe sensibilidad a periodo y estado inicial; e interprete resultados y límites sin añadir métricas derivadas de valores propios.

11 Riqueza, diversidad y composición de comunidades

Índices clásicos, semejanza, clasificación y ordenación

Una muestra comunitaria no es una lista completa de especies. Es el resultado de una unidad espacial, un periodo, un método, un esfuerzo y una capacidad de detección. Por eso, riqueza, diversidad y composición solo son comparables cuando esas condiciones tienen significado semejante. El tratamiento metodológico de este capítulo sigue los índices y métodos multivariados clásicos presentados por Henderson y Southwood (2016).

11.1. De la pregunta a la matriz comunitaria

Una pregunta comunitaria debe precisar población, unidad, periodo y atributo. Por ejemplo: **¿cómo varían la riqueza, la diversidad y la composición vegetal entre los 20 sitios de pastizal observados bajo distintas formas de manejo?** La matriz analítica es

$$\mathbf{Y} = [y_{ij}],$$

donde cada fila i es una unidad de muestreo, cada columna j una especie y y_{ij} su abundancia, cobertura o presencia. No deben mezclarse conteos, coberturas y biomasa en una misma matriz. Los metadatos de sitio se conservan en otra tabla enlazada mediante una clave única.

La población objetivo puede ser mucho mayor que las filas disponibles. Si se desconocen el marco y las probabilidades de inclusión, los resultados describen los sitios observados y generan hipótesis, pero no constituyen una estimación de diseño para todo el paisaje (Lohr 2022).

! Ceros y faltantes

Un cero indica que el protocolo se aplicó y la especie no fue registrada. Un faltante indica que la observación no está disponible. Convertir un faltante en cero inventa una ausencia y modifica riqueza, índices y distancias.

11.2. Riqueza y diversidad clásica

Para una unidad con abundancias n_j , total $N = \sum_j n_j$ y proporciones $p_j = n_j/N$, la **riqueza observada** es

$$S_{obs} = \sum_j I(n_j > 0).$$

S_{obs} cuenta especies registradas, no especies verdaderamente presentes. Su valor suele aumentar con área, duración, número de individuos y eficacia del método.

El índice de Shannon es

$$H' = - \sum_{j:p_j>0} p_j \log(p_j).$$

Crece cuando aumentan riqueza y equidad. La base del logaritmo debe declararse; aquí se usa el logaritmo natural. La concentración de Simpson es

$$D = \sum_j p_j^2,$$

la probabilidad de que dos individuos tomados de la distribución pertenezcan a la misma especie. En este capítulo se informa $1 - D$, que aumenta con la diversidad. No se deben intercambiar D , $1 - D$ y $1/D$ bajo un mismo nombre.

La equidad de Pielou relaciona Shannon con su máximo para la riqueza observada:

$$J' = \frac{H'}{\log(S_{obs})}.$$

Está definida para $S_{obs} > 1$. Una comunidad con muchas especies puede tener equidad baja si una de ellas domina.

11.3. Semejanza y disimilitud

Para dos sitios, sean a las especies compartidas y b, c las exclusivas. La disimilitud de Jaccard en presencia-ausencia es

$$d_J = \frac{b + c}{a + b + c}.$$

Jaccard ignora las abundancias y los dobles ceros. Es apropiada cuando la pregunta se refiere a identidad de especies.

La disimilitud de Bray-Curtis conserva abundancias:

$$d_{BC}(i, k) = \frac{\sum_j |y_{ij} - y_{kj}|}{\sum_j (y_{ij} + y_{kj})}.$$

También ignora dobles ceros, pero responde tanto al reemplazo de especies como a diferencias en abundancia. Un sitio sin registros no tiene una comparación Bray-Curtis interpretable. La métrica se elige antes de examinar cuál produce la separación visual más atractiva.

11.4. Clasificación y ordenación

La **clasificación jerárquica** agrupa sitios a partir de una matriz de disimilitud. El resultado depende de la distancia, la transformación y el método de enlace. El enlace promedio combina grupos mediante su disimilitud media y produce un dendrograma descriptivo. Cortar el árbol en cierto número de grupos no demuestra que existan comunidades discretas.

La **ordenación** representa sitios en pocas dimensiones. Aquí se usa análisis de coordenadas principales sobre Bray-Curtis. Los ejes aproximan la configuración de distancias; su signo es arbitrario y no son gradientes ambientales demostrados. Los autovalores negativos advierten que la distancia no es completamente euclidiana. La clasificación y la ordenación son vistas complementarias de la misma estructura, no pruebas independientes.

11.5. Aplicación con `vegan::dune`

11.5.1. Procedencia, pregunta y auditoría

`vegan::dune` contiene abundancias de 30 especies vegetales en 20 sitios de pastizales de dunas, y `dune.env` aporta variables ambientales y de manejo (Oksanen et al. 2024). Se describirá la

diversidad local y se explorará si sitios con formas de manejo semejantes también son semejantes en composición. El caso es observacional y la documentación del objeto no proporciona un marco probabilístico completo; por ello no se atribuyen efectos causales ni se generaliza a todos los pastizales.

```
if (!requireNamespace("vegan", quietly = TRUE)) {
  stop("Este capítulo requiere el paquete 'vegan'.")
}
data("dune", package = "vegan")
data("dune.env", package = "vegan")

comm <- as.matrix(dune)
env <- dune.env
site_id <- rownames(comm)

audit <- c(
  sites = nrow(comm),
  taxa = ncol(comm),
  duplicated_sites = sum(duplicated(site_id)),
  missing_abundances = sum(is.na(comm)),
  negative_abundances = sum(comm < 0, na.rm = TRUE),
  empty_sites = sum(rowSums(comm, na.rm = TRUE) == 0),
  metadata_mismatch = as.integer(nrow(comm) != nrow(env))
)
audit
#>           sites           taxa duplicated_sites missing_abundances
#>           20           30              0              0
#> negative_abundances      empty_sites metadata_mismatch
#>              0              0              0
stopifnot(audit[c("duplicated_sites", "missing_abundances",
  "negative_abundances", "empty_sites",
  "metadata_mismatch")] == 0)
```

La coincidencia por orden se comprueba en este objeto distribuido por el paquete. En un proyecto propio se usaría una columna identificadora en ambas tablas; unir por posición sin verificar claves es un error silencioso.

11.5.2. Riqueza, Shannon, Simpson y equidad

```
richness <- vegan::specnumber(comm)
shannon <- vegan::diversity(comm, index = "shannon")
```

```

simpson_1_D <- vegan::diversity(comm, index = "simpson")
evenness <- ifelse(richness > 1, shannon / log(richness), NA_real_)

site_metrics <- data.frame(
  site = site_id,
  Management = env$Management,
  total_abundance = rowSums(comm),
  richness = richness,
  shannon = shannon,
  simpson_1_D = simpson_1_D,
  evenness = evenness
)
site_metrics
#>   site Management total_abundance richness  shannon simpson_1_D evenness
#> 1      1         SF              18        5 1.440482   0.7345679 0.8950216
#> 2      2         BF              42       10 2.252516   0.8900227 0.9782554
#> 3      3         SF              40       10 2.193749   0.8787500 0.9527332
#> 4      4         SF              45       13 2.426779   0.9007407 0.9461313
#> 5      5         HF              43       14 2.544421   0.9140076 0.9641403
#> 6      6         HF              48       11 2.345946   0.9001736 0.9783356
#> 7      7         HF              40       13 2.471733   0.9075000 0.9636577
#> 8      8         HF              40       12 2.434898   0.9087500 0.9798749
#> 9      9         HF              42       13 2.493568   0.9115646 0.9721705
#> 10     10        BF              43       12 2.398613   0.9031909 0.9652727
#> 11     11        BF              32        9 2.106065   0.8671875 0.9585114
#> 12     12        SF              35        9 2.114495   0.8685714 0.9623483
#> 13     13        SF              33       10 2.099638   0.8521579 0.9118610
#> 14     14        NM              24        7 1.863680   0.8333333 0.9577421
#> 15     15        NM              23        8 1.979309   0.8506616 0.9518463
#> 16     16        SF              33        8 1.959795   0.8429752 0.9424621
#> 17     17        NM              15        7 1.876274   0.8355556 0.9642139
#> 18     18        NM              27        9 2.079387   0.8614540 0.9463699
#> 19     19        NM              31        9 2.134024   0.8740895 0.9712362
#> 20     20        NM              31        8 2.048270   0.8678460 0.9850099

```

Las funciones pueden comprobarse con las definiciones. Esta verificación también deja inequívoca la variante de Simpson.

```

manual_indices <- function(x) {
  p <- x[x > 0] / sum(x)
  S <- length(p)
  H <- -sum(p * log(p))
}

```

```

  c(richness = S, shannon = H, simpson_1_D = 1 - sum(p^2),
    evenness = if (S > 1) H / log(S) else NA_real_)
}
manual <- t(apply(comm, 1, manual_indices))
stopifnot(
  isTRUE(all.equal(unname(manual[, "richness"]), as.numeric(richness))),
  isTRUE(all.equal(unname(manual[, "shannon"]), unname(shannon))),
  isTRUE(all.equal(unname(manual[, "simpson_1_D"]), unname(simpson_1_D)))
)
round(manual[1:5, ], 3)
#>   richness shannon simpson_1_D evenness
#> 1      5    1.440      0.735    0.895
#> 2     10    2.253      0.890    0.978
#> 3     10    2.194      0.879    0.953
#> 4     13    2.427      0.901    0.946
#> 5     14    2.544      0.914    0.964

```

```

metric_names <- c("richness", "shannon", "simpson_1_D", "evenness")
management_summary <- do.call(rbind, lapply(split(site_metrics, site_metrics$Management),
  function(z) {
    data.frame(
      Management = as.character(z$Management[1]),
      n_sites = nrow(z),
      t(vapply(z[metric_names], function(x)
        c(mean = mean(x), sd = sd(x)), numeric(2)))
    )
  })))
management_summary
#>   Management n_sites      mean      sd
#> BF.richness    BF      3 10.333333 1.527525232
#> BF.shannon     BF      3  2.2523979 0.146273888
#> BF.simpson_1_D BF      3  0.8868004 0.018216721
#> BF.evenness    BF      3  0.9673465 0.010034011
#> HF.richness    HF      5 12.6000000 1.140175425
#> HF.shannon     HF      5  2.4581134 0.074182249
#> HF.simpson_1_D HF      5  0.9083992 0.005245610
#> HF.evenness    HF      5  0.9716358 0.007630362
#> NM.richness    NM      6  8.0000000 0.894427191
#> NM.shannon     NM      6  1.9968240 0.110321140
#> NM.simpson_1_D NM      6  0.8538233 0.016906378
#> NM.evenness    NM      6  0.9627364 0.014013815
#> SF.richness    SF      6  9.1666667 2.639444386

```

```
#> SF.shannon          SF      6  2.0391563 0.331117396
#> SF.simpson_1_D      SF      6  0.8462939 0.058381923
#> SF.evenness         SF      6  0.9350929 0.025983131
```

Las medias por manejo son resúmenes de grupos pequeños y desbalanceados. No constituyen por sí mismas una comparación causal ni corrigen diferencias de esfuerzo o detectabilidad.

```
op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
boxplot(richness ~ Management, data = site_metrics,
        xlab = "Manejo", ylab = "Riqueza observada", col = "#c8d5b9")
boxplot(shannon ~ Management, data = site_metrics,
        xlab = "Manejo", ylab = "Shannon", col = "#8fc0a9")
```




Figura 11.1: Riqueza y diversidad de Shannon observadas por forma de manejo.

```
par(op)
```

11.5.3. Jaccard y Bray-Curtis

```
jaccard <- vegan::vegdist(comm > 0, method = "jaccard", binary = TRUE)
bray <- vegan::vegdist(comm, method = "bray")

distance_summary <- data.frame(
  metric = c("Jaccard (presencia-ausencia)", "Bray-Curtis (abundancia)"),
  minimum = c(min(jaccard), min(bray)),
  median = c(median(jaccard), median(bray)),
  maximum = c(max(jaccard), max(bray))
)
distance_summary
#>               metric  minimum  median maximum
#> 1 Jaccard (presencia-ausencia) 0.1538462 0.7142857      1
#> 2   Bray-Curtis (abundancia) 0.2272727 0.6542529      1
```

Una correlación alta entre ambas matrices no las vuelve equivalentes. Jaccard pregunta por identidades; Bray-Curtis también conserva la distribución de abundancias.

11.5.4. Clasificación jerárquica

```
cluster_bray <- hclust(bray, method = "average")
plot(cluster_bray, xlab = "Sitio", sub = "", ylab = "Bray-Curtis")
rect.hclust(cluster_bray, k = 4, border = "#386641")
```





Figura 11.2: Clasificación de los sitios por enlace promedio y Bray-Curtis.

```
cluster_membership <- cutree(cluster_bray, k = 4)
table(cluster = cluster_membership, Management = env$Management)
#>      Management
#> cluster BF HF NM SF
#>      1  0  0  0  1
#>      2  3  5  1  4
#>      3  0  0  3  1
#>      4  0  0  2  0
```

La tabla permite describir coincidencias entre los cuatro grupos elegidos y el manejo. Cuatro es una decisión de lectura, no una cantidad estimada ni una prueba de significación.

11.5.5. Ordenación por coordenadas principales

```
pcoa <- cmdscale(bray, k = 2, eig = TRUE, add = TRUE)
site_scores <- pcoa$points
management_levels <- levels(env$Management)
cols <- setNames(c("#31572c", "#bc6c25", "#6a4c93", "#277da1"),
                 management_levels)
```

```
plot(site_scores, asp = 1, pch = 21, cex = 1.3,
     bg = cols[env$Management], xlab = "Coordenada 1", ylab = "Coordenada 2")
text(site_scores, labels = site_id, pos = 3, cex = 0.65)
legend("topright", legend = management_levels, pt.bg = cols,
     pch = 21, bty = "n")
```




Figura 11.3: Coordenadas principales de Bray-Curtis; símbolos y colores representan manejo.

```
ordination_diagnostics <- c(
  positive_eigenvalues = sum(pcoa$eig > 0),
  negative_eigenvalues = sum(pcoa$eig < -sqrt(.Machine$double.eps)),
  first_two_positive_fraction = sum(pcoa$eig[1:2]) / sum(pcoa$eig[pcoa$eig > 0])
)
ordination_diagnostics
#>      positive_eigenvalues      negative_eigenvalues
#>      18.0000000      0.0000000
#> first_two_positive_fraction
#>      0.4895187
```

La fracción informada resume cuánto representan los dos primeros ejes respecto a los autovaleores positivos. La figura comprime información: proximidad sugiere composición semejante, pero solapamiento o separación visual no establece una diferencia poblacional.

11.5.6. Sensibilidad a abundancia y presencia

```
cluster_jaccard <- cutree(hclust(jaccard, method = "average"), k = 4)
cluster_agreement <- mean(outer(cluster_membership, cluster_membership, "==") ==
                           outer(cluster_jaccard, cluster_jaccard, "=="))

bray_sqrt <- vegan::vegdist(sqrt(comm), method = "bray")
ordination_raw <- cmdscale(bray, k = 2, add = TRUE)$points
ordination_sqrt <- cmdscale(bray_sqrt, k = 2, add = TRUE)$points
ordination_distance_correlation <- cor(
  dist(ordination_raw), dist(ordination_sqrt)
)

sensitivity <- data.frame(
  comparison = c("Pares agrupados igual: Bray frente a Jaccard",
                 "Distancias en ordenación: abundancia frente a raíz"),
  agreement = c(cluster_agreement, ordination_distance_correlation)
)
sensitivity
#>                               comparison agreement
#> 1      Pares agrupados igual: Bray frente a Jaccard 1.0000000
#> 2 Distancias en ordenación: abundancia frente a raíz 0.9938093
```

La primera medida compara decisiones de agrupación por pares; la segunda compara la geometría representada después de reducir la influencia de especies abundantes. Ninguna selecciona una versión vencedora. Si la lectura ecológica cambia, debe explicarse si la pregunta depende de identidad, abundancia o dominancia.

11.6. Supuestos y alcance

- Las filas representan unidades comparables y no submuestras tratadas como réplicas independientes.
- Área, duración, método, periodo y resolución taxonómica son comparables.
- Los ceros provienen de esfuerzo válido; los faltantes no se codifican como ausencia.
- Conteos o abundancias son comparables entre sitios y no mezclan escalas.
- La detección imperfecta limita la interpretación de riqueza y composición.
- La distancia y transformación corresponden a la pregunta ecológica.
- Clasificación y ordenación describen los sitios observados; no identifican por sí solas mecanismos, causalidad ni poblaciones discretas.

11.7. Errores comunes

- Comparar riqueza entre unidades con esfuerzo o área diferentes.
- Llamar riqueza a Shannon o informar Simpson sin indicar su variante.
- Calcular equidad cuando solo se registró una especie.
- Confundir un cero observado con ausencia verdadera o con un faltante.
- Usar Jaccard para responder una pregunta sobre dominancia.
- Interpretar Bray-Curtis como recambio puro de especies.
- Elegir distancia, transformación o número de grupos después de ver la figura.
- Leer el signo de un eje de ordenación como una dirección ecológica absoluta.
- Tratar grupos del dendrograma o separaciones visuales como pruebas estadísticas.
- Generalizar los 20 sitios a un paisaje cuyo marco de muestreo no se conoce.

11.8. Síntesis

- Riqueza cuenta especies observadas; Shannon combina riqueza y abundancia; Simpson enfatiza las especies comunes; la equidad compara Shannon con su máximo para la riqueza registrada.
- Jaccard representa identidad en presencia-ausencia y Bray-Curtis representa diferencias de abundancia sin usar dobles ceros.
- Clasificación y ordenación resumen una matriz de disimilitud y dependen de las decisiones previas sobre unidad, métrica y transformación.
- El diseño, el esfuerzo, la detección y la taxonomía limitan cualquier lectura ecológica de los índices.
- Una aplicación responsable muestra auditoría, definiciones, sensibilidad y alcance, no solo una figura multivariada.

11.9. Actividad propuesta para el lector

1. Calcule a mano riqueza, Shannon, $1 - D$ y equidad para (10, 10, 10, 10) y (37, 1, 1, 1); explique qué aspecto distingue cada índice.
2. Para tres listas de especies, construya la tabla de a , b y c , calcule Jaccard y compruebe el resultado con `vegan::vegdist()`.
3. Repita la aplicación con enlace completo y enlace simple. Compare los dendrogramas sin afirmar que uno revela grupos verdaderos.
4. Construya ordenaciones separadas con Jaccard y Bray-Curtis. Relacione los cambios con identidad y abundancia.
5. Proponga un protocolo de campo que haga comparables área, esfuerzo, periodo, taxonomía y ceros entre unidades.

Parte VI

Parte VI — Síntesis

12 Proyecto completo de muestreo ecológico

De la pregunta a una comunicación reproducible con datos reales

Un proyecto de muestreo es una cadena de decisiones: la pregunta delimita la población; el marco hace posible seleccionar unidades; el protocolo produce observaciones; el estimador resume la muestra; y la incertidumbre, los diagnósticos y la sensibilidad delimitan la interpretación. Este flujo integra los principios de diseño, trabajo de campo y análisis de Henderson y Southwood (2016), Sutherland (2006), Manly y Navarro Alberto (2015) y Lohr (2022). Ningún análisis posterior repara un marco que excluyó sistemáticamente parte de la población.

12.1. La cadena de inferencia

pregunta $\rightarrow$ población y marco $\rightarrow$ selección $\rightarrow$ observación $\rightarrow$ estimación $\rightarrow$ interpretación.

Antes del campo se escriben la respuesta, la población objetivo, el periodo, la unidad de muestreo, el contraste y el **estimando**. También se separan:

- población objetivo: conjunto sobre el que se desea concluir;
- población accesible: conjunto que puede visitarse;
- marco: lista o mapa desde el cual se selecciona;
- muestra prevista: unidades seleccionadas por el diseño;
- muestra realizada: unidades con observación utilizable.

El diseño determina qué inferencia es defendible. En muestreo aleatorio simple sin reemplazo, la media y su varianza estimada son

$$\bar{y} = \frac{1}{n} \sum_{i \in s} y_i, \quad \widehat{\text{Var}}(\bar{y}) = \left(1 - \frac{n}{N}\right) \frac{s^2}{n}.$$

La corrección finita requiere conocer N . Si la selección no fue probabilística, la fórmula no transforma una muestra conveniente en una muestra representativa (Lohr 2022).

12.2. Plan previo al análisis

Un plan breve y auditable contiene:

1. pregunta y estimando;
2. población, marco y exclusiones;
3. unidad primaria, submuestras y réplicas temporales;
4. mecanismo de selección y probabilidades de inclusión;
5. protocolo, esfuerzo, instrumentos y reglas para cero y faltante;
6. estimador y método de incertidumbre compatibles con el diseño;
7. diagnósticos y decisiones de sensibilidad definidos de antemano;
8. alcance de la comunicación y archivos necesarios para reproducirla.

En campo, identificadores estables, fechas, coordenadas, observador, esfuerzo, unidades y cambios de protocolo son datos, no notas opcionales (Gregg 2008). Las submuestras mejoran la medición dentro de un sitio, pero no aumentan el número de sitios independientes.

12.3. Aplicación completa con `vegan::mite`

12.3.1. Pregunta y límites del diseño

`vegan::mite` contiene conteos de 35 taxones de ácaros oribátidos en 70 sitios; `mite.env` contiene densidad y contenido de agua del sustrato, tipo de sustrato, arbustos y topografía (Oksanen et al. 2024). La pregunta es:

En los 70 sitios registrados, ¿cuáles son la abundancia total, la riqueza y la diversidad media, y cómo difieren descriptivamente entre topografías `Blanket` y `Hummock`?

La fila, no cada ácaro, es la unidad analítica. El estimando primario es la media finita de cada atributo en los 70 sitios observados. Como el objeto no documenta un marco completo, probabilidades de inclusión, fechas, esfuerzo ni selección aleatoria, no se estiman parámetros de todo el humedal ni efectos causales de la topografía. Los intervalos que se mostrarán son intervalos t descriptivos bajo un modelo de sitios independientes; no son intervalos basados en el diseño.

12.3.2. Importación y auditoría

```

if (!requireNamespace("vegan", quietly = TRUE)) {
  stop("Este capítulo requiere el paquete 'vegan'.")
}
data("mite", package = "vegan")
data("mite.env", package = "vegan")

comm <- as.matrix(mite)
env <- mite.env
site_id <- rownames(comm)

audit <- c(
  sites = nrow(comm),
  taxa = ncol(comm),
  duplicated_site_ids = sum(duplicated(site_id)),
  missing_counts = sum(is.na(comm)),
  negative_counts = sum(comm < 0, na.rm = TRUE),
  noninteger_counts = sum(comm != floor(comm), na.rm = TRUE),
  empty_sites = sum(rowSums(comm, na.rm = TRUE) == 0),
  missing_metadata = sum(is.na(env)),
  row_mismatch = as.integer(nrow(comm) != nrow(env))
)
audit
#>           sites           taxa duplicated_site_ids      missing_counts
#>           70           35              0              0
#> negative_counts noninteger_counts      empty_sites missing_metadata
#>           0              0              0              0
#>      row_mismatch
#>           0
stopifnot(audit[c("duplicated_site_ids", "missing_counts", "negative_counts",
  "noninteger_counts", "empty_sites", "missing_metadata",
  "row_mismatch")] == 0)

```

La auditoría verifica estructura, no autenticidad de campo. Sin hojas originales no puede confirmar coordenadas, esfuerzo, identificación taxonómica ni si un cero es una no detección válida. La correspondencia por posición se acepta solo porque ambos objetos provienen juntos del paquete; datos propios deben enlazarse por una clave explícita.

```

frame_summary <- data.frame(
  item = c("Unidades observadas", "Taxones en columnas", "Blanket", "Hummock",
    "Contenido de agua mínimo", "Contenido de agua máximo"),
  value = c(nrow(comm), ncol(comm), table(env$Topo)["Blanket"],
    table(env$Topo)["Hummock"], min(env$WatrCont), max(env$WatrCont))
)

```



```
)
frame_summary
#>           item value
#> 1 Unidades observadas 70.00
#> 2 Taxones en columnas 35.00
#> 3 Blanket 44.00
#> 4 Hummock 26.00
#> 5 Contenido de agua mínimo 134.13
#> 6 Contenido de agua máximo 826.96
```

12.3.3. Construcción de variables

Se conservan los conteos originales y se crea una tabla por sitio. Shannon y Simpson se usan en sus formas clásicas (Henderson y Southwood 2016).

```
site_data <- data.frame(
  site = site_id,
  Topo = env$Topo,
  WatrCont = env$WatrCont,
  SubsDens = env$SubsDens,
  total_abundance = rowSums(comm),
  richness = vegan::specnumber(comm),
  shannon = vegan::diversity(comm, index = "shannon"),
  simpson_1_D = vegan::diversity(comm, index = "simpson")
)
site_data$evenness <- with(site_data,
  ifelse(richness > 1, shannon / log(richness), NA_real_))
stopifnot(!anyNA(site_data), all(site_data$richness > 1))
site_data[1:8, ]
#>   site Topo WatrCont SubsDens total_abundance richness shannon simpson_1_D
#> 1  1 Hummock 350.15 39.18 140 20 2.285775 0.8287755
#> 2  2 Hummock 434.81 54.99 268 23 1.930428 0.7093451
#> 3  3 Hummock 371.72 46.07 186 19 1.995647 0.7412996
#> 4  4 Hummock 360.50 48.19 286 23 2.199309 0.8097462
#> 5  5 Hummock 204.13 23.55 199 19 2.454142 0.8856342
#> 6  6 Hummock 311.55 57.32 209 21 2.557505 0.8958586
#> 7  7 Hummock 378.93 36.95 162 16 2.281889 0.8687700
#> 8  8 Blanket 266.78 80.59 126 21 2.539871 0.8877551
#>   evenness
#> 1 0.7630105
#> 2 0.6156696
```

```
#> 3 0.6777680
#> 4 0.7014233
#> 5 0.8334836
#> 6 0.8400348
#> 7 0.8230173
#> 8 0.8342430
```

Esta transformación supone que todos los sitios tuvieron esfuerzo comparable y que los conteos son abundancias comparables. La información disponible no basta para comprobar esos supuestos; se mantienen como limitaciones sustantivas.

12.3.4. Estimación e incertidumbre

Para cada respuesta se informa media, desviación estándar, error estándar e intervalo t del 95 %. Como los 70 sitios constituyen el conjunto descrito, la media es exacta para ese conjunto. El intervalo expresa variación entre sitios bajo una repetición hipotética de sitios independientes y comparables.

```
mean_ci <- function(x, level = 0.95) {
  n <- length(x)
  estimate <- mean(x)
  se <- sd(x) / sqrt(n)
  critical <- qt(1 - (1 - level) / 2, df = n - 1)
  c(n = n, estimate = estimate, sd = sd(x), se = se,
    lower = estimate - critical * se, upper = estimate + critical * se)
}

responses <- c("total_abundance", "richness", "shannon",
  "simpson_1_D", "evenness")
overall_estimates <- t(vapply(site_data[responses], mean_ci, numeric(6)))
round(overall_estimates, 3)
#>
#>      n estimate      sd      se  lower  upper
#> total_abundance 70  140.000 94.161 11.254 117.548 162.452
#> richness        70   15.114  4.642  0.555  14.007  16.221
#> shannon         70    2.016  0.408  0.049   1.919   2.113
#> simpson_1_D     70    0.794  0.112  0.013   0.767   0.821
#> evenness        70    0.755  0.109  0.013   0.729   0.781
```

La comparación topográfica usa la diferencia de medias $\Delta = \bar{y}_{Hummock} - \bar{y}_{Blanket}$ y el intervalo de Welch, que no obliga a suponer varianzas iguales. Es una descripción asociativa de estos sitios.

```

difference_ci <- function(y, group) {
  x0 <- y[group == "Blanket"]
  x1 <- y[group == "Hummock"]
  fit <- t.test(x1, x0, var.equal = FALSE)
  c(mean_Blanket = mean(x0), mean_Hummock = mean(x1),
    difference = unname(diff(rev(fit$estimate))),
    lower = fit$conf.int[1], upper = fit$conf.int[2])
}

topography_contrasts <- t(vapply(site_data[responses],
  difference_ci, numeric(5), group = site_data$Topo))
round(topography_contrasts, 3)
#>               mean_Blanket mean_Hummock difference   lower   upper
#> total_abundance      131.659      154.115      22.456 -17.083 61.996
#> richness              13.818       17.308       3.490   1.534  5.445
#> shannon                1.926        2.168       0.241   0.075  0.407
#> simpson_1_D            0.775        0.826       0.051   0.006  0.095
#> evenness               0.748        0.766       0.019  -0.028  0.065

```

El orden pasado a `t.test()` hace que el intervalo corresponda a Hummock menos Blanket. Se comprueba para evitar un error frecuente de signo.

```

observed_difference <- with(site_data,
  mean(richness[Topo == "Hummock"]) - mean(richness[Topo == "Blanket"]))
stopifnot(isTRUE(all.equal(
  unname(topography_contrasts["richness", "difference"]),
  observed_difference
)))

```

12.3.5. Diagnósticos

Los intervalos de medias son más defendibles si los sitios son independientes, la selección no concentra zonas particulares y unas pocas observaciones no dominan el resumen. Estas condiciones no se diagnostican solo con histogramas; se requiere el mapa y el protocolo. Con lo disponible se revisan asimetría, dispersión por grupo y observaciones influyentes.

```

diagnostics <- data.frame(
  response = responses,
  skewness = vapply(site_data[responses], function(x) {
    z <- (x - mean(x)) / sd(x)
    mean(z^3)
  }, numeric(1))
)

```

```

}, numeric(1)),
minimum = vapply(site_data[responses], min, numeric(1)),
maximum = vapply(site_data[responses], max, numeric(1)),
max_abs_standardized = vapply(site_data[responses], function(x)
  max(abs((x - mean(x)) / sd(x))), numeric(1))
)
diagnostics[-1] <- lapply(diagnostics[-1], round, digits = 3)
diagnostics
#>               response skewness minimum maximum max_abs_standardized
#> total_abundance total_abundance   4.511   8.000 781.000             6.808
#> richness          richness    -0.195   5.000  25.000             2.179
#> shannon            shannon    -1.251   0.356   2.655             4.073
#> simpson_1_D        simpson_1_D   -3.093   0.141   0.911             5.824
#> evenness           evenness    -1.934   0.199   0.969             5.110

op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
boxplot(total_abundance ~ Topo, data = site_data,
  xlab = "Topografía", ylab = "Abundancia total", col = "#b7b7a4")
boxplot(richness ~ Topo, data = site_data,
  xlab = "Topografía", ylab = "Riqueza", col = "#a5a58d")

```




Figura 12.1: Distribución de abundancia y riqueza por topografía en los 70 sitios.

```
par(op)
```

```
z_abundance <- with(site_data,  
  (total_abundance - mean(total_abundance)) / sd(total_abundance))  
influential_sites <- site_data[abs(z_abundance) > 2.5,  
  c("site", "Topo", "WatrCont", "total_abundance", "richness")]  
influential_sites  
#>   site   Topo WatrCont total_abundance richness  
#> 67    67 Blanket    826.96           781        6
```

Una observación extrema no se elimina por ser extrema. Primero se contrasta con la fuente y el protocolo; si es válida, representa heterogeneidad ecológica que el resultado debe conservar.

12.3.6. Composición como diagnóstico complementario

Bray-Curtis resume diferencias de abundancia y una ordenación clásica permite examinar si unos pocos sitios dominan el patrón. No se realiza un contraste inferencial ni se atribuye la configuración a la topografía.

```
bray <- vegan::vegdist(comm, method = "bray")  
pcoa <- cmdscale(bray, k = 2, eig = TRUE, add = TRUE)  
topo_cols <- c(Blanket = "#588157", Hummock = "#bc6c25")  
plot(pcoa$points, asp = 1, pch = 21, cex = 1.1,  
  bg = topo_cols[site_data$Topo],  
  xlab = "Coordenada 1", ylab = "Coordenada 2")  
legend("topright", legend = names(topo_cols), pt.bg = topo_cols,  
  pch = 21, bty = "n")
```




Figura 12.2: Coordenadas principales de Bray-Curtis para la comunidad de ácaros.

La ordenación es descriptiva. Una aparente separación puede reflejar abundancia, contenido de agua, sustrato, cobertura espacial o selección de sitios. Los ejes no identifican cuál explicación es correcta.

12.3.7. Sensibilidad

Se evalúan dos decisiones razonables sin buscar significación: retirar de uno en uno cada sitio para medir influencia sobre la diferencia de riqueza y reducir la dominancia con raíz cuadrada para examinar estabilidad de la ordenación.

```
leave_one_out_difference <- vapply(seq_len(nrow(site_data)), function(i) {
  z <- site_data[-i, ]
  with(z, mean(richness[Topo == "Hummock"]) -
        mean(richness[Topo == "Blanket"]))
}, numeric(1))

influence_summary <- data.frame(
  primary_difference = observed_difference,
  minimum_leave_one_out = min(leave_one_out_difference),
  maximum_leave_one_out = max(leave_one_out_difference),
```

```

most_influential_site = site_data$site[
  which.max(abs(leave_one_out_difference - observed_difference))]
)
influence_summary
#>   primary_difference minimum_leave_one_out maximum_leave_one_out
#> 1           3.48951           3.261818           3.821818
#>   most_influential_site
#> 1                29

```

```

bray_sqrt <- vegan::vegdist(sqrt(comm), method = "bray")
pcoa_sqrt <- cmdscale(bray_sqrt, k = 2, add = TRUE)$points
ordination_sensitivity <- cor(dist(pcoa$points), dist(pcoa_sqrt))
ordination_sensitivity
#> [1] 0.8576013

```

Una diferencia de riqueza estable al retirar un sitio es menos dependiente de una observación individual, pero continúa limitada por el marco desconocido. Una correlación baja entre configuraciones indicaría que la lectura composicional depende de cuánto pesan los taxones dominantes.

12.3.8. Interpretación y comunicación

Las cifras del texto deben generarse desde los objetos para evitar errores de transcripción.

```

richness_result <- overall_estimates["richness", ]
richness_contrast <- topography_contrasts["richness", ]
report_text <- sprintf(
  paste0("En los 70 sitios observados, la riqueza media fue%.1f especies por ",
        "sitio (intervalo t descriptivo del 95%%: %.1f a%.1f). La diferencia ",
        "media Hummock menos Blanket fue%.1f especies (%.1f a%.1f)."),
  richness_result["estimate"], richness_result["lower"],
  richness_result["upper"], richness_contrast["difference"],
  richness_contrast["lower"], richness_contrast["upper"]
)
report_text
#> [1] "En los 70 sitios observados, la riqueza media fue 15.1 especies por sitio (intervalo

```

Una comunicación completa añade que el marco, la selección, el esfuerzo y la dependencia espacial no están documentados. En consecuencia, el intervalo no cuantifica sesgo de cobertura, detección imperfecta ni error taxonómico; tampoco convierte la asociación topográfica en efecto causal. Magnitud, unidad, incertidumbre, sensibilidad y alcance deben aparecer juntos.

12.3.9. Reproducibilidad

```
reproducibility_record <- list(  
  data = c("vegan::mite", "vegan::mite.env"),  
  package_version = as.character(utils::packageVersion("vegan")),  
  R_version = R.version.string,  
  analysis_date = as.character(Sys.Date()),  
  responses = responses,  
  contrast = "Hummock - Blanket",  
  missing_rule = "No convertir faltantes en ceros"  
)  
reproducibility_record  
#> $data  
#> [1] "vegan::mite"      "vegan::mite.env"  
#>  
#> $package_version  
#> [1] "2.7.5"  
#>  
#> $R_version  
#> [1] "R version 4.5.2 (2025-10-31)"  
#>  
#> $analysis_date  
#> [1] "2026-08-21"  
#>  
#> $responses  
#> [1] "total_abundance" "richness"      "shannon"      "simpson_1_D"  
#> [5] "evenness"  
#>  
#> $contrast  
#> [1] "Hummock - Blanket"  
#>  
#> $missing_rule  
#> [1] "No convertir faltantes en ceros"
```

En un proyecto real, los datos crudos permanecen inmutables, las transformaciones se ejecutan por código, las rutas son relativas, las semillas se fijan cuando hay azar y el diccionario define cada variable y código. Un archivo de sesión o un entorno bloqueado registra versiones. Tablas, figuras y frases numéricas se regeneran desde una sesión limpia.

12.4. Supuestos y limitaciones

- Los 70 sitios y los conteos representan correctamente los registros originales.
- Las filas son sitios independientes; sin coordenadas no puede evaluarse dependencia espacial.
- Método, esfuerzo, periodo y resolución taxonómica son comparables entre sitios.
- Los ceros son no detecciones bajo un protocolo válido, no visitas fallidas.
- Los intervalos t describen variación bajo sitios comparables, pero no reparan selección no probabilística.
- La topografía no fue asignada; sus contrastes son asociaciones descriptivas.
- Riqueza e índices observados están afectados por detección y esfuerzo.
- La aplicación se limita a los 70 sitios porque el paquete no aporta un marco de muestreo completo.

12.5. Errores comunes

- Formular la pregunta después de buscar el resultado más llamativo.
- Confundir población objetivo, marco y muestra realizada.
- Tratar organismos o submuestras como unidades independientes.
- Reemplazar una unidad inaccesible por la más cercana sin registrar el cambio.
- Convertir faltantes en ceros o borrar extremos sin consultar la fuente.
- Aplicar una fórmula de muestreo aleatorio a una muestra conveniente.
- Informar solo medias sin variación, diagnóstico ni unidad.
- Interpretar un intervalo estrecho como ausencia de sesgo.
- Confundir asociación observacional con efecto de topografía o manejo.
- Ocultar que una conclusión cambia al retirar una unidad o transformar datos.
- Transcribir resultados manualmente y modificar figuras fuera del código.
- Generalizar más allá del marco, periodo, taxones y protocolo observados.

12.6. Síntesis

- Pregunta, población, marco, unidad y estimando deben concordar antes de observar los resultados.
- El mecanismo de selección y la unidad independiente determinan el alcance de la inferencia y de la incertidumbre.
- La auditoría distingue errores estructurales de limitaciones que solo pueden resolverse con metadatos y trabajo de campo.
- Estimación, intervalos, diagnósticos y sensibilidad responden preguntas diferentes y deben comunicarse en conjunto.
- Un análisis reproducible conserva procedencia y genera por código tablas, figuras y texto.

- Con `mite` pueden describirse rigurosamente 70 sitios, pero no inventarse un marco probabilístico ni una conclusión causal que los datos no documentan.

12.7. Actividad propuesta para el lector

1. Reescriba una pregunta ecológica indicando población, periodo, unidad, contraste y estimando.
2. Dibuje la relación entre población objetivo, población accesible, marco, muestra prevista y muestra realizada; anote una fuente de error en cada paso.
3. Extienda la auditoría de `mite` con rangos admisibles para `WatrCont` y `SubsDens`, sin eliminar observaciones automáticamente.
4. Repita la estimación para Shannon y explique por qué su escala no equivale a número de especies.
5. Compare la diferencia de riqueza primaria con todos los resultados de retirar un sitio. Describa estabilidad sin convertirla en una prueba de hipótesis.
6. Redacte una conclusión de cuatro frases que separe resultado observado, incertidumbre, limitación del diseño y alcance ecológico.

Parte VII

Prácticas

13 Práctica 2: Diseños probabilísticos en R

Estimación por repetición, gráficas y análisis de resultados

13.1. Presentación

Esta práctica trabaja con los dos censos usados en el capítulo 2: los 31 árboles de `datasets::trees` y las 50 hectáreas del censo de Barro Colorado (`vegan::BCI`). El documento es autocontenido: construye todos los objetos que necesita, por lo que se resuelve en una sesión nueva de R sin depender del resto del capítulo.

Materiales. Una instalación de R con el paquete `vegan`. No se requieren otros paquetes.

Cómo trabajar. La práctica es de construcción guiada: el código de cada bloque está incompleto. Los huecos están marcados con `# COMPLETAR` y, en el texto, con `----` dentro del código. Debe reemplazarlos por la expresión correcta, ejecutar el bloque y comprobar contra el cuadro de comprobación (colapsado, al final). Después trace las gráficas pedidas (escribalas usted mismo), responda las preguntas de análisis y resuelva la tarea de exploración de cada bloque, que exige modificar y volver a ejecutar. En la entrega incluya el código completado, las gráficas y las respuestas.

Convención del texto. Se usa `#>` para la salida de R. Las semillas están fijadas para que sus resultados coincidan con la comprobación.

13.2. Bloque 0. Arranque autocontenido

Construya los marcos y las verdades poblacionales. Este bloque está completo; ejecútelo y verifique los valores.

```

data(trees, package = "datasets")
U <- transform(
  trees,
  id = seq_len(nrow(trees)),
  grande = as.integer(Volume >= 30),
  x_aux = Girth^2 * Height
)
N <- nrow(U)
verdad_arboles <- c(
  media = mean(U$Volume), total = sum(U$Volume),
  proporcion = mean(U$grande), DE = sd(U$Volume)
)
X_aux <- sum(U$x_aux)
cbind(verdad_arboles)
#>                verdad_arboles
#> media                30.1709677
#> total                935.3000000
#> proporcion           0.3870968
#> DE                   16.4378464

U$estrato <- cut(U$Girth, c(8.3, 11.3, 14.0, 20.6),
  include.lowest = TRUE,
  labels = c("pequeno", "medio", "grande"))
Nh <- table(U$estrato)

asignar_enteros <- function(pesos, n_total, minimo = 2) {
  a <- rep(minimo, length(pesos)); names(a) <- names(pesos)
  faltan <- n_total - sum(a)
  if (faltan > 0) {
    cuota <- faltan * pesos / sum(pesos)
    a <- a + floor(cuota)
    resto <- n_total - sum(a)
    if (resto > 0) {
      fraccion <- cuota - floor(cuota)
      idx <- order(fraccion, decreasing = TRUE)[seq_len(resto)]
      a[idx] <- a[idx] + 1
    }
  }
  a
}

nh <- asignar_enteros(as.numeric(Nh), 10)

```

```

names(nh) <- names(Nh)
S_h <- tapply(U$Volume, U$estrato, sd)
nh_neyman <- asignar_enteros(as.numeric(Nh) * S_h, 10)
names(nh_neyman) <- names(Nh)

```

```

rbind(
  poblacion = Nh,
  proporcional = nh,
  Neyman = nh_neyman,
  S_h = round(S_h, 1)
)
#>
#>           pequeno medio grande
#> poblacion      11.0  10.0   10.0
#> proporcional     4.0   3.0    3.0
#> Neyman          3.0   3.0    4.0
#> S_h             4.9   5.4   13.2

```

```

data(BCI, BCI.env, package = "vegan")
marco_bci <- BCI.env
marco_bci$id <- seq_len(nrow(marco_bci))
marco_bci$x <- as.integer((marco_bci$UTM.EW - min(marco_bci$UTM.EW)) / 100 + 1)
marco_bci$y <- as.integer((marco_bci$UTM.NS - min(marco_bci$UTM.NS)) / 100 + 1)
marco_bci$conglomerado <- marco_bci$x
marco_bci$fila <- marco_bci$y
marco_bci$tallos <- rowSums(BCI)
marco_bci$riqueza_alta <- as.integer(vegan::specnumber(BCI) >= 95)
N_bci <- nrow(marco_bci)
verdad_bci <- mean(marco_bci$tallos)

c(N_bci = N_bci,
  conglomerados = length(unique(marco_bci$conglomerado)),
  hectareas_por_conglomerado = as.integer(table(marco_bci$conglomerado)[1]),
  verdad_media = verdad_bci)
#>
#>           N_bci           conglomerados
#>          50.00             10.00
#> hectareas_por_conglomerado      verdad_media
#>           5.00             429.14

```

13.3. Bloque 1. Auxiliar y tamaño de muestra

Compare, por repetición, el error del estimador MAS y del estimador de razón para tres tamaños de muestra ($n = 6, 10, 15$). La razón usa el auxiliar $x = \text{DAP}^2 \cdot \text{altura}$, conocido para las 31 unidades. Complete los RMSE dentro de la repetición.

```
# COMPLETAR: en cada repetición "MAS" y "razon" son filas de rep_k con las B
# réplicas de cada método. Para cada una calcule su RMSE: la raíz del promedio
# del error cuadrático frente a verdad_arboles["total"] (sección de evaluación
# por repetición del capítulo 2).
B <- 1000
set.seed(2210)
resultados_tam <- t(apply(c(6, 10, 15), function(k) {
  rep_k <- replicate(B, {
    z <- U[sample.int(N, k), ]
    c(MAS = N * mean(z$Volume),
      razon = sum(z$Volume) / sum(z$x_aux) * X_aux)
  })
  c(n = k, MAS = ____, razon = ____))
}))
resultados_tam
```

Gráfica. Escriba la gráfica del RMSE frente al tamaño de muestra.

```
# COMPLETAR: complete argumentos (lty, col) y leyenda.
matplot(resultados_tam[, "n"], resultados_tam[, c("MAS", "razon")],
        type = "b", pch = 19, lty = ____, lwd = 2, col = ____,
        xlab = "Tamaño de muestra (n)", ylab = "RMSE del total")
legend("topright", c("MAS", "Razón"), col = ____, lty = ____, bty = "n")
```

Preguntas de análisis.

1. ¿La ventaja relativa del auxiliar se mantiene, crece o desaparece al pasar de $n = 6$ a $n = 15$? Use la relación entre los RMSE.
2. ¿Qué implicación tiene ese resultado para planear el esfuerzo de muestreo cuando existe un buen auxiliar?
3. ¿Por qué el resultado (y sus RMSE) está limitado a estas 31 filas y no debe extrapolarse como una regla general?

Tarea de exploración. Repita con $c(6, 8, 10, 15, 20)$ y calcule también el sesgo de cada método (promedio de la desviación respecto de la verdad). ¿Qué le dice el cociente entre RMSE sobre el papel del auxiliar a medida que crece n ?

13.4. Bloque 2. Estratificación: asignación y ganancia de precisión

Estime el total de volumen con un MAS y con las asignaciones proporcional y de Neyman. Complete el estimador por estratos y la muestra dentro de cada estrato.

```
# COMPLETAR: total y varianza por estrato (usar N_h, n_h y var(z)).
estimar_st <- function(datos, variable, Nh, nh) {
  por_h <- lapply(names(nh), function(h) {
    z <- datos[as.character(datos$estrato) == h, variable]
    N_h <- unname(Nh[h]); n_h <- unname(nh[h])
    c(total = ____, # N_h * mean(z)
      var_total = ____ # N_h^2 * (1 - n_h/N_h) * var(z) / n_h
    )
  })
  por_h <- do.call(rbind, por_h)
  c(total = sum(por_h[, "total"]),
    var_total = sum(por_h[, "var_total"]))
}

# COMPLETAR: guarde el error estándar del MAS (columna se) calculado con la misma
# muestra que la estimación, y la "var_total" dentro de una_st(). Con est y se de
# la misma réplica se decide si el intervalo cubre la verdad y se suma la
# cobertura, que las métricas de solo puntos no reportan.
una_mas_ic <- function() {
  z <- U[sample.int(N, 10), ]
  c(est = N * mean(z$Volume),
    se = N * sqrt((1 - 10 / N) * var(z$Volume) / 10))
}

una_st <- function(nh_local) {
  ids <- unlist(lapply(names(nh_local), function(h)
    sample(___, ____))) # U$id[U$estrato == h], tamaño nh_local[h]
  z <- U[match(ids, U$id), ]
  v <- estimar_st(z, "Volume", Nh, nh_local)
  c(est = unname(v["total"]),
    se = sqrt(unname(v["____"]))) # componente de varianza del total
}

set.seed(2211)
rep_estrat <- list(
  MAS = t(replicate(B, una_mas_ic())),
  Proporcional = t(replicate(B, una_st(nh))),
  Neyman = t(replicate(B, una_st(nh_neyman)))
)
```



```

)

# COMPLETAR: defina las cinco métricas. Las cuatro primeras son, en orden, el
# sesgo (promedio de la desviación frente a la verdad), la DE empírica
# (desviación estándar de las estimaciones), el SE medio (promedio del error
# estándar predicho por la fórmula) y el RMSE (raíz del error cuadrático medio).
# La quinta cuenta la fracción de réplicas en las que el intervalo
# [est ± t·se] con t de Student (gl grados de libertad) contiene la verdad.
metricas_ic <- function(est, se, verdad, gl) c(
  sesgo = ____,
  DE_empirica = ____,
  SE_medio = ____,
  RMSE = ____,
  cobertura = ____)
```

gl = n - 1 para el MAS (se estima solo la media) y n - 3 para los
estratificados (se estima la media de cada uno de los tres estratos).

```

gl_por_diseño <- c(MAS = 9, Proporcional = 7, Neyman = 7)
metricas_estrat <- t(sapply(names(rep_estrat), function(md)
  metricas_ic(rep_estrat[[md]][, "est"], rep_estrat[[md]][, "se"],
    verdad_arboles["total"], gl_por_diseño[md])))
round(metricas_estrat, 3)
```

Gráficas. Escriba (a) la distribución del total bajo los tres esquemas y (b) la descomposición dentro/entre de los estratos.

```

# COMPLETAR: (a) cajas con las estimaciones (columna "est") de los tres diseños,
# un color por método, línea discontinua en el total verdadero y etiquetas;
# (b) la descomposición de la varianza poblacional, donde debe cumplirse
# Dentro + Entre = var(U$Volume) * (N - 1) / N.
boxplot(lapply(rep_estrat, function(r) r[, ____]), col = c(____),
  ylab = "Total estimado de volumen", las = 2)
abline(h = ____, lty = 2)
```

```

var_total <- var(U$Volume) * (N - 1) / N
mu_total <- mean(U$Volume)
var_entre <- sum((as.numeric(Nh) / N) *
  (tapply(U$Volume, U$estrato, mean) - ____)^2)
var_dentro <- var_total - ____
c(Dentro = round(var_dentro, 1), Entre = round(var_entre, 1))
barplot(c(Dentro = var_dentro, Entre = var_entre), col = c(____),
  ylab = "Componente de varianza")
```

Preguntas de análisis.

1. Compare el RMSE del MAS con el del proporcional: ¿de dónde proviene la reducción de incertidumbre? Relaciónelo con las componentes dentro y entre de los estratos.
2. ¿Por qué la asignación de Neyman mejora todavía el RMSE? ¿Qué información previa exigiría en un estudio real y por qué no debería usarse la S_h censal como si fuera un dato de marco?
3. En el boxplot, ¿los tres esquemas parecen insesgados? Apoye su respuesta con la columna de sesgo de `metricas_estrat`.
4. Compare la cobertura observada con el nivel nominal del 95 %. ¿Por qué los estratificados usan un valor crítico con menos grados de libertad que el MAS, y cómo se refleja eso en el SE medio frente a la DE empírica?

Tarea de exploración. Repita la repetición con `n_total = 12` (recalcule `nh` y `nh_neyman` con `asignar_enteros(as.numeric(Nh), 12)`). ¿Cómo cambia la ventaja relativa del proporcional frente al MAS? Además, estime `S_h` con una mini-muestra de tres unidades por estrato (un “piloto”) y construya la asignación de Neyman con esas DE; compare con la de Neyman “censal” y explique la diferencia.

13.5. Bloque 3. Sistemático: arranques y sensibilidad al orden

En el marco ordenado de las 31 unidades, enumere los 31 arranques del estimador sistemático del total en tres órdenes. Complete la función de selección.

```
# COMPLETAR: desplazamientos = floor((0:(n_k - 1)) * N_k / n_k) y los órdenes.
seleccion_sistemática <- function(arranque, n_k = 10, N_k = N) {
  desplazamientos <- ____
  ((arranque - 1 + desplazamientos) %% N_k) + 1
}

set.seed(2212)
permutacion <- sample(seq_len(N), N)
ordenes <- list(
  diametro = ____,      # marco ordenado por diámetro (desempate por id)
  volumen = ____,       # orden por volumen (solo diagnóstico retrospectivo)
  aleatorio = ____ )   # la permutación generada arriba

totales_orden <- lapply(ordenes, function(ord) {
  z <- U[ord, ]
  vapply(seq_len(N), function(a)
    ____, 0.0)          # total sistemático: N * media del subconjunto de arranque a
})
```

```
sensibilidad <- t(vapply(totales_orden, function(totales) {
  c(media = ____,
    DE_diseno = ____,          # sqrt(mean((totales - mean(totales))^2))
    RMSE = ____))
}, numeric(3)))
round(sensibilidad, 3)
```

Gráfica. Escriba los totales por arranque (tipo h) para el orden más eficiente (volumen) y para el menos eficiente (aleatorio).

```
# COMPLETAR: gráfica de totales_orden[["volumen"]] y de totales_orden[["aleatorio"]]
# con línea horizontal en la verdad.
plot(seq_len(N), ____, type = "h", lwd = 3, col = ____,
      xlab = "Arranque", ylab = "Total estimado")
abline(h = ____, lty = 2)
```

Preguntas de análisis.

1. En los tres órdenes, la media de los 31 totales coincide con el total verdadero: ¿qué propiedad del diseño sistemático revela eso?
2. Compare la DE de diseño entre el orden por diámetro, por volumen y la permutación aleatoria. ¿Qué le dice la permutación sobre el papel del gradiente?
3. ¿Por qué el orden por volumen es solo un diagnóstico retrospectivo y no una estrategia para fijar el orden de campo?

Tarea de exploración. Añada un cuarto orden por **Height** y comente dónde cae en el ranking de DE de diseño. Después, genere la realización sistemática con arranque 31 (la sorteada en el capítulo) sobre el orden por diámetro y estime el total con un MAS de diez unidades por repetición (1000 veces); compare la DE empírica de ambos con la DE de diseño sistemática.

13.6. Bloque 4. Conglomerados: orientación de las unidades primarias

Sobre el censo de Barro Colorado, compare dos particiones que observan 20 hectáreas: (a) diez columnas de cinco hectáreas, seleccionando cuatro columnas; (b) cinco filas de diez hectáreas, seleccionando dos filas. Complete la ICC y la enumeración del diseño.

```

# COMPLETAR: la variable continua para la ICC, rho y DEFF (MS_entre y MS_dentro
# ya se definen), y en de_exacta_media() complete el total estimado de cada
# combinación (el promedio pesado de los totales por conglomerado sobre N_bci).
icc_deff <- function(grupo) {
  medias <- tapply(____, grupo, mean)
  L_g <- as.integer(table(grupo)[1])
  MS_entre <- L_g * var(medias)
  MS_dentro <- mean(tapply(____, grupo, var))
  rho <- ____ # (MS_entre-MS_dentro)/(MS_entre+(L_g-1)*MS_dentro)
  c(ICC = rho, DEFF = ____) # 1 + (L_g - 1) * rho
}

de_exacta_media <- function(totales, m_sel) {
  M_g <- length(totales)
  comb <- ____ # todas las combinaciones de m_sel entre M_g
  est <- apply(comb, 2, function(idx)
    ____ # M_g/m_sel * suma de totales[idx] / N_bci
  )
  c(DE_exacta = sqrt(mean((est - mean(est))^2)),
    media_estimador = mean(est))
}

totales_col <- tapply(____, ____, sum) # tallos por columna
totales_fila <- tapply(____, ____, sum) # tallos por fila
rbind(
  columnas = c(icc_deff(____), de_exacta_media(____, 4)),
  filas = c(icc_deff(____), de_exacta_media(____, 2))
)

# DEFF empírico por repetición: cuántas veces más varía la media del diseño que
# la de un MAS del mismo esfuerzo (20 hectáreas). Complete el MAS y las
# combinaciones sorteadas.
set.seed(2216)
MAS_20 <- replicate(1000, mean(____)) # sample(marco_bci$tallos, 20)
rep_columnas <- replicate(1000, {
  idx <- sample(seq_len(10), 4)
  (10 / 4) * sum(totales_col[idx]) / N_bci
})
rep_filas <- replicate(1000, {
  idx <- sample(seq_len(5), 2)
  (5 / 2) * sum(totales_fila[idx]) / N_bci
})
c(DEFF_empirico_columnas = var(rep_columnas) / var(MAS_20),

```

```
DEFF_empirico_filas = var(rep_filas) / var(MAS_20))
```

Gráficas. Escriba (a) los mapas de las dos particiones con un ejemplo de selección y (b) el boxplot de tallos por hectárea dentro de cada conglomerado.

```
# COMPLETAR: dos paneles (par(mfrow = c(1, 2))). Panel (a): el grid de 10 x 5
# hectáreas a partir de marco_bci$x y marco_bci$y, con rect() por hectárea,
# resaltando en cada partición una selección de ejemplo (4 columnas en la de
# columnas, 2 filas en la de filas), ejes Este/Norte y leyenda. Panel (b): el
# boxplot(tallos ~ conglomerado) de la partición en columnas.
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
```

Preguntas de análisis.

1. Ambas orientaciones observan 20 hectáreas. ¿Por qué cambia la DE exacta del estimador aunque el área sea la misma? Relacione la respuesta con la ICC y el DEFF.
2. ¿Qué orientación es más eficiente en esta población y qué implica para el diseño del trabajo de campo?
3. ¿Por qué el DEFF y la ICC calculados son un diagnóstico de esta partición concreta y no una constante de BCI?

Tarea de exploración. En la orientación de columnas, submuestree solo $l = 3$ de las cinco hectáreas de cada columna seleccionada (dos etapas) y compare la DE empírica de la media con la de una etapa que censa las cinco. Reporte qué componente de varianza añade la segunda etapa y en qué condición desaparece.

13.7. Bloque 5. Auxiliar: razón frente a regresión

Compare los estimadores de razón y de regresión del total de volumen. Complete las pendientes y las métricas.

```
# COMPLETAR: la razón muestral Rhat (cociente de los totales muestrales), su
# pendiente b de la regresión de Volume sobre el auxiliar, y ambos estimadores
# del total: la razón escala Rhat por el auxiliar poblacional X_aux, y la
# regresión multiplica por N la media muestral corregida con la diferencia de
# medias del auxiliar.
set.seed(2213)
rep_r5 <- t(replicate(B, {
  z <- U[sample.int(N, 10), ]
  Rhat <- ----
```

```

b <- ____
c(razon = ____, regresion = ____))
}))

round(t(vapply(as.data.frame(rep_r5), function(x) {
  c(sesgo = ____, DE_empirica = ____, RMSE = ____))
}, numeric(3))), 3)

```

Gráficas. Escriba (a) la nube auxiliar-volumen con las dos rectas ajustadas en una muestra y (b) los residuos de la razón con su suavizado.

```

# COMPLETAR: sobre una muestra fija sf <- U[sample.int(N, 10), ] (set.seed(2214))
# calcule su razón Rhat0 y su pendiente b0. Panel (a): la nube
# plot(U$x_aux, U$Volume) con los puntos de la muestra resaltados y las dos
# rectas - la de razón (sólida, forzada al origen con pendiente Rhat0) y la de
# regresión (discontinua, con intercepto) - y leyenda. Panel (b): los residuos
# de razón e_r = sf$Volume - Rhat0 * sf$x_aux frente al auxiliar, con línea
# horizontal en cero y una curva lowess que no debe apartarse de ella.

```

Preguntas de análisis.

1. Compare RMSE de razón y regresión y explique por qué la razón lo logra pese a imponer proporcionalidad al origen.
2. En la nube de residuos, ¿hay una tendencia que aconsejara un modelo con intercepto o una transformación del auxiliar? Justifíquelo.
3. ¿En qué situación operativa preferiría un estimador de regresión y qué condición del marco exigiría?

Tarea de exploración. Repita el bloque usando como auxiliar solo el diámetro ($x_G = \text{Girth}$) y compare el RMSE con el del auxiliar completo x_{aux} . ¿Qué le dice la diferencia sobre la calidad del auxiliar?

13.8. Síntesis y comprobación

Reúna los RMSE de los métodos evaluados sobre **trees** (el mismo estimando: el total de volumen), calculándolos desde los objetos de los bloques anteriores, sin escribir números.

```

# COMPLETAR: ensamble la tabla desde metricas_estrat, sensibilidad y rep_r5.
rmse_r5 <- apply(rep_r5, 2, function(x) sqrt(mean((x - verdad_arboles["total"])^2)))
tabla_sintesis <- data.frame(

```

```

metodo = c("MAS", "Proporcional", "Neyman",
           "Sistemático (diámetro)", "Sistemático (volumen)",
           "Sistemático (aleatorio)", "Razón", "Regresión"),
RMSE = c(metricas_estrat["MAS", "RMSE"],
         metricas_estrat[____, "RMSE"],
         metricas_estrat[____, "RMSE"],
         sensibilidad[____, "RMSE"],
         sensibilidad[____, "RMSE"],
         sensibilidad[____, "RMSE"],
         rmse_r5[____], rmse_r5[____]))
tabla_sintesis

barplot(setNames(tabla_sintesis$RMSE, tabla_sintesis$metodo),
        las = 2, cex.names = 0.8, col = "#386641",
        ylab = "RMSE del total de volumen")

```

Conclusión. Escriba tres o cuatro frases que ordenen los diseños por precisión, expliquen qué estructura del marco aprovecha cada ganancia y señalen los límites de la comparación (dos censos observados, no generalizable a otro bosque). Mencione además que la cobertura de los intervalos declarados se mantuvo en torno al nivel nominal —ligeramente por debajo en el MAS y por encima en los estratificados— y qué dice eso de la fiabilidad de los intervalos. Recuerde que las DE exactas del bloque de conglomerados corresponden a la media de tallos por hectárea y no usan el mismo estimando.

i Resultados breves de comprobación

Bloque 0. *verdad_arboles*: media 30.17, total 935.3, proporción 0.39, DE 16.44. Asignaciones proporcional (4, 3, 3) y Neyman (3, 3, 4) con $S_h \approx (4.9, 5.4, 13.2)$. BCI: 50 hectáreas, 10 conglomerados de 5, verdad media 429.14.

Bloque 1. RMSE del total: MAS 186.94, 134.77 y 94.98 para $n = 6, 10, 15$; razón 28.54, 20.25 y 13.90.

Bloque 2. RMSE: MAS 130.29, proporcional 74.76, Neyman 62.69. Sesgos: MAS -5.8, proporcional -0.7, Neyman 4.1. SE medio: MAS 127.2, proporcional 67.7, Neyman 62.6. Cobertura del 95 %: MAS 0.92, proporcional 0.93, Neyman 0.96. Descomposición (varianza total 261.5): dentro 67.0 y entre 194.5.

Bloque 3. DE de diseño: diámetro 67.06, volumen 61.68, aleatorio 77.90. Media de los 31 arranques = 935.3 en los tres órdenes.

Bloque 4. Columnas: ICC 0.2140, DEFF 1.8562, DE exacta 10.13 tallos/ha. Filas: ICC 0.3109, DEFF 3.7982, DE exacta 14.79 tallos/ha. DEFF empírico por repetición: columnas 1.90, filas 3.93.

Bloque 5. RMSE: razón 20.51, regresión 23.02.

14 Práctica 3: Parcelas, cuadrantes e intercepción

Densidad, frecuencia y cobertura en R

14.1. Presentación

Esta práctica trabaja con el censo de árboles de Barro Colorado (`vegan::BCI` y `vegan::BCI.env`), las mismas 50 hectáreas del capítulo 3, y con una pequeña red simulada de transectos para ejercitar la cobertura por intercepción (el censo no contiene longitudes de línea). El documento es autocontenido: construye todos los objetos que necesita, por lo que se resuelve en una sesión nueva de R sin depender del resto del capítulo.

Materiales. Una instalación de R con el paquete `vegan`. No se requieren otros paquetes.

Cómo trabajar. La práctica es de construcción guiada: el código de cada bloque está incompleto. Los huecos están marcados con `# COMPLETAR` y, en el texto, con `----` dentro del código. Debe reemplazarlos por la expresión correcta, ejecutar el bloque y comprobar contra el cuadro de comprobación (colapsado, al final). Después trace las gráficas pedidas (escribálas usted mismo), responda las preguntas de análisis y resuelva la tarea de exploración de cada bloque, que exige modificar y volver a ejecutar. En la entrega incluya el código completado, las gráficas y las respuestas.

Convención del texto. Se usa `#>` para la salida de R. Las semillas están fijadas para que sus resultados coincidan con la comprobación. Recuerde, de la teoría, tres advertencias que volverán aquí: el soporte forma parte del estimando, la frecuencia depende de la unidad de muestreo y la réplica es la unidad con probabilidad de inclusión (la parcela o el transecto), no cada individuo ni cada metro.

14.2. Bloque 0. Arranque autocontenido

Construya el marco y las verdades poblacionales. Este bloque está completo; ejecútelo y verifique los valores.

```
# Marco espacial de Barro Colorado: conteos por hectárea y hábitat.
# - "Y": matriz 50 x 225 de conteos (unidad de observación: tallo con DAP >= 10 cm).
# - "marco": una fila por hectárea (unidad de muestreo) con coordenadas y hábitat.
data(BCI, BCI.env, package = "vegan")
Y <- as.matrix(BCI)
marco <- BCI.env
marco$id <- seq_len(nrow(marco))
marco$x <- (marco$UTM.EW - min(marco$UTM.EW)) / 100 + 1
marco$y <- (marco$UTM.NS - min(marco$UTM.NS)) / 100 + 1
marco$tallos <- rowSums(Y)
marco$riqueza <- vegan::specnumber(Y)
N <- nrow(marco)

# Frecuencia de presencia por especie, calculada una sola vez. Elegimos una
# especie de presencia parcial: Miconia.argentea, un árbol pionero presente en
# el 46% de las hectáreas.
frecuencia_especie <- colMeans(Y > 0)
focal <- "Miconia.argentea"

# Verdades poblacionales de estas 50 hectáreas.
cbind(verdad = c(
  densidad_media = mean(marco$tallos),
  DE_poblacional = sd(marco$tallos) * sqrt((N - 1) / N),
  indice_dispersion = var(marco$tallos) / mean(marco$tallos),
  riqueza_media = mean(marco$riqueza),
  frecuencia_focal = unname(frecuencia_especie[focal])
))
#>                verdad
#> densidad_media    429.140000
#> DE_poblacional    42.125531
#> indice_dispersion  4.219546
#> riqueza_media     90.780000
#> frecuencia_focal  0.460000

# Clases de hábitat del sitio (el parche secundario y el suelo anegado son
# pequeños: solo dos hectáreas cada uno).
table(marco$Habitat)
```

```
#>
#>   OldHigh   OldLow OldSlope   Swamp   Young
#>      8      26      12      2      2

# Teselación por bloques contiguos: suma celdas sin generar conteos nuevos.
# "desf_y"/"desf_x" desplazan el origen de la cuadrícula (se usará en el
# bloque 5). "alto" y "ancho" se dan en hectáreas.
agrupar <- function(z, alto, ancho, desf_y = 0, desf_x = 0) {
  fi <- seq.int(1 + desf_y, nrow(z) - alto + 1, by = alto)
  co <- seq.int(1 + desf_x, ncol(z) - ancho + 1, by = ancho)
  if (!length(fi) || !length(co)) return(numeric())
  unlist(lapply(fi, function(i) vapply(co, function(j)
    sum(z[i:(i + alto - 1), j:(j + ancho - 1)]), 0.0)))
}
```

14.3. Bloque 1. MAS de hectáreas: densidad, total y frecuencia

Seleccione un MAS de $n = 15$ hectáreas y estime la densidad de tallos, el total extendido por el área del dominio y la frecuencia de presencia de la especie focal, con su EE (incluya la corrección por población finita) y su intervalo con t_{14} .

```
# COMPLETAR: MAS de n = 15 hectáreas entre las 50 del marco.
set.seed(3401)
n <- 15
s <- marco[____, ]          # sample.int(N, n)

D_hat <- ____                # mean(s$tallos)
SE_D <- ____                 # sqrt((1 - n / N) * var(s$tallos) / n)
IC_D <- D_hat + qt(c(0.025, 0.975), n - 1) * SE_D

F_hat <- ____                # mean(Y[s$id, focal] > 0)
SE_F <- ____                 # sqrt((1 - n / N) * var(Y[s$id, focal] > 0) / n)

round(c(densidad_tallos_ha = D_hat, SE = SE_D,
  LI_densidad = IC_D[1], LS_densidad = IC_D[2],
  total_tallos = ____,          # N * D_hat
  SE_total = ____,             # N * SE_D
  frecuencia_focal = F_hat, SE_frecuencia = SE_F), 3)
```

Gráfica. Escriba el mapa de la cuadrícula de 10×5 hectáreas resaltando las 15 sorteadas.

```
# COMPLETAR: resalte la muestra (pch 15, rojo) frente al resto (gris) y añada
# leyenda y ejes en este y norte (centenas de m).
cols <- ifelse(____, "#bc4749", "grey88") # seq_len(N)%in% s$id
plot(____, ____, pch = 15, cex = 1.4, col = cols,
     xlab = "Este (centenas de m)", ylab = "Norte (centenas de m)",
     main = "Muestra MAS de hectáreas")
legend("bottomleft", c("Seleccionada", "No seleccionada"),
      pch = 15, col = c("#bc4749", "grey88"), bty = "n")
```

Preguntas de análisis.

1. Compare el ancho del intervalo de la densidad con el de la frecuencia. ¿Por qué un indicador binario con 15 observaciones aporta menos información que un conteo de la misma muestra?
2. La frecuencia estimada (0.267) queda lejos de la verdad del censo (0.46). ¿El intervalo del 95 % alcanza a contener esa verdad? ¿Qué dice eso del muestreo con pocas unidades binarias?
3. Si la misma pregunta se planteara en un bosque enorme donde $n/N = 0.001$, ¿qué cambiaría en SE_D y por qué?

Tarea de exploración. Construya el intervalo del 95 % de la frecuencia restringiéndolo al rango natural $[0, 1]$ con `pmin(1, pmax(0, ...))`. ¿Se recorta en esta realización? Después repita todo el bloque con una semilla nueva (`set.seed(3413)`) y anote cuánto se mueven la densidad y la frecuencia entre las dos muestras del mismo diseño.

14.4. Bloque 2. Repetición: las fórmulas describen la incertidumbre real

Repita el diseño 2000 veces sobre el censo y compruebe que el EE de la fórmula coincide con la variación real del estimador.

```
# COMPLETAR: est y se de cada realización del MAS de n = 15 hectáreas.
set.seed(3402)
B <- 2000
rep_mas <- t(vapply(seq_len(B), function(i) {
  z <- sample(marco$tallos, n)
  c(est = ____, # mean(z)
    se = ____, # sqrt((1 - n / N) * var(z) / n)
  ), numeric(2)))
# Metricas de largo plazo frente a la densidad del censo.
```

```
metricas_evaluacion <- function(x, verdad, df = n - 1) c(
  sesgo = ____,          # mean(x[, "est"] - verdad)
  DE_empirica = ____,    # sd(x[, "est"])
  SE_medio = ____,       # mean(x[, "se"])
  RMSE = ____,           # sqrt(mean((x[, "est"] - verdad)^2))
  cobertura = mean(abs(x[, "est"] - verdad) <= qt(0.975, df) * x[, "se"])
)
round(metricas_evaluacion(rep_mas, mean(marco$tallos)), 3)
```

Gráfica. Escriba el histograma de la densidad estimada con la línea roja de la densidad del censo y la línea verde (punteada) de la muestra del bloque 1.

```
# COMPLETAR: histograma de rep_mas[, "est"] con líneas de la verdad y de D_hat.
hist(___, breaks = 30, col = "#a7c957", border = "white",
  xlab = "Densidad estimada (tallos/ha)", main = "")
abline(v = ____, col = "#bc4749", lwd = 2)          # densidad del censo
abline(v = ____, col = "#386641", lwd = 2, lty = 2) # D_hat (muestra)
legend("topright", c("Densidad del censo", "Muestra observada"),
  col = c("#bc4749", "#386641"), lty = c(1, 2), lwd = 2, bty = "n")
```

Preguntas de análisis.

1. ¿Por qué el SE_medio (lo que predice la fórmula) debe parecerse a la DE_empirica (lo que ocurre al repetir)? ¿Qué valida esa coincidencia?
2. La cobertura dice que aproximadamente 93 de cada 100 intervalos contienen la verdad. ¿Qué supuesto probabilístico sostiene ese 93 % y no el 95 % exacto?
3. El sesgo es pequeño frente al RMSE. ¿Qué propiedad del MAS demuestra eso y por qué un sesgo distinto de cero sería un problema?

Tarea de exploración. (a) Repita la repetición estimando la *frecuencia* focal en lugar de la densidad (semilla 3407): calcule sesgo, DE, RMSE y cobertura del indicador binario y explique por qué la cobertura puede superar el 93 % de la densidad. (b) Repita la repetición de la densidad con $n = 30$ (semilla 3412) y compare RMSE y SE_medio con los de $n = 15$: ¿cuánto se reduce la incertidumbre al duplicar la muestra y coincide con $\sqrt{15/30}$?

14.5. Bloque 3. Soporte y orientación: cortar el espacio cambia el estimando

Cambie el soporte agregando celdas contiguas con `agrupar()` y describa cómo cambian densidad, varianza entre unidades y frecuencia de la especie focal al pasar de 1 ha a 2 y 4 ha y al girar la orientación.

```
# COMPLETAR: para cada geometría (alto x ancho en hectáreas) normalice por el
# área y calcule la frecuencia de presencia del focal en el nuevo soporte.
M_tallos <- xtabs(tallos ~ y + x, data = marco)
M_focal <- xtabs(Y[, focal] ~ marco$y + marco$x)

formas <- data.frame(alto = c(1, 1, 2, 1, 4), ancho = c(1, 2, 1, 4, 1))
escala <- do.call(rbind, lapply(seq_len(nrow(formas)), function(k) {
  a <- formas$alto[k] * formas$ancho[k]
  yt <- agrupar(M_tallos, ____, ____) # alto, ancho
  yf <- agrupar(M_focal, ____, ____)
  data.frame(geometria = ____, # paste(alto, "x", ancho)
             area_ha = a,
             unidades = ____, # length(yt)
             densidad = ____, # mean(yt / a)
             var_densidad = ____, # var(yt / a)
             frecuencia_focal = ____) # mean(yf > 0)
}))
escala[-c(1, 2)] <- lapply(escala[-c(1, 2)], round, 3)
escala
```

Gráfica. Escriba tres barplots en una fila: densidad media, varianza de la densidad y frecuencia del focal, con los nombres de las geometrías en el eje y, una línea horizontal en la densidad del censo en el primero y la misma escala de colores para las orientaciones (banda este—oeste y banda apilada norte—sur).

```
# COMPLETAR: barplot(escala$densidad / escala$var_densidad / escala$frecuencia_focal,
# with names.arg = escala$geometria, col diferenciando orientación).
par(mfrow = c(1, 3), mar = c(5, 4, 2, 1))
```

Preguntas de análisis.

1. La densidad media se mantiene casi fija al cambiar el soporte, pero la varianza entre unidades cae de 1810.8 (1 ha) a 548.1 (4 ha apiladas). ¿Por qué normalizar por el área cuida la densidad y qué se paga en réplicas (50 frente a 10 unidades)?
2. Compare las parejas de igual área: 1×2 frente a 2×1 y 1×4 frente a 4×1. ¿Qué orientación retiene más heterogeneidad y por qué, sabiendo que el gradiente del censo corre este—oeste?
3. La frecuencia de *Miconia argentea* sube de 0.46 a 1.00 al pasar de 1 ha a 4 ha. ¿Qué le dice la saturación sobre la escala de agregación de la especie y por qué comparar frecuencias entre estudios con soportes distintos es comparar instrumentos distintos?

Tarea de exploración. Añada la geometría 2×2 (bloques de 4 ha) con `agrupar(M_tallos, 2, 2)`: reporte unidades, densidad, varianza y frecuencia. ¿Dónde cae frente a las bandas 1×4

y 4×1? Comente qué pasaría con la varianza si el bloque fuera todavía mayor y qué implicaría para la detección de parches.

14.6. Bloque 4. Cobertura por intercepción: transectos y puntos

La cobertura se mide por línea (longitud ocupada) y por puntos. En ambos casos la réplica es la línea o el transecto, no cada metro ni cada punto.

```
# COMPLETAR: cinco transectos con longitud L_i y longitud ocupada l_i por la
# especie focal. Estime la cobertura como cociente de totales y como media de
# razones, con su EE y su intervalo usando el transecto como réplica.
set.seed(3404)
transectos <- data.frame(
  linea = seq_len(5),
  L = c(20, 25, 20, 25, 30),
  l = round(c(20, 25, 20, 25, 30) * (0.28 + rnorm(5, 0, 0.03)))
)
transectos

C_R <- ____ # sum(l) / sum(L)
C_U <- ____ # mean(l / L)
EE_U <- ____ # sd(l / L) / sqrt(nrow(transectos))
IC_U <- C_U + qt(c(0.025, 0.975), nrow(transectos) - 1) * EE_U

c(cobertura_cociente = C_R, cobertura_media = C_U,
  EE_media = EE_U, LI = IC_U[1], LS = IC_U[2])

# COMPLETAR: en intercepción por puntos se bajan 80 puntos y cada uno cae o no
# sobre la especie (simulación con semilla). Estime la cobertura con el EE
# binomial y un intervalo de Wald.
set.seed(3406)
puntos <- 80
hits <- sum(rbinom(puntos, 1, 0.15))
C_p <- ____ # hits / puntos
EE_bin <- ____ # sqrt(C_p * (1 - C_p) / puntos)
IC_wald <- C_p + c(-1, 1) * qnorm(0.975) * EE_bin
c(cobertura = C_p, EE_binomial = EE_bin, LI = IC_wald[1], LS = IC_wald[2])
```

Gráfica. Escriba un barplot de la cobertura por transecto (`transectos$l / transectos$L`) con una línea horizontal en `C_U` y rótulos por línea.

```
# COMPLETAR: barplot de la proporción ocupada por transecto y su línea en C_U.
```

Preguntas de análisis.

1. C_R y C_U difieren poco aquí. ¿Qué le da más influencia a las líneas largas en el cociente de totales y cuándo preferiría esa versión?
2. El EE binomial supone puntos independientes. Si los 80 puntos estuvieran agrupados en diez líneas, ¿qué unidad debería tratarse como réplica y qué pasaría con otra medida de incertidumbre?
3. ¿Qué medida de las tres del capítulo (densidad, frecuencia, cobertura) sería más robusta para monitorear una especie rara y gregaria como *Miconia.argentea*, y qué información sacrificaría?

Tarea de exploración. Convierta los 80 puntos en diez líneas de ocho puntos con presencia agrupada (semilla 3409): calcule la proporción global y la media de las proporciones por línea, junto con su EE ($\text{sd}(\dots) / \sqrt{10}$). Compárela con el EE_bin de la cobertura global y explique cuál describe mejor la incertidumbre cuando la línea es la réplica.

```
# COMPLETAR: semilla 3409, matriz 10 x 8 con agregación por líneas; C_global,
# C_linea = media de (hits/8), EE_linea = sd(hits/8)/sqrt(10).
```

14.7. Bloque 5. Diseños y origen de la cuadrícula

Compare con 12 hectáreas un MAS con dos criterios de estratificación previa y evalúe la sensibilidad de una teselación de 2x2 ha al origen.

```
# COMPLETAR: estimador estratificado ponderado por W_h = N_h / N.
evaluar_estrat <- function(grupo, Nh_gr, nh_local) {
  por_h <- do.call(rbind, lapply(names(nh_local), function(h) {
    u <- marco$tallos[grupo == h]
    n_h <- unname(nh_local[h])
    z <- sample(u, n_h)
    c(h = h, media = ____,          # mean(z)
      var = ____ )                 # (1 - n_h / length(u)) * var(z) / n_h
  )))
  W <- ____                        # Nh_gr[por_h[, "h"]] / sum(Nh_gr)
  c(est = sum(W * as.numeric(por_h[, "media"])),
    se = sqrt(sum(W^2 * as.numeric(por_h[, "var"]))))
}

# Criterio (a): OldLow frente a Otros (26 y 24 hectáreas), 6 + 6 observaciones.
```

```

estrato_a <- ifelse(marco$Habitat == "OldLow", "OldLow", "Otros")
Nh_a <- table(estrato_a)
nh_a <- c(OldLow = 6, Otros = 6)

set.seed(3403)
mas12 <- t(replicate(B, {
  z <- sample(marco$tallos, 12)
  c(est = ____, # mean(z)
    se = ____, # sqrt((1 - 12 / N) * var(z) / 12)
  )))
est_oldlow <- t(replicate(B, evaluar_estrat(estrato_a, Nh_a, nh_a)))

# Criterio (b): Young (2 ha) frente a Resto, 2 + 10 observaciones.
set.seed(3405)
estrato_b <- ifelse(marco$Habitat == "Young", "Young", "Resto")
Nh_b <- table(estrato_b)
nh_b <- c(Young = 2, Resto = 10)
est_young <- t(replicate(B, evaluar_estrat(estrato_b, Nh_b, nh_b)))

# Cada realización usa 12 hectáreas: el intervalo de cobertura usa df = 11.
metricas_disenos <- rbind(
  MAS = metricas_evaluacion(mas12, mean(marco$tallos), df = ____), # 11
  Estrat_OldLow = metricas_evaluacion(est_oldlow, mean(marco$tallos), df = 11),
  Estrat_Young = metricas_evaluacion(est_young, mean(marco$tallos), df = 11)
)
round(metricas_disenos, 3)

```

Gráfica. Escriba el boxplot de la densidad estimada bajo los tres diseños con la línea de la verdad y su leyenda.

```

# COMPLETAR: boxplot de mas12, est_oldlow y est_young y línea del censo.
boxplot(list(MAS = mas12[, "est"], OldLow = est_oldlow[, "est"],
  Young = est_young[, "est"]),
  col = c("grey80", "#90a955", "#386641"),
  ylab = "Densidad estimada (tallos/ha)", las = 2)
abline(h = ____, lty = 2) # media del censo

```

```

# COMPLETAR: para bloques de 2 x 2 ha el origen decide cuántas celdas completas
# quedan (8 o 10). Calcule la desviación de la densidad frente al censo para los
# cuatro orígenes posibles.
origenes <- expand.grid(desf_y = 0:1, desf_x = 0:1)
sens_origen <- do.call(rbind, lapply(seq_len(nrow(origenes)), function(k) {

```



```

yt <- agrupar(M_tallos, 2, 2, ____, ____) # desf_y[k], desf_x[k]
data.frame(origen_y = origenes$desf_y[k], origen_x = origenes$desf_x[k],
            unidades = ____, # length(yt)
            area_cubierta = 4 * length(yt),
            densidad = ____) # mean(yt / 4)
)))
sens_origen$desviacion <- sens_origen$densidad - mean(marco$tallos)
round(sens_origen, 2)

# COMPLETAR: barplot de desviaciones con nombres "(origen_y, origen_x)" y una
# línea en cero (colores según el signo).

```

Preguntas de análisis.

1. ¿Qué criterio de estratificación reduce el RMSE y por qué? Apoye la respuesta con las medias por estrato (OldLow 425 frente a Otros 434; Young 538 frente a Resto 424.6).
2. Los tres diseños son prácticamente insesgados. ¿De dónde proviene entonces la diferencia de RMSE y qué papel juega la **cobertura** en esa lectura?
3. Según el origen, la densidad con bloques de 4 ha oscila entre 410.8 y 431.5. Dos causas se combinan: el número de celdas completas (10 u 8) y la densidad del borde descartado. ¿Qué protocolo recomendaría y por qué no es defendible elegir el origen después de mirar los datos?

Tarea de exploración. Repita la comparación con dos criterios adicionales y compare su RMSE con el del MAS: (a) **Swamp** frente a **Resto** con 2 + 10 observaciones (semilla 3408) y (b) **OldHigh** frente a **Resto** con 6 + 6 observaciones (semilla 3411). Discuta cuándo la estratificación puede ser *peor* que el MAS aunque separe efectivamente dos grupos.

```

# COMPLETAR: Swamp (semilla 3408) y OldHigh (semilla 3411) como en el bloque.

```

14.8. Síntesis y comprobación

Reúna el RMSE de los tres diseños con 12 hectáreas desde los objetos del bloque 5, sin escribir números, y compare la variación entre unidades según el soporte del bloque 3.

```

# COMPLETAR: tabla de RMSE desde metricas_disenos y tabla de soporte desde escala.
tabla_disenos <- data.frame(
  diseno = c("MAS (12 ha)", "Estrat. OldLow", "Estrat. Young"),
  RMSE = metricas_disenos[, ____]) # "RMSE"
tabla_disenos

```

```

tabla_soporte <- escala[c(____, ____, ____, ____)] # geometria, unidades, var_densidad, fr
tabla_soporte

barplot(setNames(____, ____), # RMSE por diseño y sus nombres
        col = c("grey80", "#90a955", "#386641"),
        ylab = "RMSE de la densidad (tallos/ha)", las = 2)

```

Conclusión. Escriba tres o cuatro frases que ordenen los diseños por precisión, expliquen qué estructura del marco aprovecha cada ganancia (o cuándo no la hay) y relacionen la escala del soporte con la varianza y la frecuencia. Recuerde los límites: dos estratificaciones y un origen entre muchos, sobre un censo de 50 hectáreas que no es una muestra probabilística de los bosques tropicales.

i Resultados breves de comprobación

Bloque 0. *Miconia.argentea*: frecuencia 0.46 (23 de 50). Verdades: densidad media 429.14, DE poblacional 42.13, índice de dispersión 4.22, riqueza media 90.78, total 21 457. Hábitats: OldHigh 8, OldLow 26, OldSlope 12, Swamp 2, Young 2.

Bloque 1. Con la semilla 3401 y $n = 15$: densidad 411.47 (EE 10.31; IC [389.35, 433.58]), total 20 573 (EE 515.5), frecuencia focal 0.267 (EE 0.099; IC [0.055, 0.479], sin truncar). La verdad 0.46 cae fuera del IC de frecuencia: una realización binaria con $n = 15$ es imprecisa.

Bloque 2. Con la semilla 3402: sesgo -0.31 , DE empírica 9.29, SE medio 8.78, RMSE 9.29, cobertura 0.934. Exploración: (a) frecuencia (semilla 3407) con sesgo 0.005, DE 0.105, RMSE 0.105 y cobertura 0.97; (b) densidad con $n = 30$ (semilla 3412) con RMSE 4.91 y SE medio 4.85 ($9.29\sqrt{15/30}$).

Bloque 3. Densidades 429.1, 429.1, 417.4, 431.3, 417.4 (censo); varianzas 1810.8, 1444.2, 717.3, 1083.5, 548.1; frecuencias 0.46, 0.68, 0.80, 0.90, 1.00; unidades 50, 25, 20, 10, 10. Exploración 2×2: 10 unidades, densidad 417.4, varianza 547.4, frecuencia 0.90.

Bloque 4. Transectos (semilla 3404): $L = (20, 25, 20, 25, 30)$, $l = (5, 7, 5, 8, 11)$, $C_R = 0.300$, $C_U = 0.2933$ (EE 0.0224; IC [0.231, 0.356]). Puntos (semilla 3406): 10 de 80, $C = 0.125$, EE binomial 0.0370, Wald [0.053, 0.197]. Exploración por líneas (semilla 3409): presencias por línea (4, 0, 3, 0, 1, 1, 3, 0, 0, 0), $C = 0.15$, EE por línea 0.0612 frente a EE binomial 0.0399.

Bloque 5. RMSE (12 ha): MAS 10.94, OldLow 10.39, Young 9.20; sesgos -0.3 a 0.2 y cobertura 0.95. Origen 2×2: desviaciones -11.76 , $+2.38$, -18.39 y -2.55 con 10, 10, 8 y 8 celdas completas. Exploración: Swamp (semilla 3408) RMSE 10.50; OldHigh (semilla 3411) RMSE 14.45, peor que el MAS.

Parte VIII

Material complementario

Material complementario

Profundizaciones metodológicas previstas

- estimadores de razón, regresión y calibración;
- estimación de varianza para diseños complejos;
- muestreo adaptativo, de red e indirecto;
- ocupación y detectabilidad imperfecta;
- captura, marcado y recaptura;
- análisis espacial y selección de muestras balanceadas; y
- protocolos de control de calidad en campo.

Estos temas ofrecen rutas de profundización más allá del desarrollo central.

Plantillas

El repositorio incluye:

- `resources/templates/activity-report.qmd`, para informes breves;
- `resources/templates/project-report.qmd`, para proyectos autónomos; y
- `resources/templates/dataset-metadata.yml`, para documentar datos.

Lista de comprobación de reproducibilidad

1. El informe se renderiza desde una sesión limpia.
2. Las rutas son relativas a la raíz del proyecto.
3. Las semillas se fijan cuando la aleatoriedad no es el objeto de estudio.
4. Los datos originales no se modifican manualmente.
5. Las transformaciones se ejecutan mediante código.
6. Las versiones y fuentes están registradas.
7. Las tablas y figuras incluyen unidades y leyendas.
8. Los resultados principales pueden rastrearse hasta una operación documentada.

Referencias

- Campbell, M. J., y A. M. Walker. 1977. «A Survey of Statistical Work on the Mackenzie River Series of Annual Canadian Lynx Trappings for the Years 1821–1934 and a New Analysis». *Journal of the Royal Statistical Society. Series A (General)* 140 (4): 411-31. <https://doi.org/10.2307/2345277>.
- Chandler, Richard B., David I. King, y Stephen DeStefano. 2009. «Scrub-Shrub Bird Habitat Associations at Multiple Spatial Scales in Beaver Meadows in Massachusetts». *The Auk* 126 (1): 186-97. <https://doi.org/10.1525/auk.2009.08083>.
- Condit, Richard, Nigel Pitman, Egbert G. Leigh, et al. 2002. «Beta-Diversity in Tropical Forest Trees». *Science* 295 (5555): 666-69. <https://doi.org/10.1126/science.1066854>.
- Gerstman, B. Burt. 2013. *Epidemiology Kept Simple: An Introduction to Traditional and Modern Epidemiology*. 3.^a ed. Wiley-Blackwell.
- Gregg, Michael B., ed. 2008. *Field Epidemiology*. 3.^a ed. Oxford University Press.
- Harms, Kyle E., Richard Condit, Stephen P. Hubbell, y Robin B. Foster. 2001. «Habitat Associations of Trees and Shrubs in a 50-ha Neotropical Forest Plot». *Journal of Ecology* 89 (6): 947-59. <https://doi.org/10.1111/j.1365-2745.2001.00615.x>.
- Henderson, Peter A., y T. R. E. Southwood. 2016. *Ecological Methods*. 4.^a ed. Wiley-Blackwell.
- Kellner, Kenneth F., Adam D. Smith, J. Andrew Royle, Marc Kéry, Jerrold L. Belant, y Richard B. Chandler. 2023. «The unmarked R Package: Twelve Years of Advances in Occurrence and Abundance Modelling in Ecology». *Methods in Ecology and Evolution* 14 (6): 1408-15. <https://doi.org/10.1111/2041-210X.14123>.
- Lohr, Sharon L. 2022. *Sampling: Design and Analysis*. 3.^a ed. CRC Press. <https://doi.org/10.1201/9780429298899>.
- Manly, Bryan F. J., y Jorge A. Navarro Alberto. 2015. *Introduction to Ecological Sampling*. Chapman; Hall/CRC.
- Miller, David L., Eric Rexstad, Len Thomas, Laura Marshall, y Jeffrey L. Laake. 2019. «Dis-

- tance Sampling in R». *Journal of Statistical Software* 89 (1): 1-28. <https://doi.org/10.18637/jss.v089.i01>.
- Oksanen, Jari, Gavin L. Simpson, F. Guillaume Blanchet, et al. 2024. *vegan: Community Ecology Package*. <https://CRAN.R-project.org/package=vegan>.
- Pyke, Christopher R., Richard Condit, Salomón Aguilar, y Suzanne Lao. 2001. «Floristic Composition across a Climatic Gradient in a Neotropical Lowland Forest». *Journal of Vegetation Science* 12 (4): 553-66. <https://doi.org/10.2307/3237007>.
- Rota, Christopher T., Marco A. R. Ferreira, Roland Kays, et al. 2016. «A Multi-Species Occupancy Model for Two or More Interacting Species». *Methods in Ecology and Evolution* 7: 1164-73. <https://doi.org/10.1111/2041-210X.12587>.
- Stubben, Christopher J., y Brook G. Milligan. 2007. «Estimating and Analyzing Demographic Models Using the popbio Package in R». *Journal of Statistical Software* 22 (11): 1-23. <https://doi.org/10.18637/jss.v022.i11>.
- Sutherland, William J., ed. 2006. *Ecological Census Techniques: A Handbook*. 2.^a ed. Cambridge University Press.
- Woodward, Mark. 2014. *Epidemiology: Study Design and Data Analysis*. 3.^a ed. Chapman; Hall/CRC.